Introducción a *ML* y algoritmos de IA

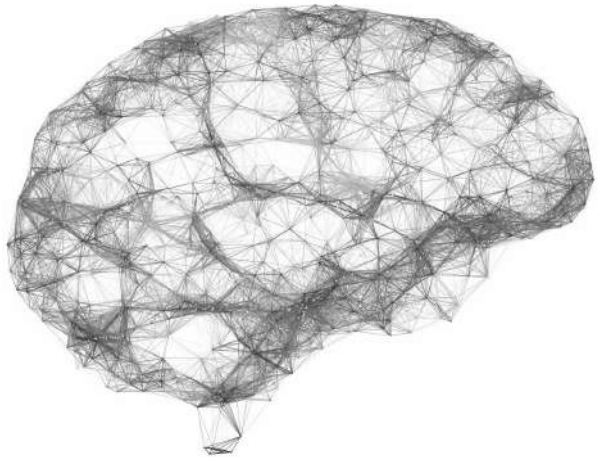
ML & algoritmos AI

Profesor Carlos Castro Correa
Clase 1

ITAM

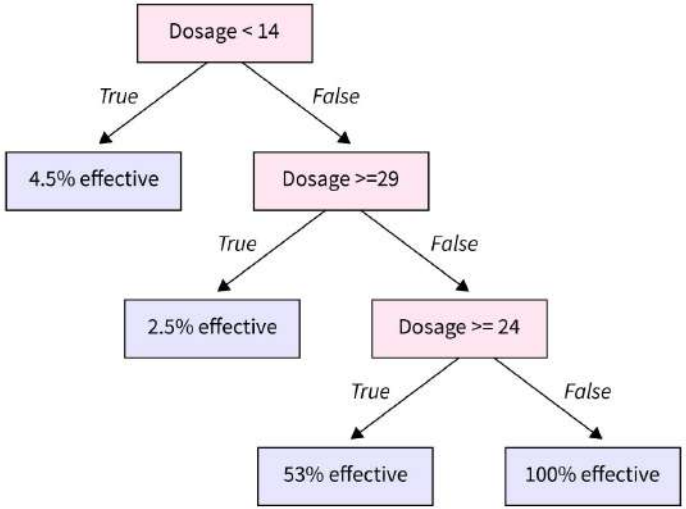
Objetivo

Que el alumno sea capaz de identificar y **estructurar** la solución de **problemas de negocio** a través de **múltiples ejemplos de aplicación real** y herramientas de análisis de datos, ***machine learning*** **e inteligencia artificial**



Motivación

Que los alumnos **apliquen correctamente técnicas de aprendizaje de máquina** en su vida profesional (profesional o académica), **sin ser, necesariamente, el responsable, de la implementación pero sí del diseño técnico y matemático**



Introducción

Clase 1
ML y análisis de datos

ITAM

¿Por qué es tan importante estudiar *machine learning*?



Porque resuelve una gran cantidad de **problemas reales**

Las herramientas de IA y ML **sustentan el funcionamiento**

de un gran número de aplicaciones y servicios populares

¿Por qué Netflix me **recomienda** cierto tipo de películas?



¿Cómo le hace Shazam para **identificar** una canción?



¿Cómo funciona el **predictor** de textos de mi celular?



¿Cómo es que Google Maps encuentra el **mejor** camino **rápidamente**?



¿Cómo funcionan los algoritmos (red neuronal) que generan **imágenes a partir de texto**?

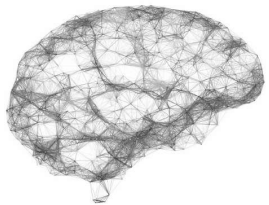
OpenAI

¿A quién debo **otorgarle** un crédito bancario?



La reciente **popularidad de AI** también ha implicado

un **entendimiento sesgado** o **incompleto** de su funcionamiento



Empecemos analizando una **creencia popular**...



¿Es cierto que tu **celular** te **espía** y escucha?



Anuncios a la medida







¿Te celular realmente necesita escucharte?



Disclaimer





¿Cómo podría presentarte anuncios **relevantes sin escucharte**?



R= Matemáticas + Datos



Rastros digitales en todo momento

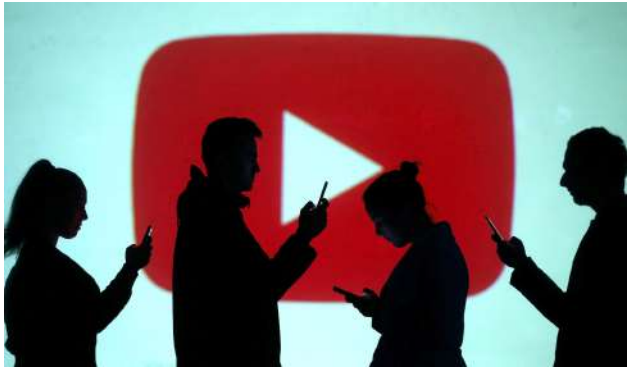


Rastros digitales en todo momento

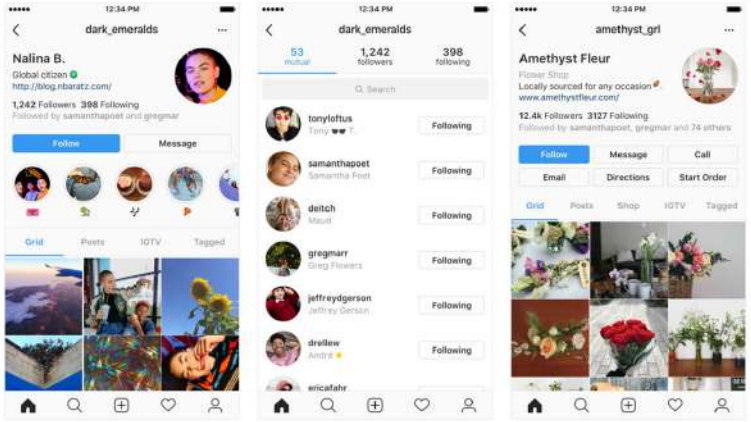


Usuarios “similares”



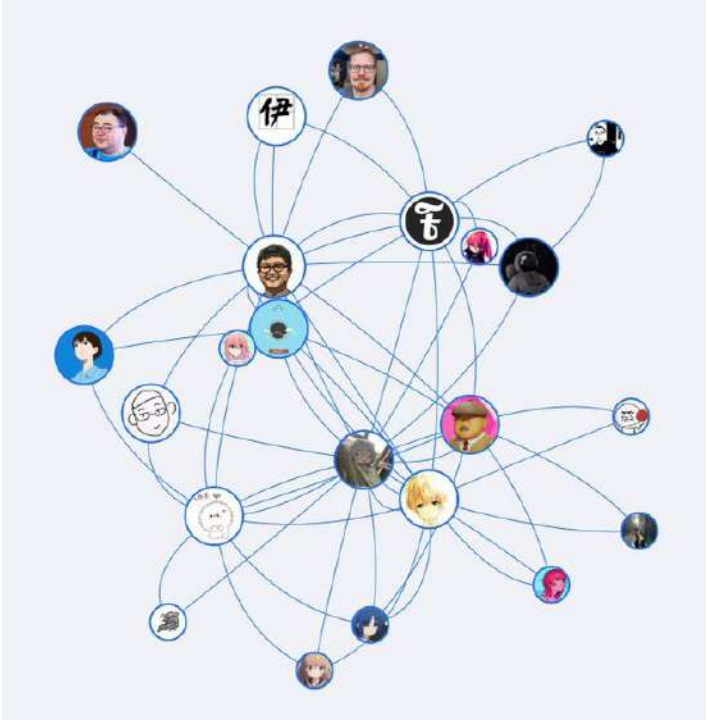






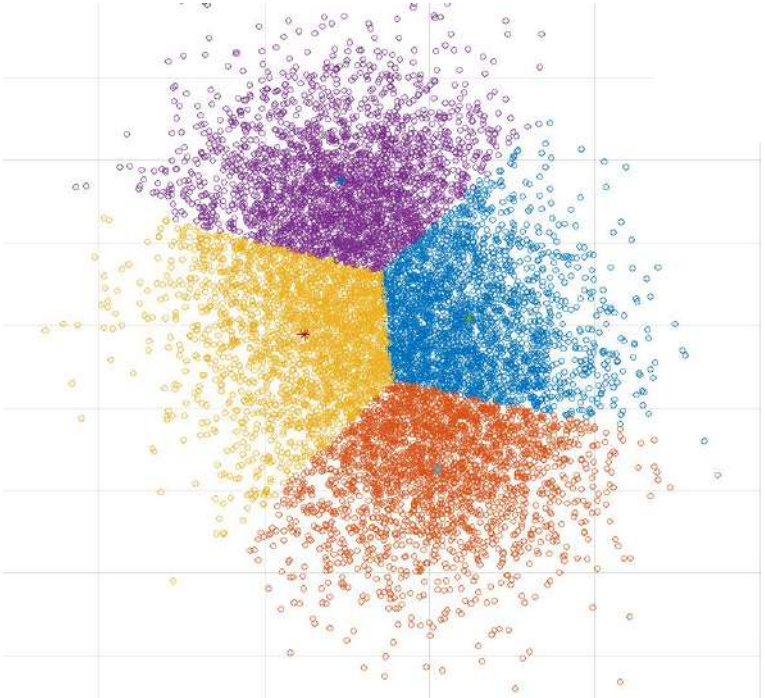
Datos almacenados

Información **analizada y procesada**



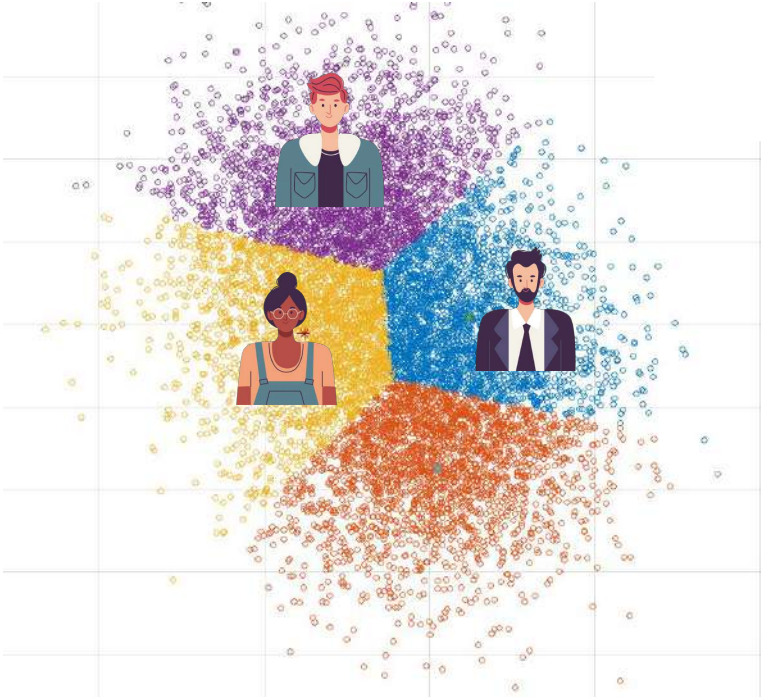
Algoritmos

Los usuarios similares se agrupan y se **crean audiencias y anuncios a la medida**



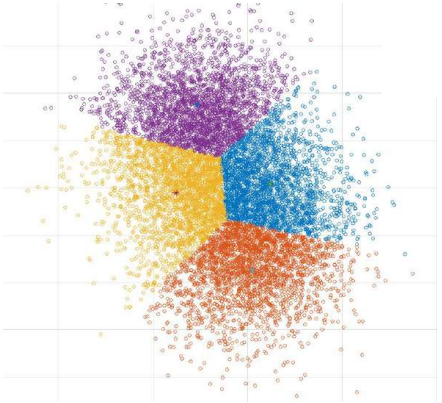
Algoritmos

Los usuarios similares se agrupan y se **crean audiencias y anuncios a la medida**



Cada **conglomerado agrupa usuarios muy similares**

pero **distintos** a los de otros grupos



¿Cómo anunciarle **destinos de vacaciones** a cada grupo?



🤔

Anuncios vacaciones





Anuncios vacaciones







Anuncios vacaciones





Anuncios vacaciones

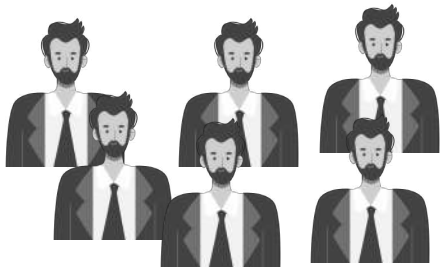






Anuncios vacaciones

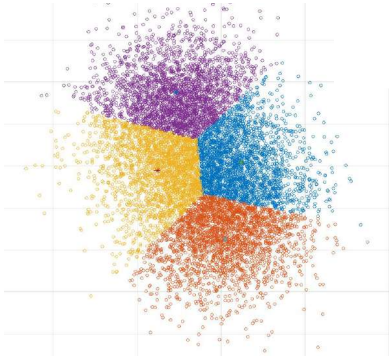




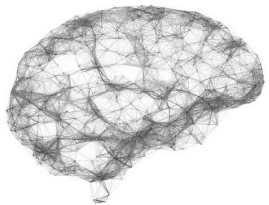


En el ***argot*** *de AI*

Algoritmo de ML no supervisado con *clustering* por k-medias



En este curso **aprenderemos** este algoritmo (*Clustering*)



¿Por qué creemos que el celular nos espía?



Algunos de los anuncios que **coinciden con tu “arquetipo”**

te pueden parecer **más precisos** o relevantes, **pero...**

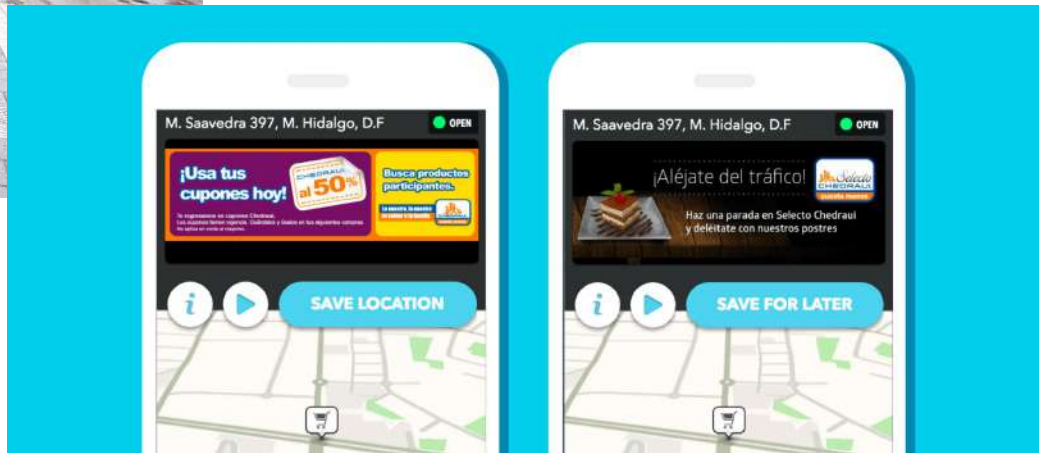
Realmente, ¿Cuántos anuncios recibes al día?



Anuncios masivos

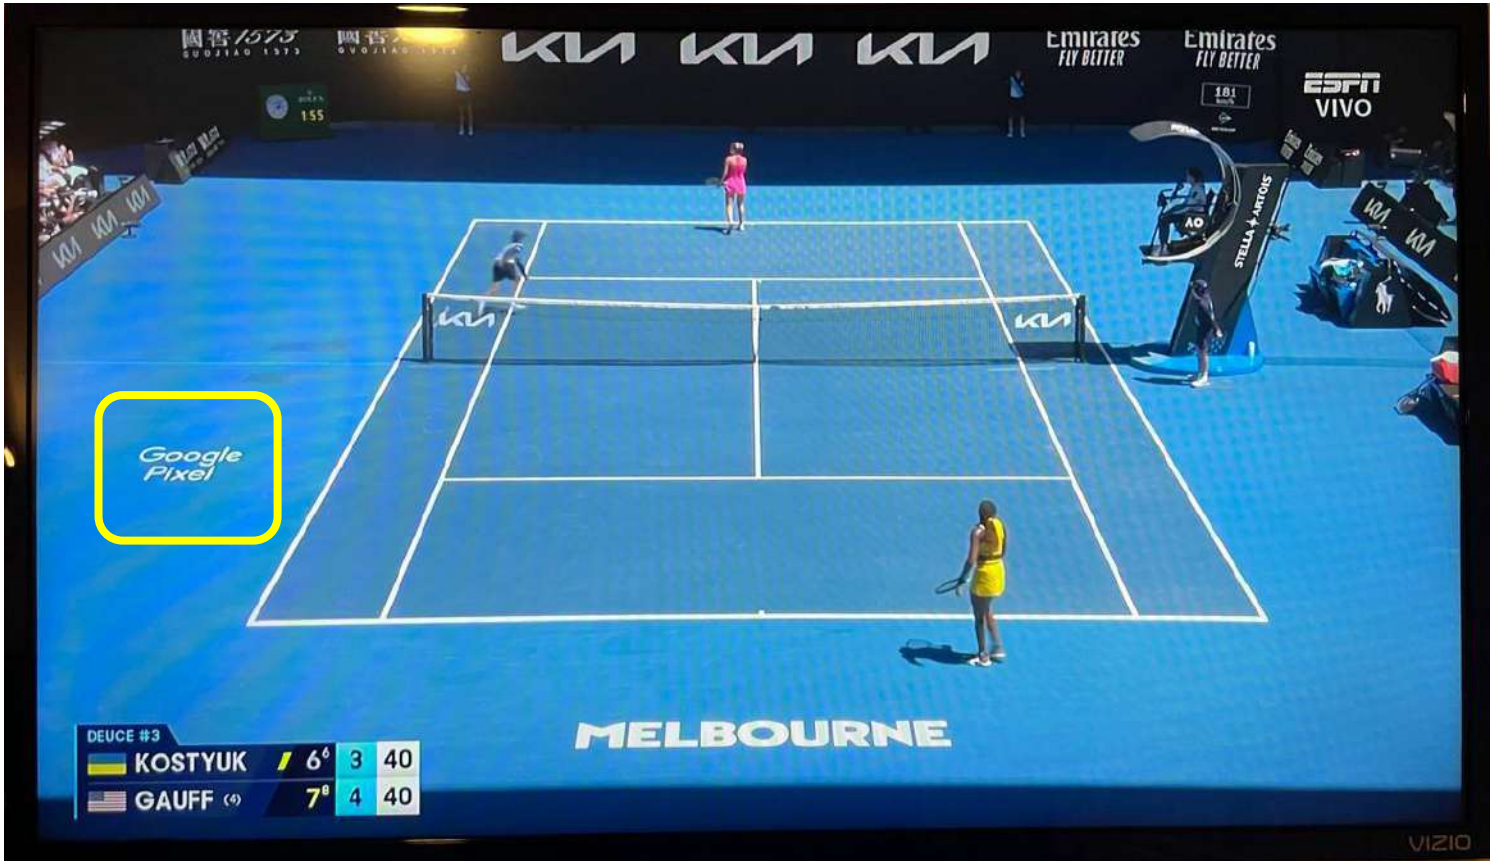






A veces es tan **sutil** que **no te das cuenta...**


Emirates FLY BETTER
Emirates FLY BETTER
ESPN VIVO
Google Pixel
STELLA ARTOIS
MELBOURNE
DEUCE #3
KOSTYUK 6 3 40
GAUFF 7 4 40
VIZIO


Emirates FLY BETTER
Emirates FLY BETTER
ESPN VIVO
Google Pixel
MELBOURNE
DEUCE #3
KOSTYUK 6 3 40
GAUFF 7 4 40
VIZIO


KIA
Emirates
FLY BETTER
ESPN
VIVO
MARRIOTT
BONVOY
MELBOURNE
KOSTYUK 6 6 5 15
GAUFF (4) 7 8 6 0


KIA
Emirates
FLY BETTER
ESPN
VIVO
MARRIOTT
BONVOY
MELBOURNE
KOSTYUK 6 6 5 15
GAUFF (4) 7 8 6 0

¿Cuántos de los anuncios que recibes son **relevantes para ti**?



¿Cuántos anuncios **viste** en esta semana y **no los recuerdas**?



En realidad, **muy muy pocos anuncios son relevantes**,

pero tendemos a recordarlos con **mayor convicción**



A la **inversa**:

Piensa en **todas los temas** sobre los que **conversaste** este mes

y **no has recibido anuncios....**



¿Por qué **recordamos más** algunos anuncios?



Sesgo de confirmación

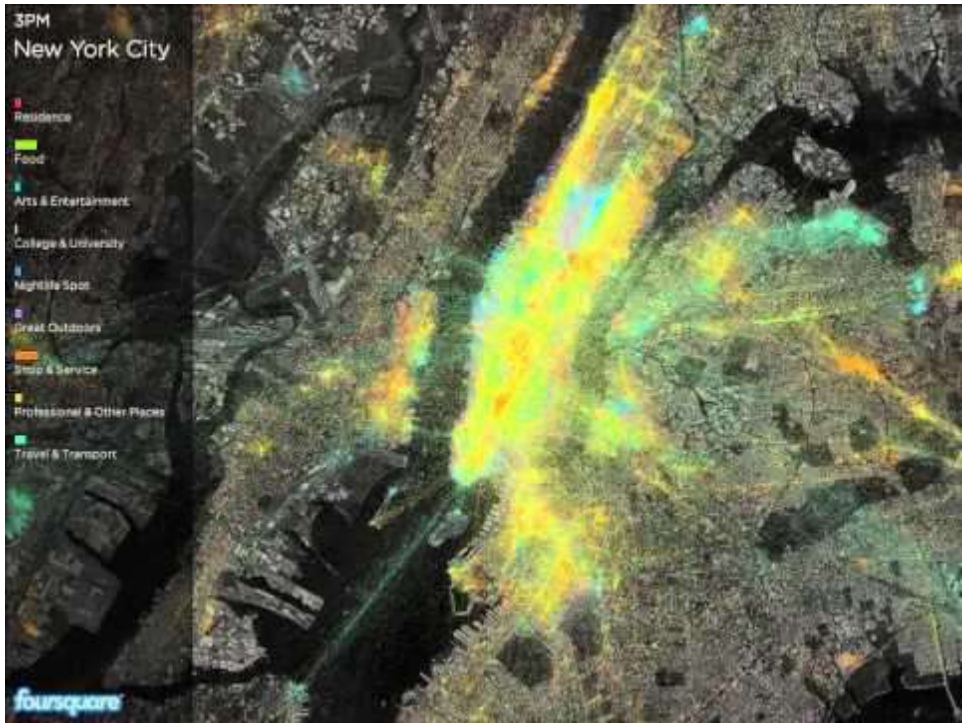


Además, ¿qué otros datos se pueden utilizar para ***target* y anuncios**?



Patrones de Movilidad

Datos anonimizados de Foursquare y redes sociales, **liga**



La información **geoespacial** aumenta la **precisión** de un anuncio



Para hacer este análisis es posible **comprar una base de datos**,

no solo con Foursquare...



Check-ins y datos anonimizados

Muchas aplicaciones “gratuitas” que cada vez que las abres, **almacenan ciertos datos demográficos** sobre el usuario:

- Fecha y hora de uso.
- Latitud y longitud.
- Tiempo en la aplicación.
- Marca de teléfono.
- Sistema operativo.
- ID único de usuario.



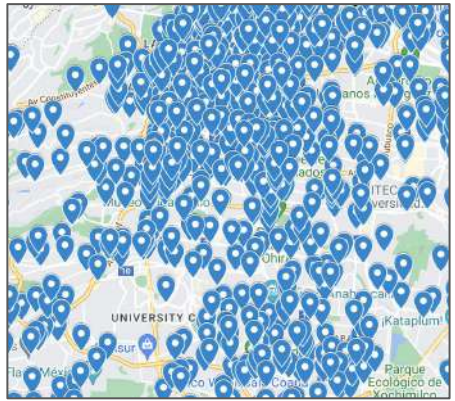
Descarga y **revisa** la siguiente BD enlace



¿Qué información contiene?



Mapa en **Kepler**



¿Cómo es que pueden acceder y almacenar estos datos?



Cada usuario concede el permiso a través de las

Condiciones de Uso y Privacidad

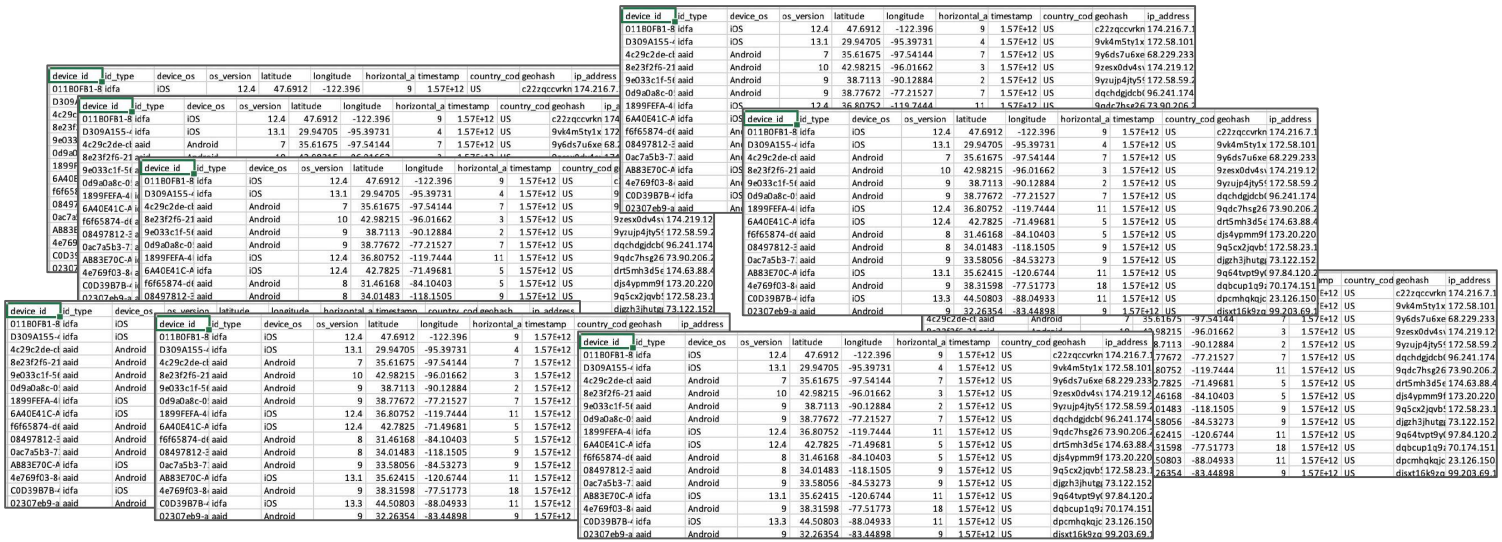
Check-ins y datos anonimizados

Al almacenar los **datos de millones** de usuarios (sin datos personales) es posible detectar **patrones de movilidad**, NSE, tráfico, entre otros.

device_id	id_type	device_os	os_version	latitude	longitude	horizontal_a	timestamp	country_cod	geohash	ip_address
011B0FB1-8	idfa	iOS	12.4	47.6912	-122.396	9	1.57E+12	US	c22zqccvrkn	174.216.7.1
D309A155-4	idfa	iOS	13.1	29.94705	-95.39731	4	1.57E+12	US	9vk4m5ty1x	172.58.101
4c29c2de-cb	aaid	Android	7	35.61675	-97.54144	7	1.57E+12	US	9y6ds7u6xe	68.229.233
8e23f2f6-21	aaid	Android	10	42.98215	-96.01662	3	1.57E+12	US	9zesx0dv4s	174.219.12
9e033c1f-5(	aaid	Android	9	38.7113	-90.12884	2	1.57E+12	US	9yzujp4jty5	172.58.59.2
0d9a0a8c-0	aaid	Android	9	38.77672	-77.21527	7	1.57E+12	US	dqchdgjdcb(	96.241.174
1899FEFA-4(	idfa	iOS	12.4	36.80752	-119.7444	11	1.57E+12	US	9qdc7hsg26	73.90.206.2
6A40E41C-A	idfa	iOS	12.4	42.7825	-71.49681	5	1.57E+12	US	drt5mh3d5e	174.63.88.4
f6f65874-d(	aaid	Android	8	31.46168	-84.10403	5	1.57E+12	US	djs4ypmm9f	173.20.220
08497812-3	aaid	Android	8	34.01483	-118.1505	9	1.57E+12	US	9q5cx2jqvb5	172.58.23.1
0ac7a5b3-7	aaid	Android	9	33.58056	-84.53273	9	1.57E+12	US	djgzh3jhutg	73.122.152
AB83E70C-A	idfa	iOS	13.1	35.62415	-120.6744	11	1.57E+12	US	9q64tvpt9y(	97.84.120.2
4e769f03-8(	aaid	Android	9	38.31598	-77.51773	18	1.57E+12	US	dqbcup1q9z	70.174.151
C0D39B7B-4	idfa	iOS	13.1	44.50803	-88.04933	11	1.57E+12	US	dpcmhqkqjc	23.126.150
02307eb9-a	aaid	Android	9	32.26354	-83.44898	9	1.57E+12	US	djsxt16k9zq	99.203.69.1

Data Resellers

Este tipo de datos son **comprados a muchas otras aplicaciones y revendidos por ciertas compañías**



Movilidad

Utilidad de esta información en ***marketing*:**

- Determinar dónde poner un **anuncio**.
- **Dónde abrir una sucursal**.
- La ubicación del **mercado objetivo**.
- Distribuir **pauta digital.**
- Objetivos de venta.
- Portafolio de productos.
- Análisis de competencia.



Este tipo de datos y su análisis también pueden servir para salvar vidas en desastres naturales

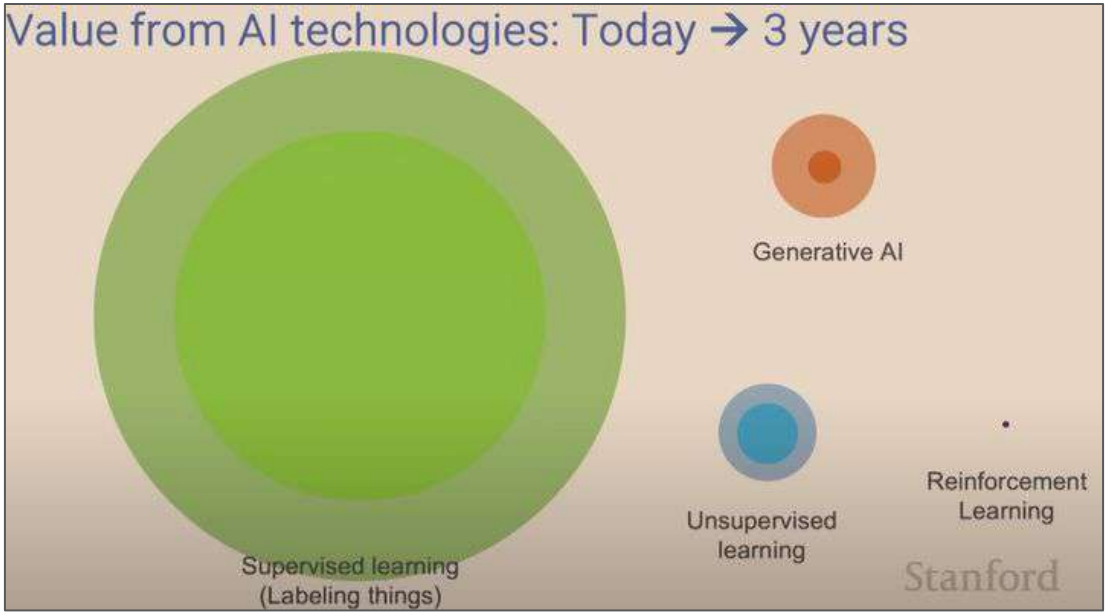
En nuestro curso, estudiaremos un caso de uso con la ONU



Por otro lado, **AI/ML tiene múltiples ramas y aplicaciones**

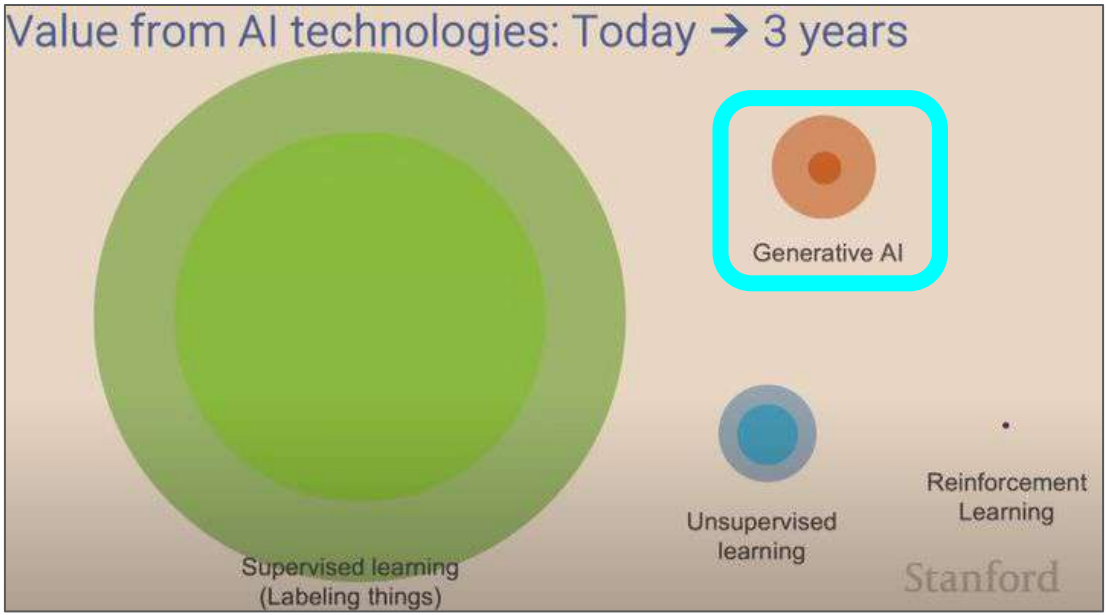
Machine Learning

4 Ramas principales de IA



Machine Learning

4 Ramas principales de IA



ChatGPT

Sin embargo, **parece** que toda la IA y ML se trata o nació con esta herramienta,

¿no?

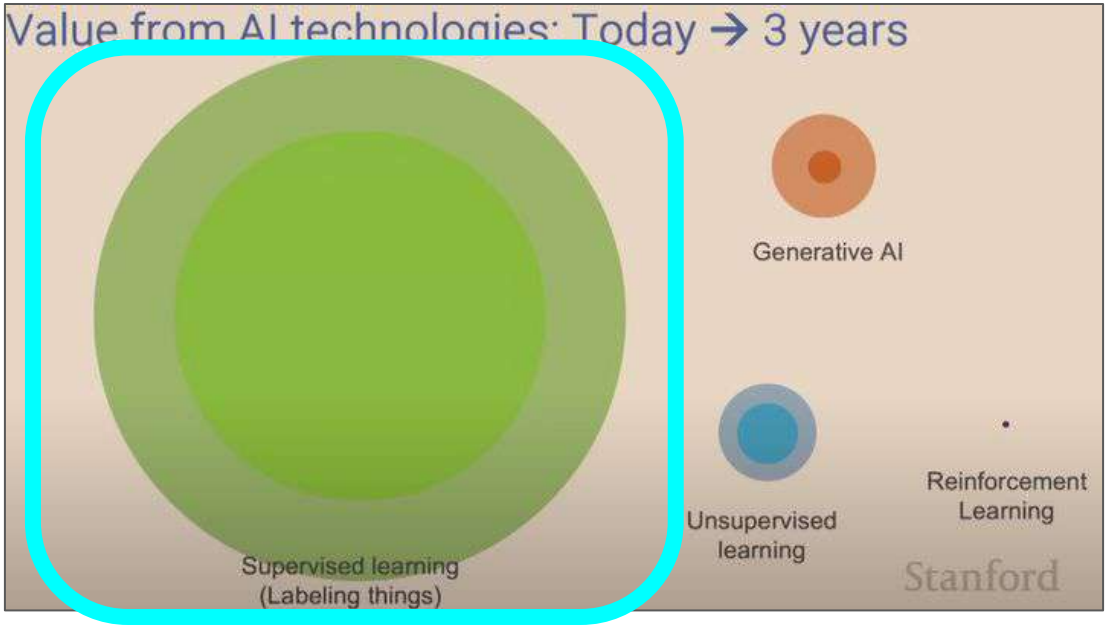


En este curso estudiaremos **todas,**

con énfasis principal en **dos**

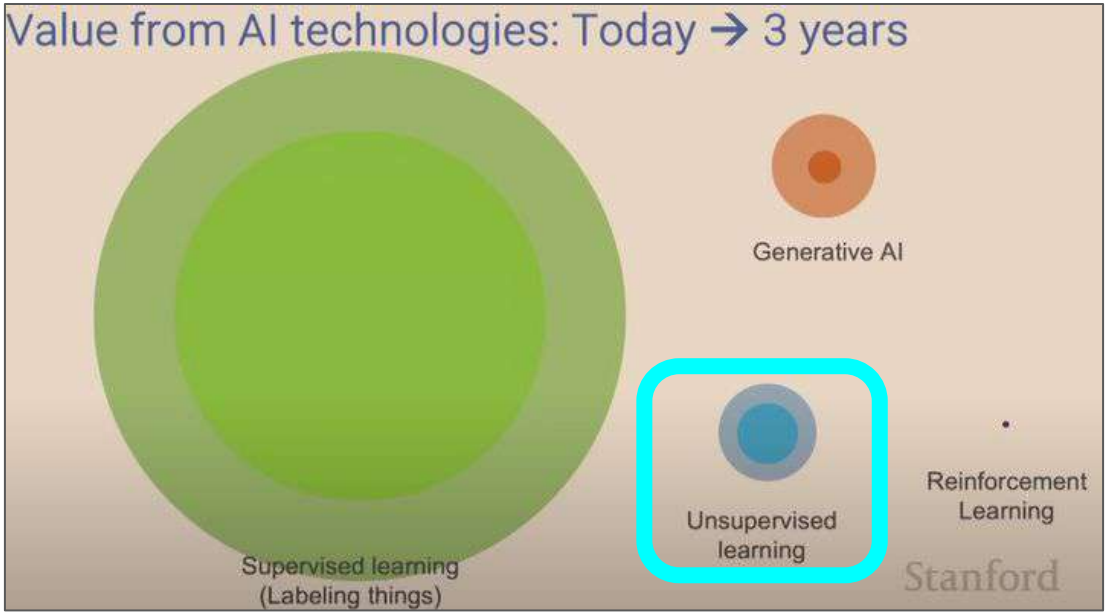
Énfasis principal

*Aprendizaje **supervisado***



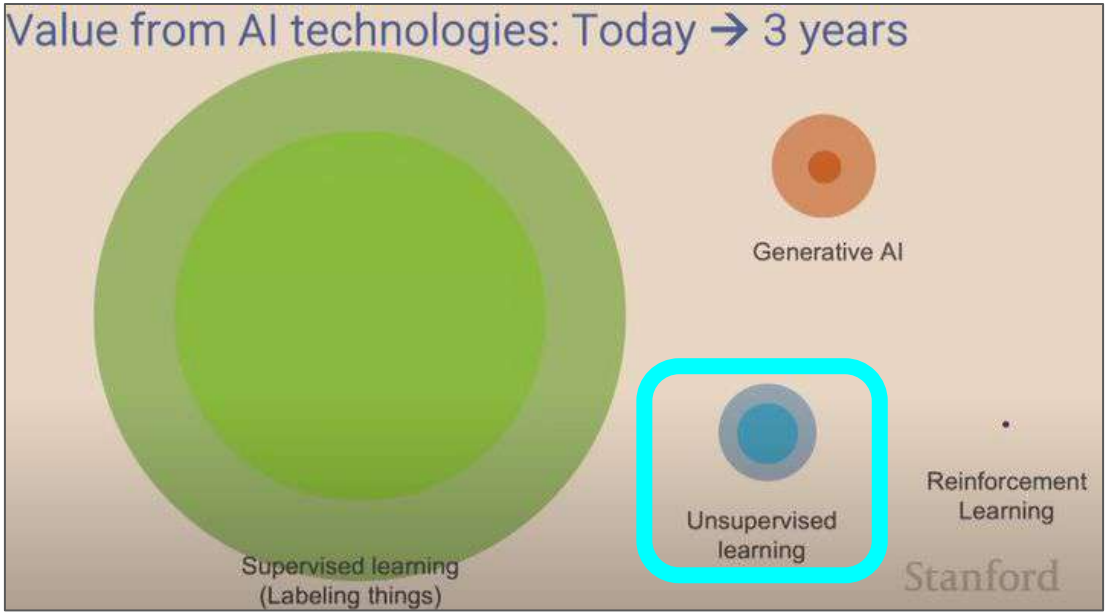
Énfasis principal

*Aprendizaje **no supervisado***

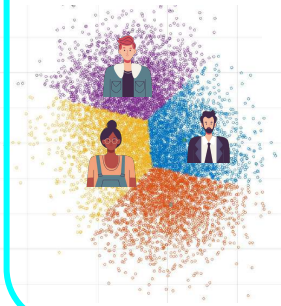


Énfasis principal

*Aprendizaje **no supervisado***



Clustering

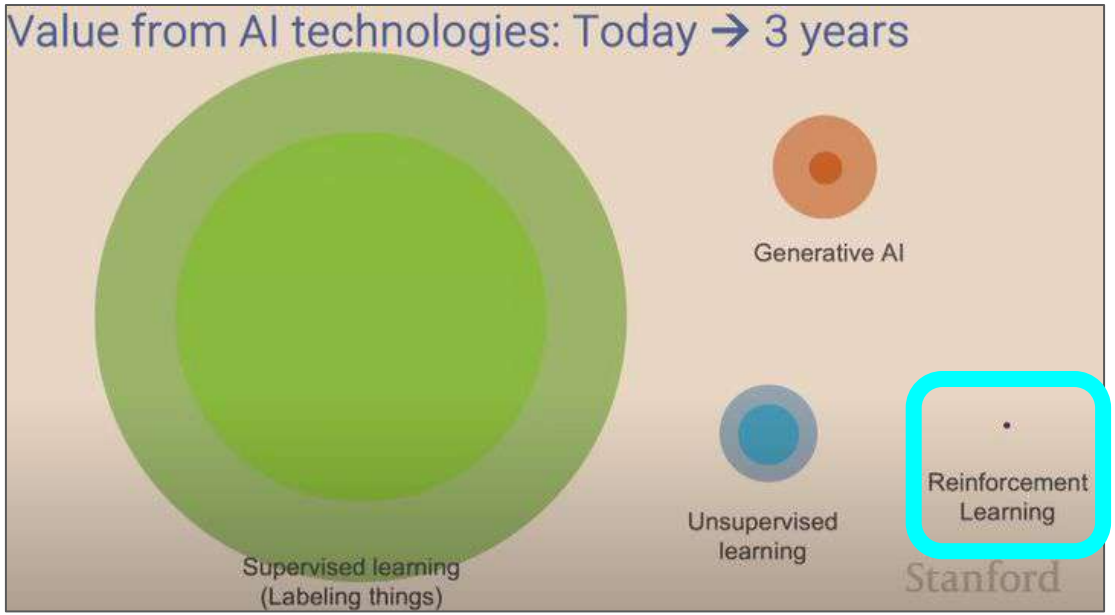


Porque son las **más poderosas** para pronosticar

y crear productos y servicios

Machine Learning

Aprendizaje ***por refuerzo***

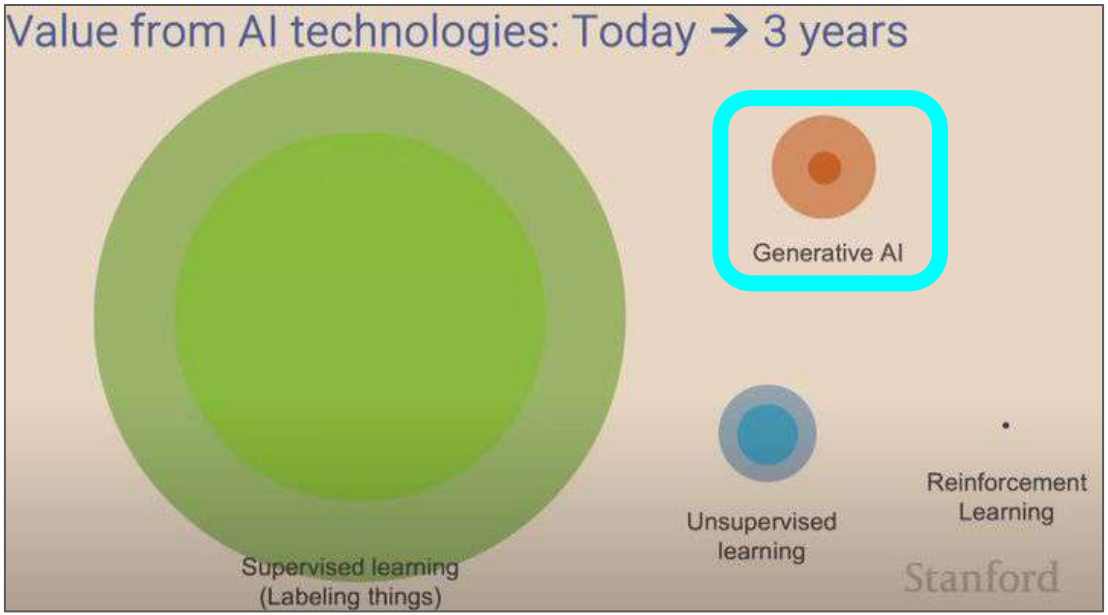


Vehículos autónomos



Machine Learning

*IA **Generativa** y modelos de lenguaje (LLM)*



ChatGPT

Pero... ¿**cómo funcionan los algoritmos de ML**, los datos y la AI?



Mejor aún:

¿Qué es un **algoritmo**?



Algoritmo

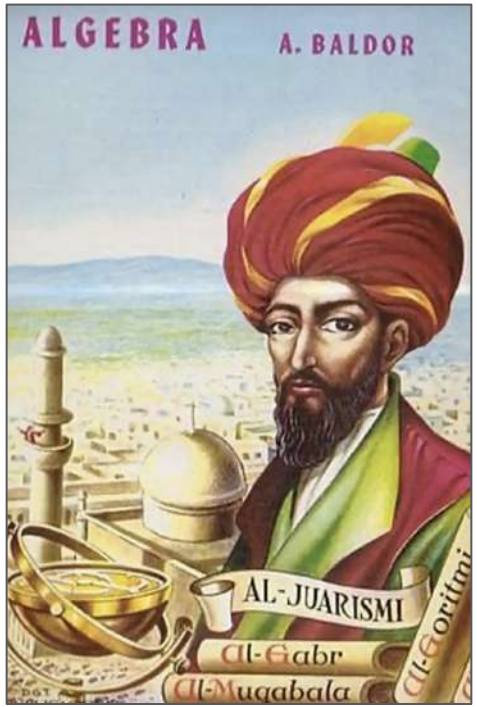
Serie de pasos que sirven para

resolver un problema o tarea de **forma estructurada**

¿De **dónde** viene este concepto?



Algoritmo



Algoritmo



Algoritmo

Representación **técnica**

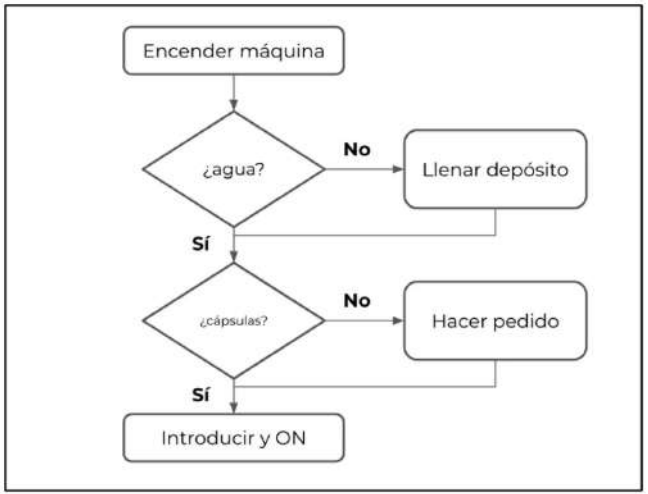
Algorithm 1: Exact Greedy Algorithm for Split Finding

Input: I, instance set of current node
Input: d, feature dimension
$gain \leftarrow 0$
$G \leftarrow \sum_{i \in I} g_i,\ H \leftarrow \sum_{i \in I} h_i$
for $k = 1$ ***to*** m **do**
  $G_L \leftarrow 0,\ H_L \leftarrow 0$
  for j *in sorted*$(I,$ *by* $\mathbf{x}_{jk})$ **do**
    $G_L \leftarrow G_L + g_j,\ H_L \leftarrow H_L + h_j$
    $G_R \leftarrow G - G_L,\ H_R \leftarrow H - H_L$
    $score \leftarrow \max(score, \frac{G_L^2}{H_L+\lambda} + \frac{G_R^2}{H_R+\lambda} - \frac{G^2}{H+\lambda})$
  end
end
Output: Split with max score

El término **no es exclusivo** de temas técnicos...

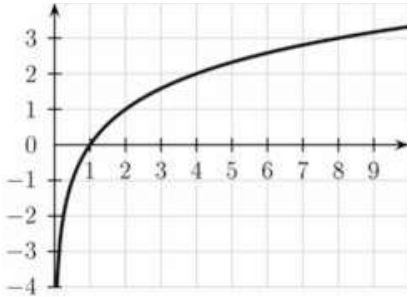
Algoritmo

Algoritmo para preparar una **taza de café**





Algoritmo **no** es lo mismo que **logaritmo**



¿Qué es un ***machine learning***?



Machine learning (ML)

Algoritmos que permiten **aprender** **patrones directamente de los datos** para tomar una decisión



Algoritmos *Machine learning*

Algunas de las opciones **más populares**:

- Bosques aleatorios
- Árboles de decisión
- Redes neuronales
- Análisis de regresión
- Regresión logística



Algoritmos *Machine learning*

Algunas de las opciones **más populares**:

- Bosques aleatorios
- Árboles de decisión
- **Redes neuronales**
- Análisis de regresión
- Regresión logística



¿Cómo **funciona** un algoritmo de **ML**?



Por ejemplo,

¿cómo podría un agricultor **separar** una fruta por su calidad, utilizando **ML**?



¿Qué **criterios** revisa una persona para

evaluar la calidad de la fruta?



¿Qué **criterios** debería revisar una máquina o algoritmo?



Características de cada clase:

Class	Images
Unripe (Green/Green-red)	
Ripe (red)	
Defective (Overripe/rotten)	







Un **algoritmo** de ML puede **“aprender” las características** de cada clase



Posteriormente, clasifica **nuevos jitomates automáticamente** de acuerdo a su calidad



Observa que la máquina **identifica características** (entrenamiento)

y utiliza el conocimiento previo para **clasificar**

Generalmente, un algoritmo puede hacerlo

más rápido y con mayor precisión que un ser humano

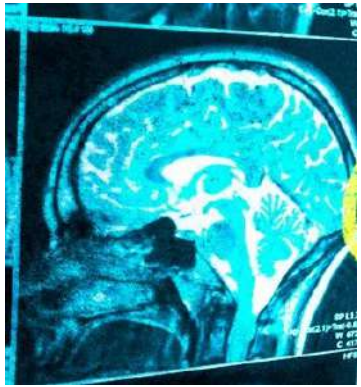


Ejemplo:

¿Cómo podemos utilizar ML para **detectar** con precisión un **tumor maligno**?



¿Qué características tiene un **tumor**?



Al igual que en los **jitomates ...**:

Class	Images
Unripe (Green/Green-red)	
Ripe (red)	
Defective (Overripe/rotten)	

Características Tumor

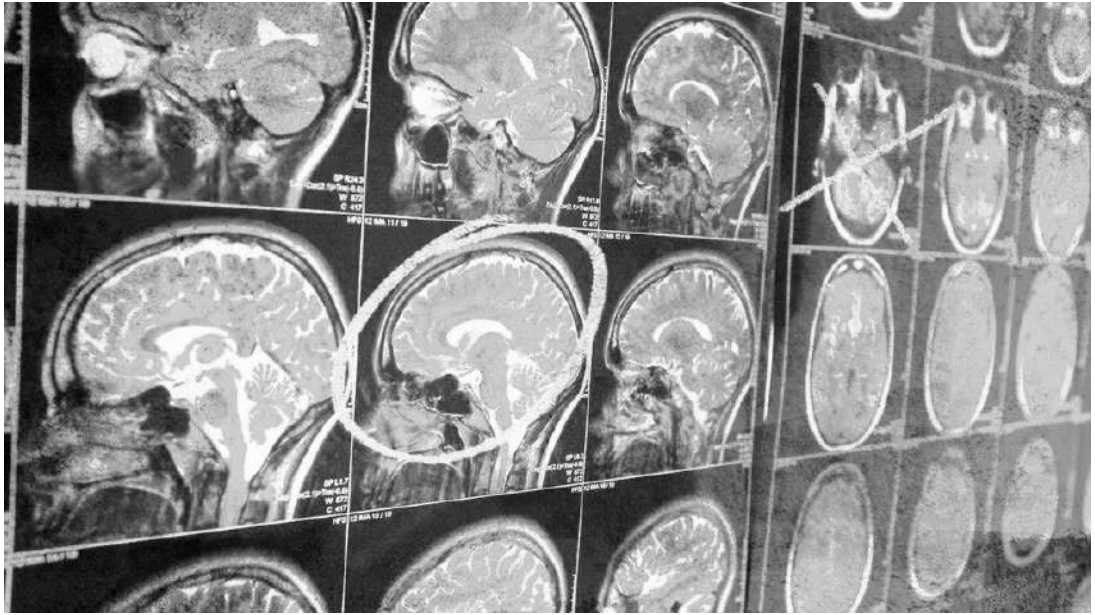
Tamaño, área, forma, agujeros, entre otros...

Features Name	Description
Area	The tota area of the object.
Pa_ratio	The perimeter to area ratio provides information about the object's shape complexity.
Solidity	The ratio of the object area to its convex hull's area indicates how compact it is.
Circularity	A measure of how closely the object resembles a circle.
Equivdiameter	The diameter of a circle provides size-related information.
Convexarea	The area of the convex hull of the object.
Extent	The ratio of the object's area to the bounding box's area provides information about its spatial distribution.
Filled area	After filling holes, the area of the object can be relevant for particular objects.
Major_axis_length	The length of the major axis of the best-fitting ellipse to the object, provides shape-related information.
Mean	The mean intensity value of the object's pixels which may be indicative of its appearance.
Std_deviation	The standard deviation of the pixel intensities provides information about texture variation.
Shannon_entropy	A measure of the object's information content relevant for texture analysis.
Skewness	A measure of the object's asymmetry in pixel intensity distribution.

Tumores no malignos de pacientes previos



Tumores malignos de pacientes previos



Un algoritmo es **“entrenado”** para detectar

las características de cada **clase de tumor**, a partir de una imagen



Y clasificar **oportunamente** el tipo de tumor de **nuevos pacientes**



ML *breast cancer*

Liga

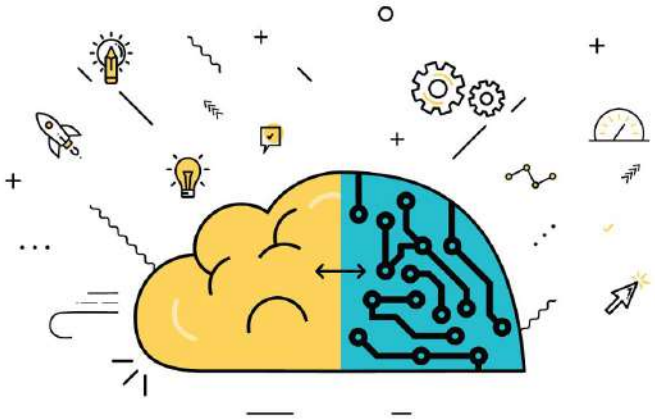


¿Qué es es **inteligencia artificial**?



Inteligencia Artificial

Disciplina que busca construir **máquinas inteligentes para comprender la inteligencia humana**.



Inteligencia Artificial

Funcionalidades de algunos servicios:













Inteligencia Artificial

Funcionalidades de algunos servicios:

- ***Recomendar***
- ***Redactar***
- ***Identificar***
- ***Dibujar***
- ***Detectar***
- ***Calcular***







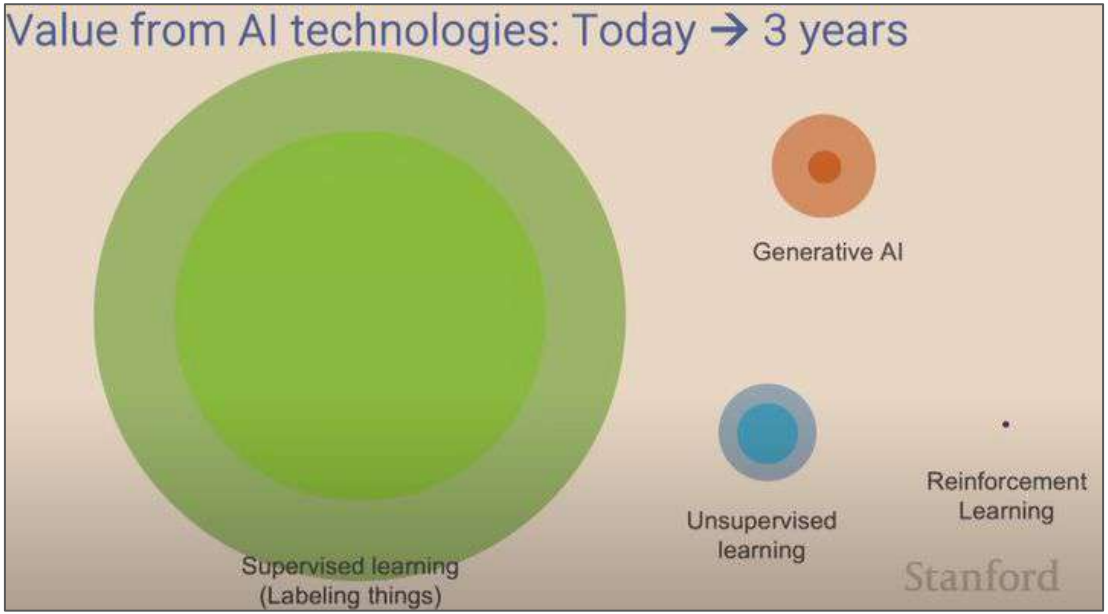






Tecnología IA

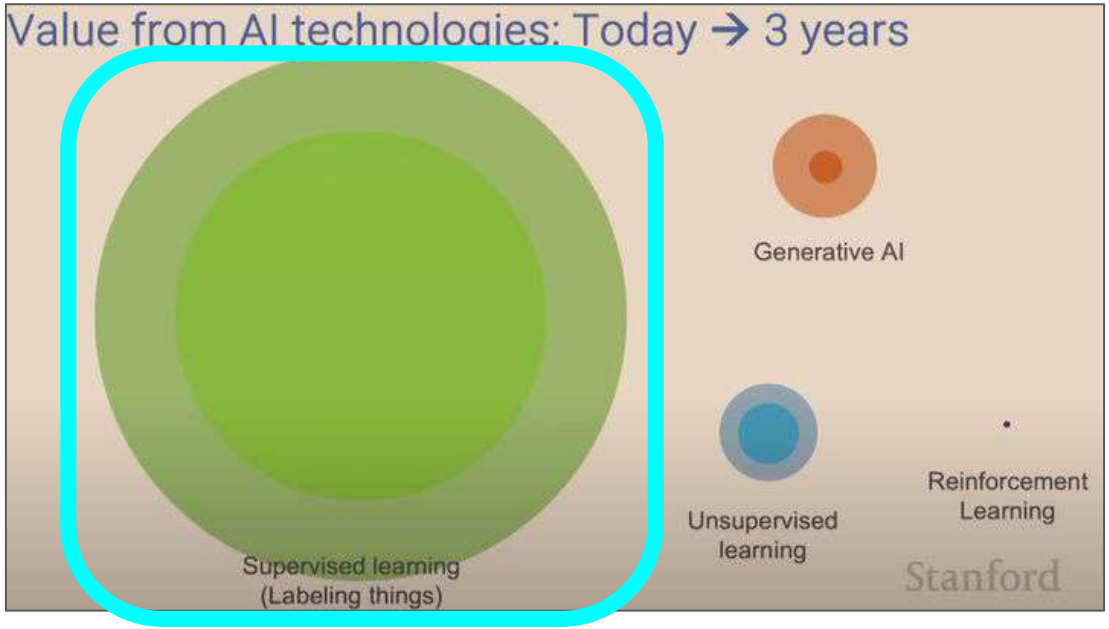
4 **ramas principales** *IA*



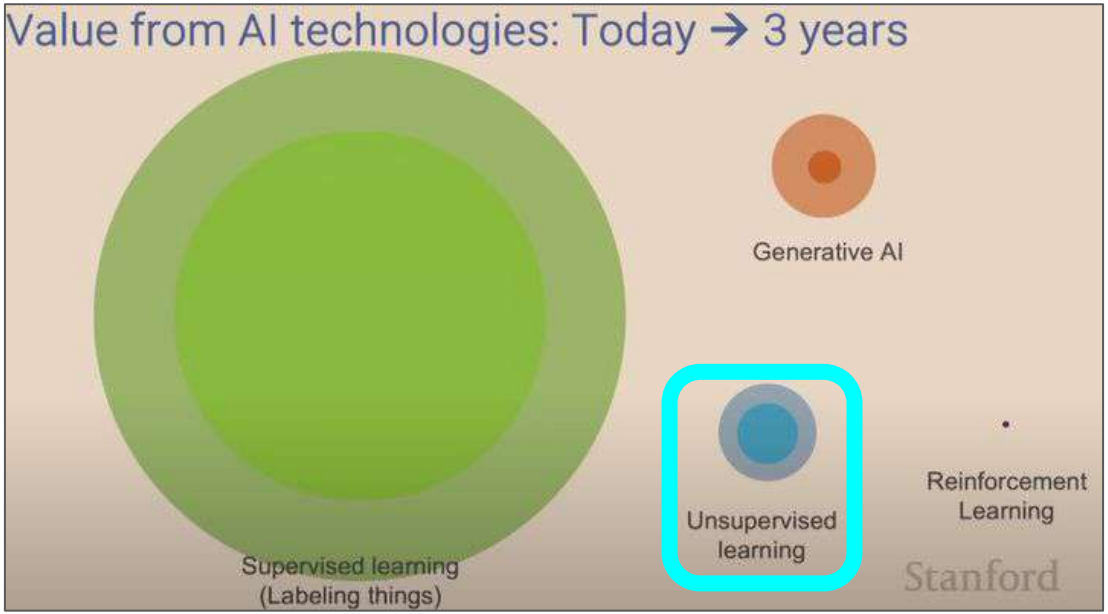
Tecnología IA

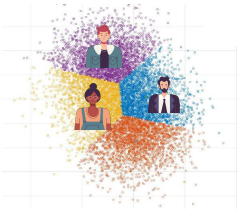




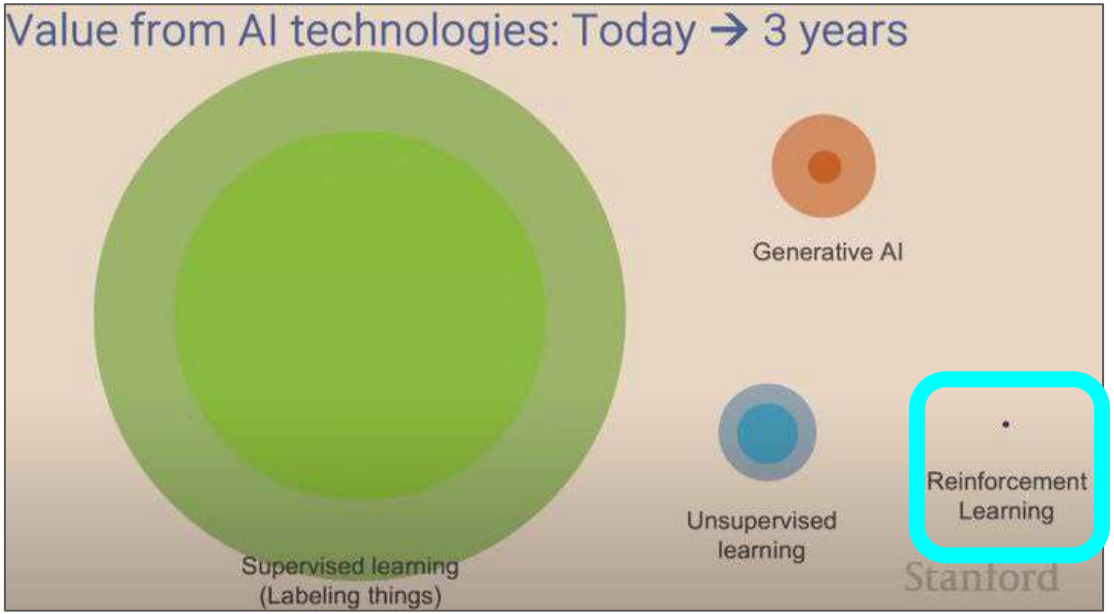


Tecnología IA



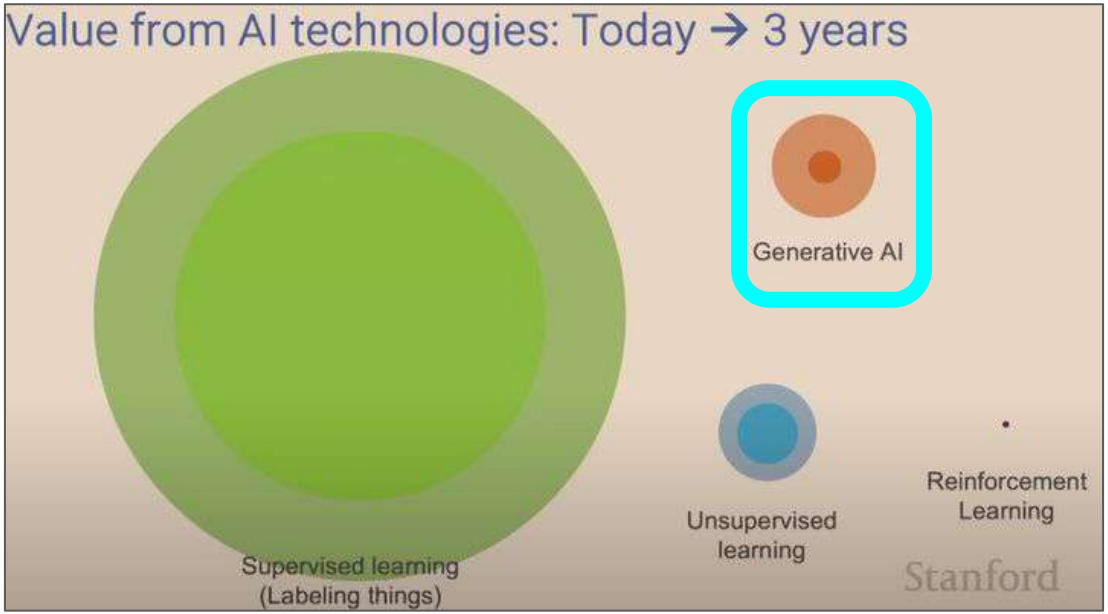


Tecnología IA





Tecnología IA



OpenAI

Temario y estructura

Clase 1
ML y análisis de datos

ITAM

Temario

En este curso tendremos cerca de **8 sesiones**, en las que incluimos **talleres prácticos**. Los temas a estudiar:

- **Módulo 1: Introducción al Aprendizaje de Máquina**
    - Estructura general de los proyectos de análisis de datos
    - Principales fuentes de datos externas y contextuales
    - Información interna, estandarización y esquemas de bases de datos

- **Módulo 2: Procesamiento de datos y recursos computacionales**
    - Conceptos frecuentes en ML
    - Servicios de almacenamiento en la nube para análisis de datos: AWS
    - Tipos de datos y sus principales operaciones

ITAM

Temario

En este curso tendremos cerca de **8 sesiones**, en las que incluimos **talleres prácticos**. Los temas a estudiar:

- **Módulo 3: Aprendizaje de máquina: algoritmos y métricas**
    - Tipos de problemas y aprendizaje
    - Supervisado
    - No supervisado
    - Aprendizaje por refuerzo (*reinforcement learning*)
    - Algoritmos de *machine learning*
    - Métricas para algoritmos de *machine learning*
    - Entrenamiento y evaluación de algoritmos
    - Técnicas avanzadas de muestreo en ML: *oversampling, undersampling y mixed*

ITAM

Temario

En este curso tendremos cerca de **8 sesiones**, en las que incluimos **talleres prácticos**. Los temas a estudiar:

- **Módulo 4: Ramas adicionales de Inteligencia Artificial**
    - *Natural language processing*, métricas y aplicaciones
    - Inteligencia artificial generativa y modelos de lenguaje
    - Diversos proyectos de aplicación real de análisis de datos a lo largo del curso

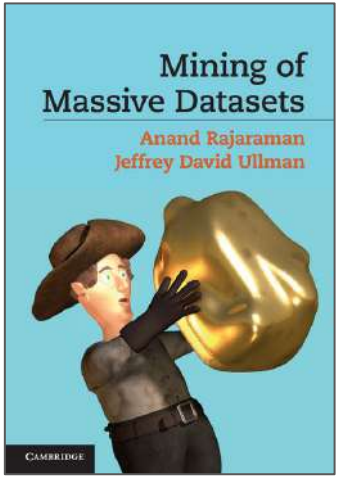
Construcción del temario

- La mayor parte de los temas se originan de mi trabajo/experiencia en distintas empresas y Gobierno; además de los clientes que atendemos

- **Este enfoque nos permite estudiar temas novedosos y sobre todo, problemas reales y frecuentes al tomar decisiones a través del análisis de datos**

- No seguimos como tal un libro pero ofreceré referencias y recomiendo siempre algunos libros para ML

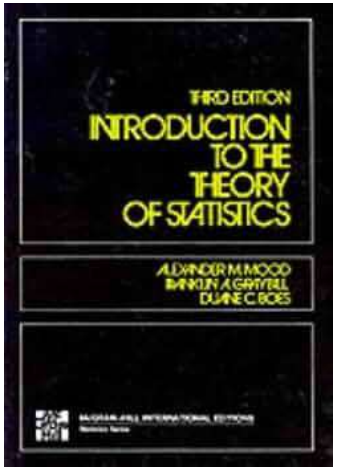
Libros de referencia



Liga



Linear Algebra, *Friedberg*



Statistics, *Mood*

Gran parte de tus **habilidades** en *ML*,

depende de tu nivel en **matemáticas**

Correr **algoritmos y programar es importante**

pero la **estructura matemática es fundamental**

Recuerda que nuestras **sesiones** duran del

3 al 26 de noviembre 2026

Aclaraciones importantes

En todo el **curso utilizaremos R** por lo que será necesario tener un **buen dominio**

Es necesario estar familiarizado con ***tidyverse*** y sus funciones para analizar *dataframes*

Tidyverse y pipe %>%

¿Familiaridad con las siguientes funciones?

- *%>%*
- *mutate()*
- *group_by()*
- *summarise()*
- *filter()*
- *select()*
- *gather() y spread()*
- **Referencia principal (revisar Explore y Wrangle)**

En este curso ofrecemos una **sesión introductoria** a R



Liga curso R

- Por favor, aprovecha esta semana para revisar este curso gratuito publicado por Hadley Wickham:



¿Cómo participar?

Todos pueden participar y plantear sus dudas de forma ordenada y respetuosa **siempre**.

Por favor, no interrumpan a sus compañeros



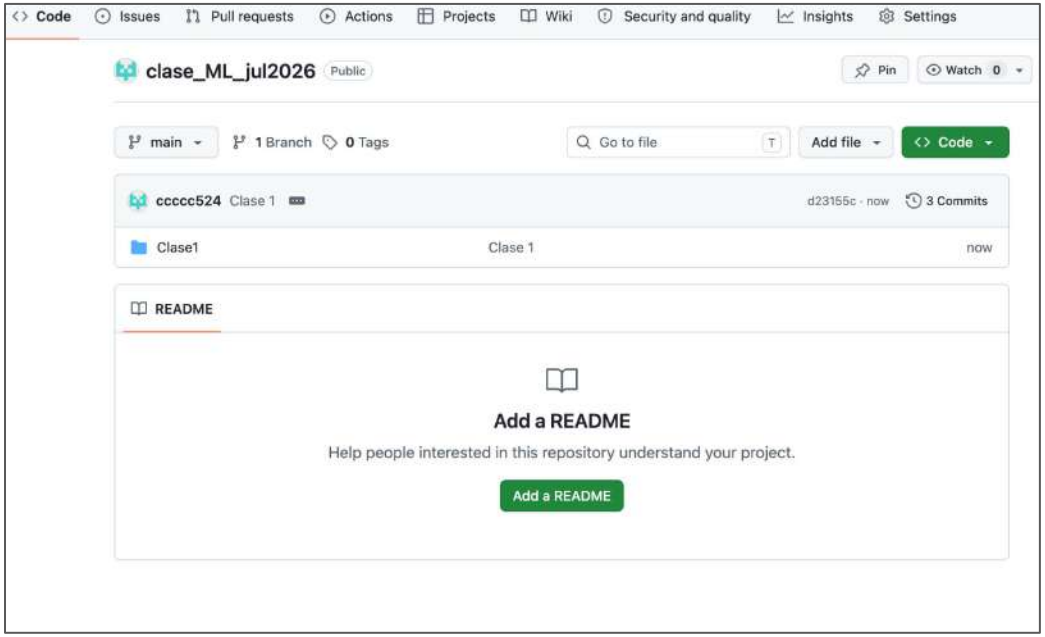
Consejo especial

Este curso es **corto e intensivo**, por lo que te aconsejo **prender tu cámara siempre (asistencia y certificado)**



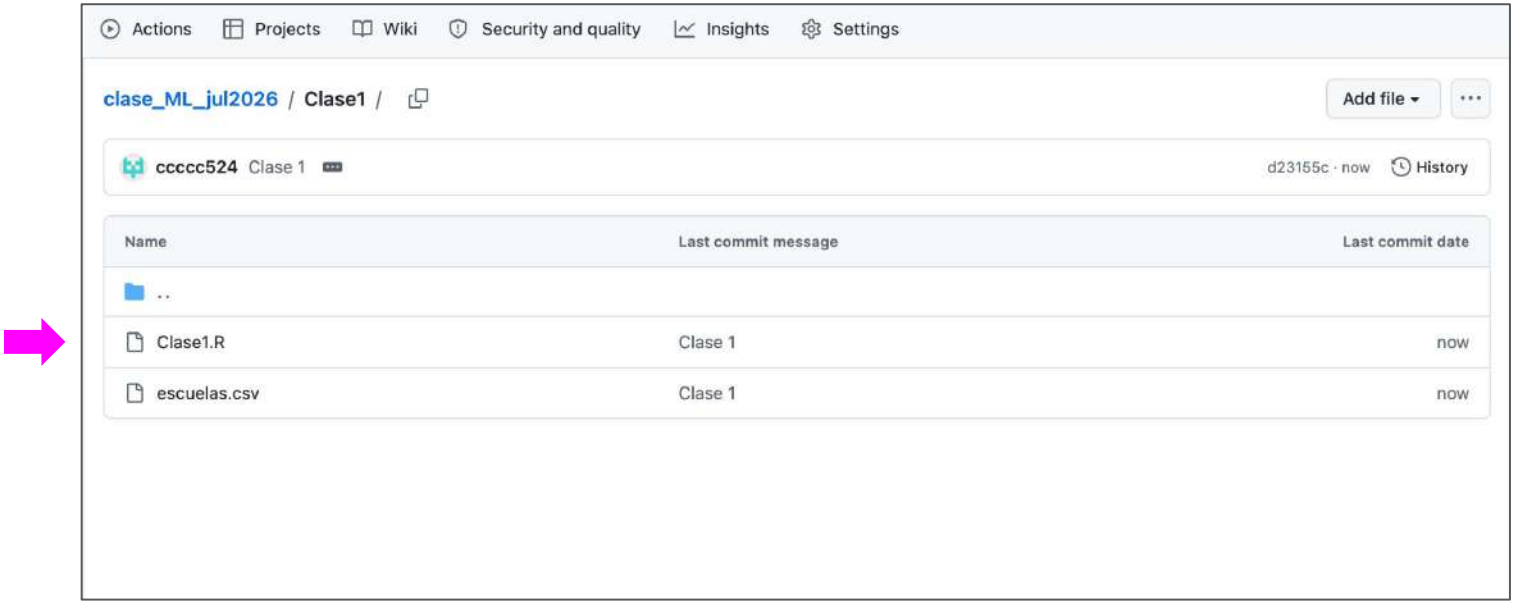
Material del curso

Todo el material será publicado **siempre** en esta siguiente [liga de Github]



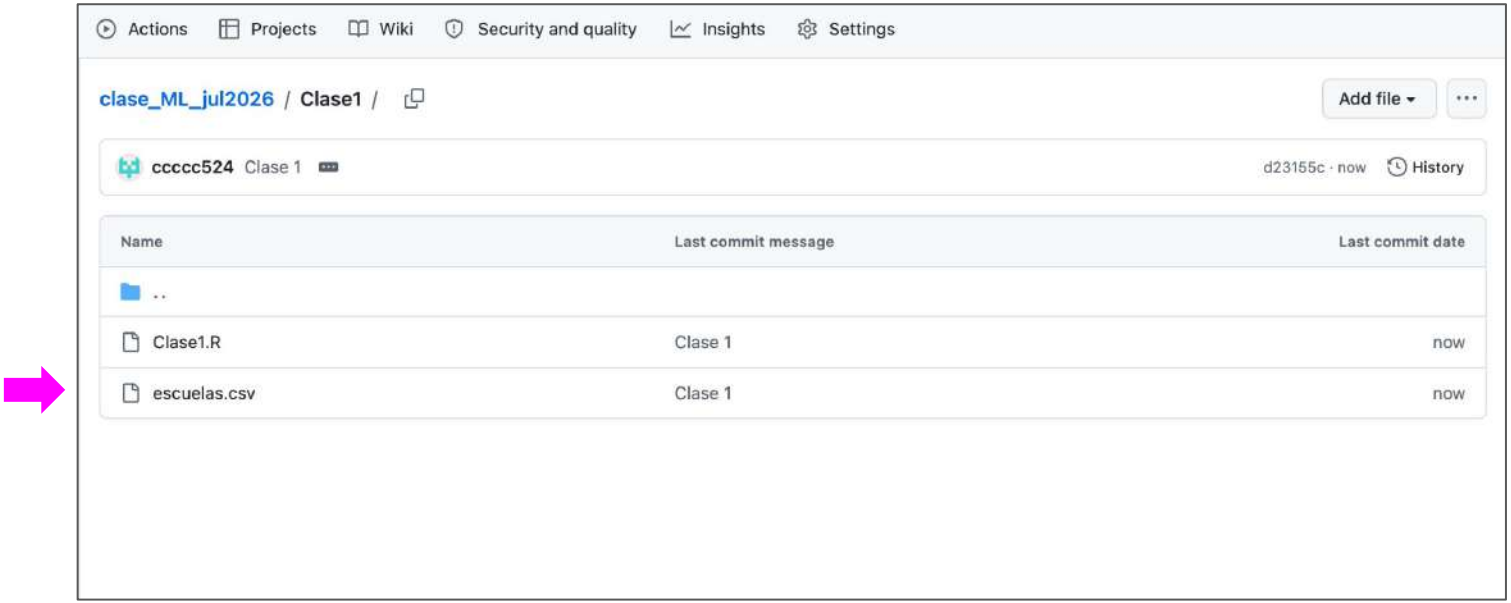
Material del curso

Dar click en **Clase 1**



Material del curso

Dar click en **Clase 1**



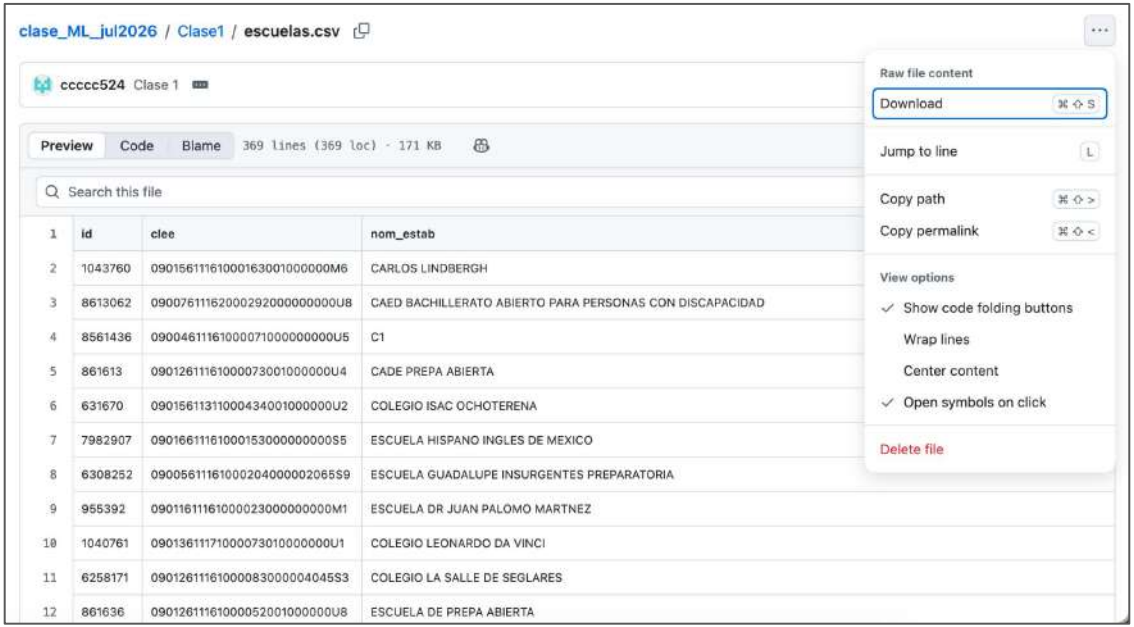
Material del curso

Dar click en **cada archivo y descargar en parte superior derecha**



Material del curso

Dar click en **cada archivo y descargar en parte superior derecha**



Nota: en las primeras sesiones estudiaremos

una serie de **conceptos fundamentales** en ML

A partir de las **sesiones 2 y 3** utilizaremos

más código y programación

Lista Asistencia

Descanso (10 minutos)

Por favor, responde la siguiente encuesta:

Perfil (cada uno responde)

Presentación Profesor

Clase 1
ML y análisis de datos

ITAM

Presentación

Carlos Castro Correa

- 14 años de experiencia profesional en **ML y matemáticas aplicadas**

- Soluciones de análisis de datos en **distintas industrias:** seguros, seguridad pública, ***retail***, **mercadotecnia**, publicidad, educación, **políticas públicas**, medios de comunicación, tecnología y equipos deportivos

Presentación

- Matemáticas Aplicadas, **ITAM**
- Maestría en Ciencia de Datos, **ITAM**



Presentación

- Fui el primer **Director de Análisis de Datos Abiertos en Presidencia de la República 2013-2016**

- **Diseño y evaluación de políticas públicas utilizando análisis de datos y modelos**

MÉXICO
PRESIDENCIA DE LA REPÚBLICA

Presentación

- Posteriormente, co-fundé una **empresa de análisis de datos + AI** que atiende al **sector privado y público**

- Transformamos datos para detectar oportunidades

hasel_

Presentación

- **Profesor de Análisis de Datos Espaciales e Inteligencia Artificial** en distintos programas de **Maestría** del ITAM **(Maestría en Ciencia de Datos & MBA)**

Opinión y Entrevistas

- Ofrezco algunas **entrevistas** en programas de **radio y televisión**



Contacto

Carlos Castro Correa

carlos.castro@itam.mx

carlos@hasel.lat

Contacto

En **adelante** (después del curso, en Linkedin)



Estructura de un proyecto de análisis de datos

Clase 1

ML y análisis de datos

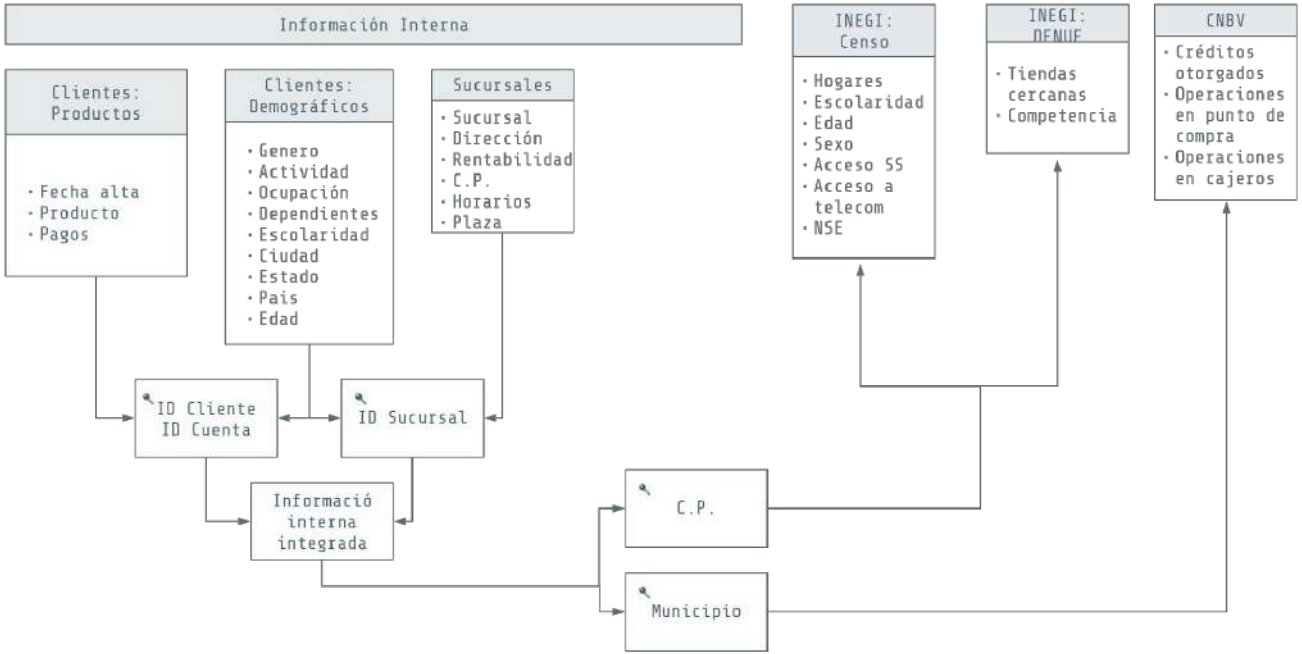
ITAM

Análisis de datos

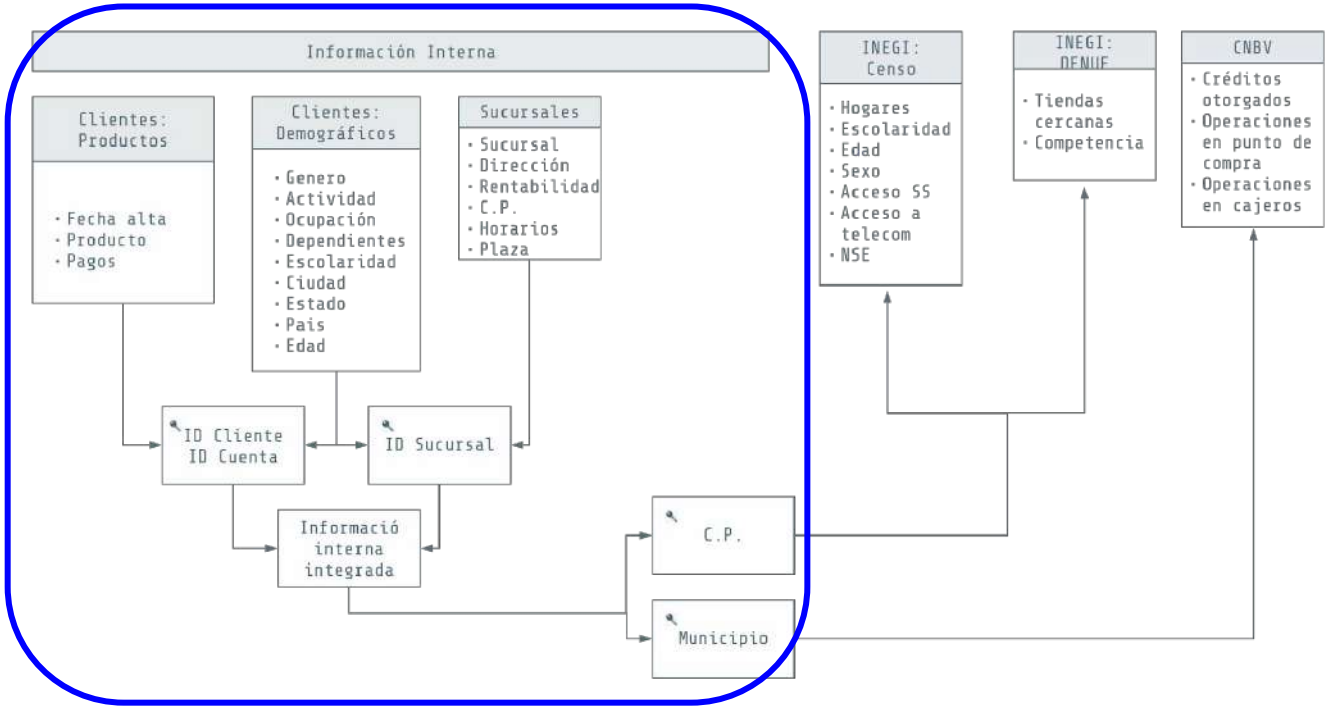
En general, una buena ejecución de proyecto consta de 4 pasos:

1. **Definición de preguntas** de negocio o investigación (fundamental)
2. **Bases de datos** internas + externas (Esquema BD)
3. **Análisis**
4. **Presentación** o herramienta (con diseño)

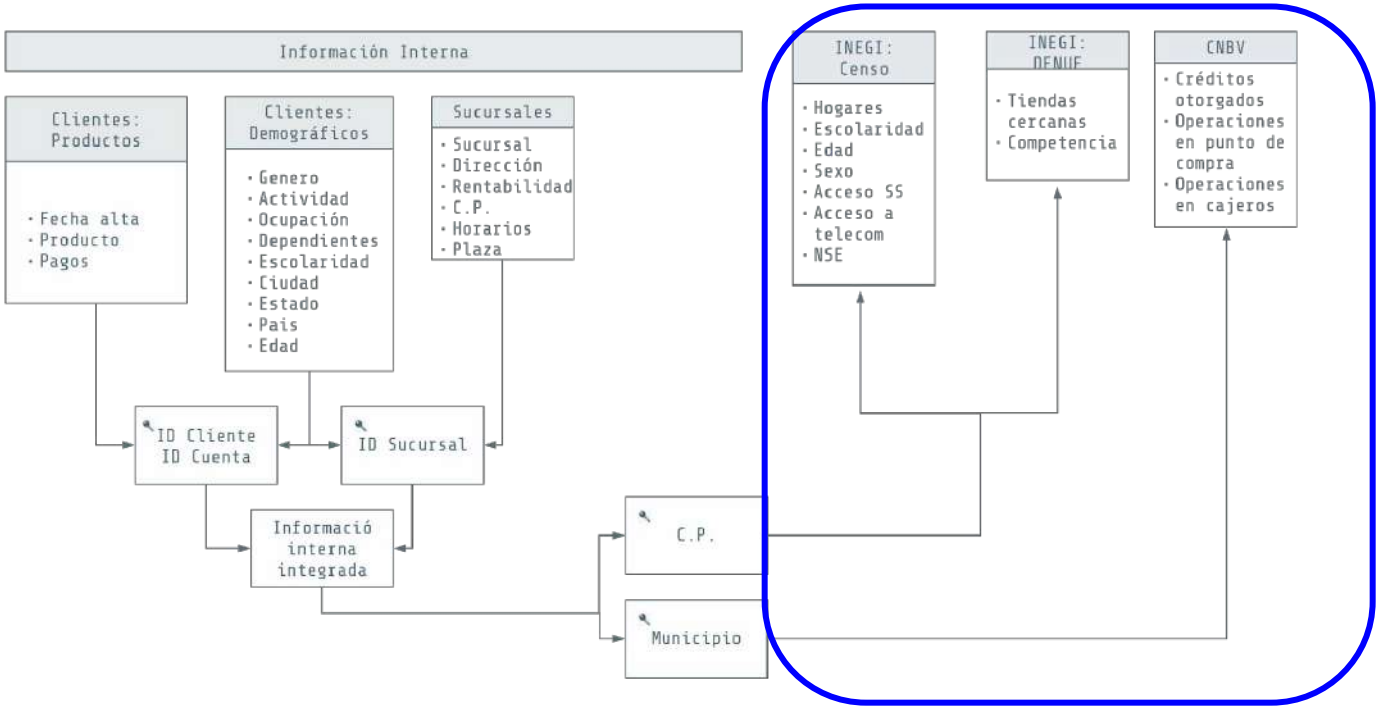
2: Bases de datos (interna + externa)



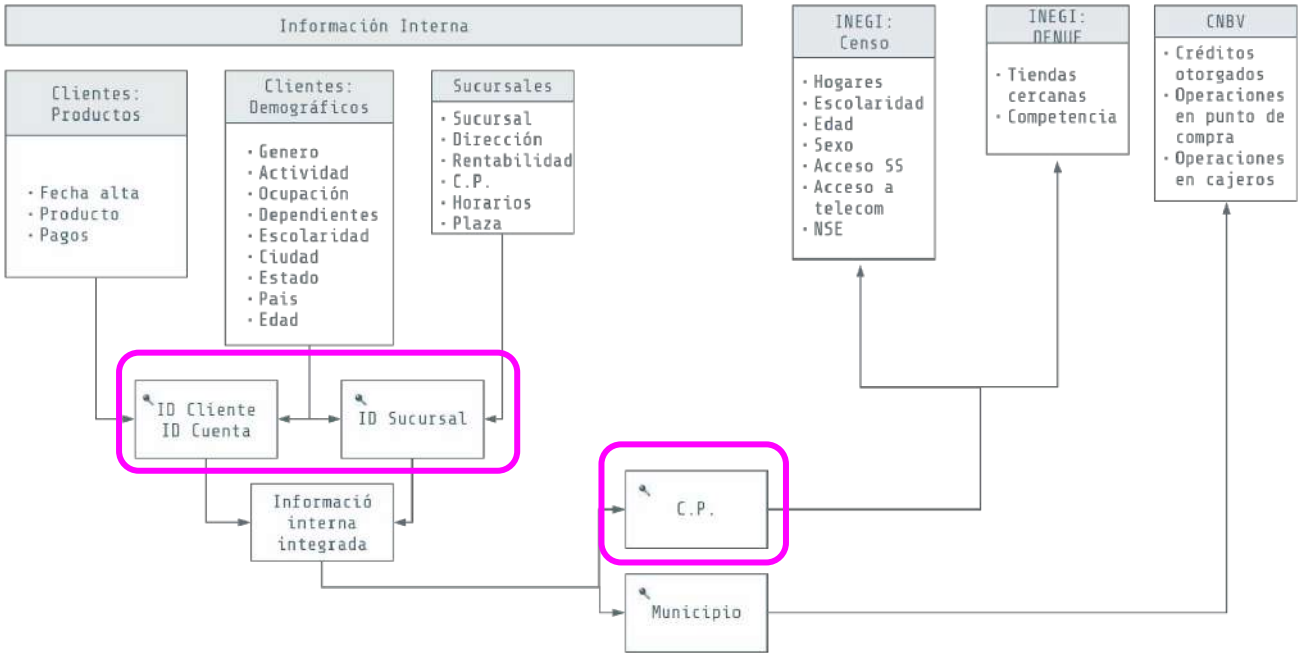
2: Bases de datos (interna + externa)



2: Bases de datos (interna + externa)



2: Bases de datos (interna + externa)



Datos Internos

Información que las empresas **generan** y **sólo ellos utilizan** para tomar decisiones

- Clientes y operaciones
- Sucursales
- Productos
- Ventas e inventario



Importancia Datos Externos

Los **datos internos** de un **mismo tipo de cliente**



- Entre 25 a 30 años
- Posgrado
- Tarjeta de crédito
- Seguro de vida
- Soltero



- Entre 25 a 30 años
- Posgrado
- Tarjeta de crédito
- Seguro de vida
- Soltero

¿Por qué son importantes los **datos externos**?

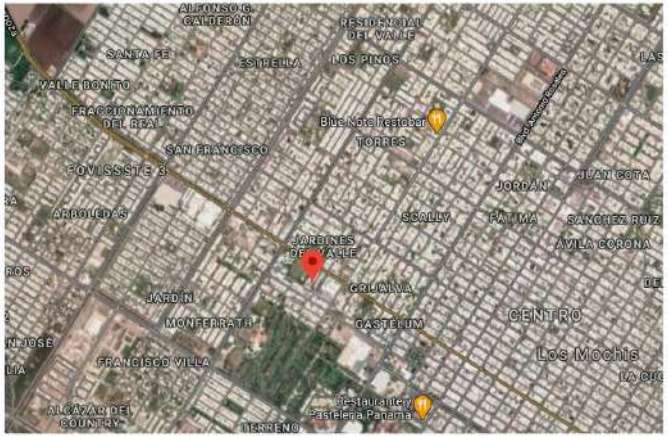


Importancia Datos Externos

Información **fundamental** y comúnmente **ignorada**









Internos

BD **internos**

Internos + Externos

BD **internos**

Información contextual y demográfica (**externos**)

En este curso estudiaremos los **datos externos** que publican

el Gobierno y otros organismos autónomos



3: Análisis

Con los datos listos, respondemos preguntas de investigación utilizando:

- Estadística
- Análisis de datos espaciales
- Optimización
- Visualización
- *Machine learning*
- Simulación Monte Carlo
- Aprendizaje reforzado
- Modelos



4: Presentación o herramienta

Para el **toma de decisiones** y **hallazgos**:



- Desarrollo de herramientas.
- Tablero de control.
- Presentación.
- Reporte.
- *App*.

Machine Learning

Introducción

Clase 1

ML y análisis de datos

ITAM

Recordemos la **definición inicial** de ML



Machine learning (ML)

Algoritmos que permiten **aprender** **patrones directamente de los datos** para tomar una decisión

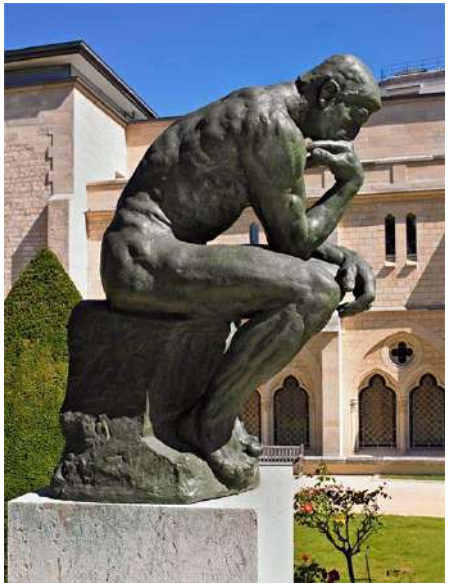


¿Por qué utilizamos ML?

¿Es realmente algo muy novedoso?



Imagina el escenario



Trabajas en un banco y durante **10 años** has revisado la información de más de **500,000 clientes** solicitando un crédito para abrir un nuevo negocio

OnlineSecurity	OnlineBackup	DeviceProtection	TechSupport	StreamingTV	StreamingMovies
No	Yes	No	No	No	No
Yes	No	Yes	No	No	No
Yes	Yes	No	No	No	No
Yes	No	Yes	Yes	No	No
No	No	No	No	No	No
No	No	Yes	No	Yes	Yes
No	Yes	No	No	Yes	No
Yes	No	No	No	No	No
No	No	Yes	Yes	Yes	Yes
Yes	Yes	No	No	No	No
Yes	No	No	No	No	No
No internet service	No internet service	No internet service	No internet service	No internet service	No internet service
No	No	Yes	No	Yes	Yes
No	Yes	Yes	No	Yes	Yes
Yes	No	Yes	Yes	Yes	Yes
Yes	Yes	Yes	Yes	Yes	Yes
No internet service	No internet service	No internet service	No internet service	No internet service	No internet service

Imagina el escenario

Con base en toda esta experiencia acumulada, ahora tienes la **intuición** para estimar si un nuevo cliente **va a pagar** el crédito que le otorgas o **no**



Imagina el escenario

Tu criterio **a veces** funciona, pero otras veces no...



Imagina el escenario

Además, en el banco **hay otra persona** que también asegura contar con la **experiencia** suficiente para determinar quién va a pagar o no el crédito



Imagina el escenario

Por supuesto, **al banco le interesa pronosticar con la mayor precisión posible** si un cliente va a pagar o no, por lo que surgen las siguientes preguntas:

1. ¿Quién ofrece el **mejor** modelo? ¿Tú o tu compañero del banco?



Imagina el escenario

Por supuesto, **al banco le interesa pronosticar con la mayor precisión posible** si un cliente va a pagar o no, por lo que surgen las siguientes preguntas:

1. ¿Quién ofrece el **mejor** modelo? ¿Tú o tu compañero del banco?

2. ¿Qué criterios o **métricas** se deben utilizar para **calificar** ambas propuestas?



Imagina el escenario

Por supuesto, **al banco le interesa pronosticar con la mayor precisión posible** si un cliente va a pagar o no, por lo que surgen las siguientes preguntas:

1. ¿Quién ofrece el **mejor** modelo? ¿Tú o tu compañero del banco?

2. ¿Qué criterios o **métricas** se deben utilizar para **calificar** ambas propuestas?

3. ¿Es necesario pasar **10 años** para diseñar un criterio para pronosticar?

   ¿Puedes **prescindir** completamente de la experiencia de los expertos en el problema?



Un **modelo de ML** te podría ayudar a **resolver** este problema

Machine learning

Los modelos cuenta con:

1. Una serie de **métricas** para evaluar las modelos y entonces **seleccionar el mejor**



Machine learning

Los modelos cuenta con:

1. Una serie de **métricas** para evaluar las modelos y entonces **seleccionar el mejor**

2. Un **gran número de modelos** (además de tu modelo y el de tu colega) formados a partir de los datos que el banco ha acumulado



Machine learning

Los modelos cuenta con:

1. Una serie de **métricas** para evaluar las modelos y entonces **seleccionar el mejor**

2. Un **gran número de modelos** (además de tu modelo y el de tu colega) formados a partir de los datos que el banco ha acumulado

3. **Aprovechando al máximo toda la información disponible,** incluso **datos que no considerabas** (internas y externas)



En español, nos podemos referir como

Aprendizaje de Máquina o Aprendizaje Automático

Ejemplos *Machine learning*

Ejemplos frecuentes:

- **Predecir** si un cliente de tarjeta de crédito va a caer en **impago** en los próximos tres meses
- Reconocer palabras escritas a mano (OCR)
- **Estimar** el ingreso mensual de un hogar a partir de las características de la vivienda, posesiones y equipamiento y localización geográfica
- **Segmentar** a los clientes de Netflix según sus gustos
- **Recomendar** artículos a clientes de un programa de lealtad o servicio *online*



Eso lo puede hacer un ser humano... ¿**por qué utilizamos ML**?



¿Para qué usamos ML?

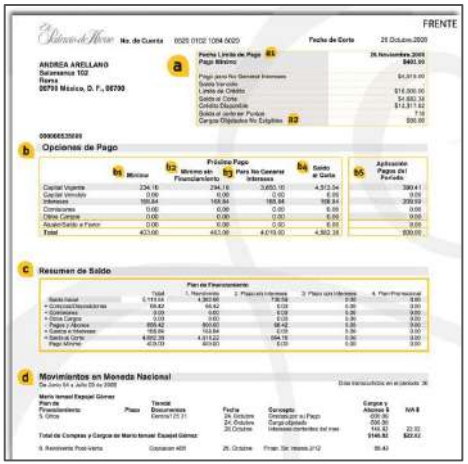
Razones principales:

- Quisiéramos obtener una **respuesta barata, rápida, automatizada,** y con suficiente precisión
- Quisiéramos **superar el desempeño actual** de los expertos o de reglas simples utilizando datos

Superar el desempeño actual

Imagina el proceso **actual y pasado** cada que un cliente solicitaba una TC o **crédito**:





No siempre es necesario usar ML, además del **tiempo** que debes invertir, es **costoso**

La razón de implementarlo debe estar totalmente **justificada**

Principales algoritmos ML

Los algoritmos se han popularizado, pero, una parte importante del planteamiento es estadística "**tradicional**":

- Análisis de conglomerados o *clustering*
- Análisis de regresión
- Árboles de decisión
- **Regresión lineal**
- *Support vector machine*
- Redes neuronales
- K-vecinos más cercanos
- Regresión logística
- Regresión multinomial



¿Todo es realmente algo muy **novedoso**?

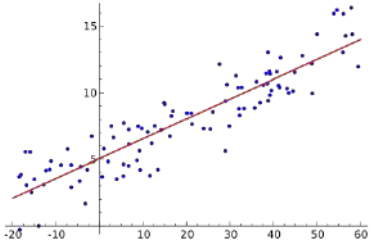


Regresión lineal

El planteamiento de mínimos cuadrados (que dio origen al modelo de regresión lineal) fue planteado por el matemático **Carl Friedrich Gauss en el año 1809**

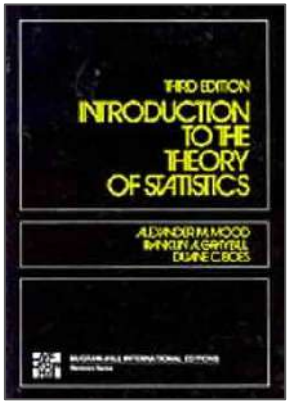


- Gauss construyó el modelo para **predecir la trayectoria de un planeta**.
- Su trabajo fue publicado en el libro "*Theoria motus corporum coelestium in sectionibus conicis solem ambientium*" y puede ser consultado aquí.

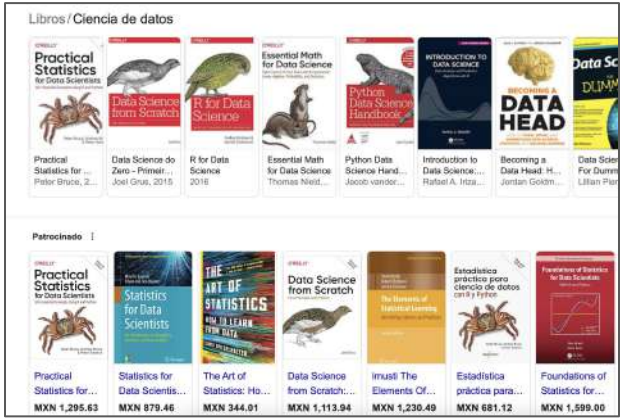


Libros Data Science / AI

Por la misma razón podrás encontrar **grandes similitudes** en el índice los libros tradicionales de estadística y los más nuevos de *data science*



Estadística

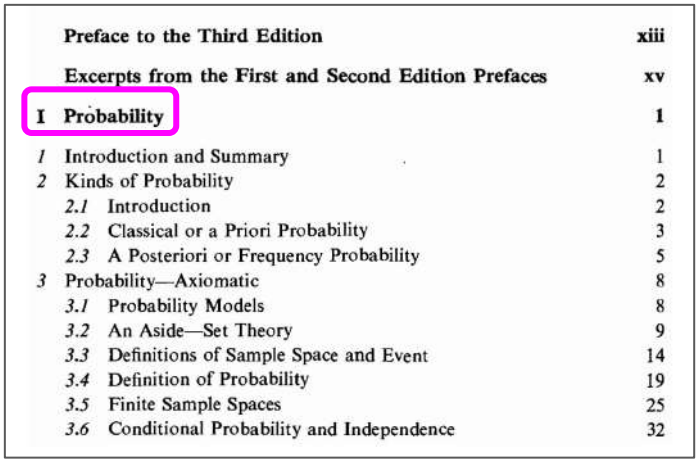


Data Science / AI

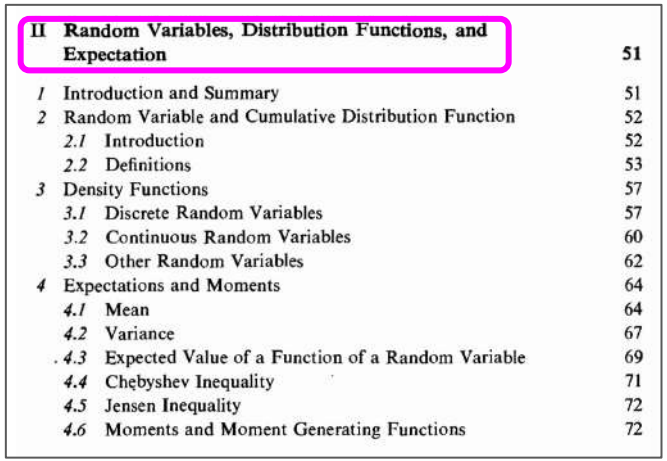
Mood - Estadística

Es el libro de referencia para aprender estadística matemática y puedes acceder libremente aquí.

Observemos el temario:



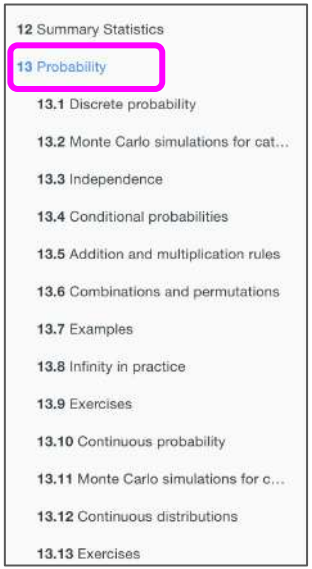
	Preface to the Third Edition	**xiii**
	Excerpts from the First and Second Edition Prefaces	**xv**
I	**Probability**	**1**
1	Introduction and Summary	1
2	Kinds of Probability	2
2.1	Introduction	2
2.2	Classical or a Priori Probability	3
2.3	A Posteriori or Frequency Probability	5
3	Probability—Axiomatic	8
3.1	Probability Models	8
3.2	An Aside—Set Theory	9
3.3	Definitions of Sample Space and Event	14
3.4	Definition of Probability	19
3.5	Finite Sample Spaces	25
3.6	Conditional Probability and Independence	32

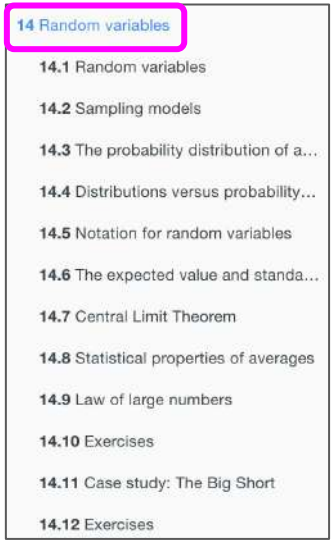


II	**Random Variables, Distribution Functions, and Expectation**	**51**
1	Introduction and Summary	51
2	Random Variable and Cumulative Distribution Function	52
2.1	Introduction	52
2.2	Definitions	53
3	Density Functions	57
3.1	Discrete Random Variables	57
3.2	Continuous Random Variables	60
3.3	Other Random Variables	62
4	Expectations and Moments	64
4.1	Mean	64
4.2	Variance	67
4.3	Expected Value of a Function of a Random Variable	69
4.4	Chębyshev Inequality	71
4.5	Jensen Inequality	72
4.6	Moments and Moment Generating Functions	72

Temario Libro *Data Science*

Ahora puedes observar el temario de este libro digital y gratuito sobre Data Science de Harvard, ingresa aquí:





*¿Qué es lo **nuevo** en el ML y AI respecto a la Estadística?*



AI y ML

Actualmente, estos campos aportan o utilizan elementos que no existían con anterioridad:

- **Capacidad computacional** (cómputo en la nube) + internet
- Variedad de datos
- **Implementación de nuevos algoritmos** que dependen fuertemente de la capacidad de cómputo (**redes neuronales**)
- Productos novedosos
- **Herramientas de uso general, sin importar la formación técnica** (ChatGPT, Claude, etc)

Introducción R

Clase 1
ML y análisis de datos

ITAM

Todos los algoritmos del curso serán implementados en R



Hoy aprenderemos a **instalarlo** y algunas **funciones básicas**



R para Ciencia de Datos

En esta sesión vamos a instalar un par de herramientas y a aprender conceptos básicos sobre su funcionamiento:

- R
- R Studio

R para ML

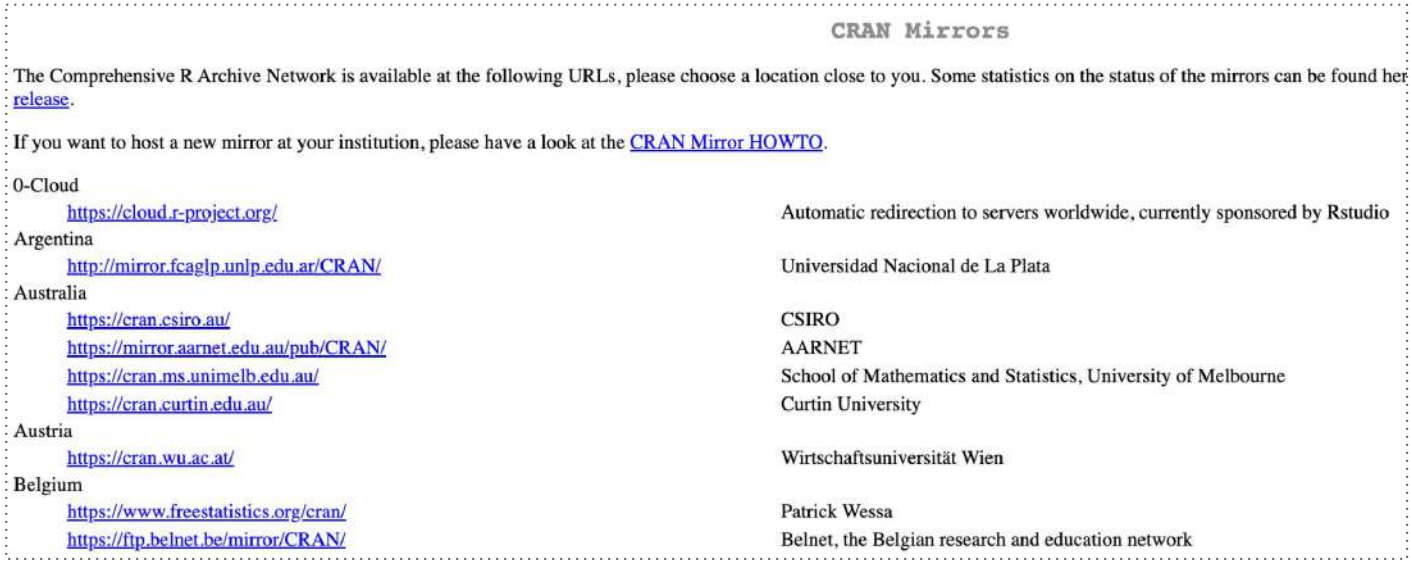
El primer paso será instalar R:

- Es una de las herramientas **más populares** para estadística y análisis de de información
- Su uso estuvo extendido principalmente en la comunidad académica
- Puedes utilizar de forma **gratuita**
- Descarga



R para ML

¿Cómo se **distribuye** R?



CRAN Mirrors

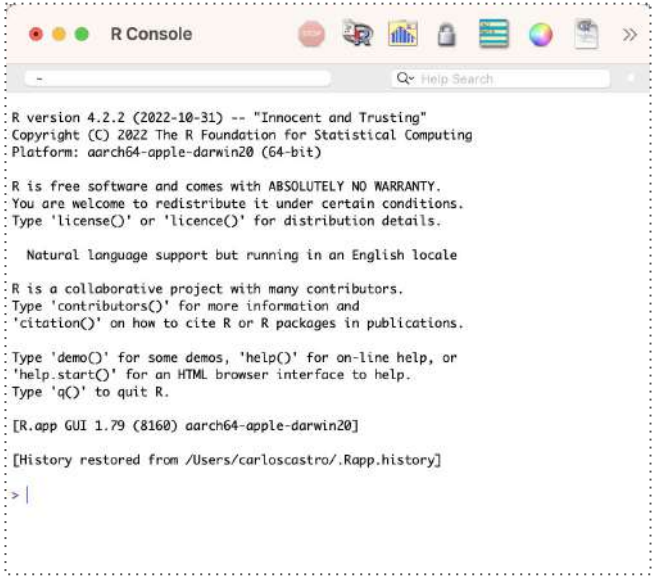
The Comprehensive R Archive Network is available at the following URLs, please choose a location close to you. Some statistics on the status of the mirrors can be found her
release.

If you want to host a new mirror at your institution, please have a look at the CRAN Mirror HOWTO.

0-Cloud	
https://cloud.r-project.org/	Automatic redirection to servers worldwide, currently sponsored by Rstudio
Argentina	
http://mirror.fcaglp.unlp.edu.ar/CRAN/	Universidad Nacional de La Plata
Australia	
https://cran.csiro.au/	CSIRO
https://mirror.aarnet.edu.au/pub/CRAN/	AARNET
https://cran.ms.unimelb.edu.au/	School of Mathematics and Statistics, University of Melbourne
https://cran.curtin.edu.au/	Curtin University
Austria	
https://cran.wu.ac.at/	Wirtschaftsuniversität Wien
Belgium	
https://www.freestatistics.org/cran/	Patrick Wessa
https://ftp.belnet.be/mirror/CRAN/	Belnet, the Belgian research and education network

R para ML

Abre la consola de R, **¿qué puedes notar?**



La consola es útil para hacer operaciones y código,

no es muy amigable para desarrollar código (variables, paquetes, gráfica, etc)



Por esta razón existe **RStudio**



RStudio

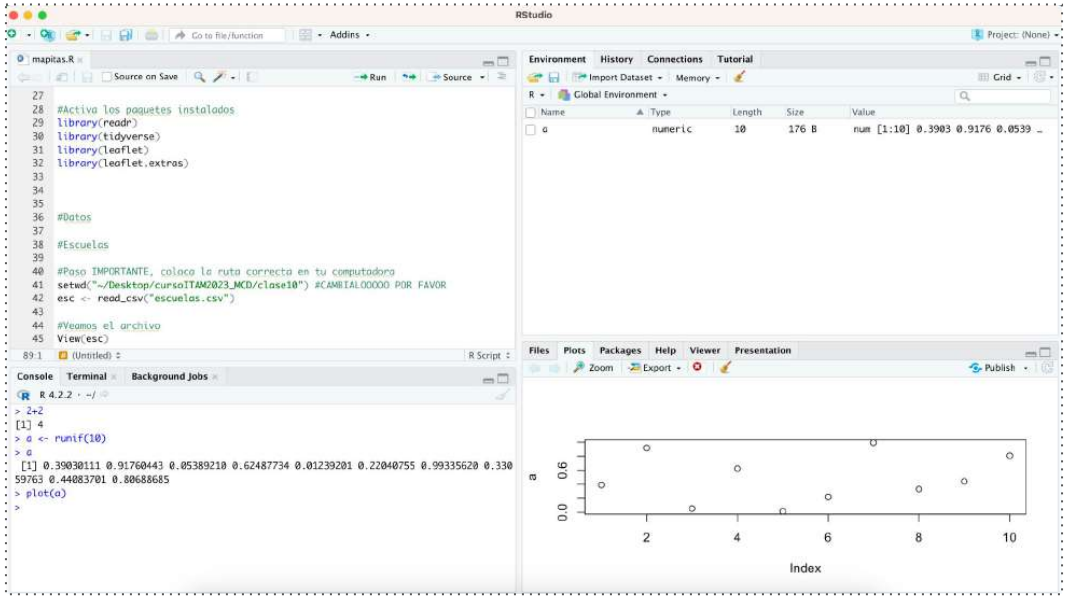
El segundo paso consiste en instalar **R Studio**:

- De igual forma, se puede descargar y utilizar **gratuitamente**
- Descarga aquí
- Recuerda que R debe estar instalado **previamente**



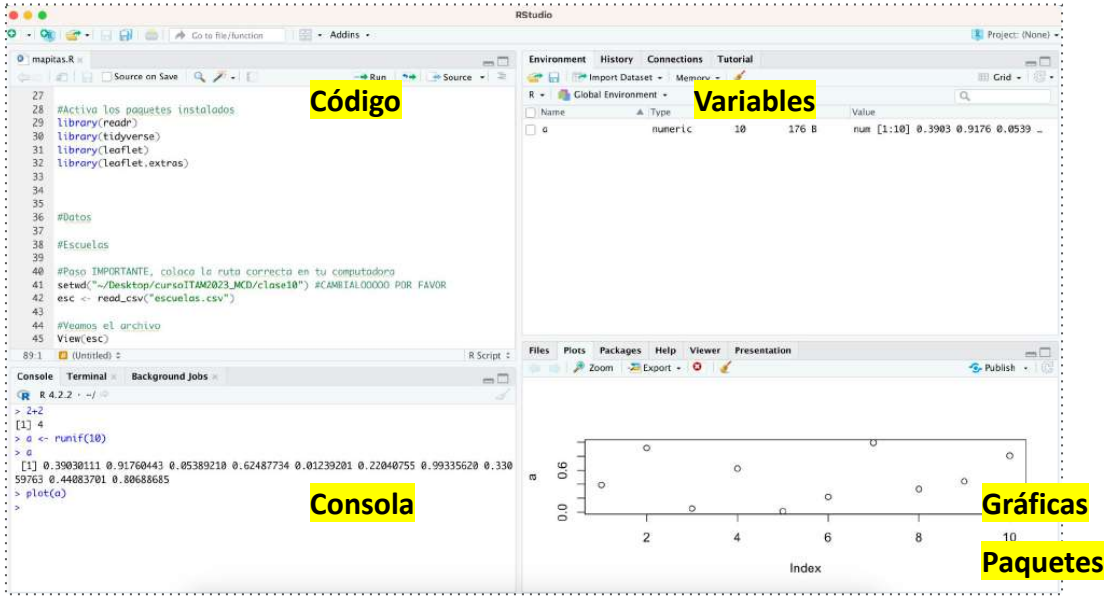
RStudio

Consola de R Studio, **¿qué puedes notar?**



RStudio

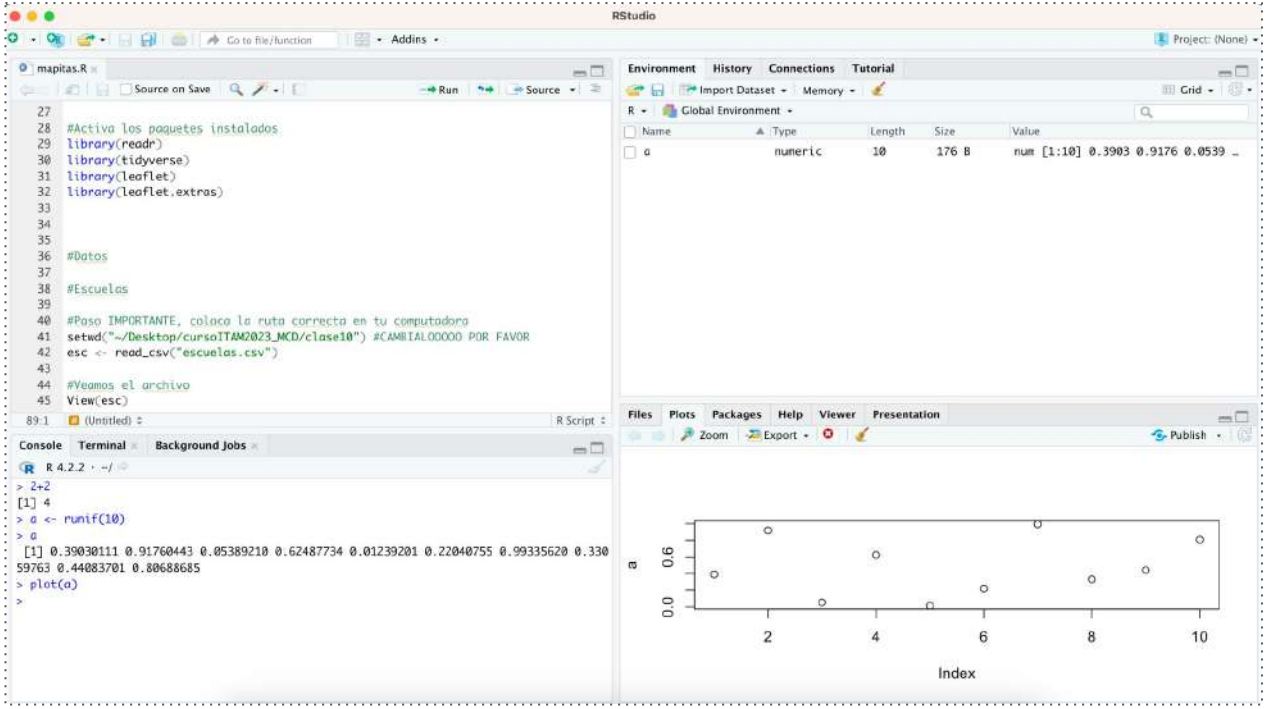
Consola de R Studio, **¿qué puedes notar?**



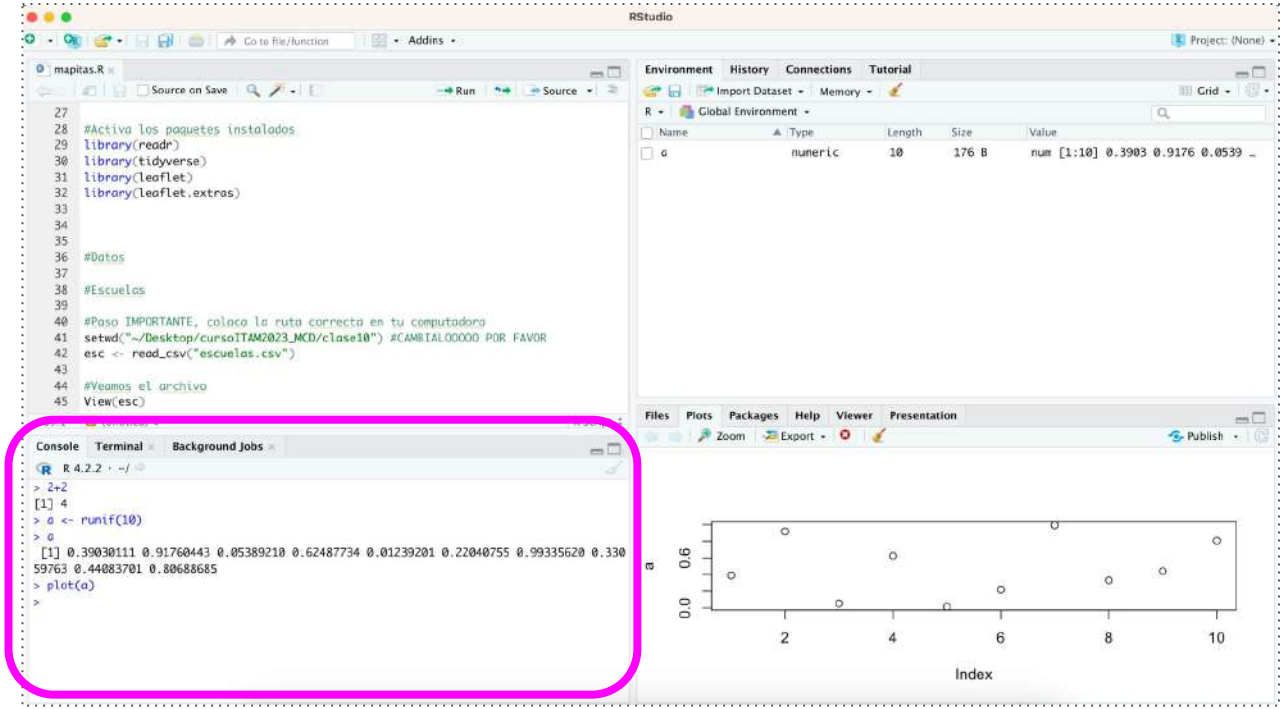
¿En dónde queda la **consola inicial** de R?



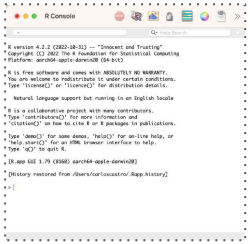
RStudio

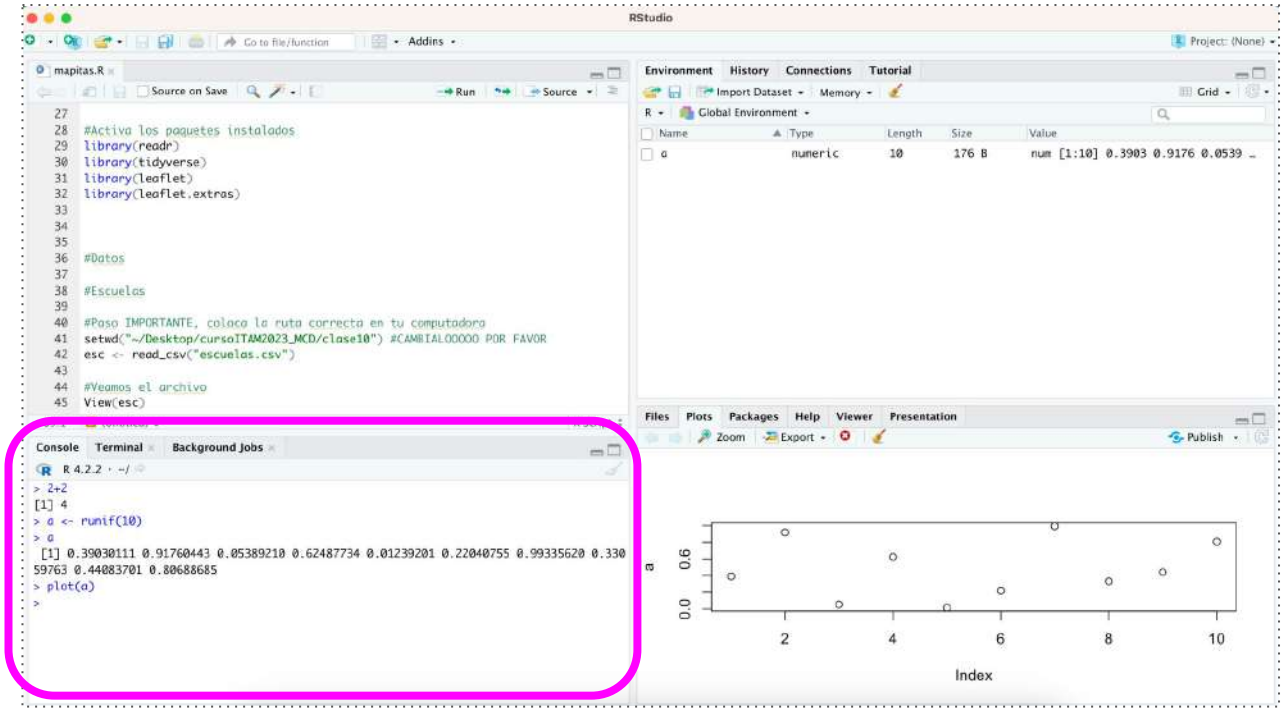

RStudio
mapitas.R
Source on Save
Run
Source
#Activa los paquetes instalados
library(readr)
library(tidyverse)
library(leaflet)
library(leaflet.extras)
#Datos
#Escuelas
#Paso IMPORTANTE, coloca la ruta correcta en tu computadora
setwd("~/Desktop/cursoITAM2023_MCD/clase10") #CAMBIALOOOOO POR FAVOR
esc <- read_csv("escuelas.csv")
#Veamos el archivo
View(esc)
Console
Terminal
Background Jobs
R 4.2.2
> 2+2
[1] 4
> a <- runif(10)
> a
[1] 0.39030111 0.91760443 0.05389210 0.62487734 0.01239201 0.22040755 0.99335620 0.33059763 0.44083701 0.80688685
> plot(a)
Environment
History
Connections
Tutorial
Import Dataset
Memory
Global Environment
Name
Type
Length
Size
Value
a
numeric
10
176 B
num [1:10] 0.3903 0.9176 0.0539 …
Files
Plots
Packages
Help
Viewer
Presentation
Zoom
Export
Publish
a
0.0
0.6
2
4
6
8
10
Index

RStudio


RStudio
mapitas.R
#Activa los paquetes instalados
library(readr)
library(tidyverse)
library(leaflet)
library(leaflet.extras)
#Datos
#Escuelas
#Paso IMPORTANTE, coloca la ruta correcta en tu computadora
setwd("~/Desktop/cursoITAM2023_MCD/clase10") #CAMBIALOOOOO POR FAVOR
esc <- read_csv("escuelas.csv")
#Veamos el archivo
View(esc)
Environment
History
Connections
Tutorial
Name
Type
Length
Size
Value
a
numeric
10
176 B
num [1:10] 0.3903 0.9176 0.0539 …
Console
Terminal
Background Jobs
> 2+2
[1] 4
> a <- runif(10)
> a
[1] 0.39030111 0.91760443 0.05389210 0.62487734 0.01239201 0.22040755 0.99335620 0.33059763 0.44083701 0.80688685
> plot(a)
Files
Plots
Packages
Help
Viewer
Presentation
Zoom
Export
Publish
a
0.0
0.6
2
4
6
8
10
Index

RStudio


R Console
R version 4.2.2 (2022-10-31) -- "Innocent and Trusting"
Copyright (C) 2022 The R Foundation for Statistical Computing
Platform: aarch64-apple-darwin20 (64-bit)
R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.
Natural language support but running in an English locale
R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.
Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.
[R.app GUI 1.79 (8360) aarch64-apple-darwin20]
[History restored from /Users/carlosastro/.Rapp.history]


RStudio
mapitas.R
Source on Save
Run
Source
#Activa los paquetes instalados
library(readr)
library(tidyverse)
library(leaflet)
library(leaflet.extras)
#Datos
#Escuelas
#Paso IMPORTANTE, coloca la ruta correcta en tu computadora
setwd("~/Desktop/cursoITAM2023_MCD/clase10") #CAMBIALOOOOO POR FAVOR
esc <- read_csv("escuelas.csv")
#Veamos el archivo
View(esc)
Environment
History
Connections
Tutorial
Import Dataset
Memory
Global Environment
Name
Type
Length
Size
Value
a
numeric
10
176 B
num [1:10] 0.3903 0.9176 0.0539 …
Console
Terminal
Background Jobs
R 4.2.2 · ~/
> 2+2
[1] 4
> a <- runif(10)
> a
[1] 0.39030111 0.91760443 0.05389210 0.62487734 0.01239201 0.22040755 0.99335620 0.33059763 0.44083701 0.80688685
> plot(a)
Files
Plots
Packages
Help
Viewer
Presentation
Zoom
Export
Publish
a
0.0
0.6
2
4
6
8
10
Index

Revisemos el código Clase1.R



RStudio

¿Por qué estudiar R?

- Utilizarlo es más **sencillo** de lo que se piensa
- Nos sirve para correr algoritmos (sin caer en la **narrativa esotérica**)
- Es ampliamente utilizado ahora para **AI y ML**
- Es una excelente **herramienta de visualización**
- Muy probablemente los *data scientist* con los que interactúas lo utilizan (o Python o ambos)
- **Es gratis**

Por favor, estudia este **curso**