Introducción a *ML* y algoritmos de IA

Machine Learning

Problemas de clasificación

Clase 2

ML y análisis de datos

ITAM

Problema de clasificación

¿Cómo podrías determinar si una vivienda está en **San Francisco o Nueva York**, con base en sus características?





Machine learning

¿Cuáles crees que sean las **principales diferencias** entre ambos lugares?



Viviendas en San Francisco







Viviendas en NY







NYC - SFO

Si nos dieran **nuevas fotografías** de otras viviendas y nos piden **determinar de dónde son...**





¿Qué **tipo** de problema ML sería? **¿Clasificación o regresión?**



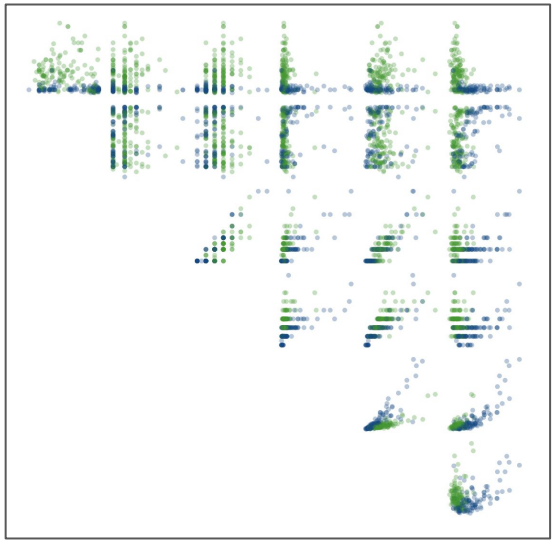
Es un problema de clasificación pues queremos

predecir la **etiqueta o clase (NY o SFO)** de una observación



Ejercicio

Abre la base de datos ***nyc_sfo_deptos.xlsx***



Ejercicio

Toma unos minutos y revisa con atención todas las pestañas, en particular la **Base de Datos y Diccionario de datos**

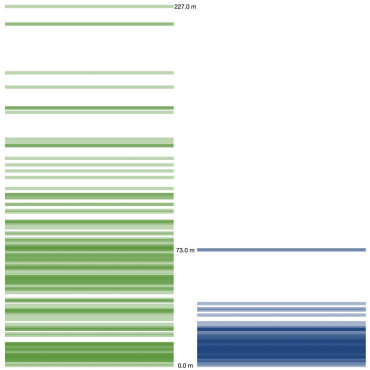
in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation
0	2	1	999000	1960	1000	999	10
0	2	2	2750000	2006	1418	1939	0
0	2	2	1350000	1900	2150	628	9
0	1	1	629000	1903	500	1258	9
0	0	1	439000	1930	500	878	10
0	0	1	439000	1930	500	878	10
0	1	1	475000	1920	500	950	10
0	1	1	975000	1930	900	1083	10
0	1	1	975000	1930	900	1083	12
0	2	1	1895000	1921	1000	1895	12
0	3	3	2095000	1926	2200	952	4
0	1	1	999000	1982	784	1274	5
0	1	1	999000	1982	784	1274	5
0	1	1	1249000	1987	826	1512	3
0	0	1	1110000	2008	698	1590	5
0	2	2	2059500	2008	1373	1500	5
0	2	2	2000000	1928	1200	1667	10
0	1	1	715000	1903	557	1284	3
0	2	2	2498000	2005	1260	1983	2
0	2	1.5	2650000	1915	2500	1060	5
0	2	2	3450000	1900	1850	1865	9
0	1	1	3105000	2016	1108	2802	10
0	4	5	13750000	2016	3699	3717	10
0	2	2	1185000	1900	1000	1185	4
0	1	2	1699000	1900	1500	1133	5
0	1	1	1195000	1900	1093	1093	6
0	1	1	450000	1920	500	900	10

Ejercicio

Revisemos la pestaña **Análisis_Variables**:

Elevación	
Etiquetas de fila	**Promedio de elevation**
0	13.50446429
1	61.8619403
Total general	**39.84552846**

Baños	
Etiquetas de fila	**Promedio de bath**
0	1.819196429
1	1.977985075
Total general	**1.905691057**



Ejercicio

Nota que hay un par de columnas incompletas en la pestaña **Base de Datos**, ¿qué son?

Opción Algoritmo 1	Diferencia
0	No
1	Sí
1	Sí
0	No
0	No
0	No
0	No
0	No
0	No
0	No
1	Sí



Ejercicio

¿Cuántos casos clasifica correctamente?

casos_correctos / casos_total

x / 492



Ejercicio

¿Cuántos casos clasifica correctamente?

casos_correctos / casos_total

325 / 492



Ejercicio

Toma **10 minutos** para producir en **Excel** una **regla de clasificación** que determine si un departamento **está en SFO o NY**



Ejercicio

¿Qué tal funciona tu algoritmo, **clasifica correctamente**?

¿Cómo medirías su **eficiencia**?



Ejercicio

¿Cuántos casos clasifica correctamente?

casos_correctos / casos_total

x / 492



La métrica anterior se llama ***accuracy*** y es una de las **más utilizadas en ML clasificación**

Accuracy:

Indep. de la clase (NY o SFO), ¿qué **porcentaje** de registros están **correctamente clasificados**?

¿Qué **variable** te parece la **más importante para clasificar**?



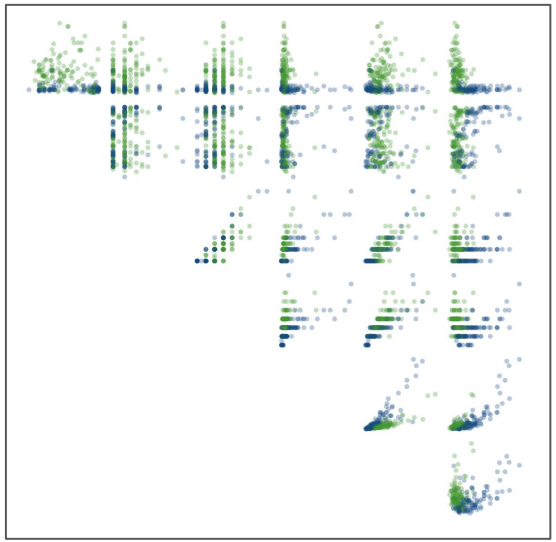
Ejercicio

Para observar el funcionamiento de un algoritmo de clasificación, podemos utilizar siguiente recurso.

Let's say you had to determine whether a home is in **San Francisco** or in **New York**. In machine learning terms, categorizing data points is a **classification** task.

Since San Francisco is relatively hilly, the elevation of a home may be a good way to distinguish the two cities.

Based on the home-elevation data to the right, you could argue that a home above 73 meters should be **classified** as one in San Francisco.



Machine Learning

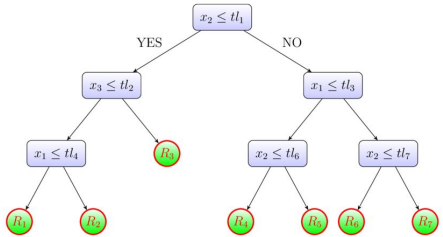
Un algoritmo eficiente es capaz de producir **más y mejores reglas para clasificar los datos**.

Y generalmente es **más preciso** que un humano



Algoritmos en R

Abre el código **Clase2. R**



Preguntas R

Calcula en R y responde lo siguiente:

- ¿Cuál es el **accuracy** de este modelo en R?
- ¿Es **mejor** este modelo en R o tu mejor modelo (Excel)?
- ¿Qué tan bien predice los depas de **NY**? ¿Cómo lo calcularías?
- ¿Qué tan bien predice los depas de **SFO**? ¿Cómo lo calcularías?



Preguntas R

Calcula en R y responde lo siguiente:

- ¿Cuál es el **accuracy** de este modelo en R?
- ¿Es **mejor** este modelo en R o tu mejor modelo (Excel)?
- ¿Qué tan bien predice los depas de **NY**? ¿Cómo lo calcularías?
- ¿Qué tan bien predice los depas de **SFO**? ¿Cómo lo calcularías?

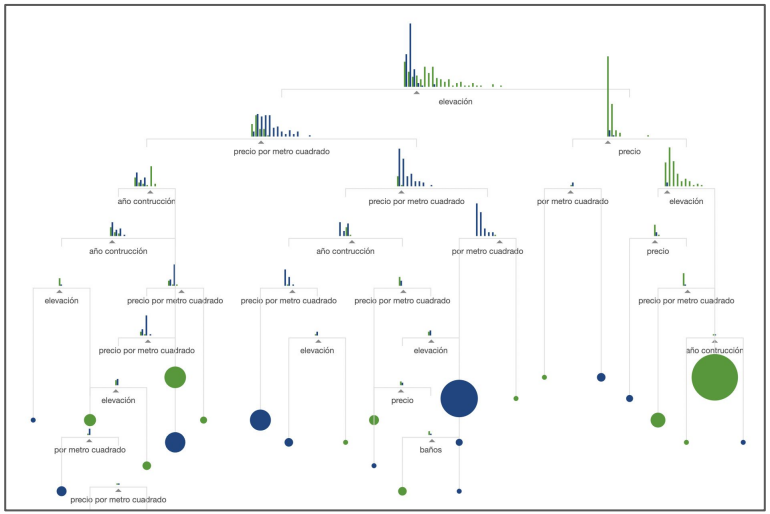


¿Por qué nos **conviene** utilizar un **algoritmo**?



¿Por qué usamos algoritmo?

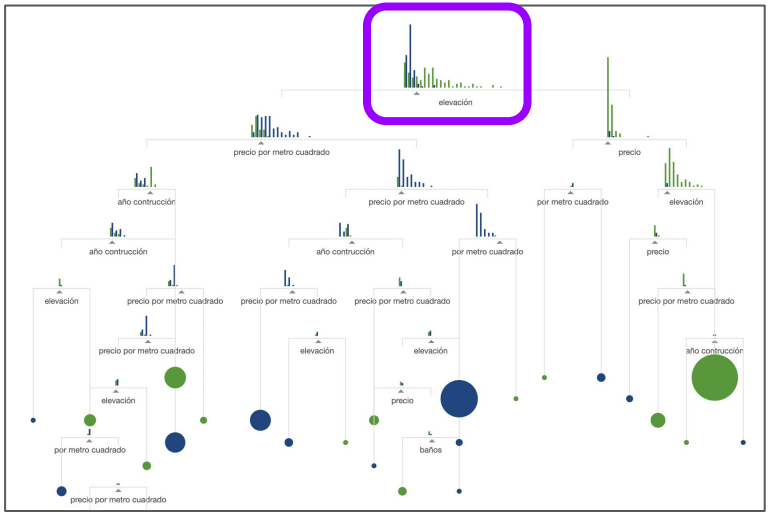
Imagina el **tiempo y precisión que te llevaría explorar todas las siguientes opciones**:



¿Por qué usamos algoritmo?

Imagina el **tiempo y precisión que te llevaría explorar todas las siguientes opciones**:

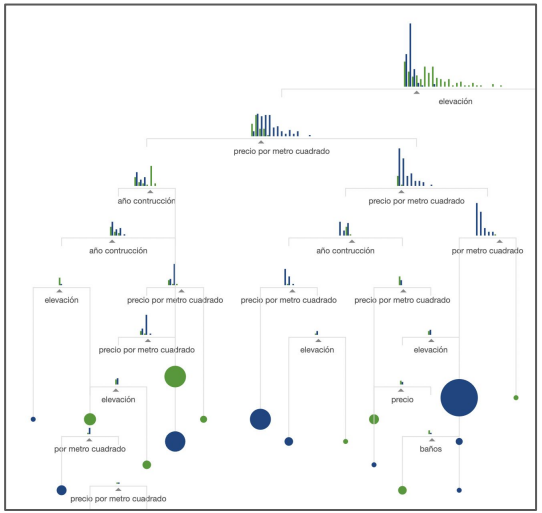
- **¿Qué pasa si la rama inicia es el precio en lugar de la elevación?**



¿Por qué usamos algoritmo?

Imagina el **tiempo y precisión que te llevaría explorar todas las siguientes opciones**:

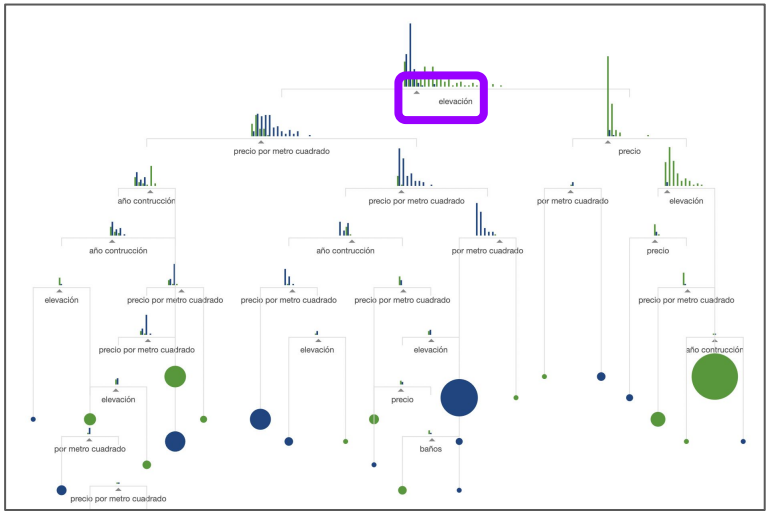
- ¿Qué pasa si la rama inicia es el precio en lugar de la elevación?
- **¿El árbol cambia si usamos sólo las primeras 4 variables?**



¿Por qué usamos algoritmo?

Imagina el **tiempo y precisión que te llevaría explorar todas las siguientes opciones**:

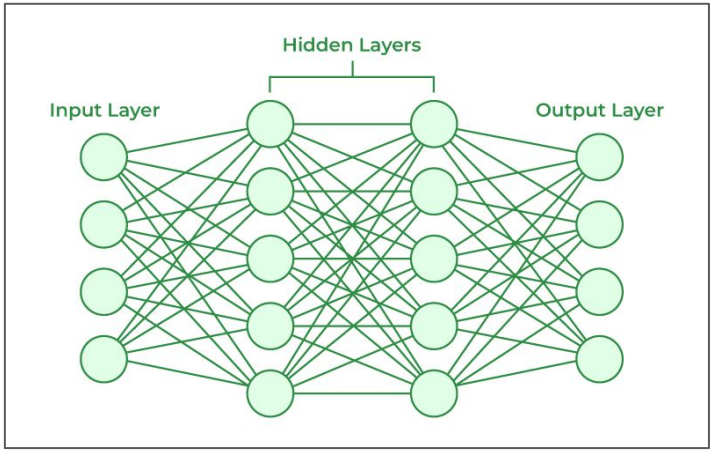
- ¿Qué pasa si la rama inicia es el precio en lugar de la elevación?
- ¿El árbol cambia si usamos sólo las primeras 4 variables?
- **¿Qué pasa sí en lugar de que la primera rama corte en 13 metros corta en 11.3 metros? ¿Mejora la predicción?**



¿Por qué usamos algoritmo?

Imagina el **tiempo y precisión que te llevaría explorar todas las siguientes opciones**:

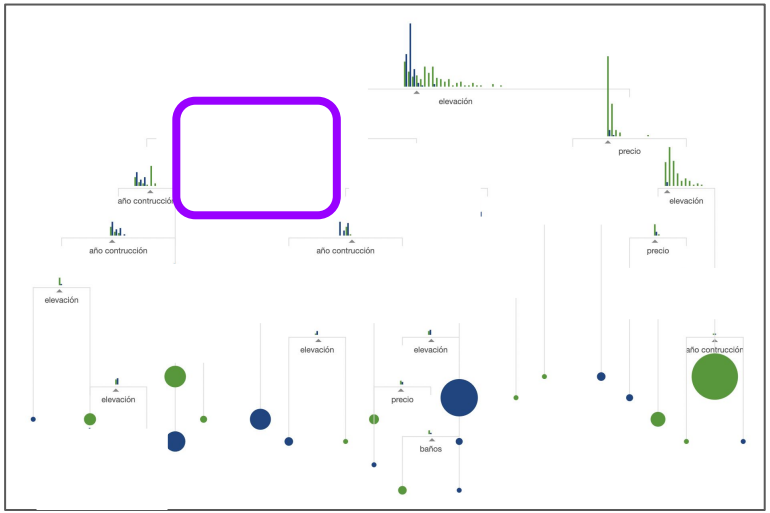
- ¿Qué pasa si la rama inicia es el precio en lugar de la elevación?
- ¿El árbol cambia si usamos sólo las primeras 4 variables?
- ¿Qué pasa sí en lugar de que la primera rama corte en 13 metros corta en 11.3 metros? ¿Mejora la predicción?
- **¿Qué pasa si en lugar de utilizar un árbol de clasificación utilizo una red neuronal?**



¿Por qué usamos algoritmo?

Imagina el **tiempo y precisión que te llevaría explorar todas las siguientes opciones**:

- ¿Qué pasa si la rama inicia es el precio en lugar de la elevación?
- ¿El árbol cambia si usamos sólo las primeras 4 variables?
- ¿Qué pasa sí en lugar de que la primera rama corte en 13 metros corta en 11.3 metros? ¿Mejora la predicción?
- ¿Qué pasa si en lugar de utilizar un árbol de clasificación utilizo una red neuronal?
- **¿Tengo alguna ventaja si excluyo la variable precio por metro cuadrado?**



Imagina el **tiempo y precisión que te llevaría** explorar todas las preguntas anteriores...

¿Por qué usamos algoritmos?

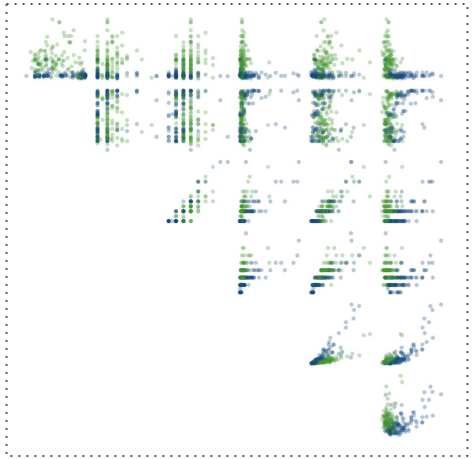
Recordemos:

- Quisiéramos obtener una **respuesta barata, rápida, automatizada,** y con suficiente precisió.

- Quisiéramos **superar el desempeño actual** de los expertos o de reglas simples utilizando datos

Otros aspectos a estudiar

- ¿Qué características tienen las variables?
- ¿Con qué variable recomendarías hacer la primera clasificación? ¿Por qué?
- **¿Qué características debe tener una buena variable para clasificar?**



Machine Learning

Nota importante: Antes de implementar cualquier algoritmo o análisis, los datos ya deben estar: **limpios, ordenados y entendidos completamente** (diccionarios de datos).

En otro caso, las predicciones pueden ser **incorrectas**

Machine Learning

Los algoritmos de ML consumen y aprenden directamente de la BD

Machine Learning

Algoritmos de clasificación

Clase 2

ML y análisis de datos

ITAM

Ya aprendimos a identificar problemas de clasificación y

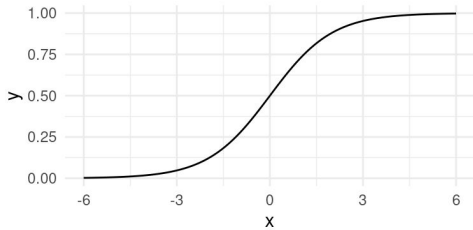
revisamos un algoritmo para estudiarlos: **árbol de decisión**

Existen **distintos algoritmos** que se pueden

implementar para problemas de clasificación

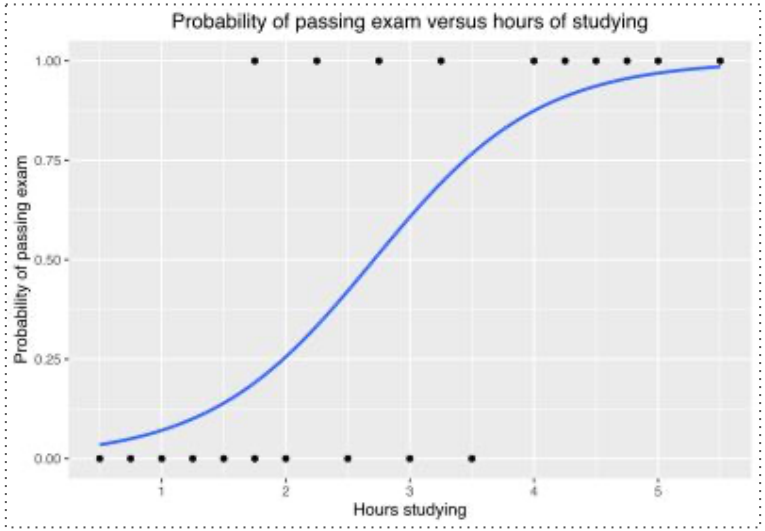


Regresión Logística



Regresión logística

Es un tipo de modelo de regresión que ayuda a predecir una variable categórica **(dos clases, por ejemplo: positivo o negativo)** con base en variables independientes de una BD



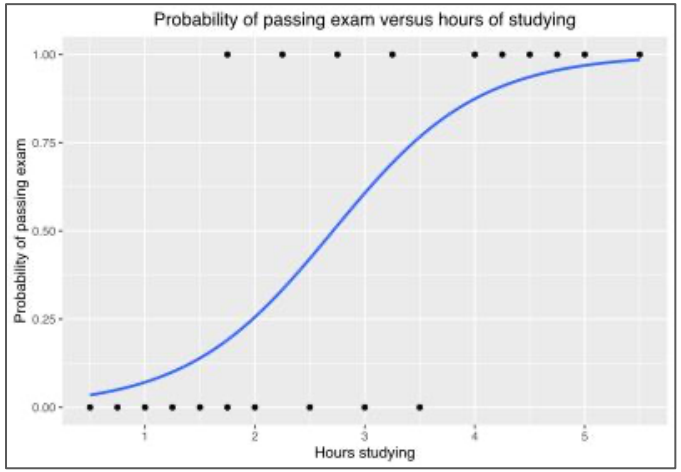
Regresión logística

Una regresión logística es en realidad un MLG con **liga** Binomial (función enlace logit)

Distribution	Support of distribution	Typical uses	Link name	Link function, $\mathbf{X}\boldsymbol{\beta} = g(\mu)$	Mean function
Normal	real: $(-\infty, +\infty)$	Linear-response data	Identity	$\mathbf{X}\boldsymbol{\beta} = \mu$	$\mu = \mathbf{X}\boldsymbol{\beta}$
Exponential	real: $(0, +\infty)$	Exponential-response data, scale parameters	Negative inverse	$\mathbf{X}\boldsymbol{\beta} = -\mu^{-1}$	$\mu = -(\mathbf{X}\boldsymbol{\beta})^{-1}$
Gamma					
Inverse Gaussian	real: $(0, +\infty)$		Inverse squared	$\mathbf{X}\boldsymbol{\beta} = \mu^{-2}$	$\mu = (\mathbf{X}\boldsymbol{\beta})^{-1/2}$
Poisson	integer: $0, 1, 2, \ldots$	count of occurrences in fixed amount of time/space	Log	$\mathbf{X}\boldsymbol{\beta} = \ln(\mu)$	$\mu = \exp(\mathbf{X}\boldsymbol{\beta})$
Bernoulli	integer: $\{0, 1\}$	outcome of single yes/no occurrence		$\mathbf{X}\boldsymbol{\beta} = \ln\left(\frac{\mu}{1-\mu}\right)$	
Binomial	integer: $0, 1, \ldots, N$	count of # of "yes" occurrences out of N yes/no occurrences		$\mathbf{X}\boldsymbol{\beta} = \ln\left(\frac{\mu}{n-\mu}\right)$	

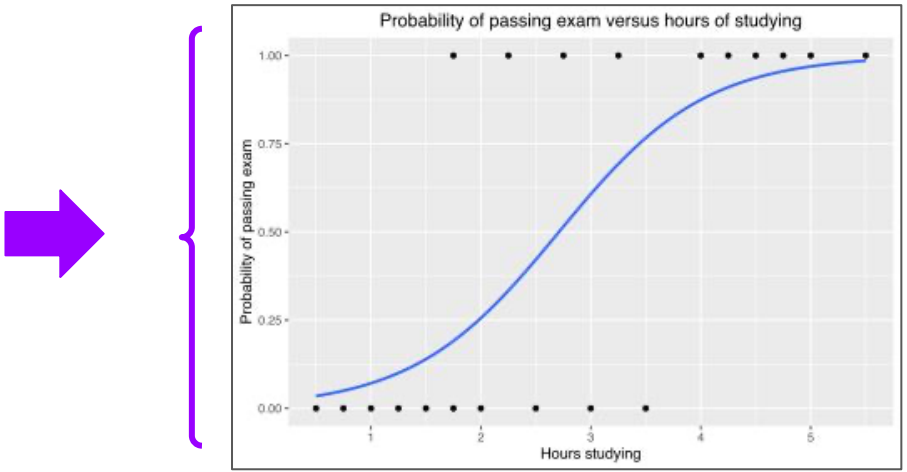
Regresión logística

En lugar de predecir una variable numérica como en la regresión, se busca predecir dos clases **positivo o negativo, crédito o no crédito**, etc.



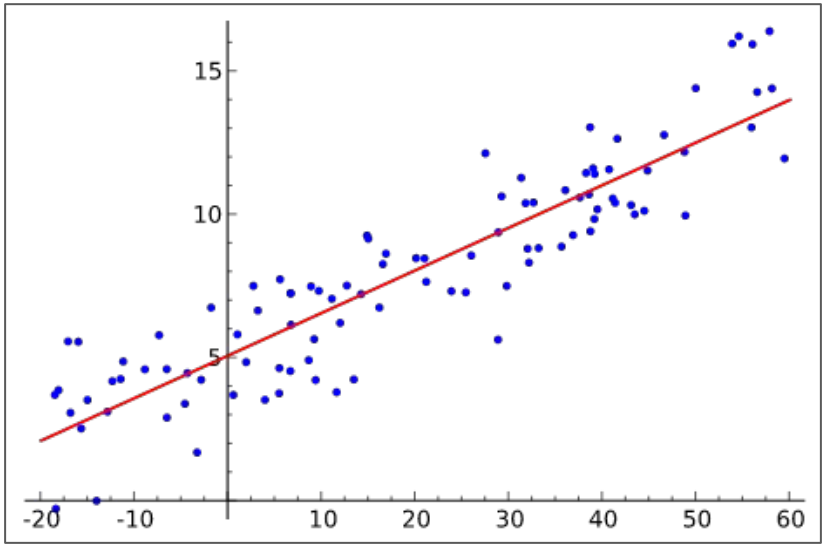
Regresión logística

En lugar de predecir una variable numérica como en la regresión, se busca predecir dos clases **positivo o negativo, crédito o no crédito**, etc.



Regresión logística

Tiene fundamento en el **análisis de regresión lineal** clásico (predecir una valor numérico)



Regresión logística

El **análisis de regresión clásico** utiliza la siguiente ecuación:

$$p_\beta(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

- Observa que la predicción puede ser negativa, positiva o cero, **puede tomar cualquier valor**.

Regresión logística

El modelo clásico de **análisis de regresión clásico** es adaptado por una función **h()**

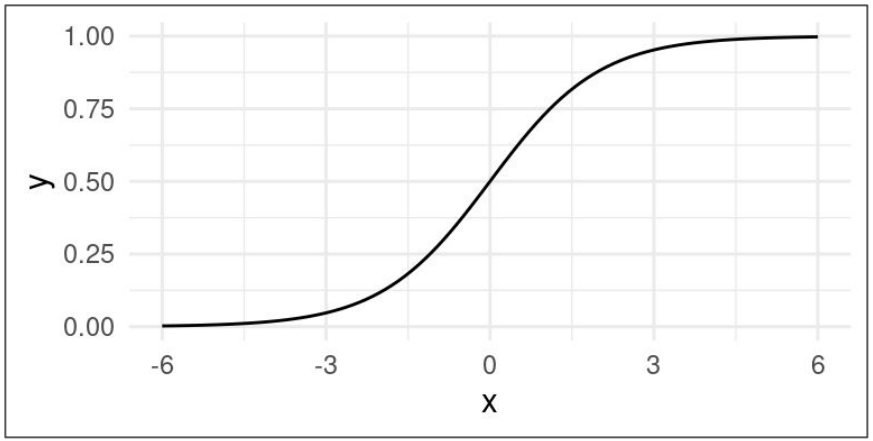
$$p_\beta(x) = h(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p)$$

- h es tal que toma **valores entre 0 y 1** (como probabilidad).
- h es una función **creciente y diferenciable**.

Regresión logística

- La función **h(x)** que utiliza este tipo de regresión se conoce como **función logística** y tiene la siguiente forma y ecuación:

$$h(x) = \frac{e^x}{1 + e^x}$$



Regresión logística

En términos matemáticos, el problema de r**egresión logística** se define de la siguiente forma:

$$p_1(x) = p_1(x;\beta) = h(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p)$$

y

$$p_0(x) = p_0(x;\beta) = 1 - p_1(x;\beta),$$

donde $\beta = (\beta_0, \beta_1, \beta_2, \cdots, \beta_p)$.

Nota: **no es necesario profundizar en las ecuaciones anteriores**,

sólo se ofrecen como referencia para quien prefiera conocer los fundamentos.

Comparación

Por ejemplo, en un **problema clásico de regresión lineal**, se tiene la siguiente BD con algunas variables y el objetivo es pronosticar la glucosa (**numérica**) con base en las demás variables:

	npreg	glu	bp	skin	bmi	ped	age
	<int>	<int>	<int>	<int>	<dbl>	<dbl>	<int>
1	5	86	68	28	30.2	0.364	24
2	7	195	70	33	25.1	0.163	55
3	5	77	82	41	35.8	0.156	35
4	0	165	76	43	47.9	0.259	26
5	0	107	60	25	26.4	0.133	23
6	5	97	76	27	35.6	0.378	52
7	3	83	58	31	34.3	0.336	25
8	1	193	50	16	25.9	0.655	24
9	3	142	80	15	32.4	0.2	63
10	2	128	78	37	43.3	1.22	31

Comparación

En regresión logística, podríamos estimar si un paciente tiene o no diabetes (**categórica**) con base en las demás variables:

	npreg	glu	bp	skin	bmi	ped	age	type
	<int>	<int>	<int>	<int>	<dbl>	<dbl>	<int>	<fct>
1	5	86	68	28	30.2	0.364	24	No
2	7	195	70	33	25.1	0.163	55	Yes
3	5	77	82	41	35.8	0.156	35	No
4	0	165	76	43	47.9	0.259	26	No
5	0	107	60	25	26.4	0.133	23	No
6	5	97	76	27	35.6	0.378	52	Yes
7	3	83	58	31	34.3	0.336	25	No
8	1	193	50	16	25.9	0.655	24	No
9	3	142	80	15	32.4	0.2	63	No
10	2	128	78	37	43.3	1.22	31	Yes

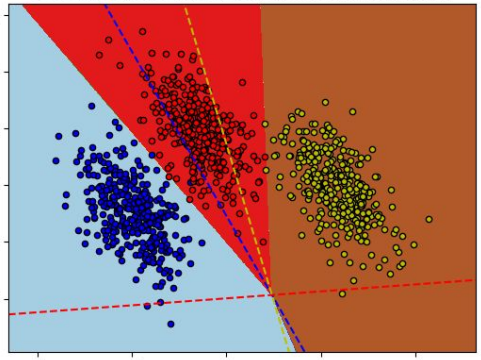
Nota: La regresión logística sirve para

problemas de ML de clasificación de 2 clase



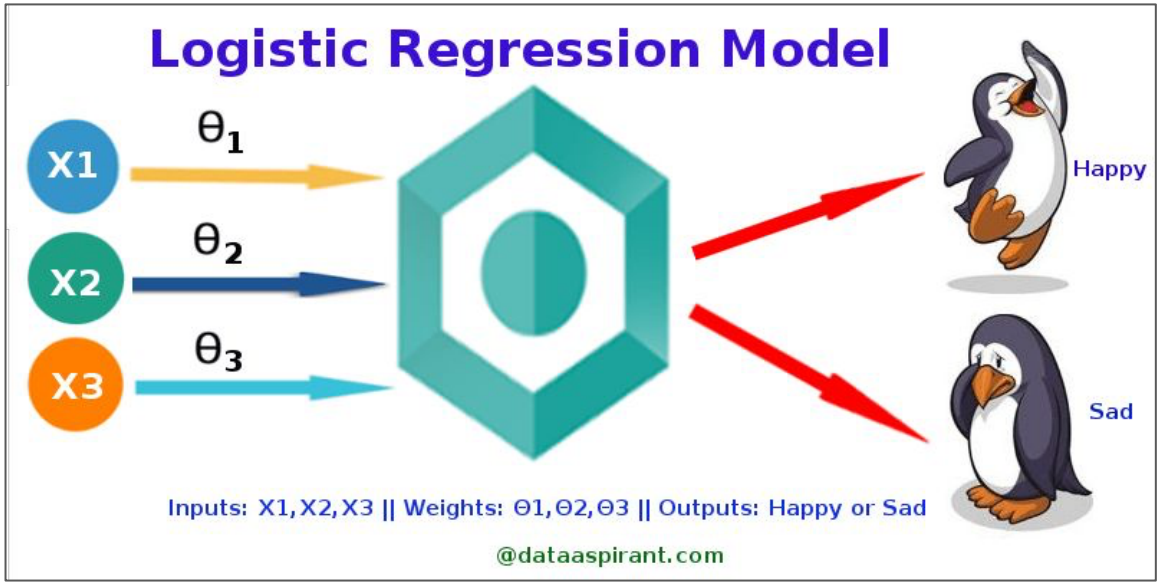
Se puede adaptar para más clases como

Regresión Multinomial Logística



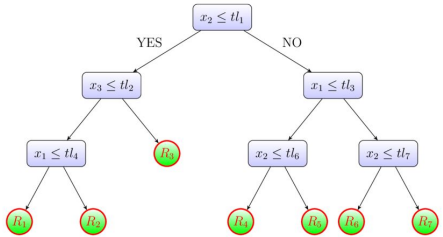
Esquema

Referencia

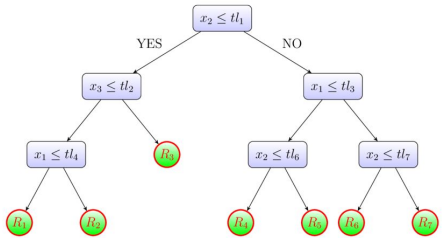


Algoritmos en R

Abre el código **Clase2. R**



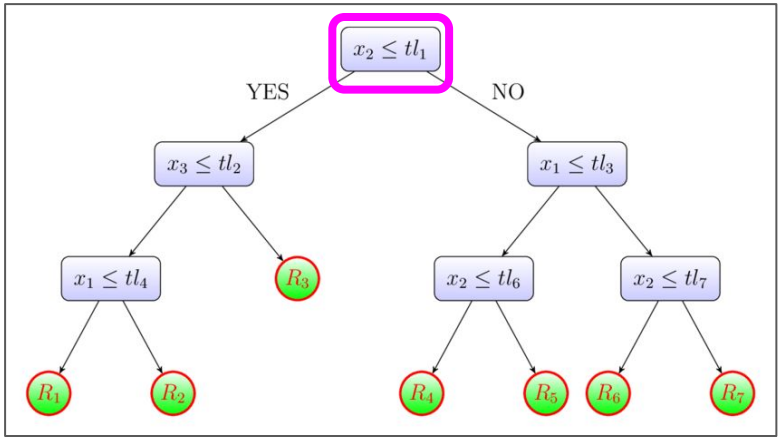
Árboles de decisión



Árboles de decisión

Es un método que permite pronosticar valores y etiquetas de nuevas observaciones a partir de datos de entrenamiento (conocimiento *a priori*). Para referencias. Referencia 2.

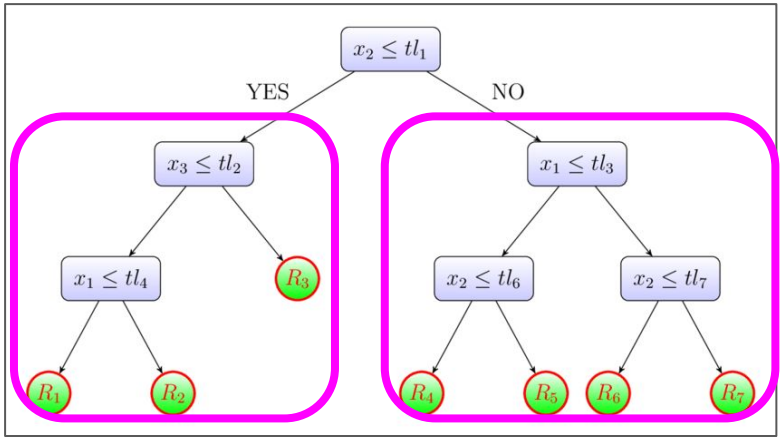
- **Empieza por una raíz o nodo inicial para tomar la primera decisión**



Árboles de decisión

Es un método que permite pronosticar valores y etiquetas de nuevas observaciones a partir de datos de entrenamiento (conocimiento *a priori*).

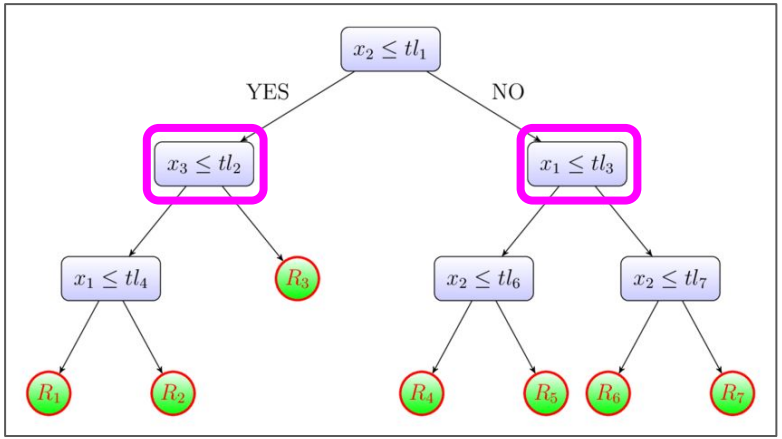
- **Rama: los distintos caminos del árbol a través de sus ramas.**



Árboles de decisión

Es un método que permite pronosticar valores y etiquetas de nuevas observaciones a partir de datos de entrenamiento (conocimiento *a priori*).

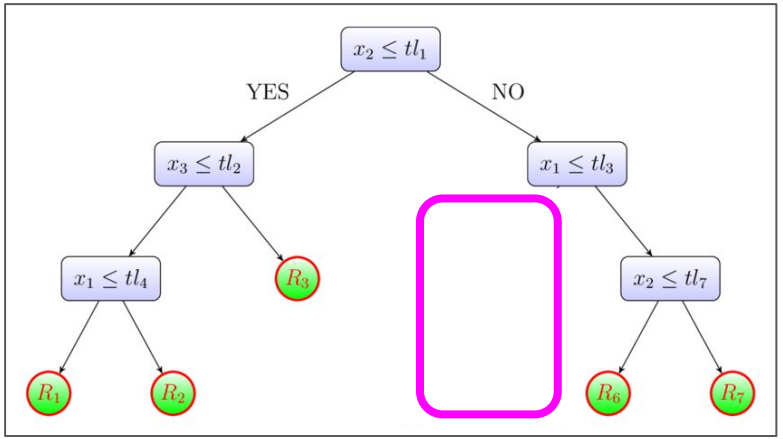
- **Podado: cuando se eliminar algunas variables del conjunto original por ser poco útiles.**



Árboles de decisión

Es un método que permite pronosticar valores y etiquetas de nuevas observaciones a partir de datos de entrenamiento (conocimiento *a priori*).

- **Podado: cuando se eliminar algunas variables del conjunto original por ser poco útiles.**



Intuitivamente, se puede pensar en **podar** una rama

con variables que **aportan poca información** o dificulte la clasificación

Por ejemplo, en una BD sobre departamentos

:
precio x m2 en pesos y precio x m2 en dólares para el mismo día

Intuitivamente, ¿sería útil incluir ambas?



En general, **nunca borramos ninguna variable** pues puede ser **marginalmente útil**

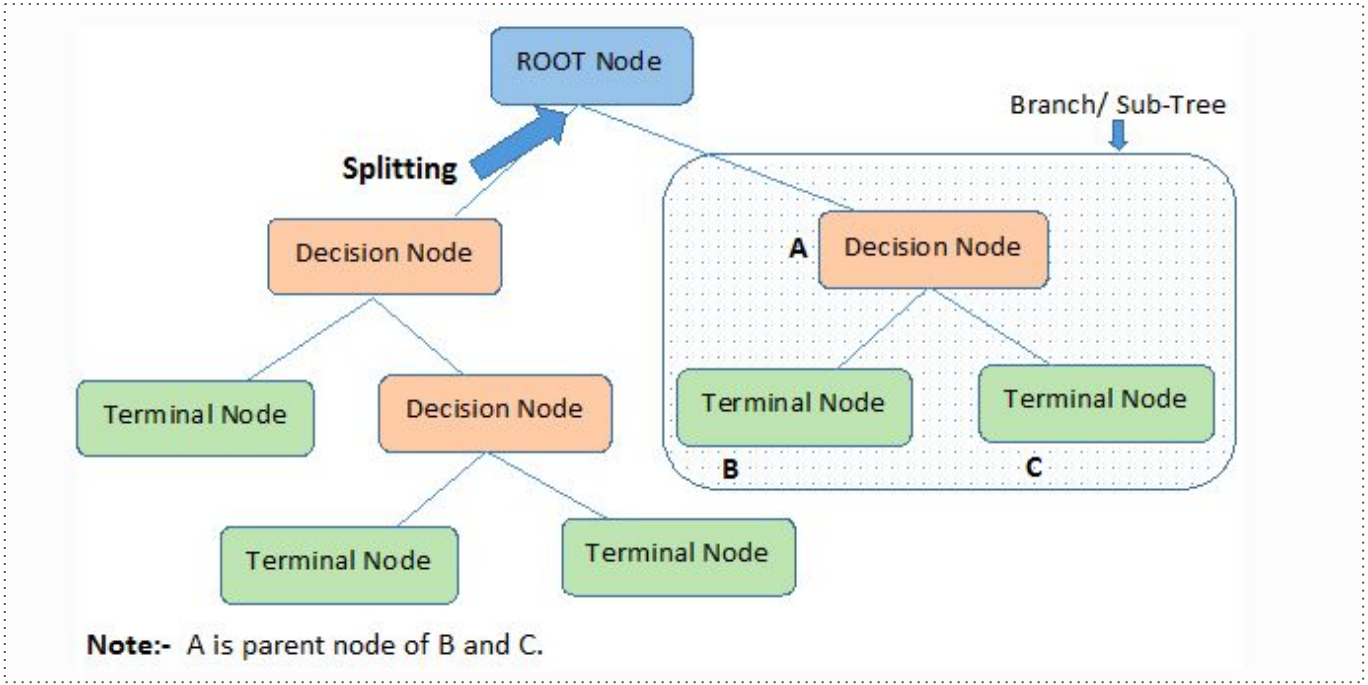


Si hay que eliminar variables por el tiempo de procesamiento o costo,

puedes hacerlo con las que ofrecen información redundante



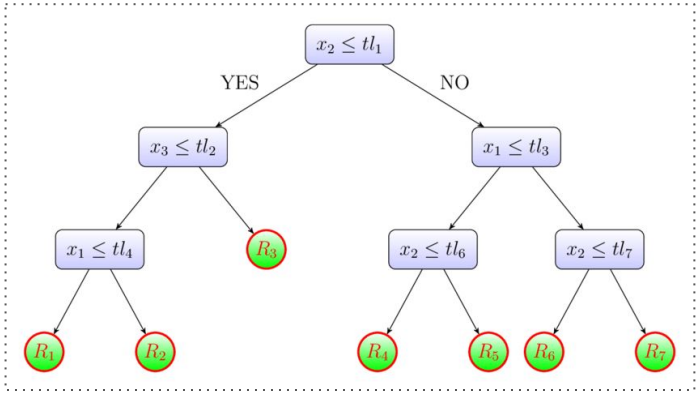
Árboles de decisión



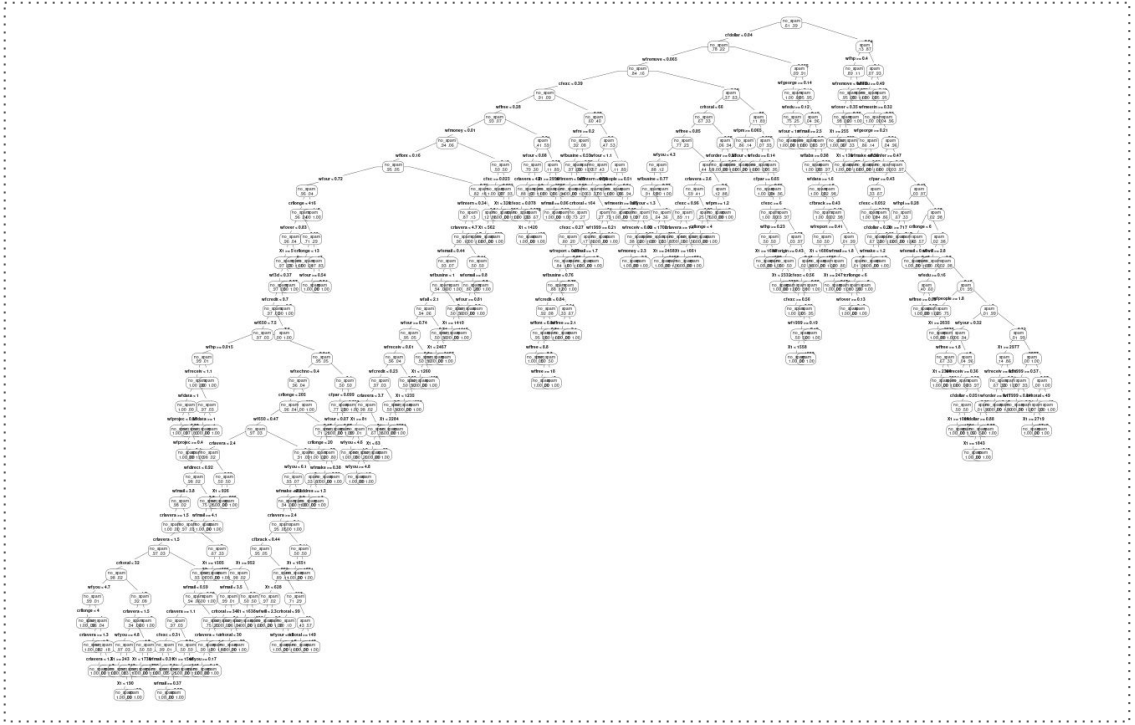
Árboles de decisión

La **complejidad de estos métodos** consiste en seleccionar un modelo respondiendo a las siguientes preguntas:

- ¿Qué **profundidad** debe tener mi árbol?
- ¿Puedo **descartar alguna variable** *a priori*?
- ¿Cuáles son las reglas de decisión o **cortes óptimos**?
- **¿Qué variable y punto de corte utilizar en cada nivel?**

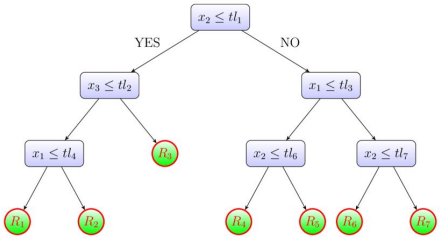


Implementación Árbol de decisión

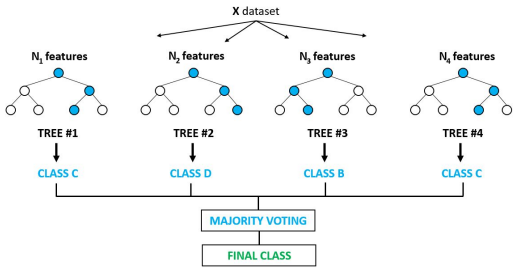


Algoritmos en R

Abre el código **Clase2. R**



Bosques Aleatorios

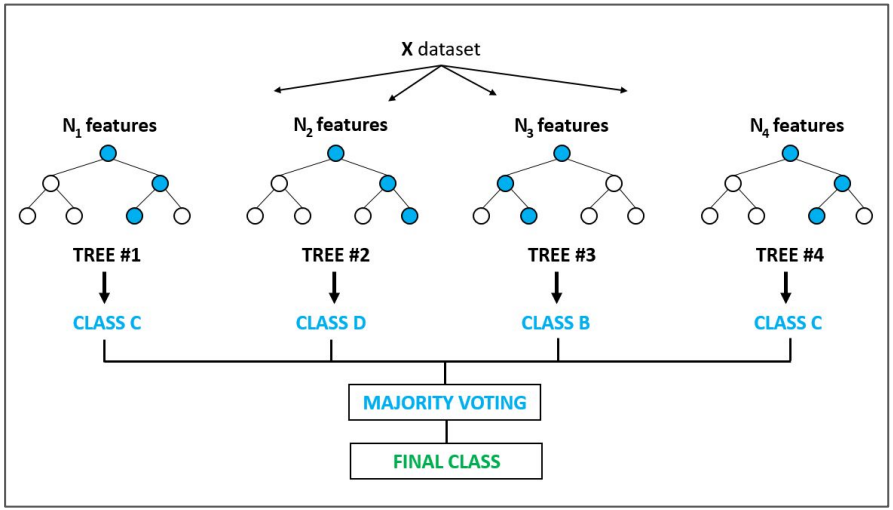


¿Qué crees que son los **bosques aleatorios**?



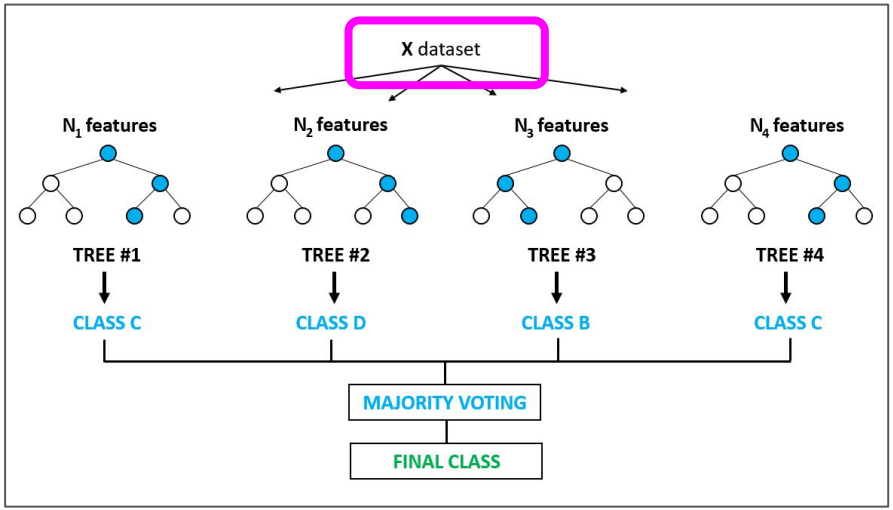
Bosques aleatorios

Se puede definir como una **colección de árboles de decisión** **que entregan una predicción considerando varios modelos, con distintos parámetros**.



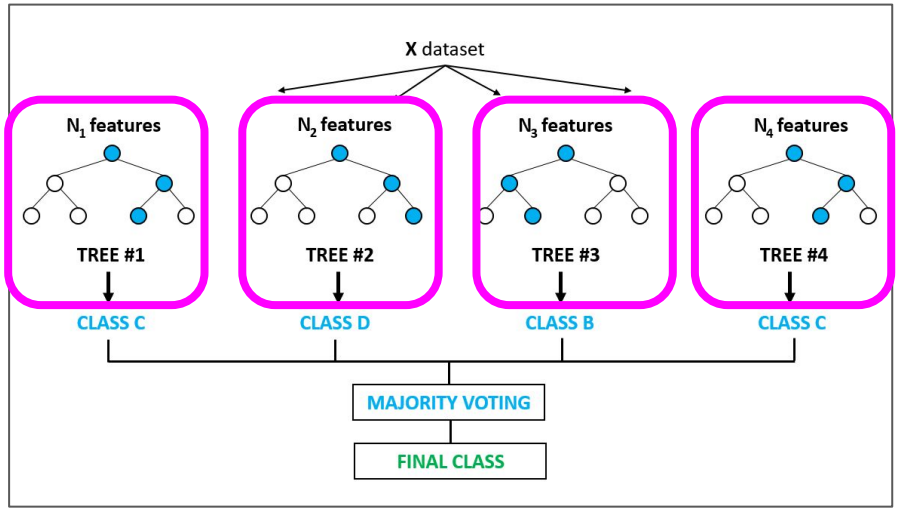
Bosques aleatorios

Mismo conjunto de datos



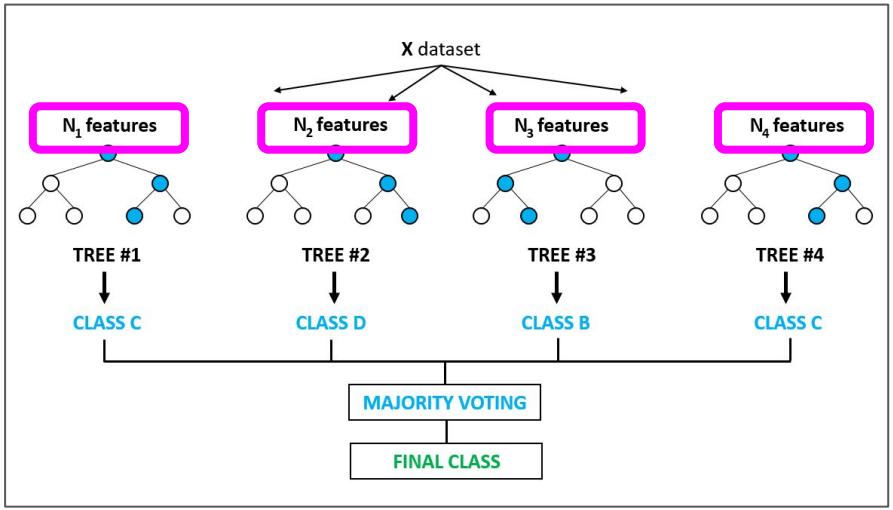
Bosques aleatorios

Distintos árboles



Bosques aleatorios

Distintos parámetros y variables



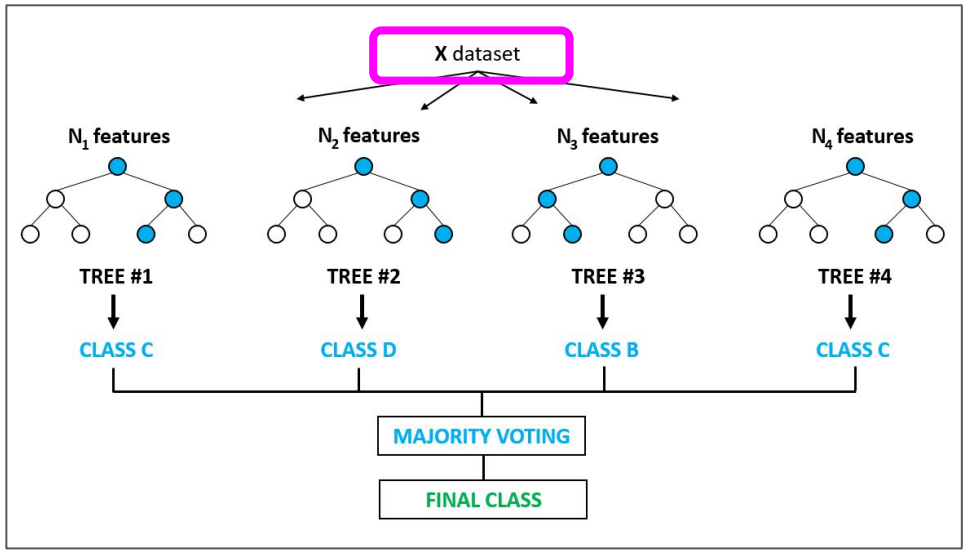
Bosques aleatorios

Distintos parámetros y variables

Pero diseñados con la misma BD

Por ejemplo:

- Distinta profundidad.
- Árboles podados.
- Distintos valores en los nodos de decisión.

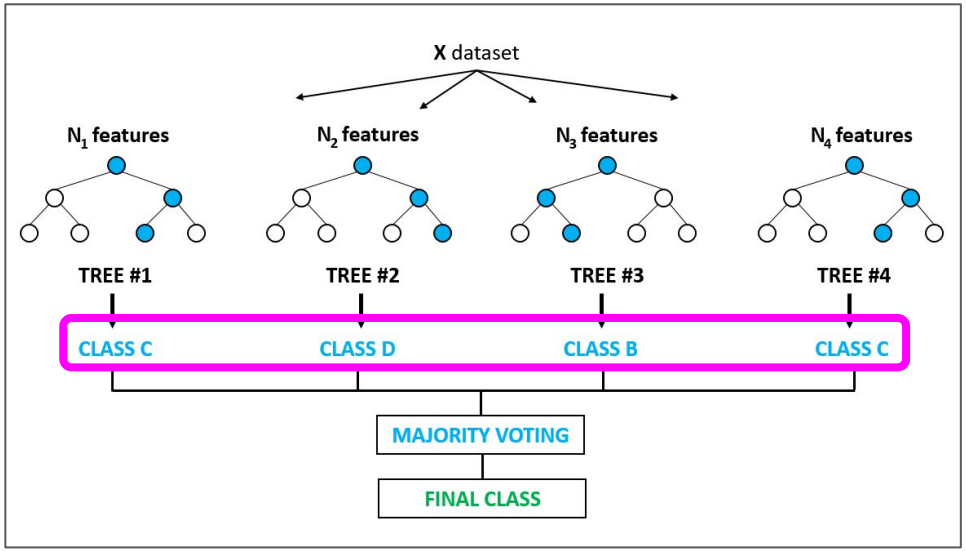


¿Cómo decidimos en un **problema de clasificación**?



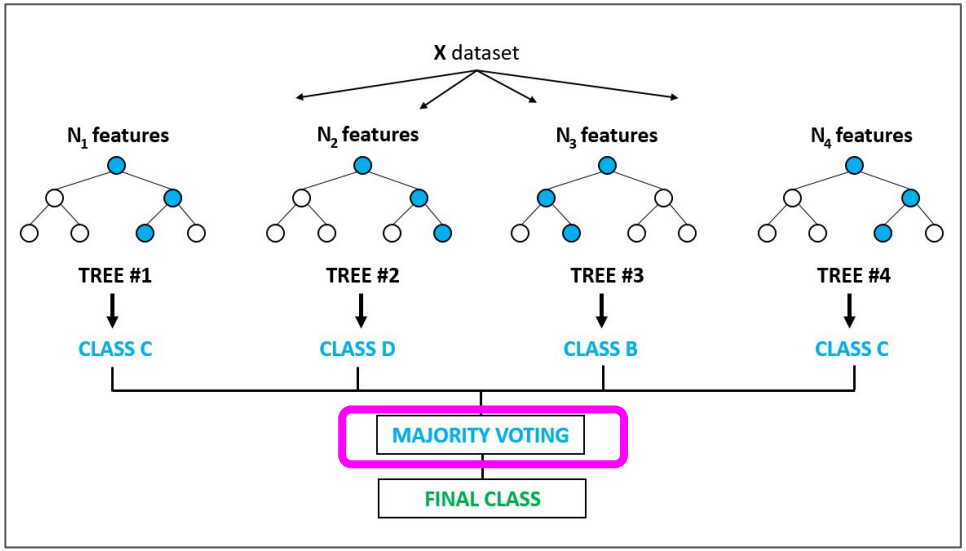
Bosques aleatorios

“Promediamos” el conocimiento (que aporta cada uno de los árboles)**.**



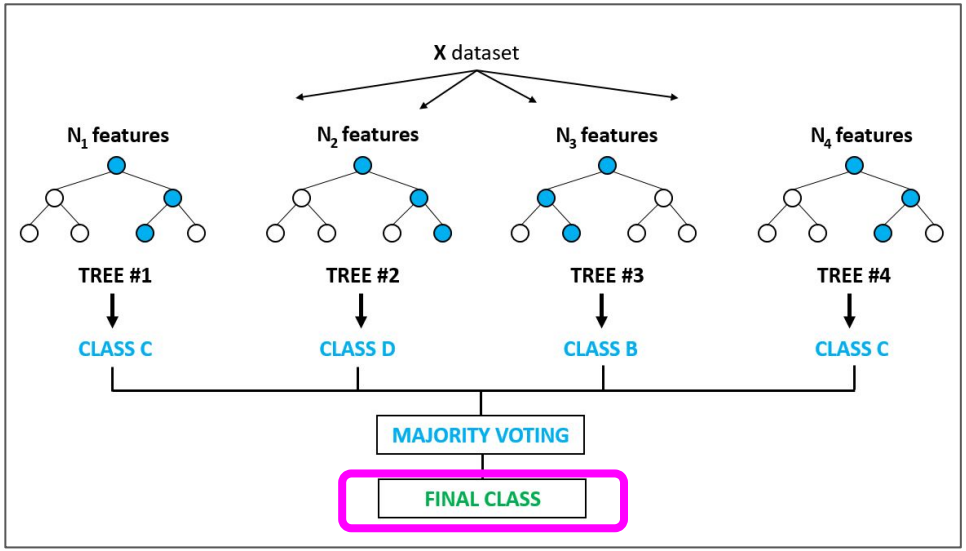
Bosques aleatorios

“Promediamos” el conocimiento (que aporta cada uno de los árboles)**.**



Bosques aleatorios

Predicción final **(clasificación)**



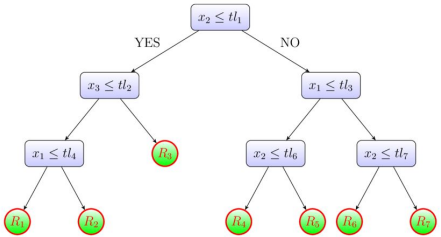
¿Qué crees que **tarde más tiempo en correr**,

un árbol de decisión o un bosque? ¿Por qué?

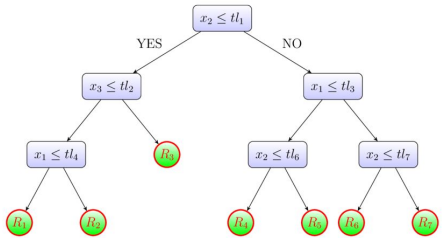


Algoritmos en R

Abre el código **Clase2. R**



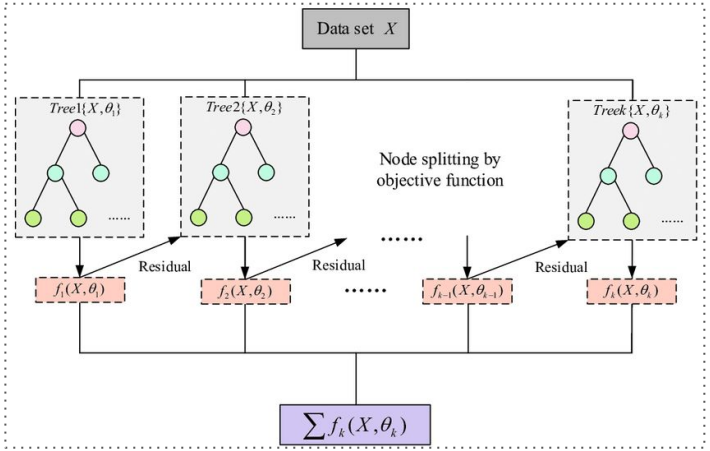
XGBoost


$x_2 \leq tl_1$
YES
NO
$x_3 \leq tl_2$
$x_1 \leq tl_3$
$x_1 \leq tl_4$
R_3
$x_2 \leq tl_6$
$x_2 \leq tl_7$
R_1
R_2
R_4
R_5
R_6
R_7

XGBoost

Algoritmo sustentado en los árboles de decisión. Este método **puede funcionar mejor** que un árbol de decisión o incluso mejor que **bosques aleatorios**:

- Es muy popular en la actualidad
- Es de fácil implementación
- Es un algoritmo que se puede **paralelizar**



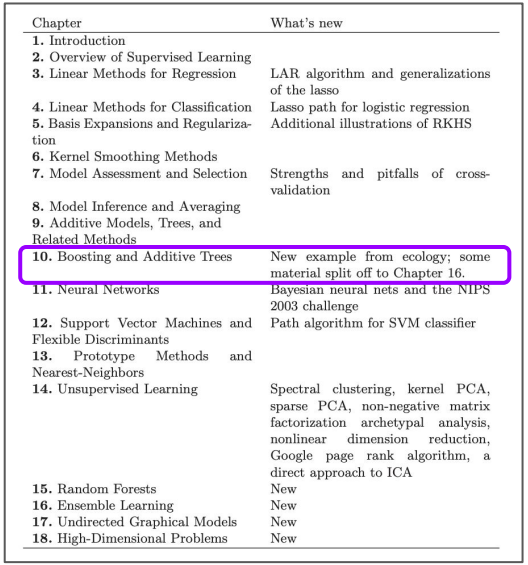
¿Conoces que significa **paralelizar** en computación?



XGBoost

Referencias **adicionales**:

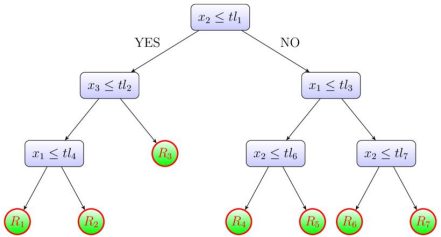
- Referencia original
- Referencia 1
- Referencia 2
- Referencia 3



Chapter	What's new
1. Introduction	
2. Overview of Supervised Learning	
3. Linear Methods for Regression	LAR algorithm and generalizations of the lasso
4. Linear Methods for Classification	Lasso path for logistic regression
5. Basis Expansions and Regularization	Additional illustrations of RKHS
6. Kernel Smoothing Methods	
7. Model Assessment and Selection	Strengths and pitfalls of cross-validation
8. Model Inference and Averaging	
9. Additive Models, Trees, and Related Methods	
10. Boosting and Additive Trees	New example from ecology; some material split off to Chapter 16.
11. Neural Networks	Bayesian neural nets and the NIPS 2003 challenge
12. Support Vector Machines and Flexible Discriminants	Path algorithm for SVM classifier
13. Prototype Methods and Nearest-Neighbors	
14. Unsupervised Learning	Spectral clustering, kernel PCA, sparse PCA, non-negative matrix factorization archetypal analysis, nonlinear dimension reduction, Google page rank algorithm, a direct approach to ICA
15. Random Forests	New
16. Ensemble Learning	New
17. Undirected Graphical Models	New
18. High-Dimensional Problems	New

Algoritmos en R

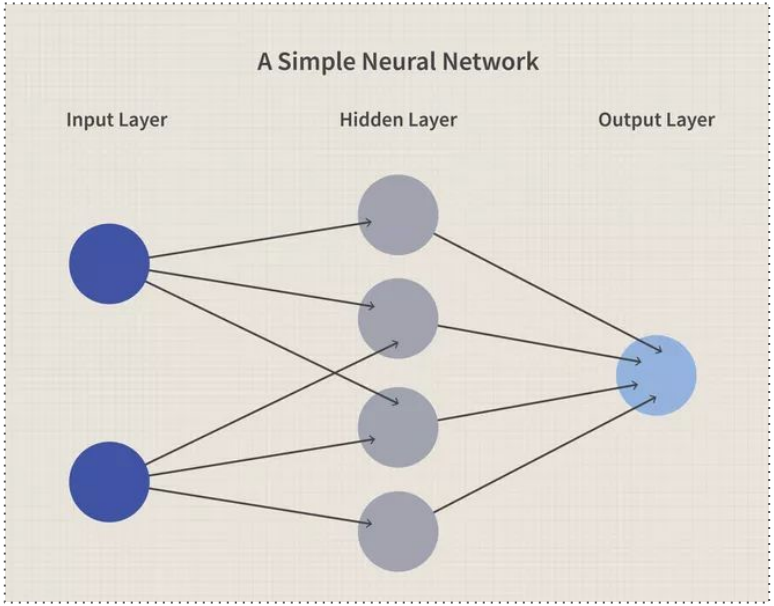
Abre el código **Clase2. R**



Redes Neuronales

Redes Neuronales

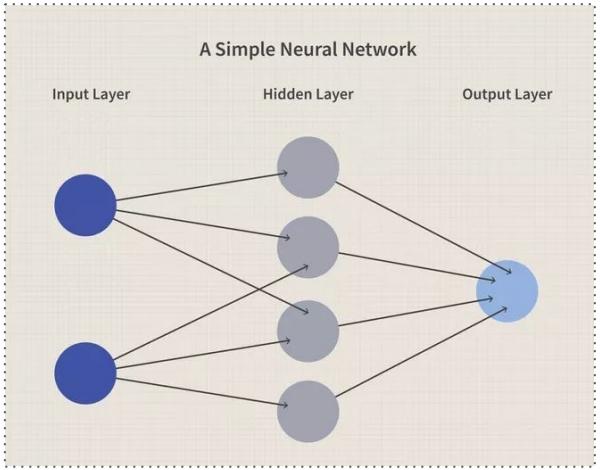
Se puede definir como una serie de **nodos** (neuronas) y **múltiples capas** que ayudan a realizar predicciones.



Redes Neuronales

Se puede definir como una serie de nodos (neuronas) y múltiples capas que ayudan a realizar predicciones.

- Este modelo es muy popular y está inspirado en el funcionamiento del cerebro
- Depende mucho del poder de procesamiento computacional (**recursos de computación**)
- **Deficiencia: es complicado entender por qué predice o clasifica de cierta forma**

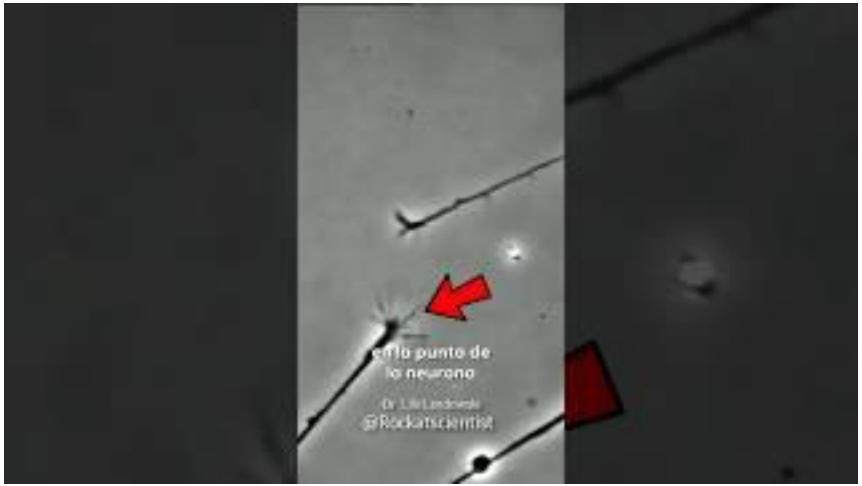


¿Por qué les dicen redes **“neuronales”**?



Neuronas en el cerebro

Conexiones e interacciones entre neuronas



Podríamos pensar que en una BD,

las **neuronas son las variables**

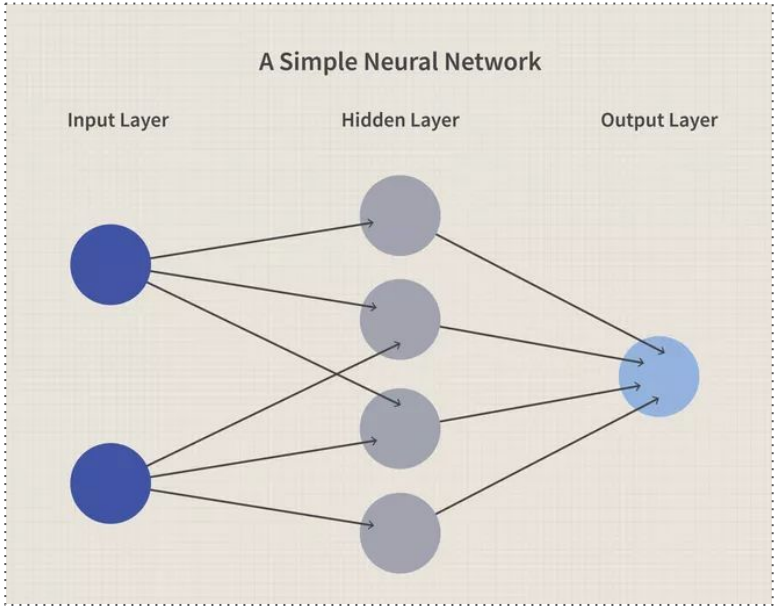
Situación inicial

BD original

in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation
0	2	1	999000	1960	1000	999	10
0	2	2	2750000	2006	1418	1939	0
0	2	2	1350000	1900	2150	628	9
0	1	1	629000	1903	500	1258	9
0	0	1	439000	1930	500	878	10
0	0	1	439000	1930	500	878	10
0	1	1	475000	1920	500	950	10
0	1	1	975000	1930	900	1083	10
0	1	1	975000	1930	900	1083	12
0	2	1	1895000	1921	1000	1895	12
0	3	3	2095000	1926	2200	952	4
0	1	1	999000	1982	784	1274	5
0	1	1	999000	1982	784	1274	5
0	1	1	1249000	1987	826	1512	3
0	0	1	1110000	2008	698	1590	5
0	2	2	2059500	2008	1373	1500	5
0	2	2	2000000	1928	1200	1667	10
0	1	1	715000	1903	557	1284	3
0	2	2	2498000	2005	1260	1983	2
0	2	1.5	2650000	1915	2500	1060	5

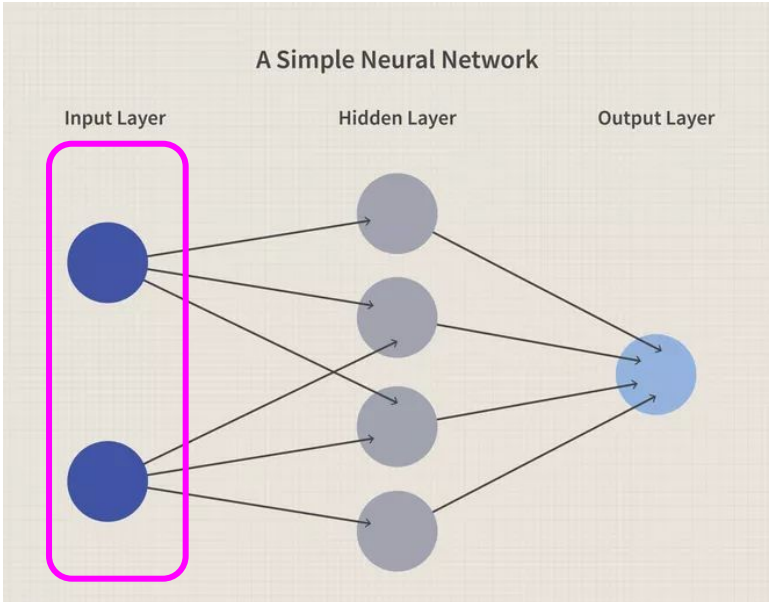
Conexiones neuronales en los datos

Interacción



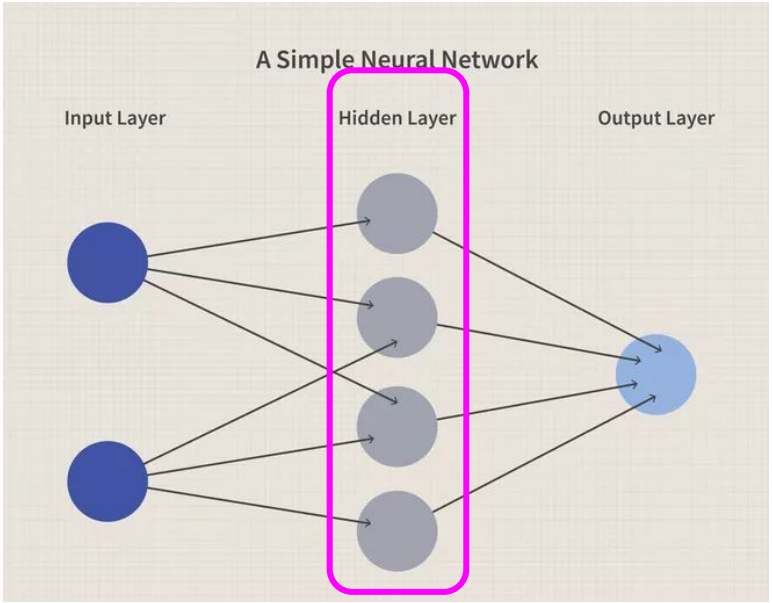
Conexiones neuronales en los datos

Datos originales



Conexiones neuronales en los datos

Interacciones y conexiones



A partir de las variables originales, se crean **nuevas variables**

Nuevas variables

in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation
0	2	1	999000	1960	1000	999	10
0	2	2	2750000	2006	1418	1939	0
0	2	2	1350000	1900	2150	628	9
0	1	1	629000	1903	500	1258	9
0	0	1	439000	1930	500	878	10
0	0	1	439000	1930	500	878	10
0	1	1	475000	1920	500	950	10
0	1	1	975000	1930	900	1083	10
0	1	1	975000	1930	900	1083	12
0	2	1	1895000	1921	1000	1895	12
0	3	3	2095000	1926	2200	952	4
0	1	1	999000	1982	784	1274	5
0	1	1	999000	1982	784	1274	5
0	1	1	1249000	1987	826	1512	3
0	0	1	1110000	2008	698	1590	5
0	2	2	2059500	2008	1373	1500	5
0	2	2	2000000	1928	1200	1667	10
0	1	1	715000	1903	557	1284	3
0	2	2	2498000	2005	1260	1983	2
0	2	1.5	2650000	1915	2500	1060	5
0	2	2	3450000	1900	1850	1865	9
0	1	1	3105000	2016	1108	2802	10
0	4	5	13750000	2016	3699	3717	10
0	2	2	1185000	1900	1000	1185	4

Nuevas variables

in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation	X1	X2	X3	X4	X5	X6
0	2	1	999000	1960	1000	999	10	1008990	992467.689	-990	115,122,331,690.00	10,475,018,292,970.00	3,767.66
0	2	2	2750000	2006	1418	1939	0	2750000	0	-1418	117,824,182,716.00	10,720,860,336,504.00	-
0	2	2	1350000	1900	2150	628	9	1355652	823326.836	-2141	111,598,179,859.00	10,154,353,801,809.00	3,029.88
0	1	1	629000	1903	500	1258	9	640322	795351.384	-491	111,774,385,858.00	10,170,387,924,537.00	2,931.55
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62
0	1	1	475000	1920	500	950	10	484500	667358.96	-490	112,772,895,870.00	10,261,242,679,930.00	2,481.76
0	1	1	975000	1930	900	1083	10	985830	1020705.84	-890	113,360,255,100.00	10,314,686,428,090.00	3,815.55
0	1	1	975000	1930	900	1083	12	987996	1224847.01	-888	113,360,255,102.00	10,314,686,428,092.00	4,578.66
0	2	1	1895000	1921	1000	1895	12	1917740	2259130.65	-988	112,831,632,255.00	10,266,586,795,308.00	8,405.59
0	3	3	2095000	1926	2200	952	4	2098808	561124.419	-2196	113,125,312,862.00	10,293,308,105,380.00	2,093.22
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06
0	1	1	1249000	1987	826	1512	3	1253536	409556.627	-823	116,708,200,350.00	10,619,317,120,251.00	1,576.20
0	0	1	1110000	2008	698	1590	5	1117950	659850.771	-693	117,941,653,767.00	10,731,549,537,341.00	2,566.31
0	2	2	2059500	2008	1373	1500	5	2067000	873066.693	-1368	117,941,654,442.00	10,731,549,156,641.00	3,395.55
0	2	2	2000000	1928	1200	1667	10	2016670	1814166.37	-1190	113,242,783,634.00	10,303,997,464,138.00	6,774.60
0	1	1	715000	1903	557	1284	3	718852	285604.315	-554	111,774,385,909.00	10,170,387,892,383.00	1,052.70
0	2	2	2498000	2005	1260	1983	2	2501966	442271.415	-1258	117,765,446,677.00	10,715,516,028,242.00	1,717.52
0	2	1.5	2650000	1915	2500	1060	5	2655300	832524	-2495	112,479,218,450.00	10,234,519,565,045.00	3,087.91
0	2	2	3450000	1900	1850	1865	9	3466785	2268078.59	-1841	111,598,179,559.00	10,154,353,971,009.00	8,346.63
0	1	1	3105000	2016	1108	2802	10	3133020	2930143.56	-1098	118,411,541,246.00	10,774,304,485,114.00	11,441.40
0	4	5	13750000	2016	3699	3717	10	13787170	7102080.9	-3689	118,411,543,837.00	10,774,303,023,790.00	27,731.65
0	2	2	1185000	1900	1000	1185	4	1189740	470900.585	-996	111,598,178,704.00	10,154,354,450,404.00	1,732.94

Nuevas variables

Creadas a partir de la **BD original**

in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation	X1	X2	X3	X4	X5	X6
0	2	1	999000	1960	1000	999	10	1008990	992467.689	-990	115,122,331,690.00	10,475,018,292,970.00	3,767.66
0	2	2	2750000	2006	1418	1939	0	2750000	0	-1418	117,824,182,716.00	10,720,860,336,504.00	-
0	2	2	1350000	1900	2150	628	9	1355652	823326.836	-2141	111,598,179,859.00	10,154,353,801,809.00	3,029.88
0	1	1	629000	1903	500	1258	9	640322	795351.384	-491	111,774,385,858.00	10,170,387,924,537.00	2,931.55
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62
0	1	1	475000	1920	500	950	10	484500	667358.96	-490	112,772,895,870.00	10,261,242,679,930.00	2,481.76
0	1	1	975000	1930	900	1083	10	985830	1020705.84	-890	113,360,255,100.00	10,314,686,428,090.00	3,815.55
0	1	1	975000	1930	900	1083	12	987996	1224847.01	-888	113,360,255,102.00	10,314,686,428,092.00	4,578.66
0	2	1	1895000	1921	1000	1895	12	1917740	2259130.65	-988	112,831,632,255.00	10,266,586,795,308.00	8,405.59
0	3	3	2095000	1926	2200	952	4	2098808	561124.419	-2196	113,125,312,862.00	10,293,308,105,380.00	2,093.22
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06
0	1	1	1249000	1987	826	1512	3	1253536	409556.627	-823	116,708,200,350.00	10,619,317,120,251.00	1,576.20
0	0	1	1110000	2008	698	1590	5	1117950	659850.771	-693	117,941,653,767.00	10,731,549,537,341.00	2,566.31
0	2	2	2059500	2008	1373	1500	5	2067000	873066.693	-1368	117,941,654,442.00	10,731,549,156,641.00	3,395.55
0	2	2	2000000	1928	1200	1667	10	2016670	1814166.37	-1190	113,242,783,634.00	10,303,997,464,138.00	6,774.60
0	1	1	715000	1903	557	1284	3	718852	285604.315	-554	111,774,385,909.00	10,170,387,892,383.00	1,052.70
0	2	2	2498000	2005	1260	1983	2	2501966	442271.415	-1258	117,765,446,677.00	10,715,516,028,242.00	1,717.52
0	2	1.5	2650000	1915	2500	1060	5	2655300	832524	-2495	112,479,218,450.00	10,234,519,565,045.00	3,087.91
0	2	2	3450000	1900	1850	1865	9	3466785	2268078.59	-1841	111,598,179,559.00	10,154,353,971,009.00	8,346.63
0	1	1	3105000	2016	1108	2802	10	3133020	2930143.56	-1098	118,411,541,246.00	10,774,304,485,114.00	11,441.40
0	4	5	13750000	2016	3699	3717	10	13787170	7102080.9	-3689	118,411,543,837.00	10,774,303,023,790.00	27,731.65
0	2	2	1185000	1900	1000	1185	4	1189740	470900.585	-996	111,598,178,704.00	10,154,354,450,404.00	1,732.94

¿Cómo modelar la interacción entre **variables** (**neuronas**) de nuestra BD?



Interacción entre variables

Abre el archivo de Excel **redes_neuronales.xlsx**

Revisa las **fórmulas** de las variables X1, X2, X3, X4 y X5



Interacción entre variables

Variables nuevas:

X1 = (Elevation * Year_Built) + Price

X2 = (3.1416 * price_per_sqft * elevation) * raiz(sqft)

X3 = elevation - sqft

¿Qué significan estas **nuevas** variables?



Posteriormente se sigue un **proceso mucho más técnico** que involucra matemáticas,

funciones **sigmoide e iteraciones** sobre todos los datos (originales y creados)

Referencia 1
Referencia 2
Referencia 3

¿Por qué creamos estas **nuevas** variables que son **difíciles de interpretar**?

Aumentar variables e **interacciones**,

podría mejorar la precisión de las predicciones de un modelo de ML (por ejemplo, el ***accuracy***)

*in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation	X1	X2	X3	X4	X5	X6	
0	2	1	999000	1960	1000	999	10	1008990	992467.689	-990	115,122,331,690.00	10,475,018,292,970.00	3,767.66	
0	2	2	2750000	2006	1418	1939	0	2750000	0	-1418	117,824,182,716.00	10,720,860,336,504.00	-	
0	2	2	1350000	1900	2150	628	9	1355652	823326.836	-2141	111,598,179,859.00	10,154,353,801,809.00	3,029.88	
0	1	1	629000	1903	500	1258	9	640322	795351.384	-491	111,774,385,858.00	10,170,387,924,537.00	2,931.55	
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62	
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62	
0	1	1	475000	1920	500	950	10	484500	667358.96	-490	112,772,895,870.00	10,261,242,679,930.00	2,481.76	
0	1	1	975000	1930	900	1083	10	985830	1020705.84	-890	113,360,255,100.00	10,314,686,428,090.00	3,815.55	
0	1	1	975000	1930	900	1083	12	987996	1224847.01	-888	113,360,255,102.00	10,314,686,428,092.00	4,578.66	
0	2	1	1895000	1921	1000	1895	12	1917740	2259130.65	-988	112,831,632,255.00	10,266,586,795,308.00	8,405.59	
0	3	3	2095000	1926	2200	952	4	2098808	561124.419	-2196	113,125,312,862.00	10,293,308,105,380.00	2,093.22	
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06	
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06	
0	1	1	1249000	1987	826	1512	3	1253536	409556.627	-823	116,708,200,350.00	10,619,317,120,251.00	1,576.20	
0	0	1	1110000	2008	698	1590	5	1117950	659850.771	-693	117,941,653,767.00	10,731,549,537,341.00	2,566.31	
0	2	2	2059500	2008	1373	1500	5	2067000	873066.693	-1368	117,941,654,442.00	10,731,549,156,641.00	3,395.55	
0	2	2	2000000	1928	1200	1667	10	2016670	1814166.37	-1190	113,242,783,634.00	10,303,997,464,138.00	6,774.60	
0	1	1	715000	1903	557	1284	3	718852	285604.315	-554	111,774,385,909.00	10,170,387,892,383.00	1,052.70	
0	2	2	2498000	2005	1260	1983	2	2501966	442271.415	-1258	117,765,446,677.00	10,715,516,028,242.00	1,717.52	
0	2	1.5	2650000	1915	2500	1060	5	2655300	832524	-2495	112,479,218,450.00	10,234,519,565,045.00	3,087.91	
0	2	2	3450000	1900	1850	1865	9	3466785	2268078.59	-1841	111,598,179,559.00	10,154,353,971,009.00	8,346.63	
0	1	1	3105000	2016	1108	2802	10	3133020	2930143.56	-1098	118,411,541,246.00	10,774,304,485,114.00	11,441.40	
0	4	5	13750000	2016	3699	3717	10	13787170	7102080.9	-3689	118,411,543,837.00	10,774,303,023,790.00	27,731.65	
0	2	2	1185000	1900	1000	1185	4	1189740	470900.585	-996	111,598,178,794.00	10,154,354,450,404.00	1,732.94	

¿Si agregamos **cualquier variable**, debería entonces aumentar la precisión de nuestro ML?



En general, **No**



Variables relacionadas

En general, las variables que incluyas deberían tener un **impacto o relación con la variable a pronosticar**

Por ejemplo, en los deptos NY-SFO, es natural pensar que las siguientes variables tienen una **relación con el lugar en donde se ubica la vivienda**:

- Metro cuadrado
- Precio
- Habitaciones
- Año de construcción

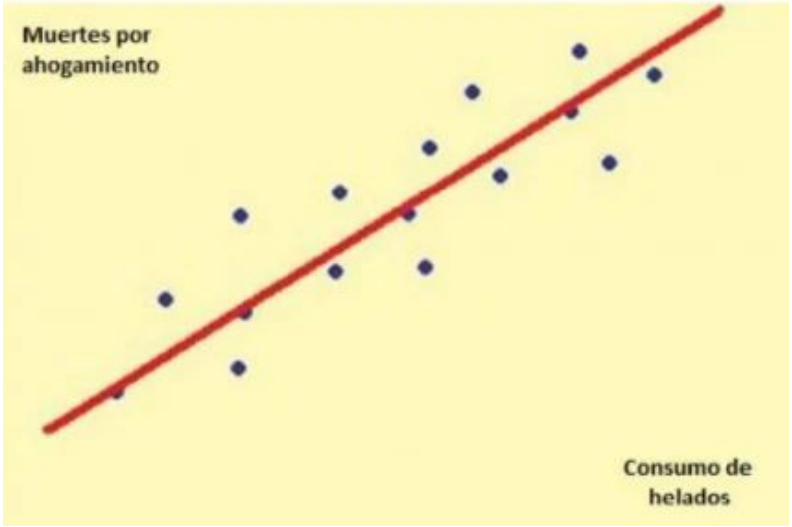
Por otro lado, **¿crees que mejoraría la precisión? Si incluimos como variables:**

- Número de letras del nombre del propietario
- Promedio de la Universidad del propietario
- Edad promedio de los inquilinos de la vivienda



Seguramente estas variables no aportan nada a mejorar la predicción del ML, y si lo hacen podrían ser **relaciones espurias**

Relaciones espurias



¿Existe una relación **causal** entre la venta de **helados** y la muerta por **ahogamientos** en el mar?



Relaciones espurias







Las ventas de helado y el número de personas que nadan,

aumentan cuando hace calor

¿Cuál es la **gran desventaja** de los modelos de redes neuronales?

Redes neuronales

Imagina que necesitas un modelo de ***score* de crédito** para otorgar un **préstamos** o no a una persona,

* ¿Te interesa saber **por qué lo descartas**? Por ejemplo, nivel de ingreso, escolaridad, etc.



Piensa que le tienes que **explicar claramente** por qué no se lo diste (o al regulador)

¿Le podrías decir que la variable **X2** resultó **poco favorable** en su análisis de crédito?



X2 = (3.1416 * price_per_sqft * elevation) * raiz(sqft)

¿Cómo interpretar esto?

Interpretación

En estos problemas necesitarías un modelo que te ayude a **entender el impacto de las variables originales**:

- Edad
- Salario
- Saldo promedio en la tarjeta de crédito
- Nivel de escolaridad

Interpretación

En estos problemas necesitarías un modelo que te ayude a **entender el impacto de las variables originales**:

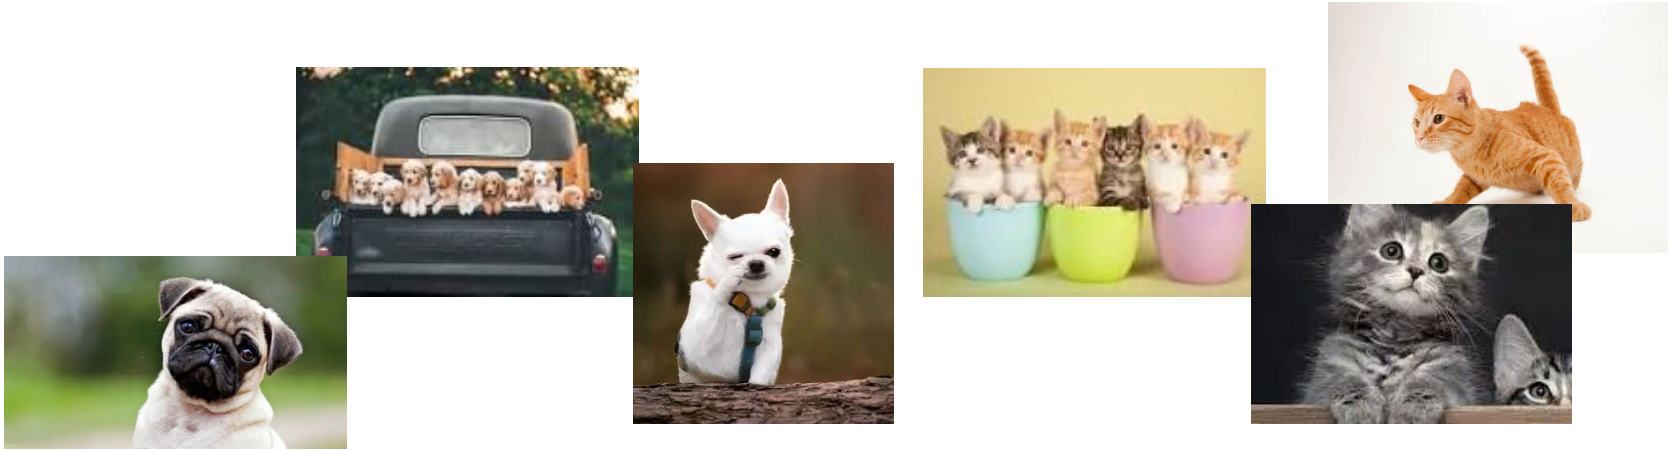
- Edad
- Salario
- Saldo promedio en la tarjeta de crédito
- Nivel de escolaridad

“No le otorgamos el crédito porque su salario es insuficiente para el monto y plazo solicitado”

Por otro lado, **no siempre es tan importante** entender la relación entre las variables y la predicción

Redes neuronales

Supón que tiene un **millón de imágenes de perritos y gatitos**... construyes una red neuronal y clasifica **perfecto**



¿Te interesa **mucho** saber **por qué** clasifica así cada observación?



NO, sólo me interesa asignar correctamente la **mayor cantidad posible**





Gran cantidad de las **herramientas modernas de AI** utilizan redes neuronales (*ChatGPT*),

por eso es fundamental entender su **funcionamiento, alcances y las reglas con las que deben operar**

Reflexiones al momento

¿Una red neuronal (ChatGPT) **piensa**?

¿Una máquina puede **abstraer** como lo hace el **cerebro** humano?

¿Las máquinas producen discursos **racistas** por vonlutad propia?

...



Nota: **el dominio de cada técnica requiere mucho tiempo y estudio,**

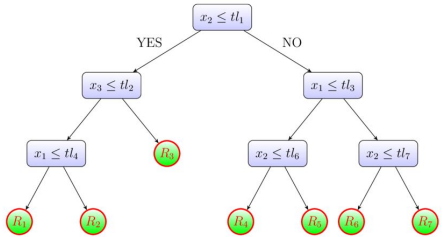
podríamos hacer un curso para cada una...

Ejercicios

Toma 10 minutos para este ejercicio

Considerando este modelo de regresión logística, el árbol y los datos de deptos NY-SFO de la Clase 2, responde lo siguiente:

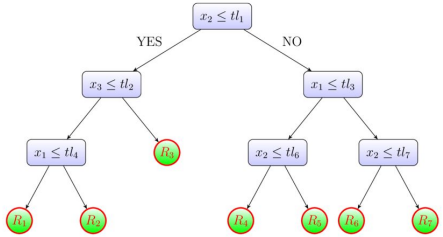
- ¿Qué modelo tiene mejor ***accuracy***? ¿El árbol o la regresión logística?
- **¿Qué modelo pronóstica con más precisión las viviendas de NY?**
- **¿Qué modelo pronóstica con más precisión las viviendas de SFO?**
- ¿Qué modelo **tarda más tiempo en correr**? ¿Cómo lo podrías medir?



Algoritmos en R

Tiempo de procesamiento Clase2. R





Tabasco Global Pulse

Ejemplo Políticas Públicas

Clase 2

ML y análisis de datos

ITAM

¿Cómo podemos mejorar la atención de **desastres naturales**?



Situación inundaciones Tabasco 2009

Tabasco es uno de los estados que sufren, con mayor frecuencia, inundaciones en la temporada de huracanes y tormentas en el golfo de México.

- El 28 de octubre del 2009, el frente frío no. 9 entró por el noroeste de México, llegó a Tabasco el 31 de octubre y permaneció por cuatro días.

- Según datos del Servicio Meteorológico Nacional, se registraron 800mm de lluvia acumulada que implica **cuatro veces más** el nivel usual en el mes de noviembre.

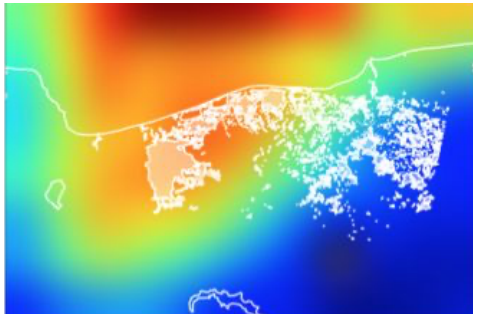


Imagen satelital de la precipitación acumulada en Tabasco durante las dos primeras semanas de noviembre.

Pregunta 1:

¿Cómo podemos aprovechar la información demográfica y los patrones de movilidad de la población para evaluar la situación después de un **desastre natural**?



Pregunta 2:

¿Es posible diseñar una mejor estrategia de protección civil?



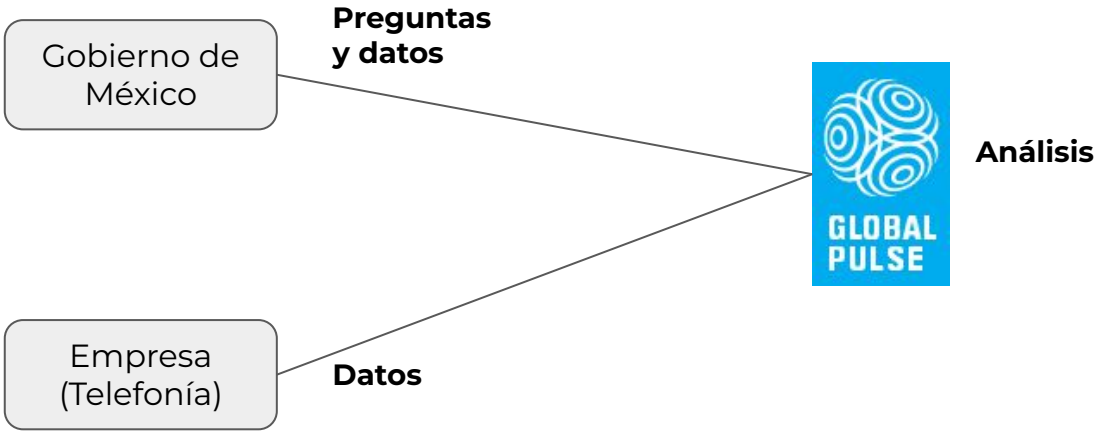
UN Global Pulse

Esta investigación fue realizada en colaboración con *Global Pulse*, iniciativa de análisis de datos de la ONU.

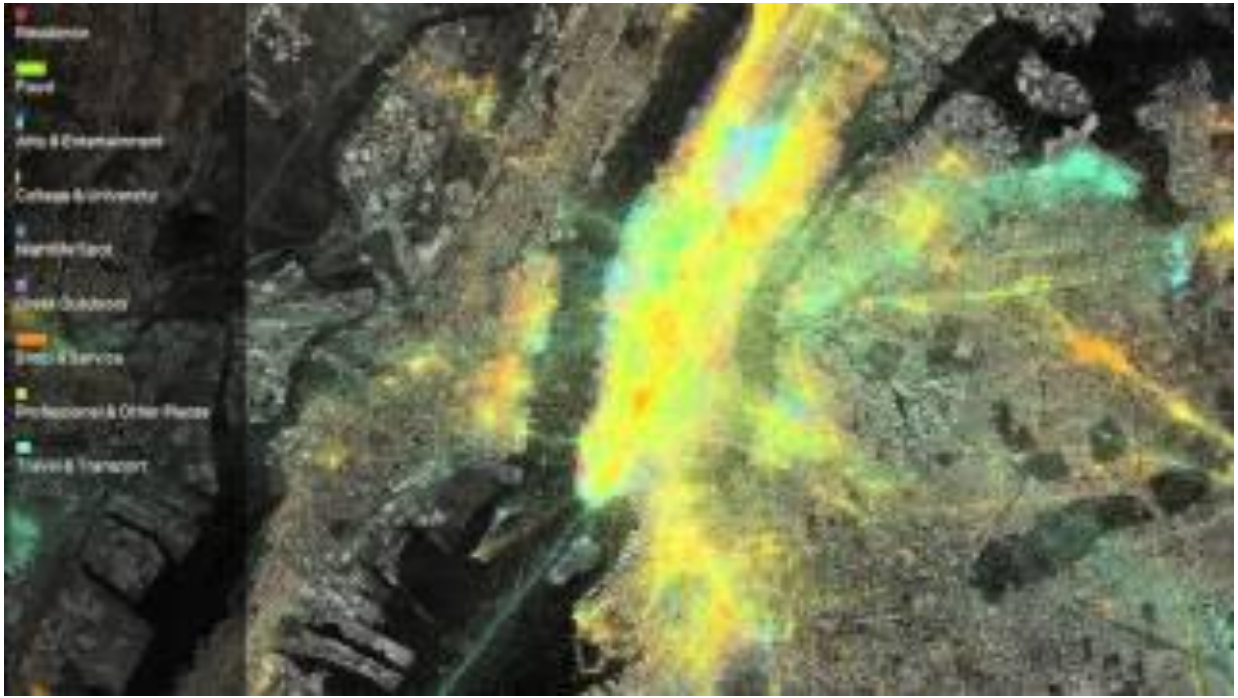
Información y referencias proporcionadas para este análisis:

- Dirección General de Protección Civil
- INEGI
- CONAGUA
- SRE
- CENAPRED

DSSG: Esquema de Colaboración



CDR Telefonía



Fuentes de datos

Antenas telefónicas

- Están localizadas geográficamente con **latitud y longitud.**
- El área de cobertura por cada antena se conoce como célula.
- La antena que brinda cobertura a un celular es asignada en función del tráfico en la red y la posición geográfica.

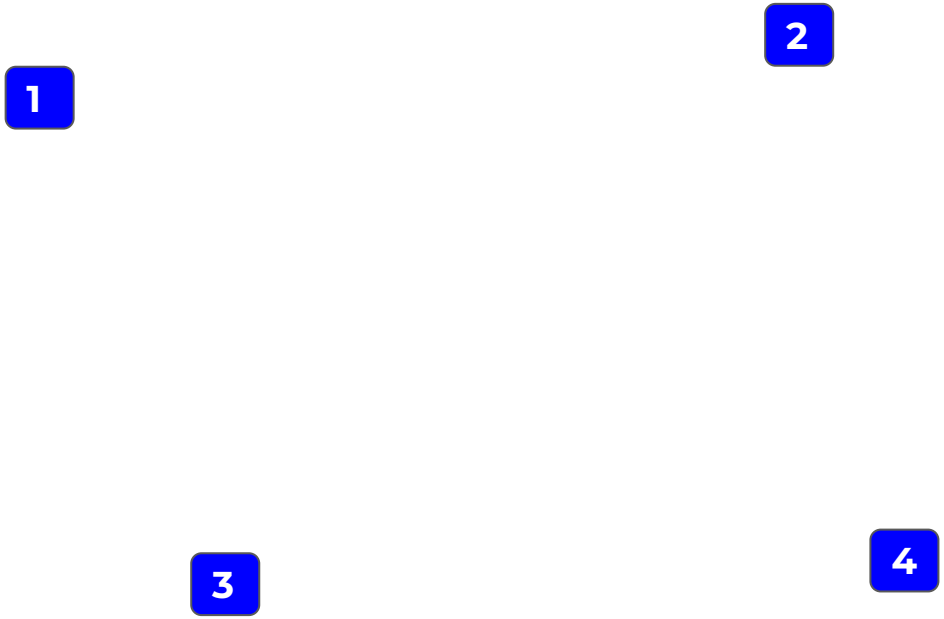
Registros de llamadas

- Cada que un teléfono celular recibe o realiza una llamada, mensaje u otro servicio, se registra información como la duración y antena a la que fue enlazado.
- Aunque no existe información sobre la posición exacta del teléfono, se puede estimar considerando la ubicación de la antena.
- La información utilizada para este estudio incluye datos encriptados de la fecha, hora, duración y antena a la que fue enlazada cada llamada. El equipo de la CEDN no participó en la extracción y resguardo de esta información que estuvo a cargo del equipo de Global Pulse de la ONU.

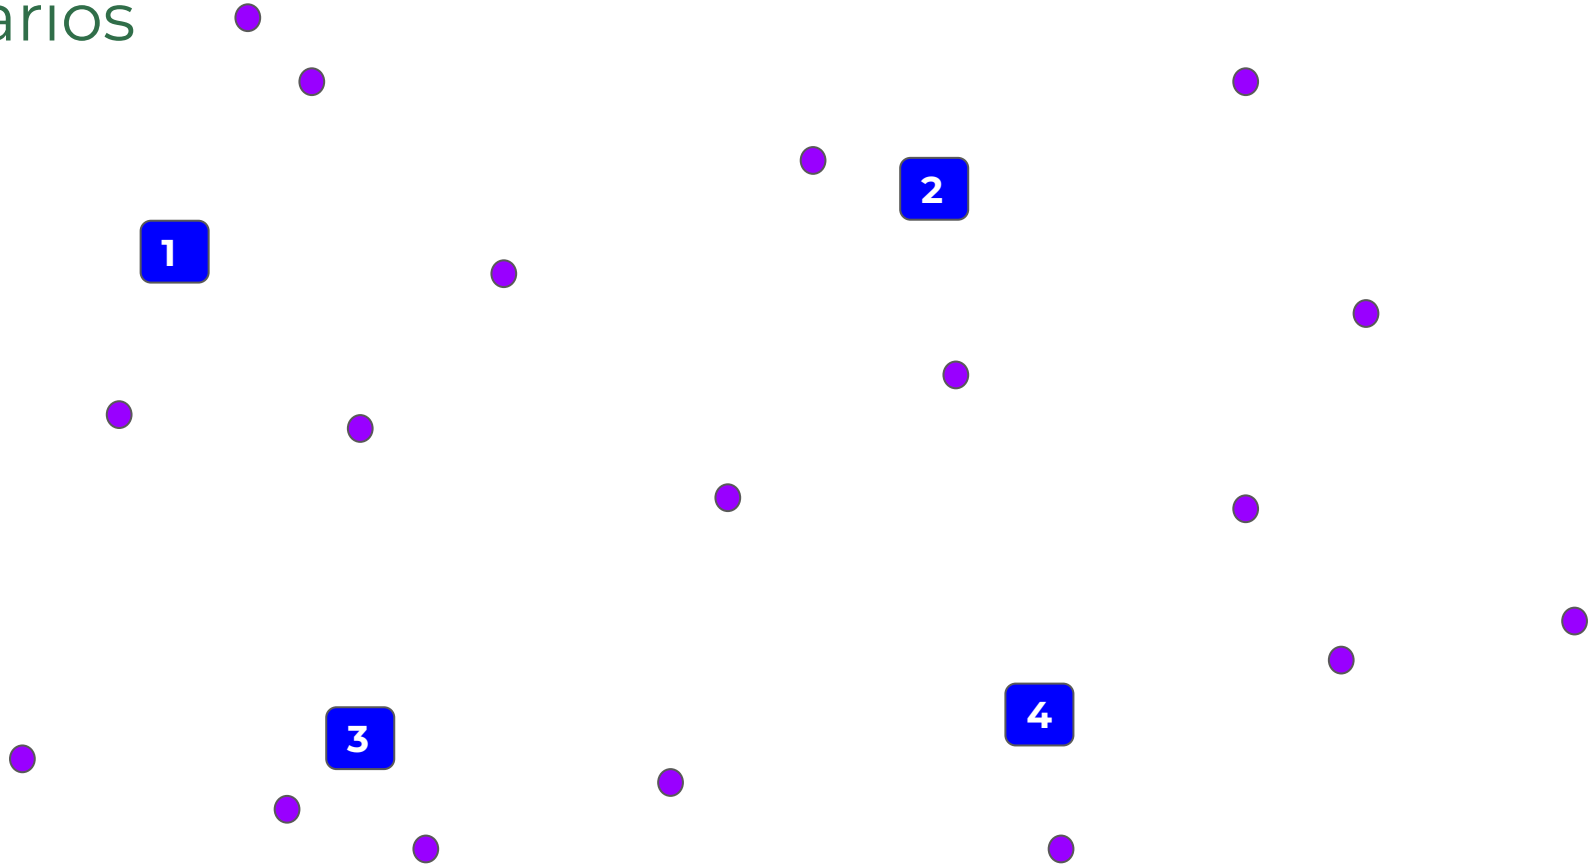
¿Cómo podemos deducir **patrones de movilidad** a partir de estos datos?



Antenas



Usuarios

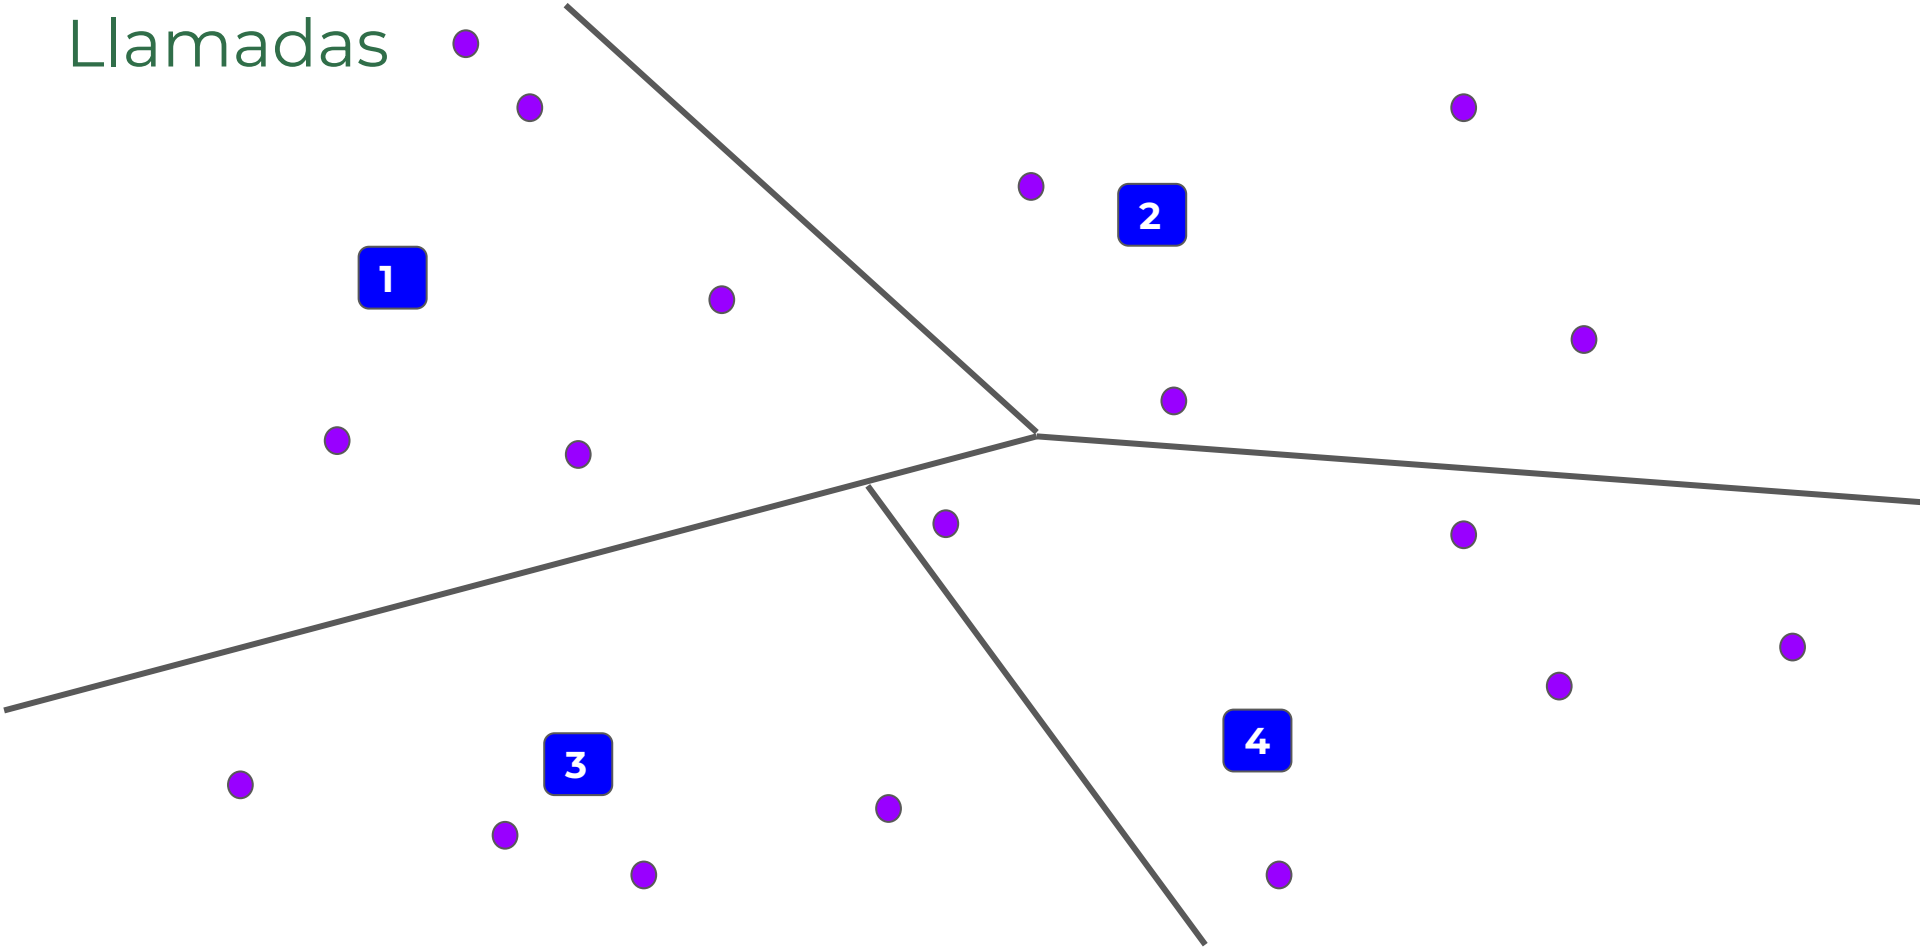


La **ubicación exacta** de los usuarios es **desconocida**

¿Qué antena procesa tu llamada?

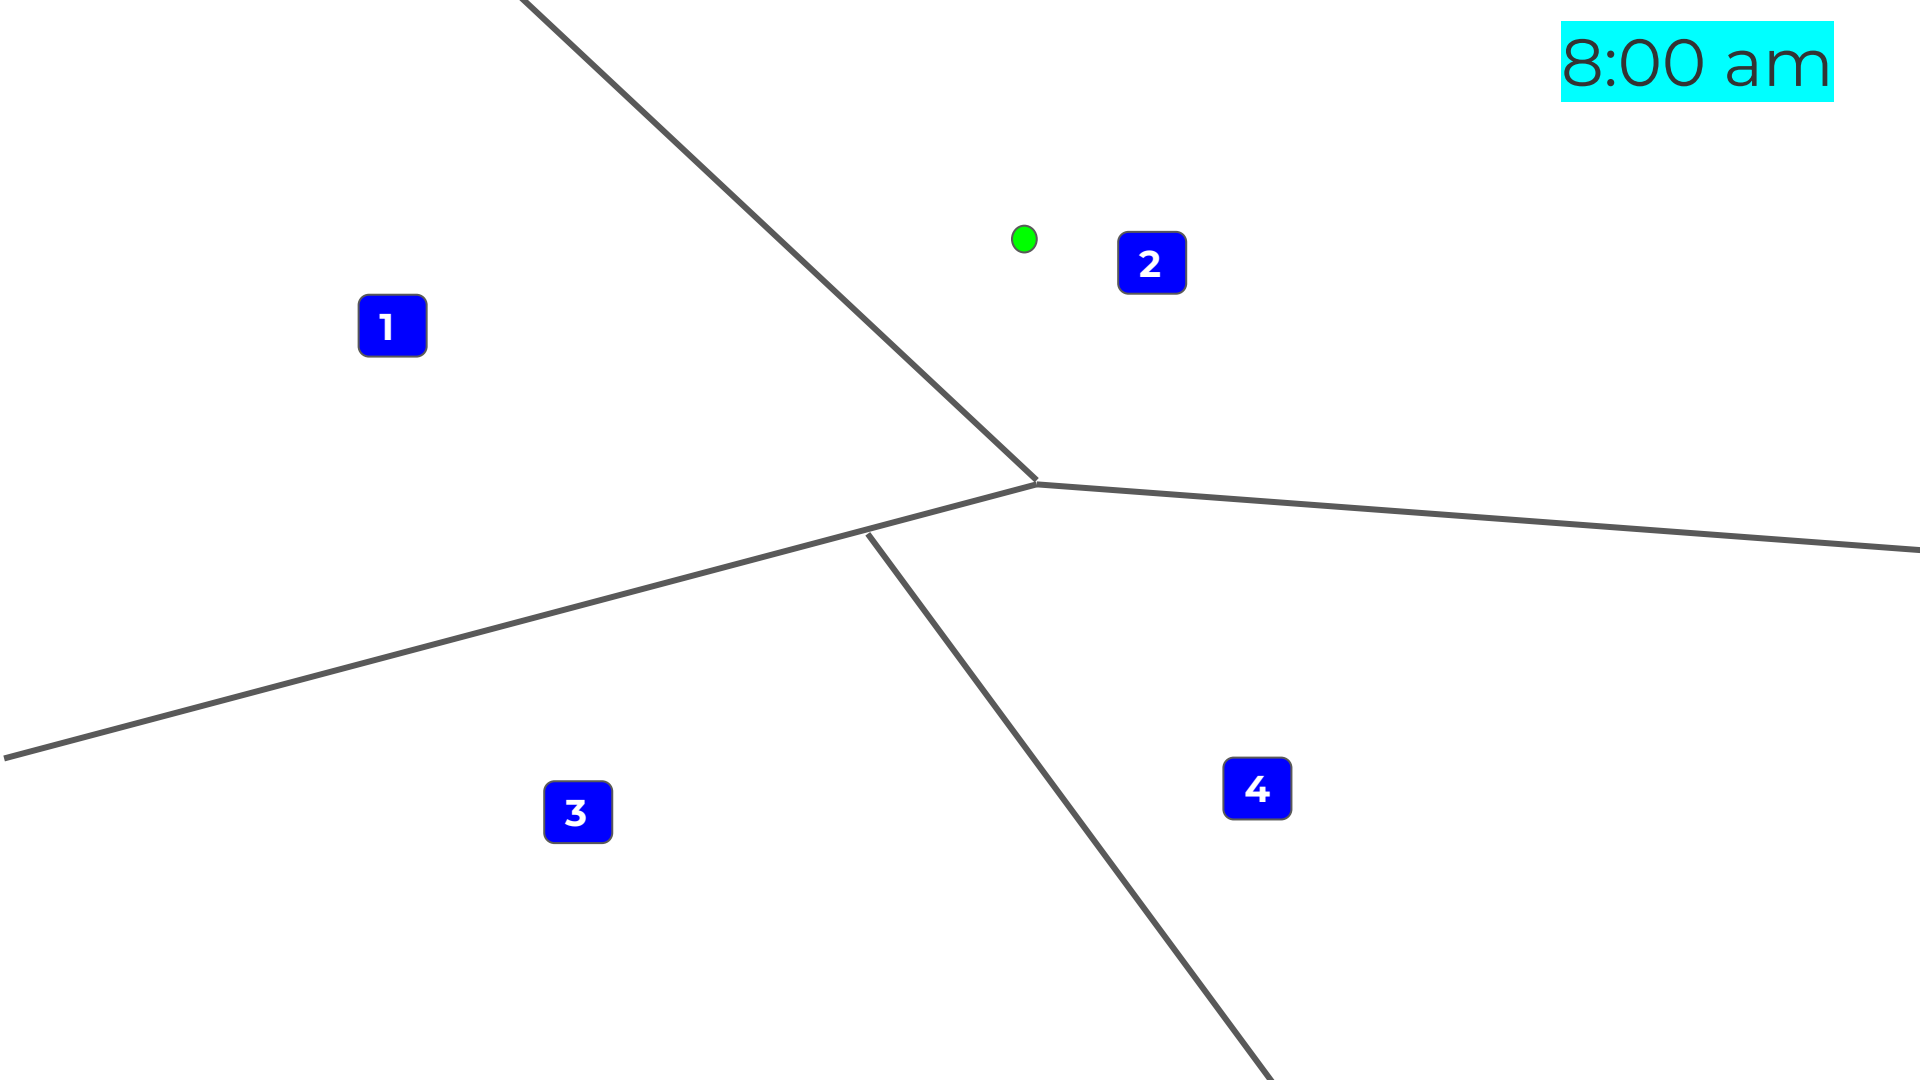


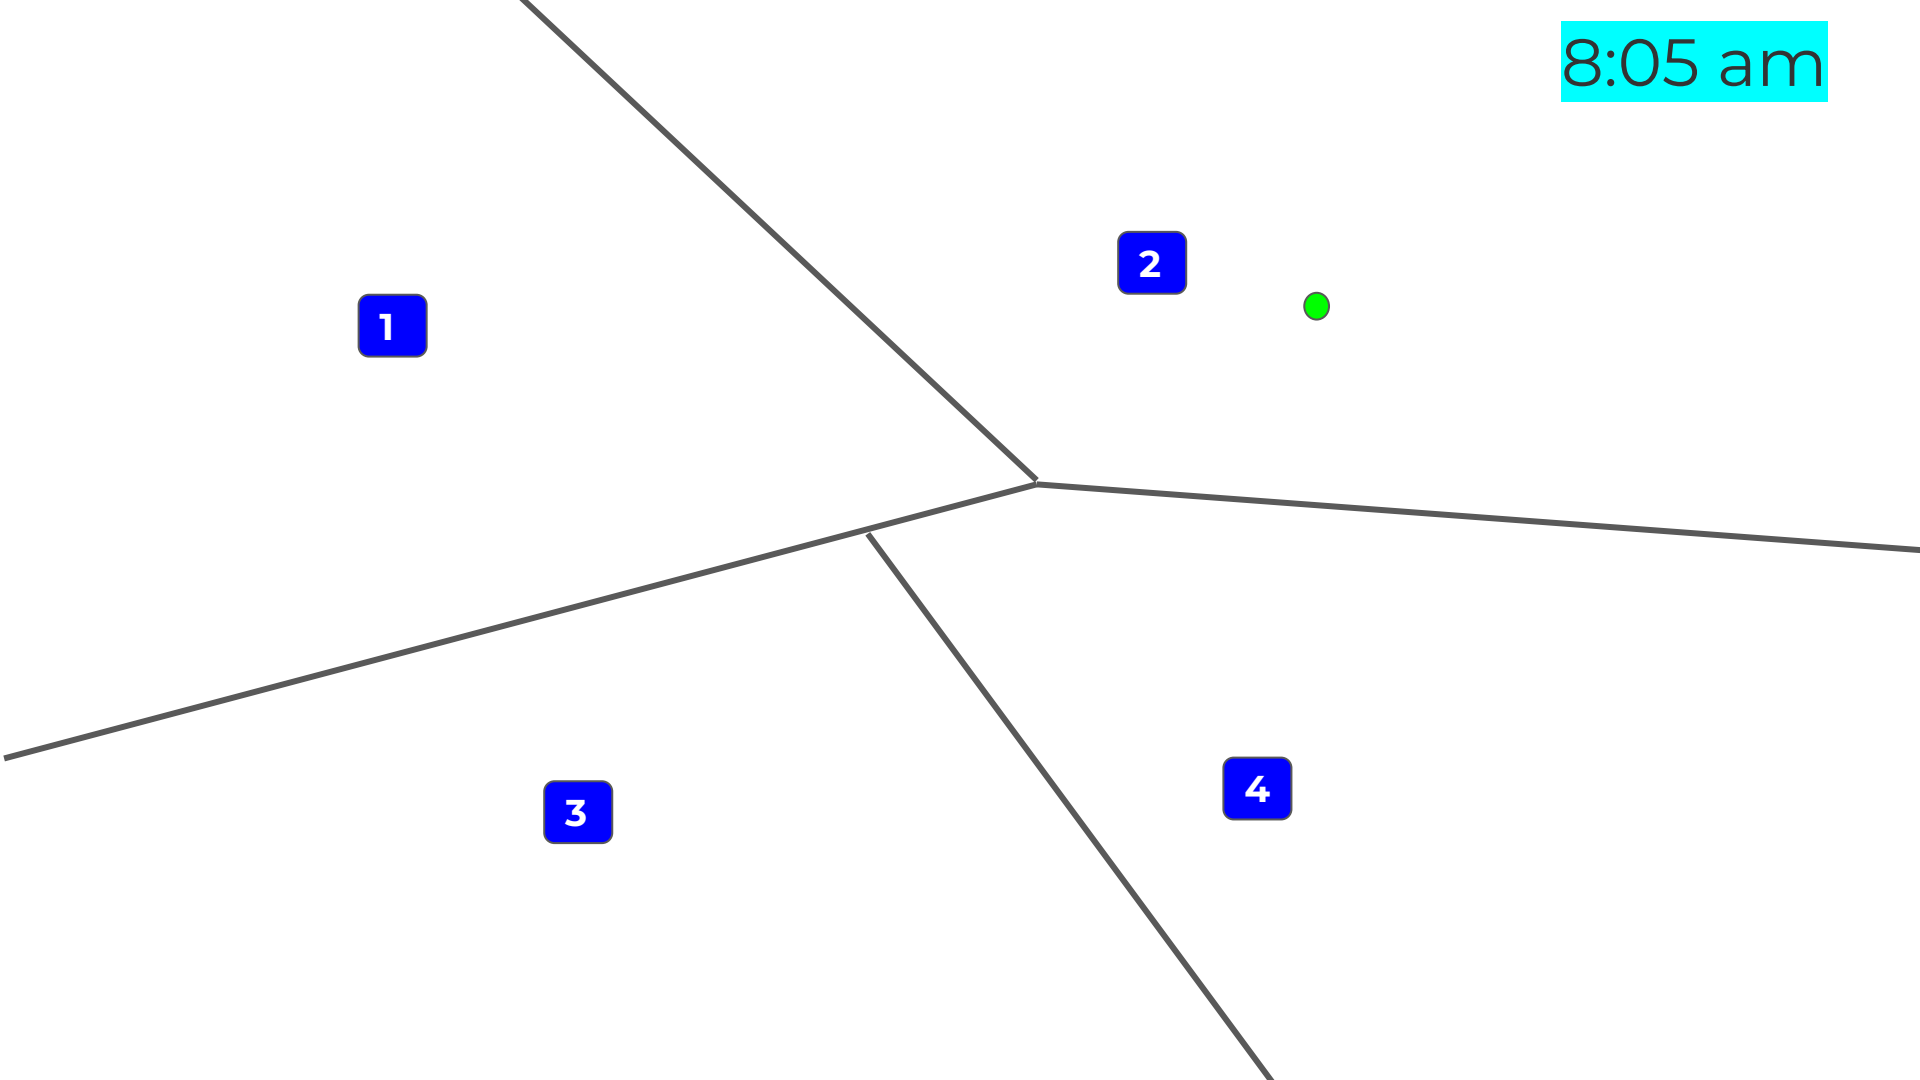
Llamadas

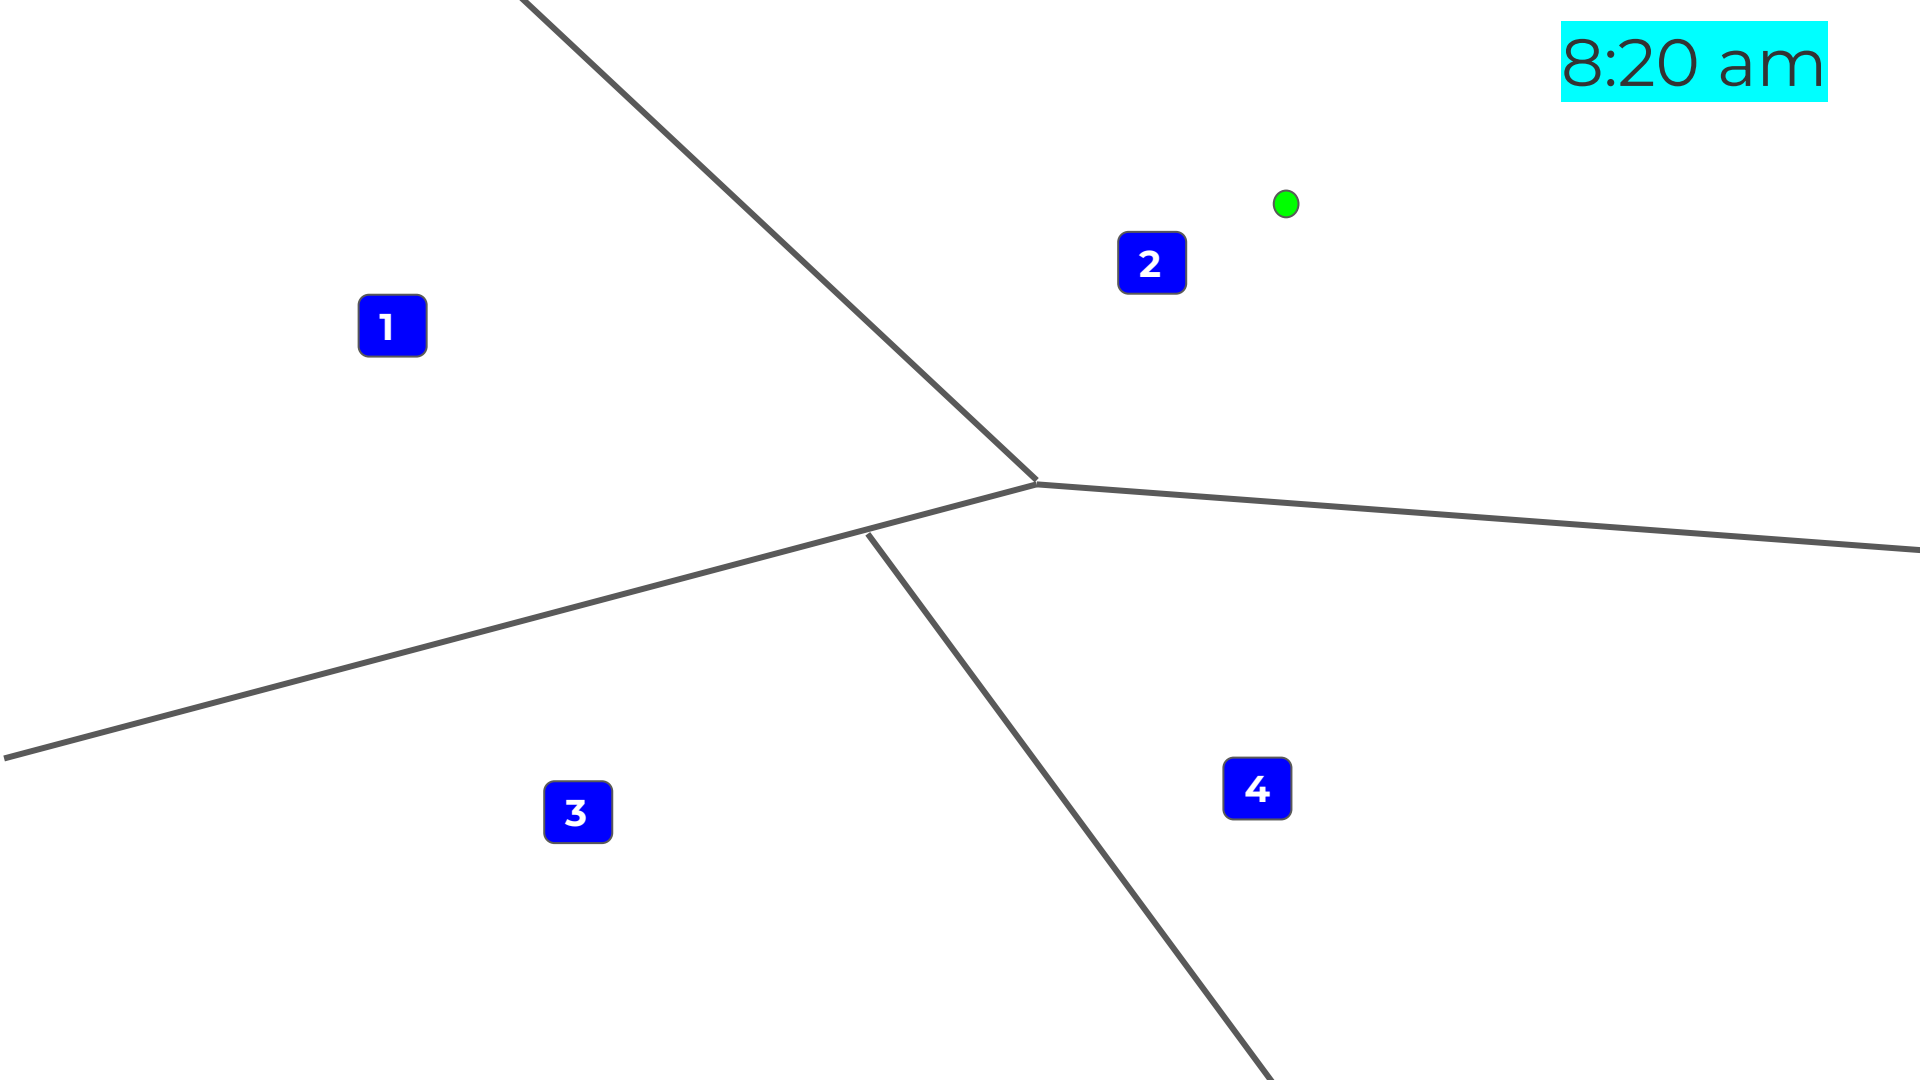


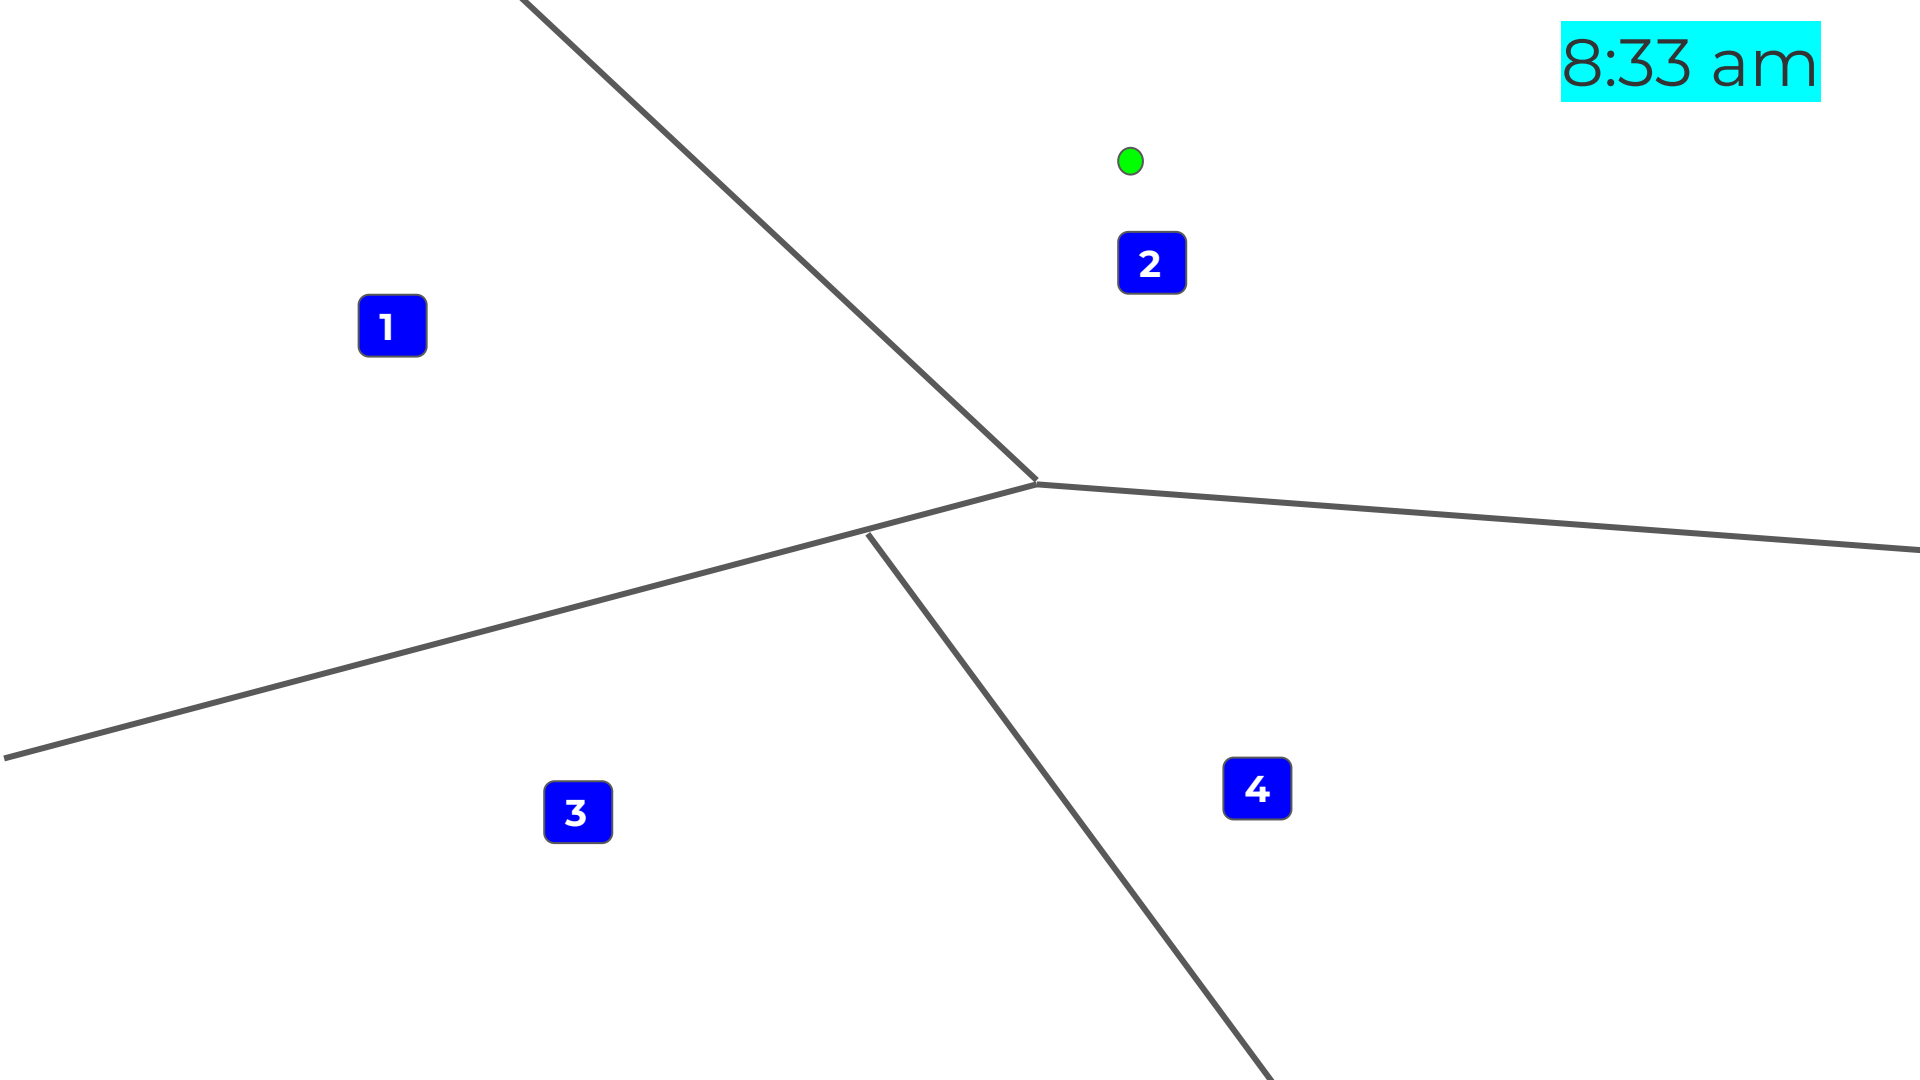
La fecha y hora en que cada usuario se enlaza a las antenas
se registran en una BD conocida como ***Call details records*** (CDR).

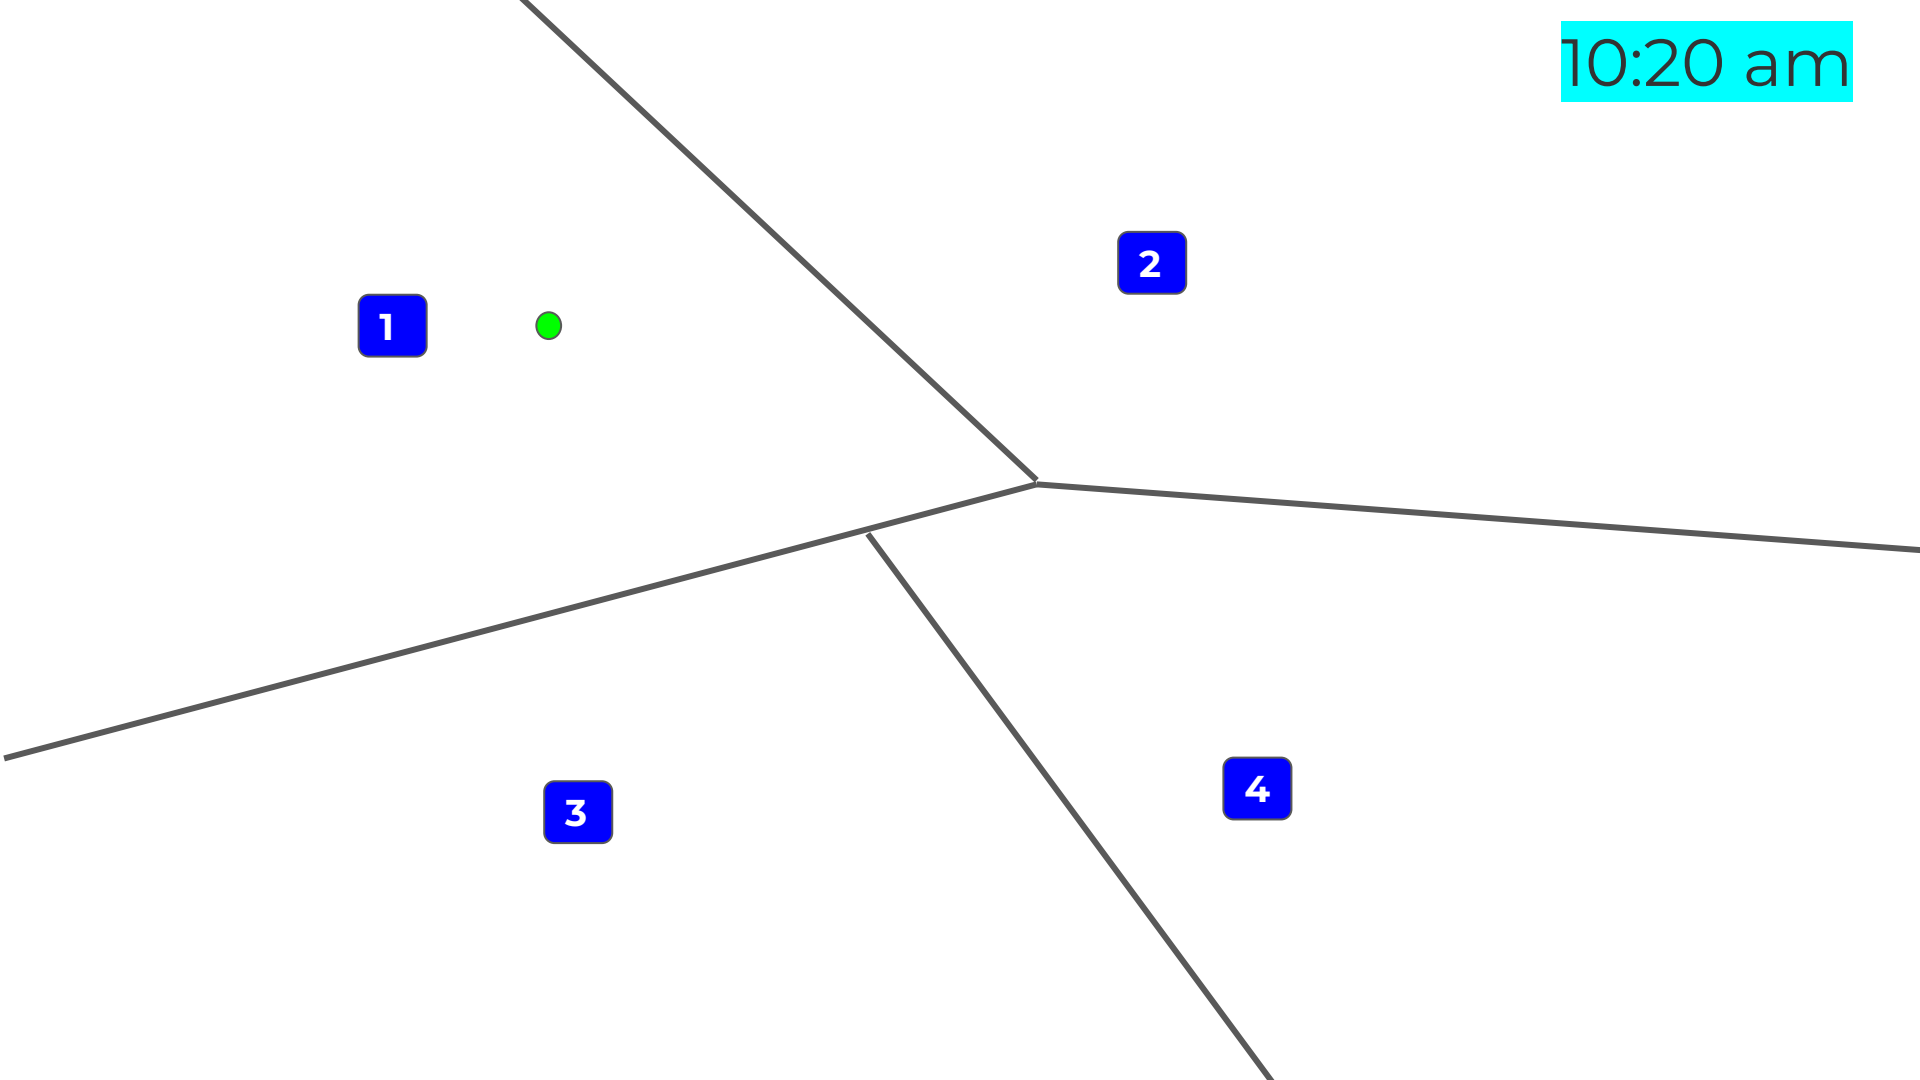
Cada usuario **tiene un ID_único** y es posible
determinar la **fecha y hora en la que se enlazo a cada antena**

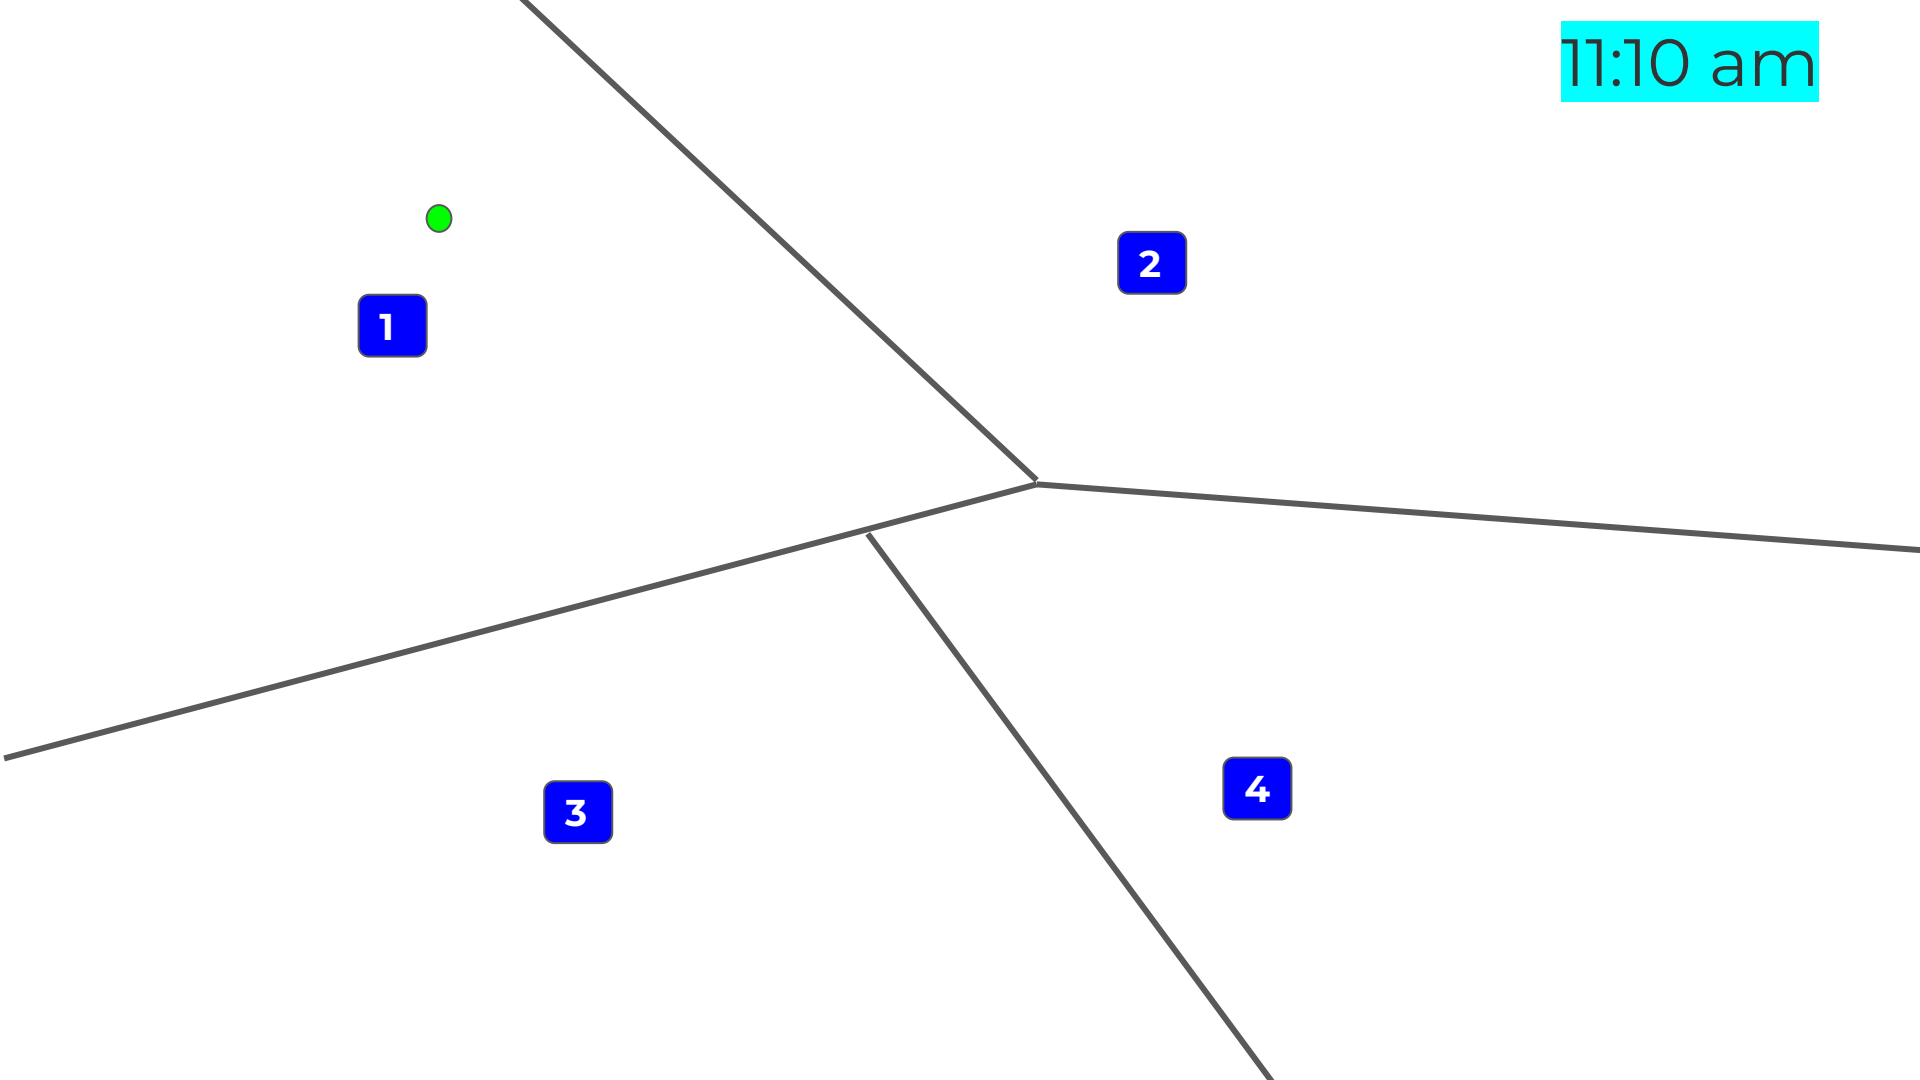

8:00 am
1
2
3
4


8:05 am
1
2
3
4

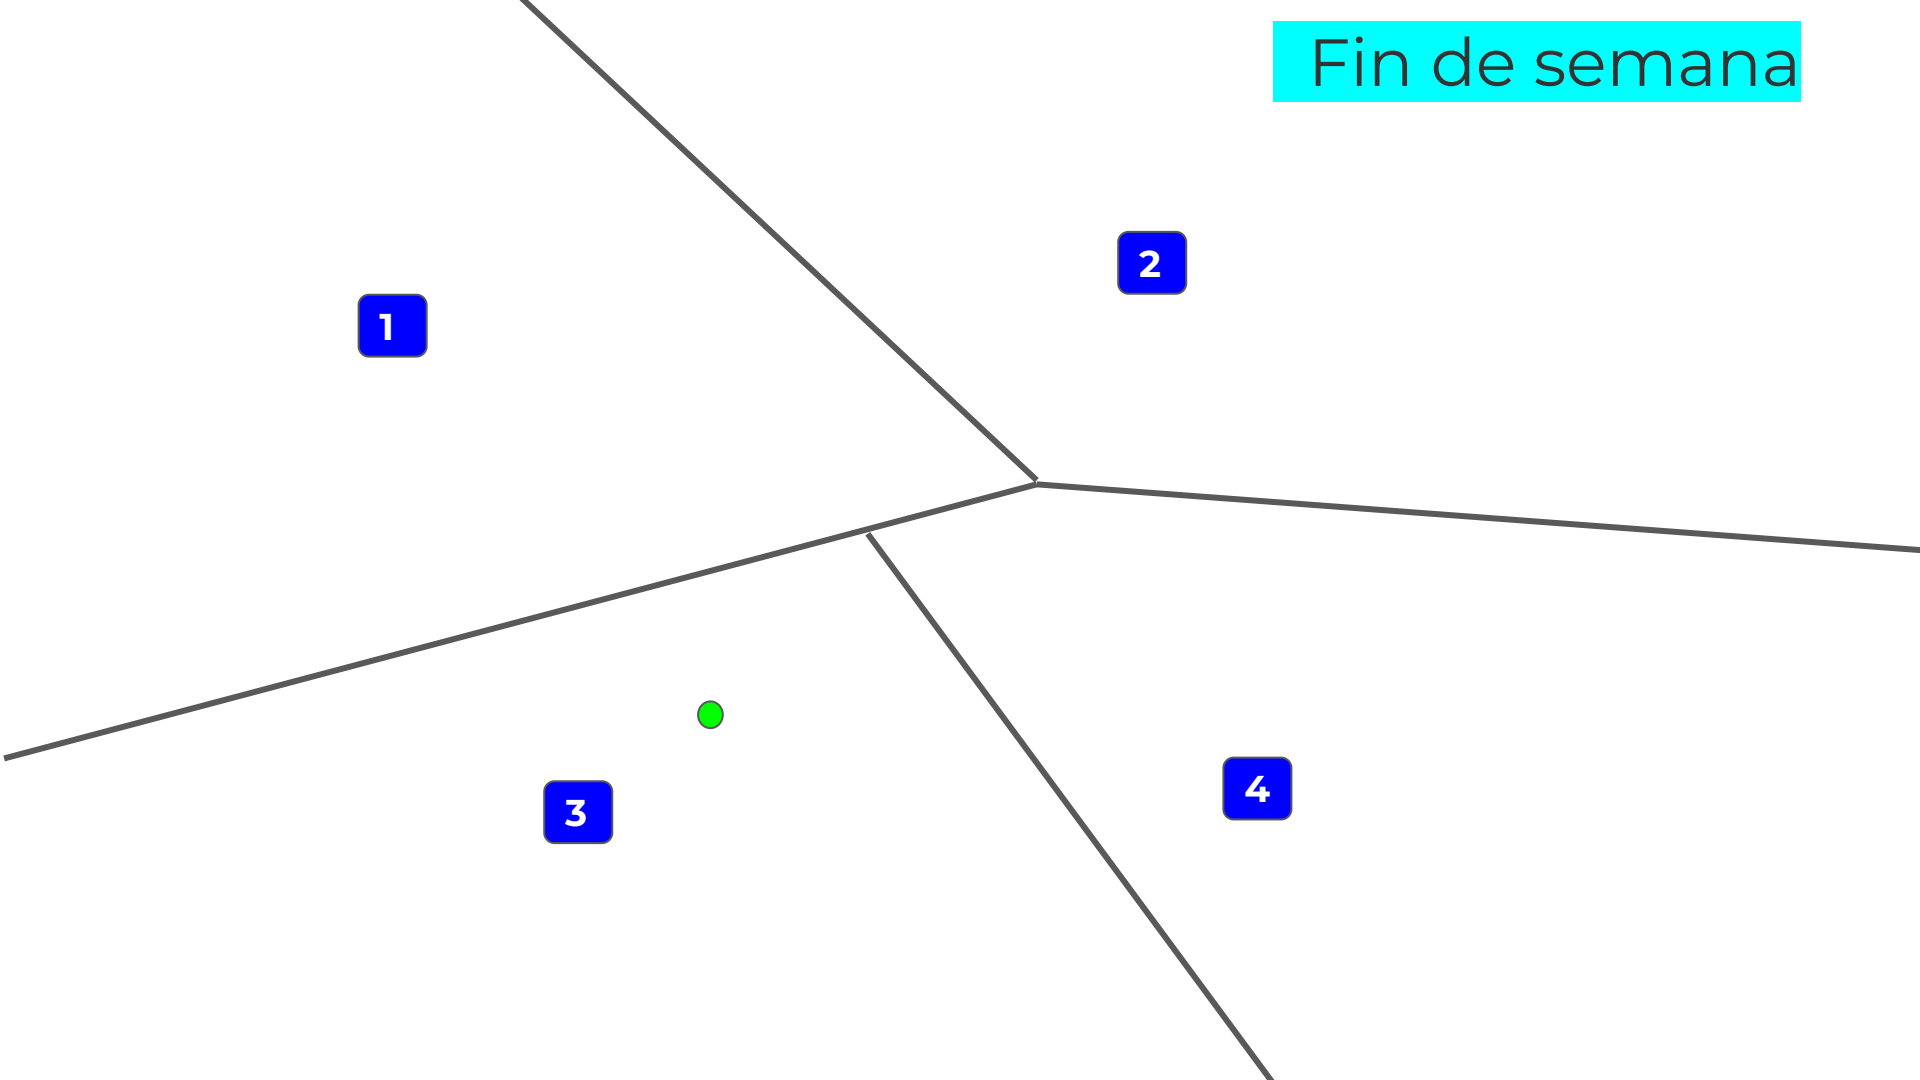

8:20 am
1
2
3
4


8:33 am
1
2
3
4

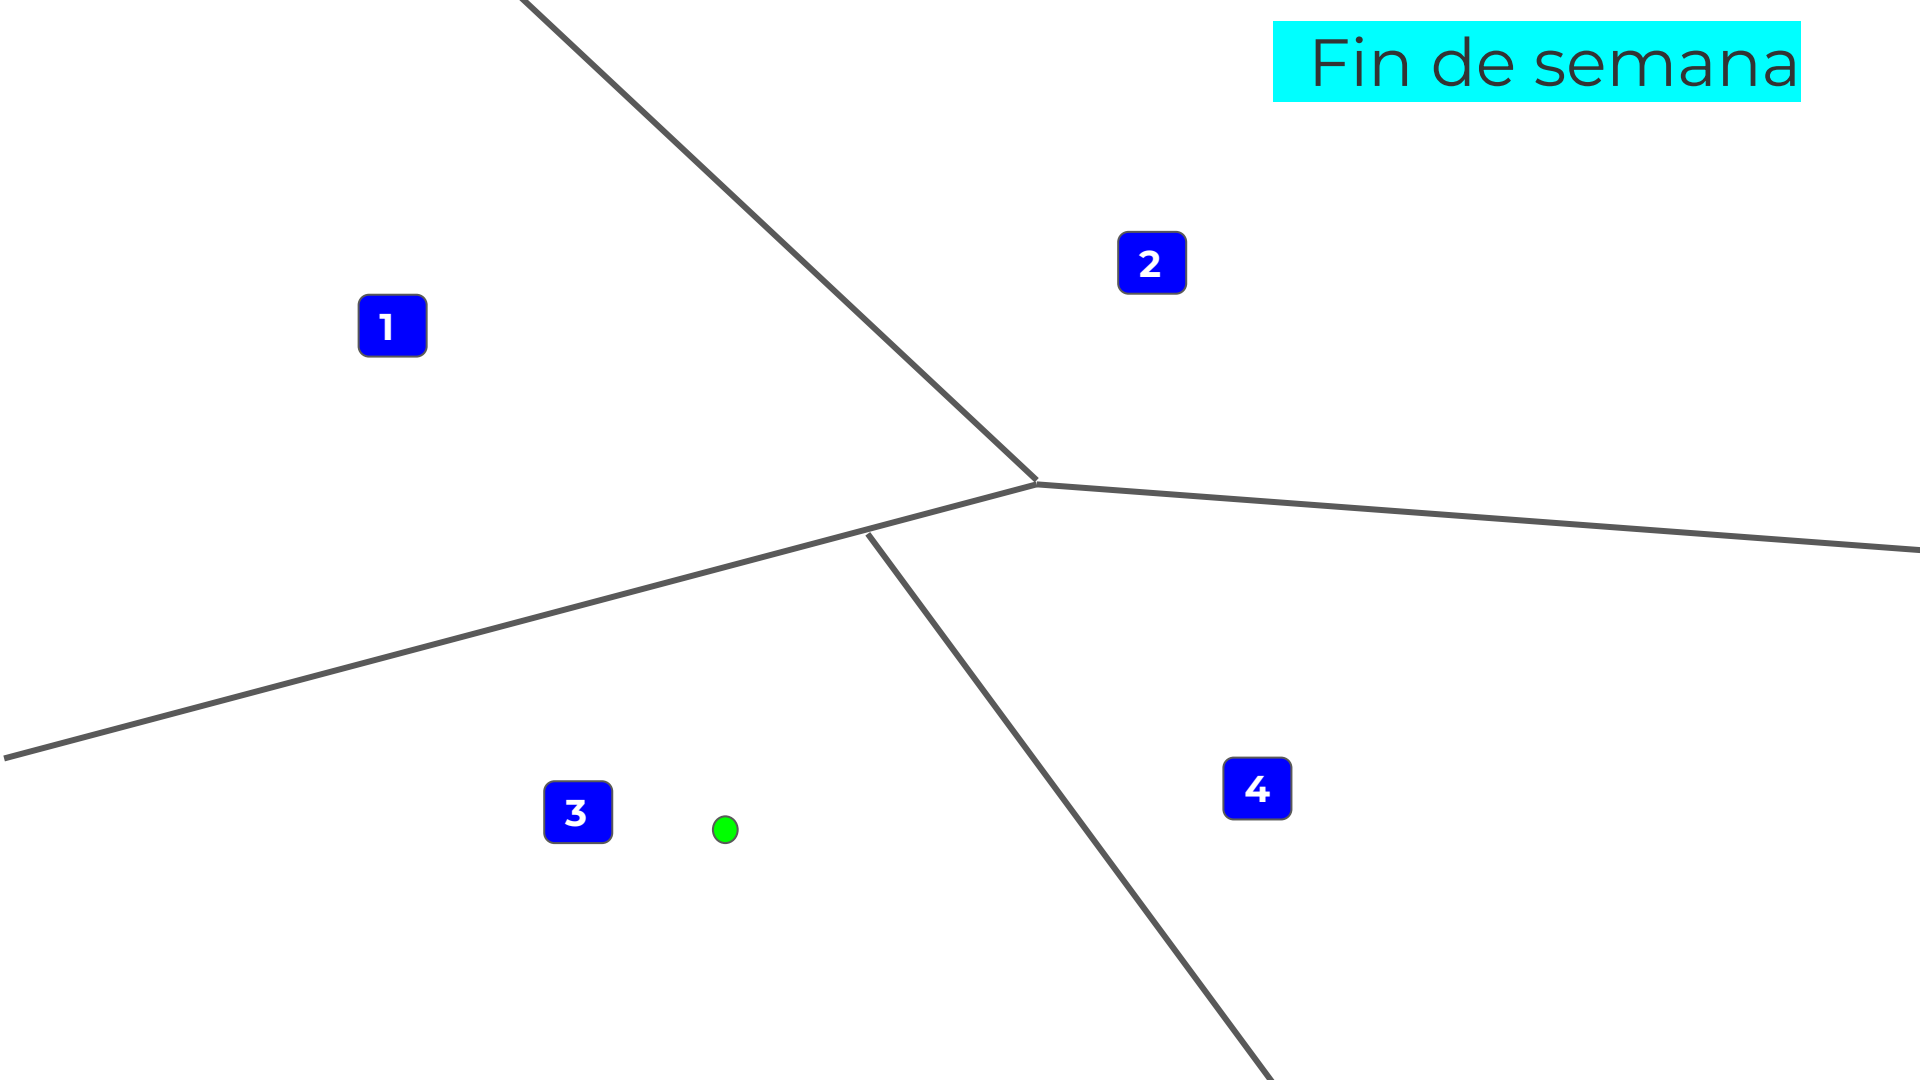

10:20 am
1
2
3
4


11:10 am
1
2
3
4

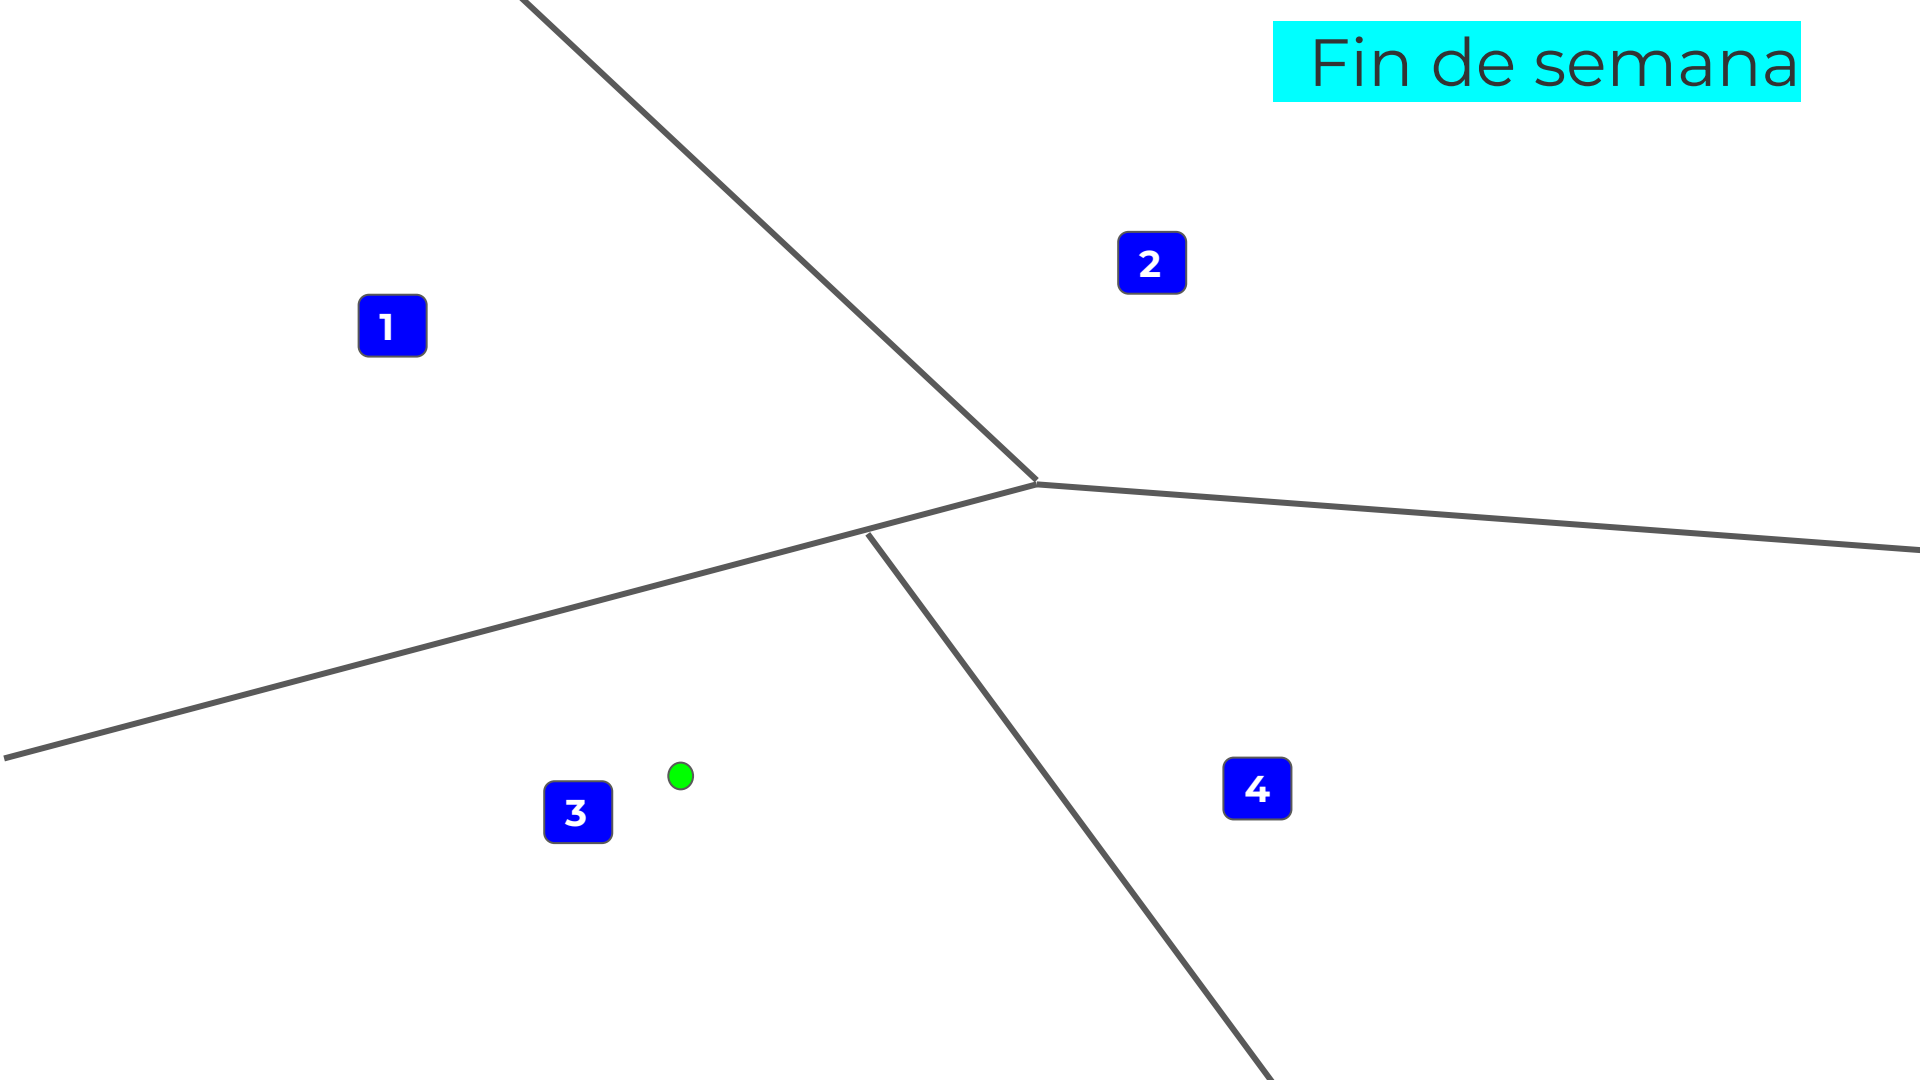
Fin de semana



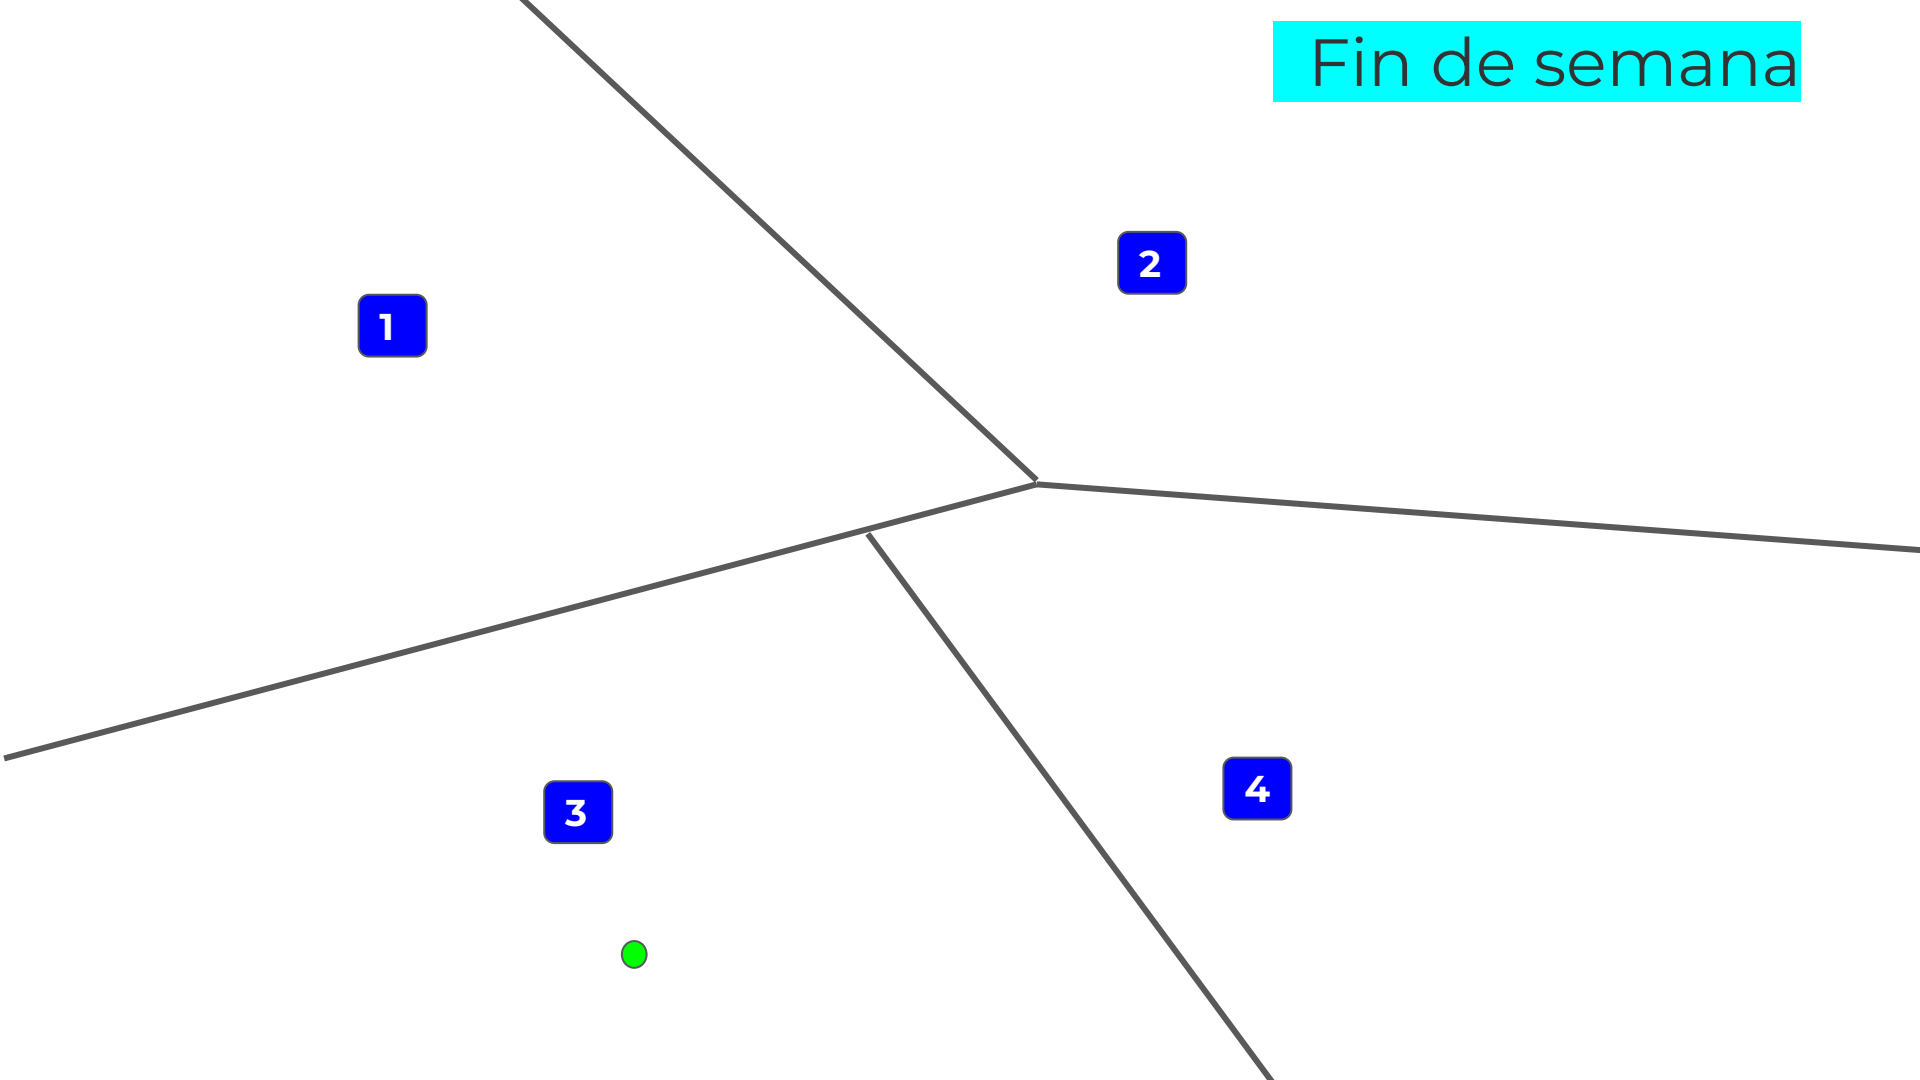
Fin de semana

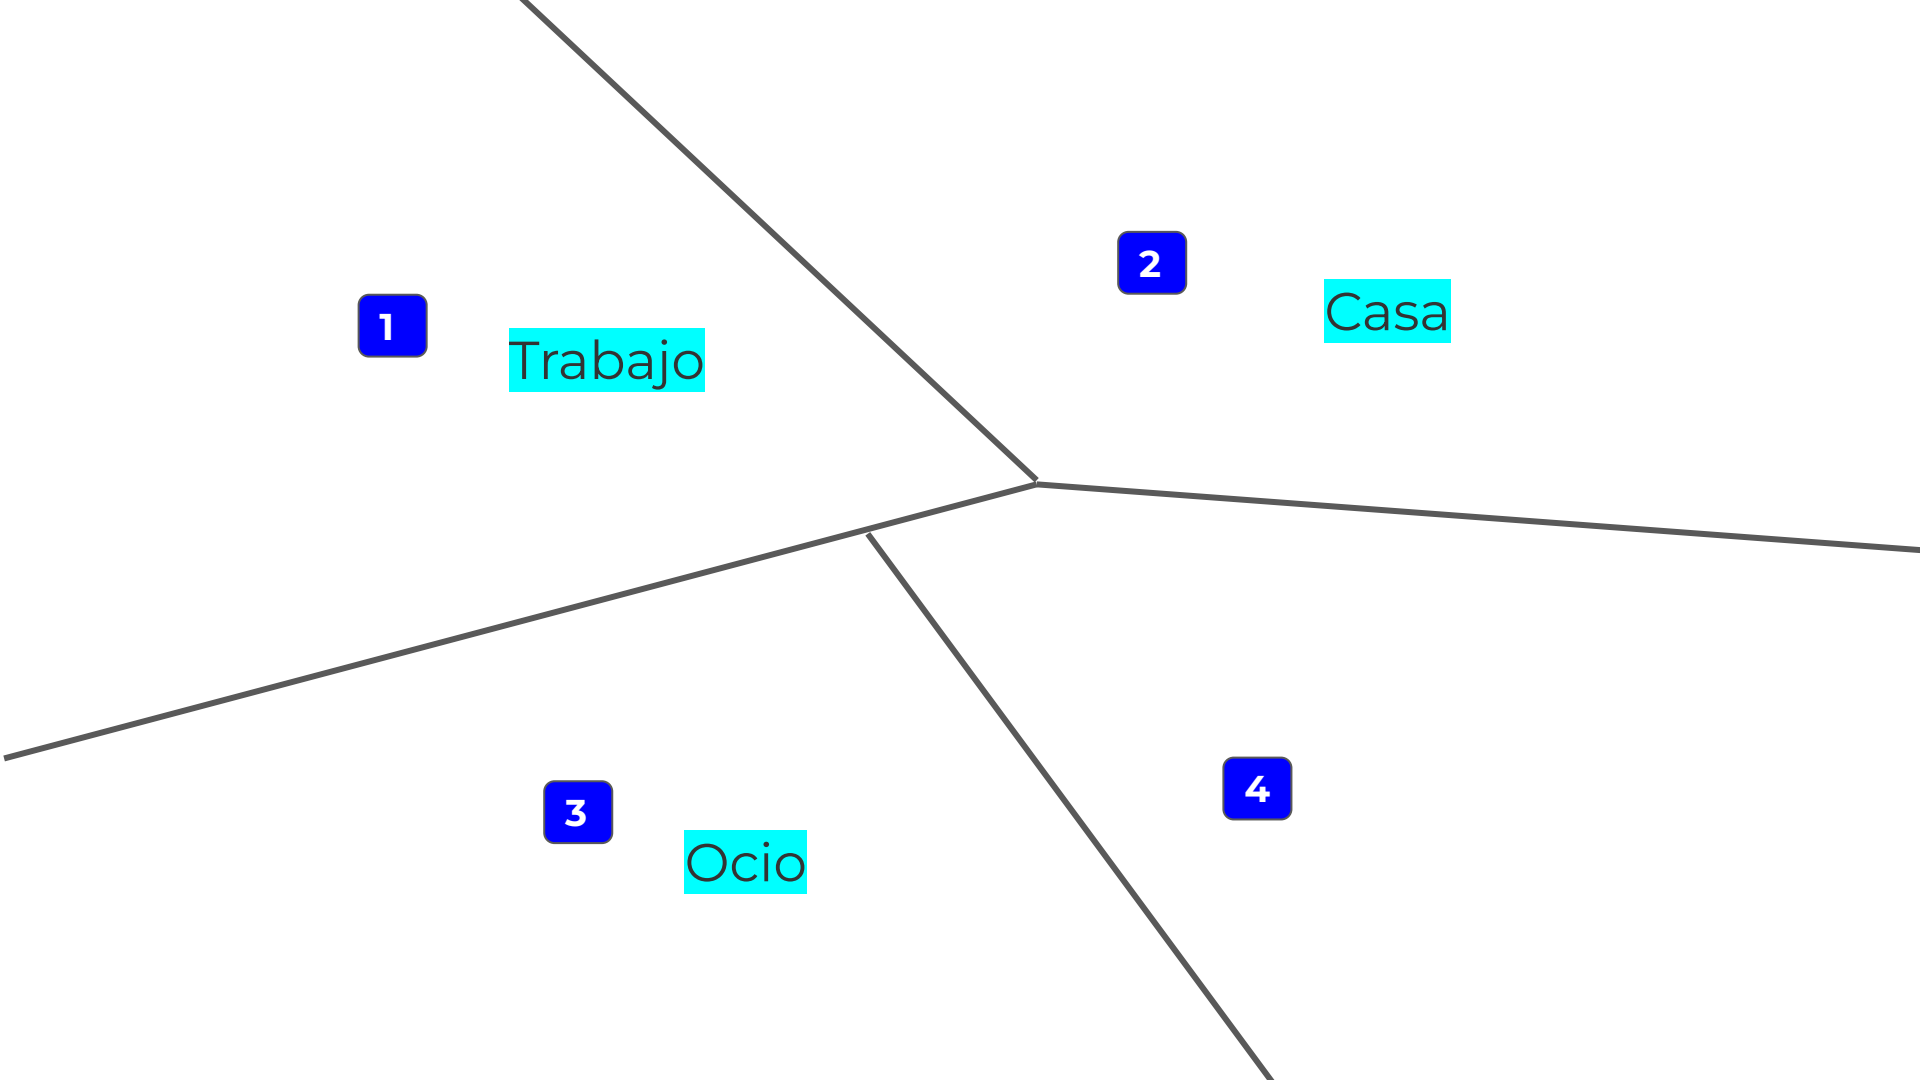


Fin de semana



Fin de semana




1
Trabajo
2
Casa
3
Ocio
4

Aún **sin conocer la ubicación exacta** de cada usuario,
es posible **aproximar** su ubicación mediante la antena utilizada

Nota: sólo la propia empresa de telefonía tiene acceso a los *CDR*

(Es un dato interno para ellos)

Otras fuentes de datos externos

Imágenes satelitales

- Ayudan a determinar el área afectada con mayor precisión que sólo utilizando noticias y documentos históricos.

Precipitación pluvial

- Permite conocer el nivel de precipitación durante el desastre. Estos datos permiten comparar el nivel de lluvia con la actividad en las antenas celulares.

Protección civil

- Información sobre población afectada, albergues y refugios temporales. Estos datos permiten validar los resultados obtenidos con otras fuentes de información.
- Sistema de alertamiento de ciclones tropicales.

Otras fuentes de datos externos

Censo INEGI

- Utilizado para evaluar la representatividad y distribución de la población inferido por los registro telefónicos.

Sistemas de Información geográfica

- Información contextual de la inundación: carreteras, calles y red hidrográfica.

Otra información contextual

- Atlas Nacional de Riesgos.
- Noticias y fotografías de diversos periódicos.

Otras preguntas de investigación

- ¿Existe alguna **relación entre la dinámica social** durante un desastre natural y los registros de llamadas de las antenas telefónicas?
- ¿La información de las antenas telefónicas podría ser utilizada, en el futuro, para mejorar la respuesta ante un desastre natural como las inundaciones de Tabasco en el año 2009?
- ¿Los hallazgos obtenidos por los registros de las antenas **contrastan** con la información que proveen dependencias oficiales?
- ¿Cómo **afectan las inundaciones a los patrones usuales** de comunicación y movilidad en la región?



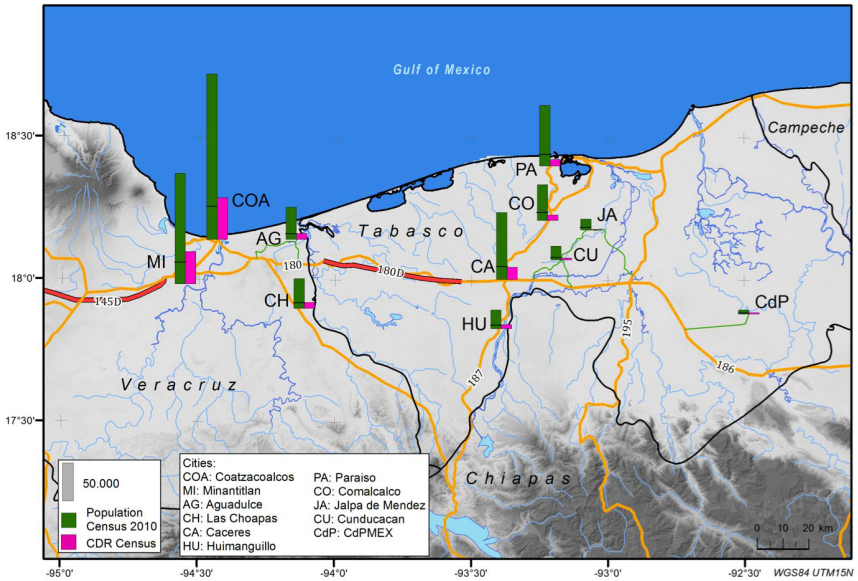
Metodología

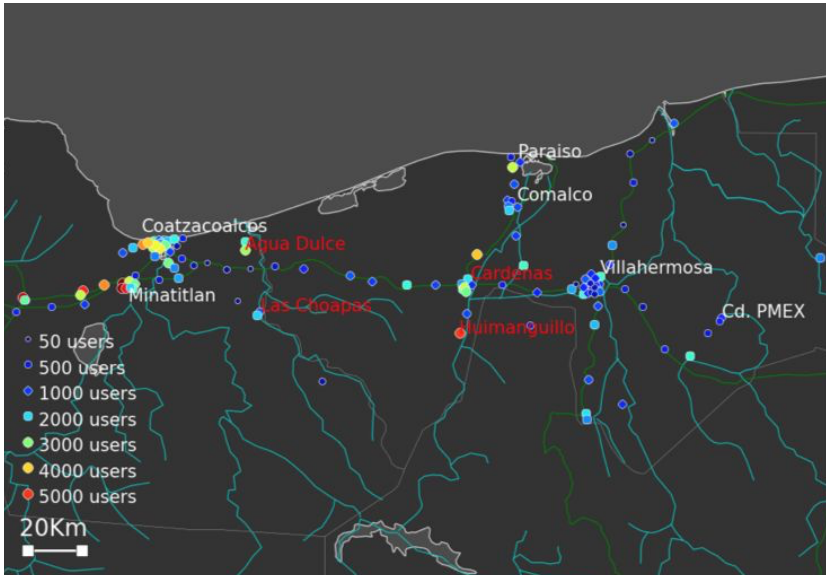
- El periodo base de estudio empezó con los datos de **01/11/2009**, aproximadamente un mes antes de las inundaciones. La información de las llamadas y usuarios que tuvieron actividad en Tabasco durante este periodo fueron considerados en el análisis.

- Para cada usuario, se determina la antena principal aquella que fue más utilizada en la noche en este periodo. **El objetivo es definir la antena que está más cerca del lugar en donde vive y por tanto, los usuarios que viven en cada municipio.**



Usuarios por municipio





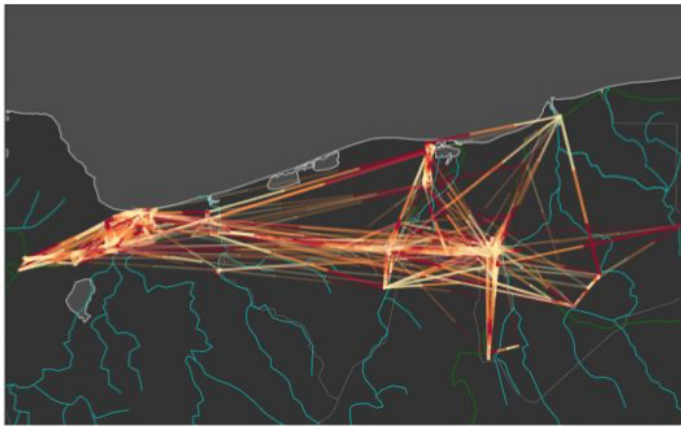
Métrica de variación

- Los datos de **cada antenas** fueron **agregados por día y hora** en la región afectada.
- Se define x(t) actividad de comunicación de la antena como el número de usuarios únicos que realizaron o recibieron alguna llamada en cada día. Para analizar el cambio en esta actividad, se propone una métrica de variación xnorm(t) tal que:
- **Variación en el patrón de llamadas**

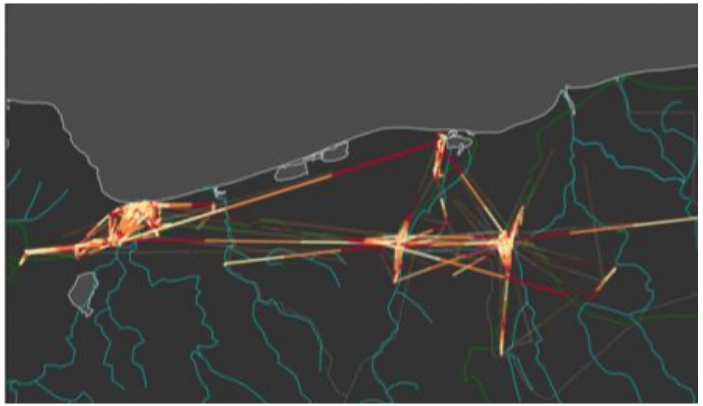
$$x_{norm}(t) = \frac{x(t) - \mu_{BL}}{\sigma_{BL}}$$

Desplazamientos

Desplazamientos poblacionales, considerando la métrica de variación. **En color rojo son salidas y en amarillo el desplazamiento a nuevos lugares.**



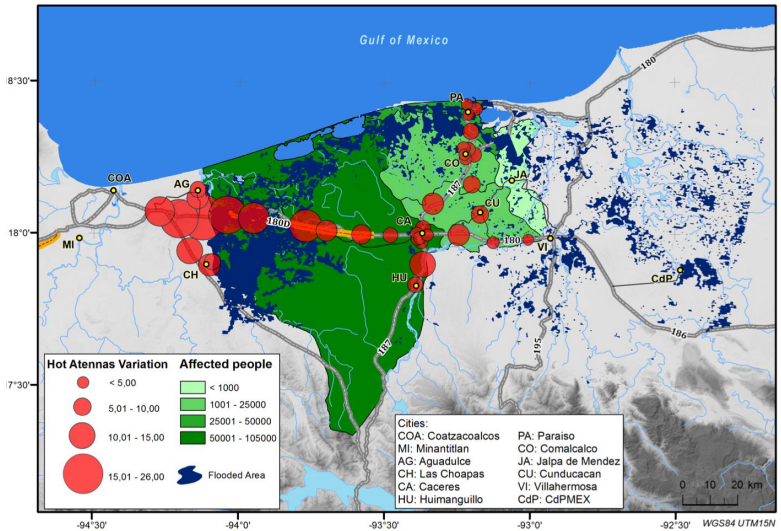
- Durante la inundación



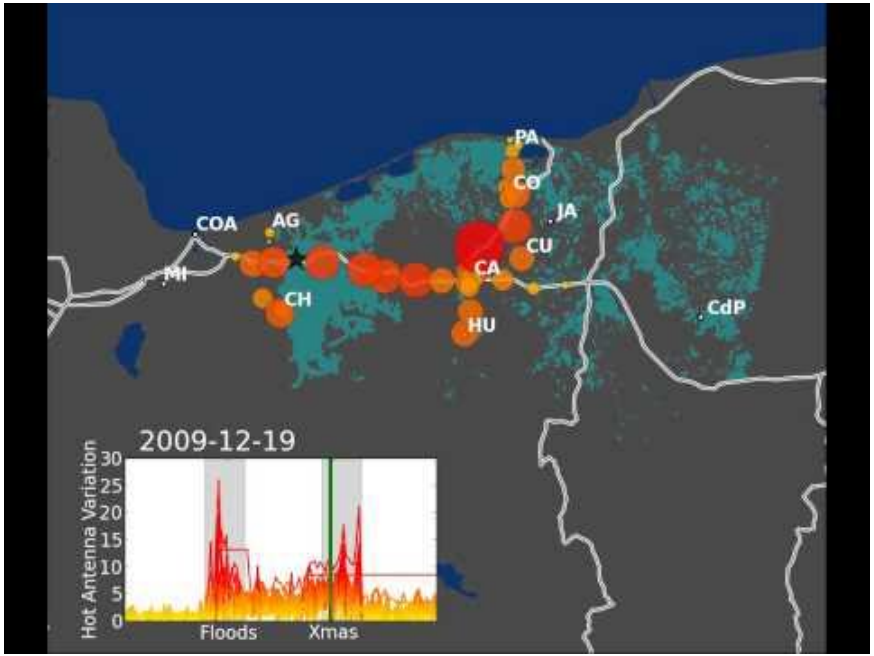
- Periodo aleatorio

Desplazamientos

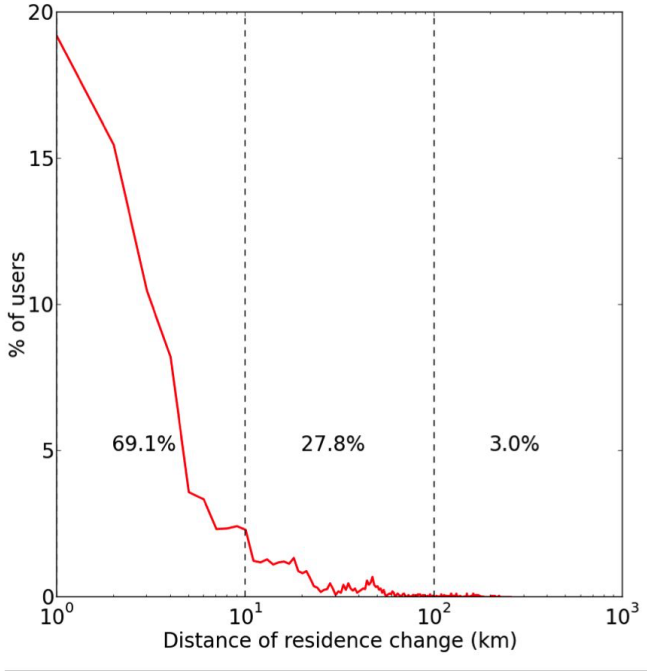
Los lugares con **mayor cambio en la métrica de variación, coinciden con las zonas más afectadas por las inundaciones**: los municipios de Cárdenas y Huimanguillo.



Animación

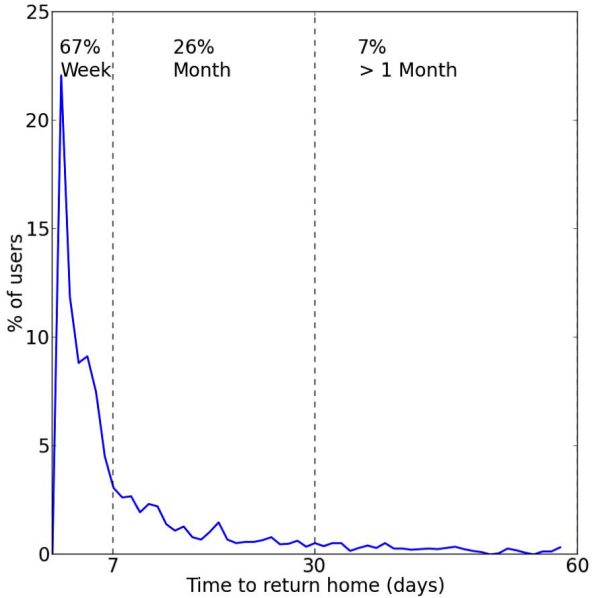

PA
CO
JA
COA
AG
CU
CA
MI
CH
HU
CdP
2009-12-19
Hot Antenna Variation
30
25
20
15
10
5
0
Floods
Xmas

Distancia



- La gráfica muestra la **distancia** recorrida entre el lugar donde se localiza la **antena principal de los usuarios y una nueva zona** debido al desplazamiento por las inundaciones.
    - El 70% de los usuarios se desplaza más de 10 kilómetros.
    - El 3% tuvo que desplazarse más de 100 kilómetros.

Tiempo



- Ahora se muestra el **tiempo promedio** que los usuarios tardan en **regresar a su lugar habitual**, a partir del primer desplazamiento.
    - El 70% de los usuarios tardó menos de una semana en regresar a casa.
    - El 7% de los usuarios duró más de un mes fuera.

Actividad y niveles de precipitación

- Las antenas con mayor cambio en la métrica de variación fueron las localizadas cerca de caminos, carreteras y autopistas.

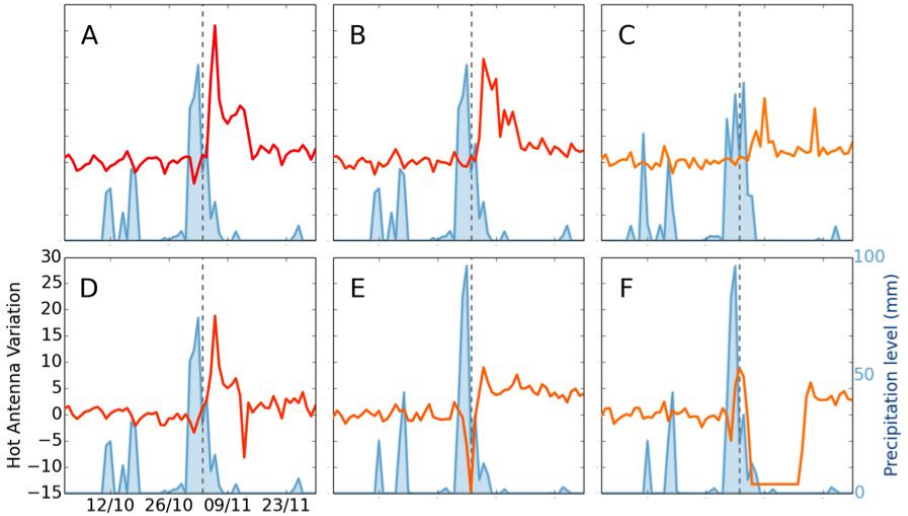
- Las antenas cercanas a la **carretera federal 180D tuvieron una gran variación, este camino terminó totalmente inundado**.



Actividad y niveles de precipitación

Para estudiar el uso en tiempo real de los teléfonos celulares, se **compara el nivel de precipitación por hora contra la métrica de variación en diferentes antenas**.

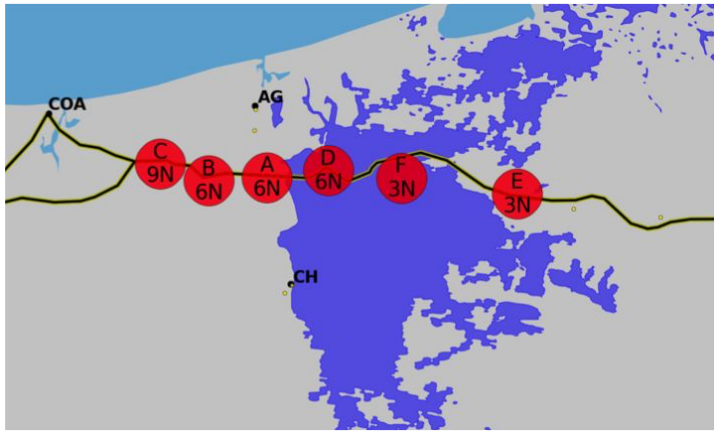
- Existe una diferencia de **cuatro días** entre el tiempo de la mayor variación en la actividad celular y la precipitación pluvial máxima.
- Esto sugiere que la **población no responde**, inmediatamente, a condiciones climatológicas extremas durante el periodo de alerta.



Referencias

- Una **alerta de Protección Civil** fue difundida el día **03/11/2009** en el estado, sin embargo, un **cambio en la métrica de variación sólo puede ser observado en dos antenas cercanas a la carretera federal 180D.**

- Durante el día **05/11/2009 y 06/11/2009 se registró un desbordamiento** en algunos ríos y presas debido a la precipitación pluvial de días anteriores. **La población empezó a reaccionar, al menos en términos de comunicación, hasta la inundación y no durante la alerta**.



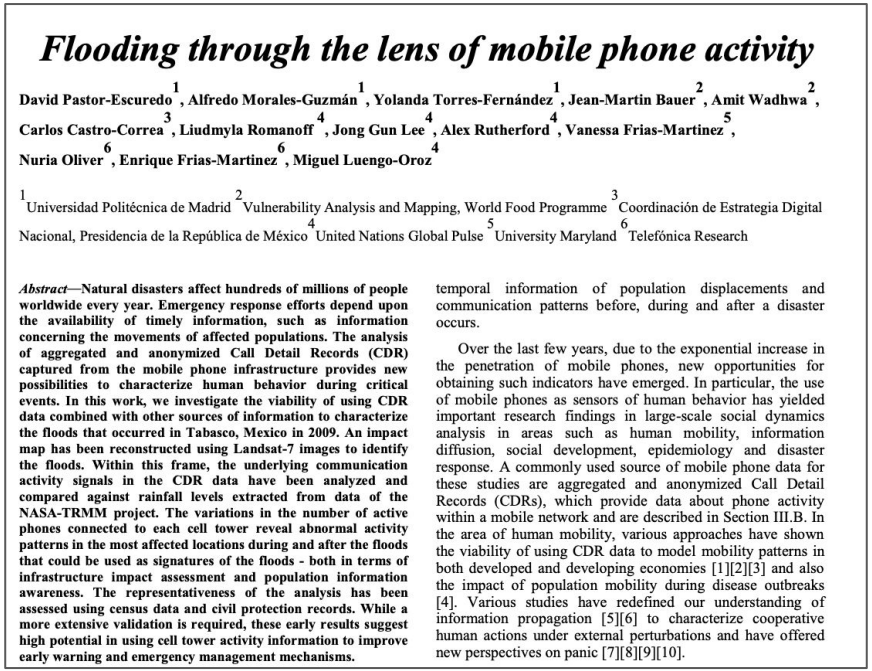
Referencias

- Liga 1
- Liga 2
- Liga 3



Referencias

- Liga 1
- Liga 2
- Liga 3



Flooding through the lens of mobile phone activity

David Pastor-Escuredo[1], Alfredo Morales-Guzmán[1], Yolanda Torres-Fernández[1], Jean-Martin Bauer[2], Amit Wadhwa[2], Carlos Castro-Correa[3], Liudmyla Romanoff[4], Jong Gun Lee[4], Alex Rutherford[4], Vanessa Frias-Martinez[5], Nuria Oliver[6], Enrique Frias-Martinez[6], Miguel Luengo-Oroz[4]

[1]Universidad Politécnica de Madrid [2]Vulnerability Analysis and Mapping, World Food Programme [3]Coordinación de Estrategia Digital Nacional, Presidencia de la República de México [4]United Nations Global Pulse [5]University Maryland [6]Telefónica Research

***Abstract*—Natural disasters affect hundreds of millions of people worldwide every year. Emergency response efforts depend upon the availability of timely information, such as information concerning the movements of affected populations. The analysis of aggregated and anonymized Call Detail Records (CDR) captured from the mobile phone infrastructure provides new possibilities to characterize human behavior during critical events. In this work, we investigate the viability of using CDR data combined with other sources of information to characterize the floods that occurred in Tabasco, Mexico in 2009. An impact map has been reconstructed using Landsat-7 images to identify the floods. Within this frame, the underlying communication activity signals in the CDR data have been analyzed and compared against rainfall levels extracted from data of the NASA-TRMM project. The variations in the number of active phones connected to each cell tower reveal abnormal activity patterns in the most affected locations during and after the floods that could be used as signatures of the floods - both in terms of infrastructure impact assessment and population information awareness. The representativeness of the analysis has been assessed using census data and civil protection records. While a more extensive validation is required, these early results suggest high potential in using cell tower activity information to improve early warning and emergency management mechanisms.**

temporal information of population displacements and communication patterns before, during and after a disaster occurs.

Over the last few years, due to the exponential increase in the penetration of mobile phones, new opportunities for obtaining such indicators have emerged. In particular, the use of mobile phones as sensors of human behavior has yielded important research findings in large-scale social dynamics analysis in areas such as human mobility, information diffusion, social development, epidemiology and disaster response. A commonly used source of mobile phone data for these studies are aggregated and anonymized Call Detail Records (CDRs), which provide data about phone activity within a mobile network and are described in Section III.B. In the area of human mobility, various approaches have shown the viability of using CDR data to model mobility patterns in both developed and developing economies [1][2][3] and also the impact of population mobility during disease outbreaks [4]. Various studies have redefined our understanding of information propagation [5][6] to characterize cooperative human actions under external perturbations and have offered new perspectives on panic [7][8][9][10].

¿Puedes identificar los elementos?

Global Pulse Tabasco

- **Definición de preguntas** de negocio o investigación (fundamental).
- **Bases de datos** internas + externas.
- **Análisis**.
- **Presentación** o herramienta (con diseño).

Machine Learning

Métricas para clasificación

Clase 3

ML y análisis de datos

ITAM

Situación

Imagina que tienes **5 algoritmos de ML clasificación** distintos para determinar si otorgas un crédito o no a una persona

Esquema

¿Cómo puedes determinar qué algoritmo **te conviene más**?



Métricas y evaluación

Al estudiar un problema con un enfoque de aprendizaje de máquina surgen las siguientes preguntas:

Técnico:

1. Tengo *n* distintos algoritmos pero**, ¿cómo puedo seleccionar el mejor?**

Métricas y evaluación

Al estudiar un problema con un enfoque de aprendizaje de máquina surgen las siguientes preguntas:

Técnico:

1. Tengo *n* distintos algoritmos pero, **¿cómo puedo seleccionar el mejor?**

Negocio:

2. ¿Cuánto me va a **costar implementarlo** con datos reales?
3. ¿**Cuánto tiempo** me va a tomar desarrollarlo? ¿**Cuántas personas** necesito contratar?

No es extraño que la limitante por decisión de **Negocio** ocurra en las aplicaciones reales

El punto **Técnico**, se puede resolver utilizando **métricas** para problemas de clasificación

Métricas ML clasificación

Todas las métricas y matrices que estudiaremos

en esta sección son para **problemas de clasificación**

Métrica: matriz de confusión

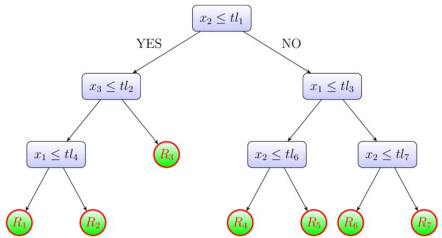
Aplicas un análisis para **detectar enfermedad a partir de una muestra de sangre (positivo** o **negativo)**



Por ahora,

considera que **ya sabes el resultado real** de cada análisis (**positivo** o **negativo**) gracias a **otro** estudio o criterio

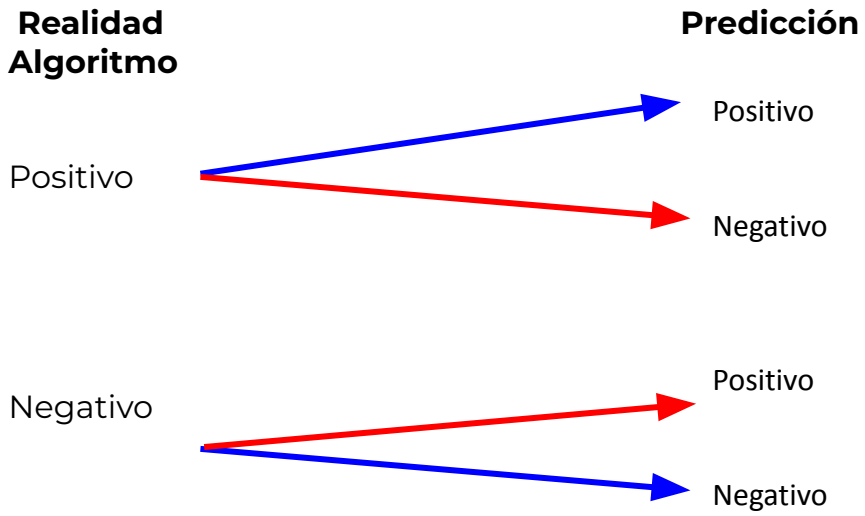
Pero quieres probar qué tan bien **habría funcionado** un nuevo algoritmo de ML para clasificación



¿Cómo podrías **organizar** estos resultados?



Métrica: matriz de confusión



Estos resultados se pueden presentar en una **Matriz de Confusión**

Resultados

Supón que estos son los **resultados del primer algoritmo** y responde a continuación:

1. ¿Cuántos positivos detectó correctamente?
2. ¿Cuántos positivos clasificó erróneamente como negativos?
3. ¿Cuántos negativos clasificó erróneamente como positivos?
4. ¿Cuántos registros clasificó correctamente (indep. de la etiqueta)?
5. ¿Cuántos registros en total se analizaron?

		Realidad	
		positivo	**negativo**
Predicción		69	5
		10	45

¿Cuáles son los componentes de una **matriz de confusión**?



Matriz de confusión

Positivos clasificados **correctamente** como positivos

vp: verdaderos positivos

	positivo	negativo	total
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Matriz de confusión

Negativos clasificados **correctamente** como negativos

vn: verdaderos negativos

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Matriz de confusión

Negativos clasificados **erróneamente** como positivos

fp: falsos positivos

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Matriz de confusión

Positivos clasificados **erróneamente** como negativos

fn: falsos negativos

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Matriz de confusión

Realidad

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Predicción

Matriz de confusión

De acuerdo a la naturaleza de este problema de **análisis de salud (positivo o negativo)**,

¿**Cuál consideras que sería la predicción más delicada / importante**?

	positivo	negativo
positivo.pred	vp	fp
negativo.pred	fn	vn
total	pos	neg



Analiza la **situación real** en cada una de las 4 entradas de la Matriz de Confusión



Matriz de confusión

fn (falsos negativos): una persona recibe un diagnóstico negativo, aunque **sí tiene la enfermedad**.

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Ahora considera que tienes **dos algoritmos ML clasificación** para resolver este problema...

Resultados

Supón que implementan otros dos algoritmos para analizar los **129** casos, **¿cuál es mejor?**

	positivo	negativo
	69	5
	10	45

	positivo	negativo
	69	31
	17	12

Resultados

Supón que implementan otros dos algoritmos para analizar los 129 casos, **¿cuál es mejor?**

Realidad (normalmente desconocida)

Predicción

	positivo	negativo
	69	5
	10	45

	positivo	negativo
	69	31
	17	12

Resultados

Supón que implementan otros dos algoritmos para analizar los 129 casos, **¿cuál es mejor?**

positivo	negativo
69	5
10	45

positivo	negativo
69	31
17	12

Resultados

Supón que implementan otros dos algoritmos para analizar los 129 casos, **¿cuál es mejor?**

positivo	negativo
69	5
10	45

positivo	negativo
69	31
17	12

Resultados

Supón que implementan otros dos algoritmos para analizar los 129 casos, **¿cuál es mejor?**

positivo	negativo
69	5
10	45

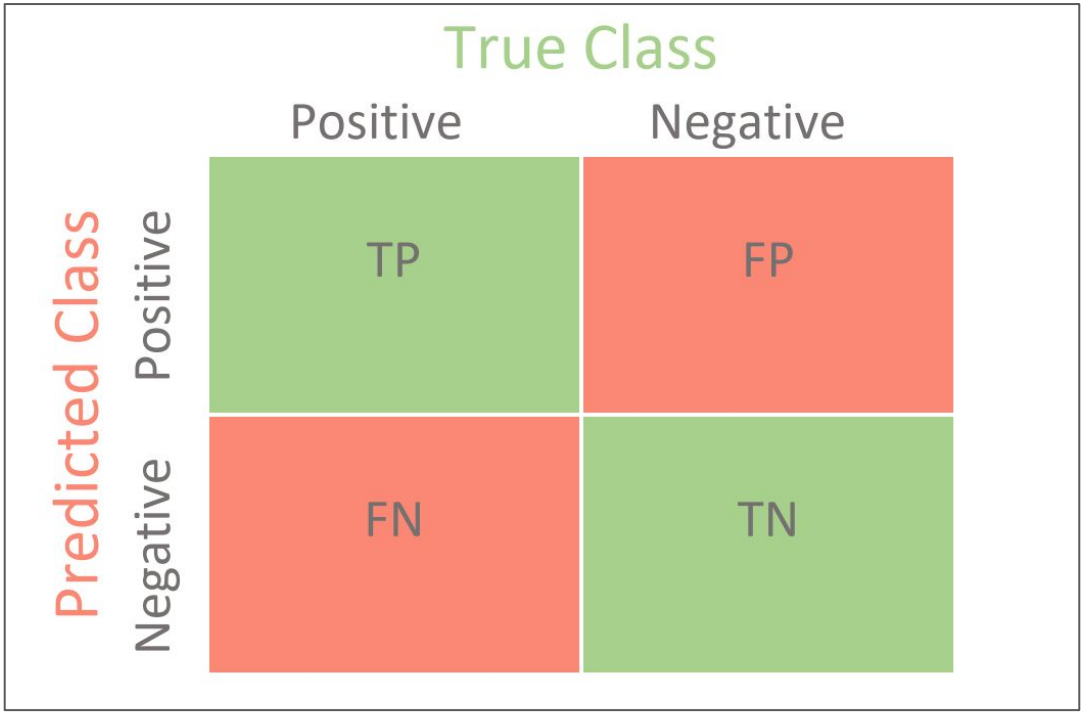
positivo	negativo
69	31
17	12

Machine Learning

Intuitivamente, queremos algoritmos que acumulen **más** casos en la **diagonal** (*Accuracy)*

sin embargo, esto **depende de la naturaleza del problema**

Matriz de confusión



Machine Learning

Además de la matriz de confusión **existen otras métricas**

muy útiles para evaluar un algoritmo

Entradas Matriz de confusión

Construcción de métricas **a partir de estos indicadores**:

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Métricas

Otras **métricas** para algoritmos de **clasificación**:

- Tasa de falsos positivos: proporción de veces que nos equivocamos en la clasificación para casos negativos.

$$\frac{fp}{fp + nv} = \frac{fp}{neg}$$

- Tasa de falsos negativos: proporción de veces que nos equivocamos en la clasificación para casos positivos.

$$\frac{fn}{pv + fn} = \frac{fn}{pos}$$

Analicemos la **tasa de falsos positivos**



Tasa de falsos positivos

- Tasa de falsos positivos: proporción de veces que nos equivocamos en la clasificación para casos negativos.

$$\frac{fp}{fp + nv} = \frac{fp}{neg}$$

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Tasa de falsos positivos

- Tasa de falsos positivos: proporción de veces que nos equivocamos en la clasificación para casos negativos.

$$\frac{fp}{fp + nv} = \frac{fp}{neg}$$

Negativos que clasifiqué erroneamente como positivos... 🤓

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Tasa de falsos positivos

- Tasa de falsos positivos: proporción de veces que nos equivocamos en la clasificación para casos negativos.

$$\frac{fp}{fp + nv} = \frac{fp}{neg}$$

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Métricas Complementarias (a tasas falsos)

Otras **métricas** para algoritmos de **clasificación**:

- Especificidad: tasa de correctos entre negativos, es el complemento de la tasa de falsos positivos.

$$\frac{vn}{fp + vn} = \frac{vn}{neg}$$

- Sensibilidad o Recall o Exhaustividad: tasa de correctos entre positivos, es el complemento de la tasa de falsos negativos.

$$\frac{vp}{vp + fn} = \frac{vp}{pos}$$

Métricas

Otras **métricas** para algoritmos de **clasificación**:

- Precisión o valor predictivo positivo: tasa de correctos entre todos los que *clasificamos* como positivos

$$\frac{vp}{vp + fp} = \frac{vp}{pred.\,pos}$$

- Valor predictivo negativo: tasa de correctos entre todos los que *clasificamos* como negativos

$$\frac{vn}{fn + vn} = \frac{vn}{pred.\,neg}$$

Métricas

Otras **métricas** para algoritmos de **clasificación**:

- **Tasa de clasificación incorrecta**

$$\frac{fn + fv}{neg + pos}$$

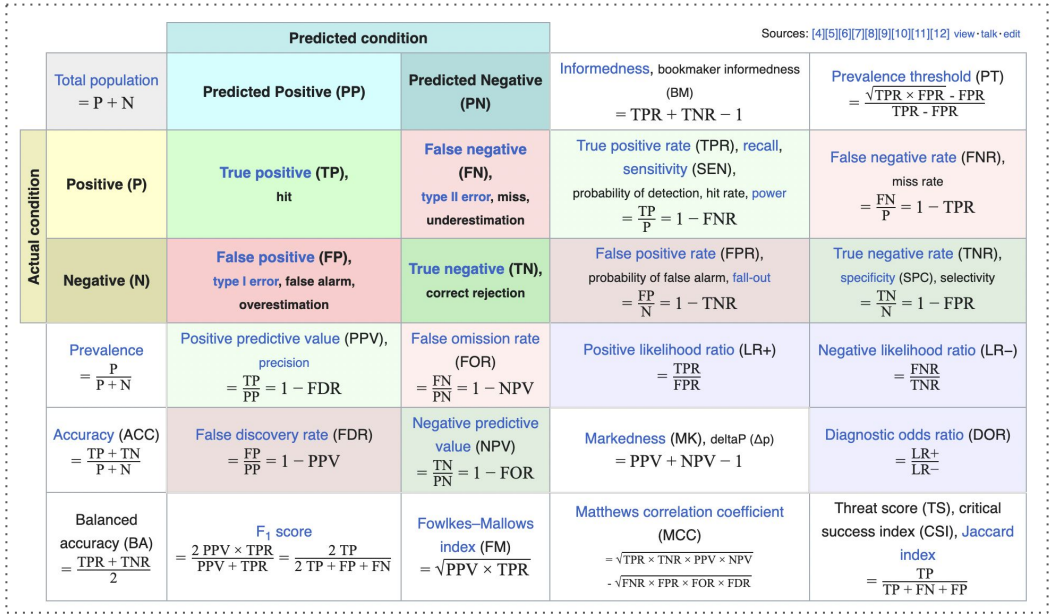
Y existen otras medidas que intentan resumir los dos tipos de errores de distinta manera, como

- **Medida F** (media armónica de precisión y recall)

$$2\frac{precision \cdot recall}{precision + recall}$$

Lista de Métricas

Si quieres conocer una lista más grande de posibles métricas, ingresa en el siguiente enlace
Seleccionar la o las métricas correctas para cada problema es clave



		Predicted condition		Sources: [4][5][6][7][8][9][10][11][12] view · talk · edit	
	Total population $= P + N$	**Predicted Positive (PP)**	**Predicted Negative (PN)**	Informedness, bookmaker informedness (BM) $= TPR + TNR - 1$	Prevalence threshold (PT) $= \frac{\sqrt{TPR \times FPR} - FPR}{TPR - FPR}$
Actual condition	**Positive (P)**	**True positive (TP),** hit	**False negative (FN),** type II error, miss, underestimation	True positive rate (TPR), recall, sensitivity (SEN), probability of detection, hit rate, power $= \frac{TP}{P} = 1 - FNR$	False negative rate (FNR), miss rate $= \frac{FN}{P} = 1 - TPR$
	Negative (N)	**False positive (FP),** type I error, false alarm, overestimation	**True negative (TN),** correct rejection	False positive rate (FPR), probability of false alarm, fall-out $= \frac{FP}{N} = 1 - TNR$	True negative rate (TNR), specificity (SPC), selectivity $= \frac{TN}{N} = 1 - FPR$
	Prevalence $= \frac{P}{P + N}$	Positive predictive value (PPV), precision $= \frac{TP}{PP} = 1 - FDR$	False omission rate (FOR) $= \frac{FN}{PN} = 1 - NPV$	Positive likelihood ratio (LR+) $= \frac{TPR}{FPR}$	Negative likelihood ratio (LR−) $= \frac{FNR}{TNR}$
	Accuracy (ACC) $= \frac{TP + TN}{P + N}$	False discovery rate (FDR) $= \frac{FP}{PP} = 1 - PPV$	Negative predictive value (NPV) $= \frac{TN}{PN} = 1 - FOR$	Markedness (MK), deltaP (Δp) $= PPV + NPV - 1$	Diagnostic odds ratio (DOR) $= \frac{LR+}{LR-}$
	Balanced accuracy (BA) $= \frac{TPR + TNR}{2}$	F_1 score $= \frac{2\,PPV \times TPR}{PPV + TPR} = \frac{2\,TP}{2\,TP + FP + FN}$	Fowlkes–Mallows index (FM) $= \sqrt{PPV \times TPR}$	Matthews correlation coefficient (MCC) $= \sqrt{TPR \times TNR \times PPV \times NPV} - \sqrt{FNR \times FPR \times FOR \times FDR}$	Threat score (TS), critical success index (CSI), Jaccard index $= \frac{TP}{TP + FN + FP}$

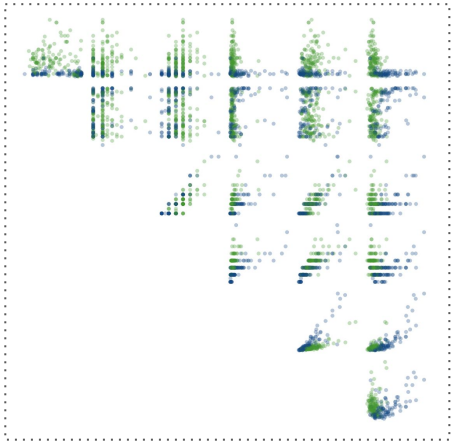
Observa que para seleccionar “el **mejor** algoritmo”,

antes debes **decidir el criterio o métrica**

Deptos NY - SFO

En el problema de los departamentos, podrías responder preguntas más específicas sobre las eficiencia de tus modelos, **por ejemplo:**

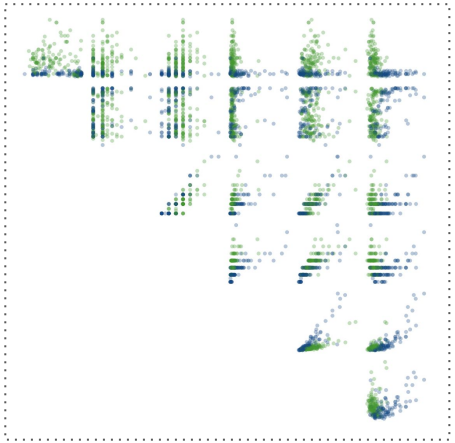
- ¿Qué porcentaje del **total** de registros clasifica correctamente?
- Respecto a los depto en **NY**, ¿cuántos clasifica correctamente?
- Respecto a los depto en **SFO**, ¿cuántos clasifica correctamente?
- ¿Qué porcentaje del **total** de registros clasifica erróneamente?



Deptos NY - SFO

En el problema de los departamentos, podrías responder preguntas más específicas sobre las eficiencia de tus modelos, **por ejemplo:**

- ¿Qué porcentaje del **total** de registros clasifica correctamente?
- Respecto a los depto en **NY**, ¿cuántos clasifica correctamente?
- Respecto a los depto en **SFO**, ¿cuántos clasifica correctamente?
- ¿Qué porcentaje del **total** de registros clasifica erróneamente?



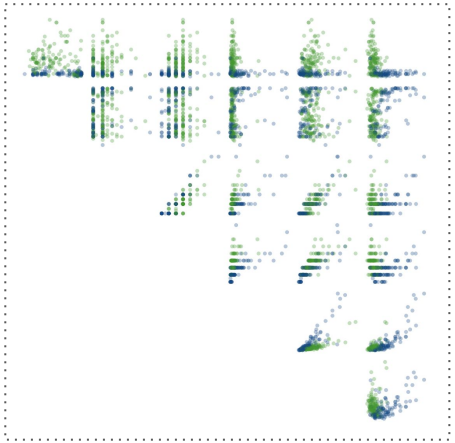
Deptos NY - SFO

En el problema de los departamentos, podrías responder preguntas más específicas sobre las eficiencia de tus modelos, **por ejemplo:**

- ¿Qué porcentaje del **total** de registros clasifica correctamente?
- Respecto a los depto en **NY**, ¿cuántos clasifica correctamente?
- Respecto a los depto en **SFO**, ¿cuántos clasifica correctamente?
- ¿Qué porcentaje del **total** de registros clasifica erróneamente?

🤓

Tasas de falsos
y sus complementos



Machine Learning

¿Cómo cambiaría la matriz de confusión si tuvieras **3 clases**?

A, B y C



Predicción

Matriz de confusión (3 clases)

Realidad

A,A	A,B	A,C
B,A	B,B	B,C
C,A	C,B	C,C

Predicción

Matriz de confusión (3 clases)

Realidad

A,A	A,B	A,C
B,A	B,B	B,C
C,A	C,B	C,C

Matriz de confusión (3 clases)

Ejemplo: ¿Cómo armar matriz de confusión con una BD?

Ejemplo: Matriz de confusión (3 clases)

¿Cómo podemos armar una matriz de confusión dada una BD?

Descarga la siguiente BD en csv - Predicciones
Liga



Machine learning

Arma la matriz de confusión en Excel

Toma **5 minutos** para realizarlo

