Introducción a *ML* y algoritmos de IA

ML & algoritmos AI

Profesor Carlos Castro Correa
Clase 3

ITAM

Redes Neuronales

Redes Neuronales

Se puede definir como una serie de **nodos** (neuronas) y **múltiples capas** que ayudan a realizar predicciones.

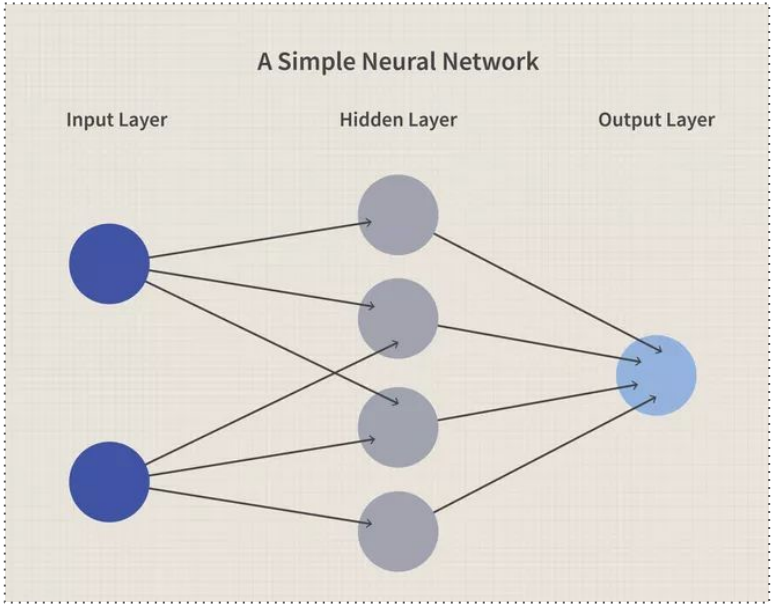

Redes Neuronales

Se puede definir como una serie de nodos (neuronas) y múltiples capas que ayudan a realizar predicciones.

- Este modelo es muy popular y está inspirado en el funcionamiento del cerebro
- Depende mucho del poder de procesamiento computacional (**recursos de computación**)
- **Deficiencia: es complicado entender por qué predice o clasifica de cierta forma**

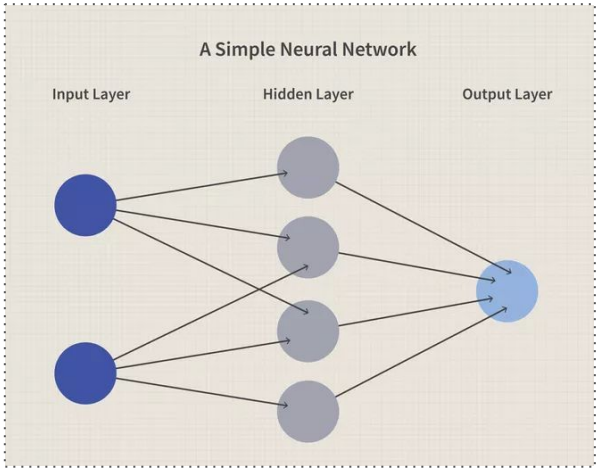

¿Por qué les dicen redes **“neuronales”**?

Neuronas en el cerebro

Conexiones e interacciones entre neuronas

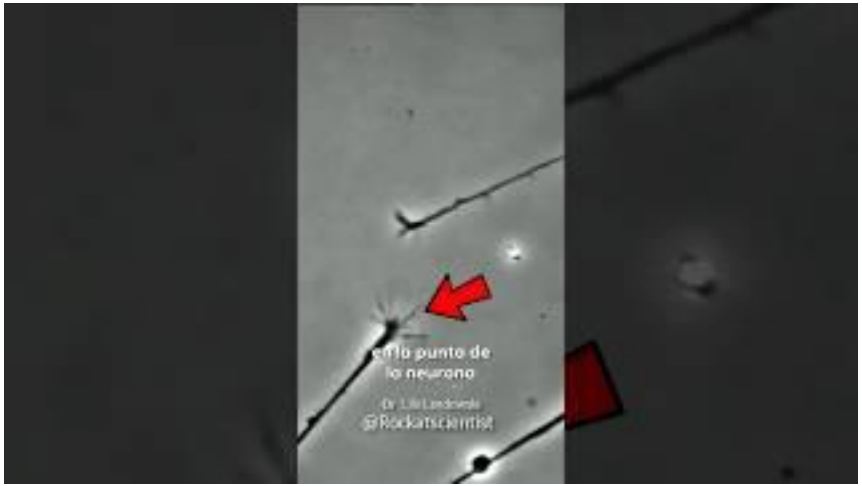

Podríamos pensar que en una BD,

las **neuronas son las variables**

Situación inicial

BD original

in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation
0	2	1	999000	1960	1000	999	10
0	2	2	2750000	2006	1418	1939	0
0	2	2	1350000	1900	2150	628	9
0	1	1	629000	1903	500	1258	9
0	0	1	439000	1930	500	878	10
0	0	1	439000	1930	500	878	10
0	1	1	475000	1920	500	950	10
0	1	1	975000	1930	900	1083	10
0	1	1	975000	1930	900	1083	12
0	2	1	1895000	1921	1000	1895	12
0	3	3	2095000	1926	2200	952	4
0	1	1	999000	1982	784	1274	5
0	1	1	999000	1982	784	1274	5
0	1	1	1249000	1987	826	1512	3
0	0	1	1110000	2008	698	1590	5
0	2	2	2059500	2008	1373	1500	5
0	2	2	2000000	1928	1200	1667	10
0	1	1	715000	1903	557	1284	3
0	2	2	2498000	2005	1260	1983	2
0	2	1.5	2650000	1915	2500	1060	5

Conexiones neuronales en los datos

Interacción

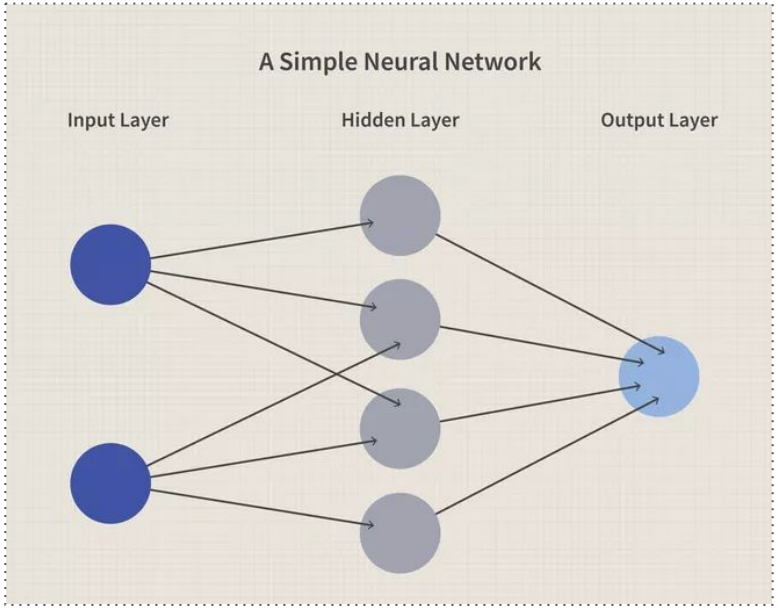

Conexiones neuronales en los datos

Datos originales

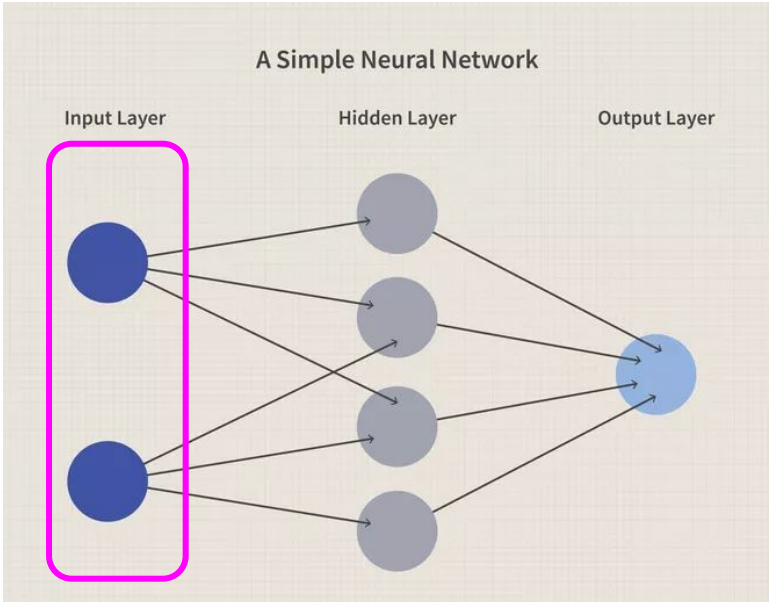

Conexiones neuronales en los datos

Interacciones y conexiones

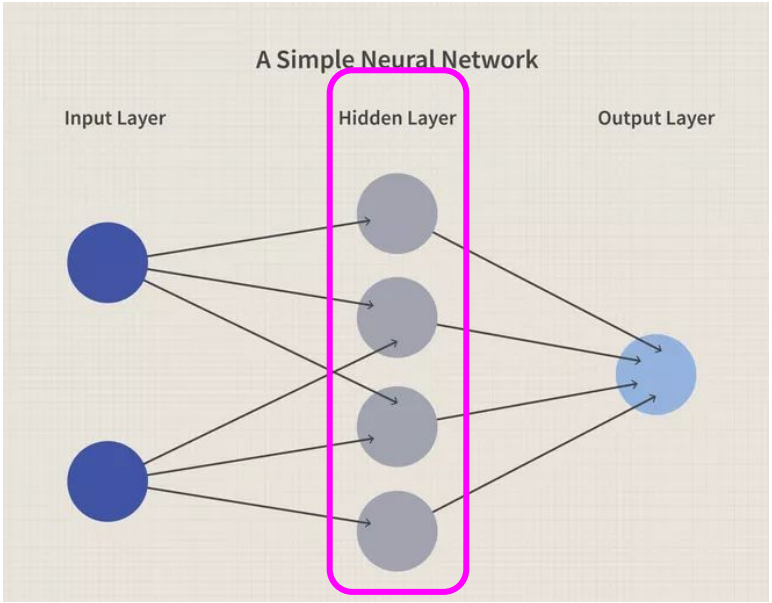

A partir de las variables originales, se crean **nuevas variables**

Nuevas variables

in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation
0	2	1	999000	1960	1000	999	10
0	2	2	2750000	2006	1418	1939	0
0	2	2	1350000	1900	2150	628	9
0	1	1	629000	1903	500	1258	9
0	0	1	439000	1930	500	878	10
0	0	1	439000	1930	500	878	10
0	1	1	475000	1920	500	950	10
0	1	1	975000	1930	900	1083	10
0	1	1	975000	1930	900	1083	12
0	2	1	1895000	1921	1000	1895	12
0	3	3	2095000	1926	2200	952	4
0	1	1	999000	1982	784	1274	5
0	1	1	999000	1982	784	1274	5
0	1	1	1249000	1987	826	1512	3
0	0	1	1110000	2008	698	1590	5
0	2	2	2059500	2008	1373	1500	5
0	2	2	2000000	1928	1200	1667	10
0	1	1	715000	1903	557	1284	3
0	2	2	2498000	2005	1260	1983	2
0	2	1.5	2650000	1915	2500	1060	5
0	2	2	3450000	1900	1850	1865	9
0	1	1	3105000	2016	1108	2802	10
0	4	5	13750000	2016	3699	3717	10
0	2	2	1185000	1900	1000	1185	4

Nuevas variables

in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation	X1	X2	X3	X4	X5	X6
0	2	1	999000	1960	1000	999	10	1008990	992467.689	-990	115,122,331,690.00	10,475,018,292,970.00	3,767.66
0	2	2	2750000	2006	1418	1939	0	2750000	0	-1418	117,824,182,716.00	10,720,860,336,504.00	-
0	2	2	1350000	1900	2150	628	9	1355652	823326.836	-2141	111,598,179,859.00	10,154,353,801,809.00	3,029.88
0	1	1	629000	1903	500	1258	9	640322	795351.384	-491	111,774,385,858.00	10,170,387,924,537.00	2,931.55
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62
0	1	1	475000	1920	500	950	10	484500	667358.96	-490	112,772,895,870.00	10,261,242,679,930.00	2,481.76
0	1	1	975000	1930	900	1083	10	985830	1020705.84	-890	113,360,255,100.00	10,314,686,428,090.00	3,815.55
0	1	1	975000	1930	900	1083	12	987996	1224847.01	-888	113,360,255,102.00	10,314,686,428,092.00	4,578.66
0	2	1	1895000	1921	1000	1895	12	1917740	2259130.65	-988	112,831,632,255.00	10,266,586,795,308.00	8,405.59
0	3	3	2095000	1926	2200	952	4	2098808	561124.419	-2196	113,125,312,862.00	10,293,308,105,380.00	2,093.22
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06
0	1	1	1249000	1987	826	1512	3	1253536	409556.627	-823	116,708,200,350.00	10,619,317,120,251.00	1,576.20
0	0	1	1110000	2008	698	1590	5	1117950	659850.771	-693	117,941,653,767.00	10,731,549,537,341.00	2,566.31
0	2	2	2059500	2008	1373	1500	5	2067000	873066.693	-1368	117,941,654,442.00	10,731,549,156,641.00	3,395.55
0	2	2	2000000	1928	1200	1667	10	2016670	1814166.37	-1190	113,242,783,634.00	10,303,997,464,138.00	6,774.60
0	1	1	715000	1903	557	1284	3	718852	285604.315	-554	111,774,385,909.00	10,170,387,892,383.00	1,052.70
0	2	2	2498000	2005	1260	1983	2	2501966	442271.415	-1258	117,765,446,677.00	10,715,516,028,242.00	1,717.52
0	2	1.5	2650000	1915	2500	1060	5	2655300	832524	-2495	112,479,218,450.00	10,234,519,565,045.00	3,087.91
0	2	2	3450000	1900	1850	1865	9	3466785	2268078.59	-1841	111,598,179,559.00	10,154,353,971,009.00	8,346.63
0	1	1	3105000	2016	1108	2802	10	3133020	2930143.56	-1098	118,411,541,246.00	10,774,304,485,114.00	11,441.40
0	4	5	13750000	2016	3699	3717	10	13787170	7102080.9	-3689	118,411,543,837.00	10,774,303,023,790.00	27,731.65
0	2	2	1185000	1900	1000	1185	4	1189740	470900.585	-996	111,598,178,704.00	10,154,354,450,404.00	1,732.94

Nuevas variables

Creadas a partir de la **BD original**

in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation	X1	X2	X3	X4	X5	X6
0	2	1	999000	1960	1000	999	10	1008990	992467.689	-990	115,122,331,690.00	10,475,018,292,970.00	3,767.66
0	2	2	2750000	2006	1418	1939	0	2750000	0	-1418	117,824,182,716.00	10,720,860,336,504.00	-
0	2	2	1350000	1900	2150	628	9	1355652	823326.836	-2141	111,598,179,859.00	10,154,353,801,809.00	3,029.88
0	1	1	629000	1903	500	1258	9	640322	795351.384	-491	111,774,385,858.00	10,170,387,924,537.00	2,931.55
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62
0	1	1	475000	1920	500	950	10	484500	667358.96	-490	112,772,895,870.00	10,261,242,679,930.00	2,481.76
0	1	1	975000	1930	900	1083	10	985830	1020705.84	-890	113,360,255,100.00	10,314,686,428,090.00	3,815.55
0	1	1	975000	1930	900	1083	12	987996	1224847.01	-888	113,360,255,102.00	10,314,686,428,092.00	4,578.66
0	2	1	1895000	1921	1000	1895	12	1917740	2259130.65	-988	112,831,632,255.00	10,266,586,795,308.00	8,405.59
0	3	3	2095000	1926	2200	952	4	2098808	561124.419	-2196	113,125,312,862.00	10,293,308,105,380.00	2,093.22
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06
0	1	1	1249000	1987	826	1512	3	1253536	409556.627	-823	116,708,200,350.00	10,619,317,120,251.00	1,576.20
0	0	1	1110000	2008	698	1590	5	1117950	659850.771	-693	117,941,653,767.00	10,731,549,537,341.00	2,566.31
0	2	2	2059500	2008	1373	1500	5	2067000	873066.693	-1368	117,941,654,442.00	10,731,549,156,641.00	3,395.55
0	2	2	2000000	1928	1200	1667	10	2016670	1814166.37	-1190	113,242,783,634.00	10,303,997,464,138.00	6,774.60
0	1	1	715000	1903	557	1284	3	718852	285604.315	-554	111,774,385,909.00	10,170,387,892,383.00	1,052.70
0	2	2	2498000	2005	1260	1983	2	2501966	442271.415	-1258	117,765,446,677.00	10,715,516,028,242.00	1,717.52
0	2	1.5	2650000	1915	2500	1060	5	2655300	832524	-2495	112,479,218,450.00	10,234,519,565,045.00	3,087.91
0	2	2	3450000	1900	1850	1865	9	3466785	2268078.59	-1841	111,598,179,559.00	10,154,353,971,009.00	8,346.63
0	1	1	3105000	2016	1108	2802	10	3133020	2930143.56	-1098	118,411,541,246.00	10,774,304,485,114.00	11,441.40
0	4	5	13750000	2016	3699	3717	10	13787170	7102080.9	-3689	118,411,543,837.00	10,774,303,023,790.00	27,731.65
0	2	2	1185000	1900	1000	1185	4	1189740	470900.585	-996	111,598,178,704.00	10,154,354,450,404.00	1,732.94

¿Cómo modelar la interacción entre **variables** (**neuronas**) de nuestra BD?

Interacción entre variables

Abre el archivo de Excel **redes_neuronales.xlsx**

Revisa las **fórmulas** de las variables X1, X2, X3, X4 y X5

Interacción entre variables

Variables nuevas:

X1 = (Elevation * Year_Built) + Price

X2 = (3.1416 * price_per_sqft * elevation) * raiz(sqft)

X3 = elevation - sqft

¿Qué significan estas **nuevas** variables?

Posteriormente se sigue un **proceso mucho más técnico** que involucra matemáticas,

funciones **sigmoide e iteraciones** sobre todos los datos (originales y creados)

Referencia 1
Referencia 2
Referencia 3

¿Por qué creamos estas **nuevas** variables que son **difíciles de interpretar**?

Aumentar variables e **interacciones**,

podría mejorar la precisión de las predicciones de un modelo de ML (por ejemplo, el ***accuracy***)

*in_sf	beds	bath	price	year_built	sqft	price_per_sq	elevation	X1	X2	X3	X4	X5	X6	
0	2	1	999000	1960	1000	999	10	1008990	992467.689	-990	115,122,331,690.00	10,475,018,292,970.00	3,767.66	*
0	2	2	2750000	2006	1418	1939	0	2750000	0	-1418	117,824,182,716.00	10,720,860,336,504.00	-	*
0	2	2	1350000	1900	2150	628	9	1355652	823326.836	-2141	111,598,179,859.00	10,154,353,801,809.00	3,029.88	*
0	1	1	629000	1903	500	1258	9	640322	795351.384	-491	111,774,385,858.00	10,170,387,924,537.00	2,931.55	*
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62	*
0	0	1	439000	1930	500	878	10	447780	616780.176	-490	113,360,254,700.00	10,314,686,653,690.00	2,305.62	*
0	1	1	475000	1920	500	950	10	484500	667358.96	-490	112,772,895,870.00	10,261,242,679,930.00	2,481.76	*
0	1	1	975000	1930	900	1083	10	985830	1020705.84	-890	113,360,255,100.00	10,314,686,428,090.00	3,815.55	*
0	1	1	975000	1930	900	1083	12	987996	1224847.01	-888	113,360,255,102.00	10,314,686,428,092.00	4,578.66	*
0	2	1	1895000	1921	1000	1895	12	1917740	2259130.65	-988	112,831,632,255.00	10,266,586,795,308.00	8,405.59	*
0	3	3	2095000	1926	2200	952	4	2098808	561124.419	-2196	113,125,312,862.00	10,293,308,105,380.00	2,093.22	*
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06	*
0	1	1	999000	1982	784	1274	5	1005370	560335.776	-779	116,414,520,895.00	10,592,595,157,061.00	2,151.06	*
0	1	1	1249000	1987	826	1512	3	1253536	409556.627	-823	116,708,200,350.00	10,619,317,120,251.00	1,576.20	*
0	0	1	1110000	2008	698	1590	5	1117950	659850.771	-693	117,941,653,767.00	10,731,549,537,341.00	2,566.31	*
0	2	2	2059500	2008	1373	1500	5	2067000	873066.693	-1368	117,941,654,442.00	10,731,549,156,641.00	3,395.55	*
0	2	2	2000000	1928	1200	1667	10	2016670	1814166.37	-1190	113,242,783,634.00	10,303,997,464,138.00	6,774.60	*
0	1	1	715000	1903	557	1284	3	718852	285604.315	-554	111,774,385,909.00	10,170,387,892,383.00	1,052.70	*
0	2	2	2498000	2005	1260	1983	2	2501966	442271.415	-1258	117,765,446,677.00	10,715,516,028,242.00	1,717.52	*
0	2	1.5	2650000	1915	2500	1060	5	2655300	832524	-2495	112,479,218,450.00	10,234,519,565,045.00	3,087.91	*
0	2	2	3450000	1900	1850	1865	9	3466785	2268078.59	-1841	111,598,179,559.00	10,154,353,971,009.00	8,346.63	*
0	1	1	3105000	2016	1108	2802	10	3133020	2930143.56	-1098	118,411,541,246.00	10,774,304,485,114.00	11,441.40	*
0	4	5	13750000	2016	3699	3717	10	13787170	7102080.9	-3689	118,411,543,837.00	10,774,303,023,790.00	27,731.65	*
0	2	2	1185000	1900	1000	1185	4	1189740	470900.585	-996	111,598,178,794.00	10,154,354,450,404.00	1,732.94	*

¿Si agregamos **cualquier variable**, debería entonces aumentar la precisión de nuestro ML?

En general, **No**

Variables relacionadas

En general, las variables que incluyas deberían tener un **impacto o relación con la variable a pronosticar**

Por ejemplo, en los deptos NY-SFO, es natural pensar que las siguientes variables tienen una **relación con el lugar en donde se ubica la vivienda**:

- Metro cuadrado
- Precio
- Habitaciones
- Año de construcción

Por otro lado, **¿crees que mejoraría la precisión? Si incluimos como variables:**

- Número de letras del nombre del propietario
- Promedio de la Universidad del propietario
- Edad promedio de los inquilinos de la vivienda

Seguramente estas variables no aportan nada a mejorar la predicción del ML, y si lo hacen podrían ser **relaciones espurias**

Relaciones espurias

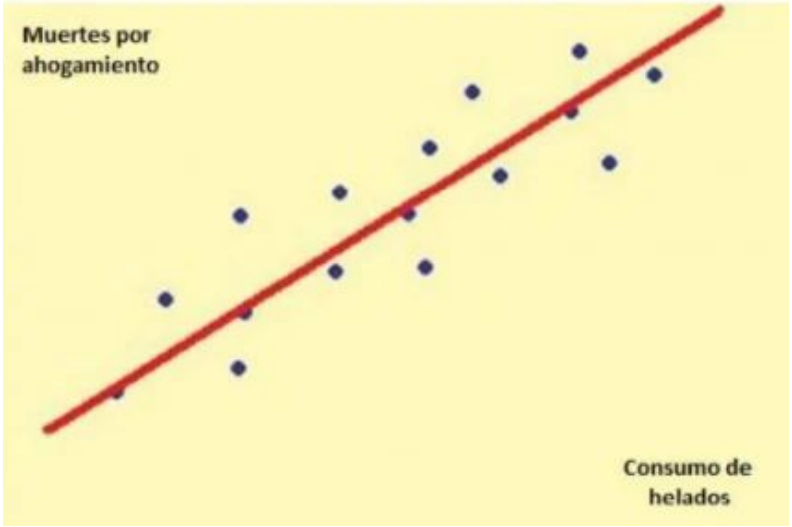

¿Existe una relación **causal** entre la venta de **helados** y la muerta por **ahogamientos** en el mar?

Relaciones espurias

Las ventas de helado y el número de personas que nadan,

aumentan cuando hace calor

¿Cuál es la **gran desventaja** de los modelos de redes neuronales?

Redes neuronales

Imagina que necesitas un modelo de ***score* de crédito** para otorgar un **préstamos** o no a una persona,

* ¿Te interesa saber **por qué lo descartas**? Por ejemplo, nivel de ingreso, escolaridad, etc.

Piensa que le tienes que **explicar claramente** por qué no se lo diste (o al regulador)

¿Le podrías decir que la variable **X2** resultó **poco favorable** en su análisis de crédito?

X2 = (3.1416 * price_per_sqft * elevation) * raiz(sqft)

¿Cómo interpretar esto?

Interpretación

En estos problemas necesitarías un modelo que te ayude a **entender el impacto de las variables originales**:

- Edad
- Salario
- Saldo promedio en la tarjeta de crédito
- Nivel de escolaridad

Interpretación

En estos problemas necesitarías un modelo que te ayude a **entender el impacto de las variables originales**:

- Edad
- Salario
- Saldo promedio en la tarjeta de crédito
- Nivel de escolaridad

“No le otorgamos el crédito porque su salario es insuficiente para el monto y plazo solicitado”

Por otro lado, **no siempre es tan importante** entender la relación entre las variables y la predicción

Redes neuronales

Supón que tiene un **millón de imágenes de perritos y gatitos**... construyes una red neuronal y clasifica **perfecto**

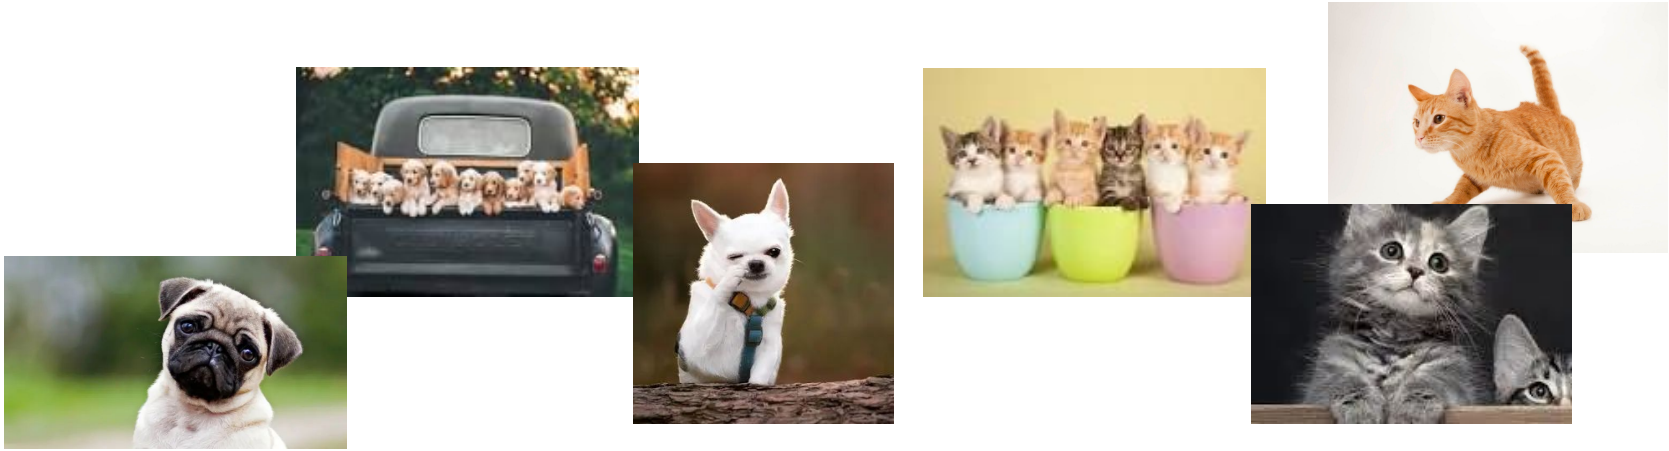

¿Te interesa **mucho** saber **por qué** clasifica así cada observación?

NO, sólo me interesa asignar correctamente la **mayor cantidad posible**

Gran cantidad de las **herramientas modernas de AI** utilizan redes neuronales (*ChatGPT*),

por eso es fundamental entender su **funcionamiento, alcances y las reglas con las que deben operar**

Reflexiones al momento

¿Una red neuronal (ChatGPT) **piensa**?

¿Una máquina puede **abstraer** como lo hace el **cerebro** humano?

¿Las máquinas producen discursos **racistas** por vonlutad propia?

...

Nota: **el dominio de cada técnica requiere mucho tiempo y estudio,**

podríamos hacer un curso para cada una...

Ejercicios

Toma 10 minutos para este ejercicio

Considerando este modelo de regresión logística, el árbol y los datos de deptos NY-SFO de la Clase 2, responde lo siguiente:

- ¿Qué modelo tiene mejor ***accuracy***? ¿El árbol o la regresión logística?
- **¿Qué modelo pronóstica con más precisión las viviendas de NY?**
- **¿Qué modelo pronóstica con más precisión las viviendas de SFO?**
- ¿Qué modelo **tarda más tiempo en correr**? ¿Cómo lo podrías medir?

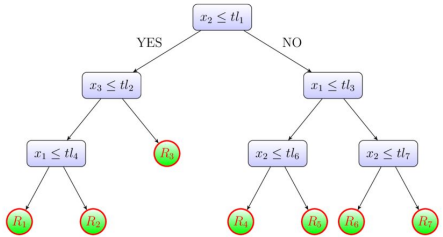

Algoritmos en R

Tiempo de procesamiento Clase_3_4. R

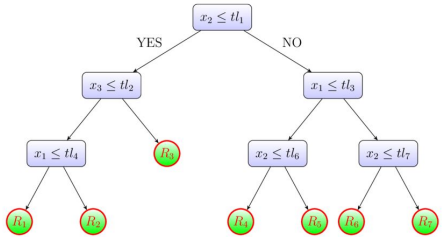

Machine Learning

Métricas para clasificación

Clase 3

ML y análisis de datos

ITAM

Situación

Imagina que tienes **5 algoritmos de ML clasificación** distintos para determinar si otorgas un crédito o no a una persona

Esquema

¿Cómo puedes determinar qué algoritmo **te conviene más**?

Métricas y evaluación

Al estudiar un problema con un enfoque de aprendizaje de máquina surgen las siguientes preguntas:

Técnico:

1. Tengo *n* distintos algoritmos pero**, ¿cómo puedo seleccionar el mejor?**

Métricas y evaluación

Al estudiar un problema con un enfoque de aprendizaje de máquina surgen las siguientes preguntas:

Técnico:

1. Tengo *n* distintos algoritmos pero, **¿cómo puedo seleccionar el mejor?**

Negocio:

2. ¿Cuánto me va a **costar implementarlo** con datos reales?
3. ¿**Cuánto tiempo** me va a tomar desarrollarlo? ¿**Cuántas personas** necesito contratar?

No es extraño que la limitante por decisión de **Negocio** ocurra en las aplicaciones reales

El punto **Técnico**, se puede resolver utilizando **métricas** para problemas de clasificación

Métricas ML clasificación

Todas las métricas y matrices que estudiaremos

en esta sección son para **problemas de clasificación**

Métrica: matriz de confusión

Aplicas un análisis para **detectar enfermedad a partir de una muestra de sangre (positivo** o **negativo)**

Por ahora,

considera que **ya sabes el resultado real** de cada análisis (**positivo** o **negativo**) gracias a **otro** estudio o criterio

Pero quieres probar qué tan bien **habría funcionado** un nuevo algoritmo de ML para clasificación

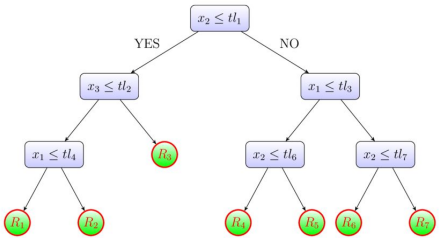

¿Cómo podrías **organizar** estos resultados?

Métrica: matriz de confusión

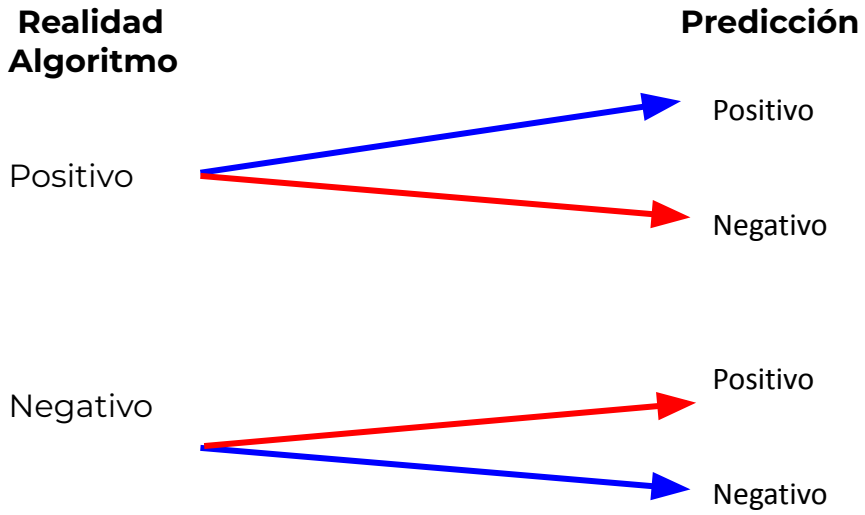

Estos resultados se pueden presentar en una **Matriz de Confusión**

Resultados

Supón que estos son los **resultados del primer algoritmo** y responde a continuación:

1. ¿Cuántos positivos detectó correctamente?
2. ¿Cuántos positivos clasificó erróneamente como negativos?
3. ¿Cuántos negativos clasificó erróneamente como positivos?
4. ¿Cuántos registros clasificó correctamente (indep. de la etiqueta)?
5. ¿Cuántos registros en total se analizaron?

		Realidad	
		positivo	**negativo**
Predicción		69	5
		10	45

¿Cuáles son los componentes de una **matriz de confusión**?

Matriz de confusión

Positivos clasificados **correctamente** como positivos

vp: verdaderos positivos

	positivo	negativo	total
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Matriz de confusión

Negativos clasificados **correctamente** como negativos

vn: verdaderos negativos

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Matriz de confusión

Negativos clasificados **erróneamente** como positivos

fp: falsos positivos

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Matriz de confusión

Positivos clasificados **erróneamente** como negativos

fn: falsos negativos

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Matriz de confusión

Realidad

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Predicción

Matriz de confusión

De acuerdo a la naturaleza de este problema de **análisis de salud (positivo o negativo)**,

¿**Cuál consideras que sería la predicción más delicada / importante**?

	positivo	negativo
positivo.pred	vp	fp
negativo.pred	fn	vn
total	pos	neg

Analiza la **situación real** en cada una de las 4 entradas de la Matriz de Confusión

Matriz de confusión

fn (falsos negativos): una persona recibe un diagnóstico negativo, aunque **sí tiene la enfermedad**.

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Ahora considera que tienes **dos algoritmos ML clasificación** para resolver este problema...

Resultados

Supón que implementan otros dos algoritmos para analizar los **129** casos, **¿cuál es mejor?**

	positivo	negativo
	69	5
	10	45

	positivo	negativo
	69	31
	17	12

Resultados

Supón que implementan otros dos algoritmos para analizar los 129 casos, **¿cuál es mejor?**

Realidad (normalmente desconocida)

Predicción

	positivo	negativo
	69	5
	10	45

	positivo	negativo
	69	31
	17	12

Resultados

Supón que implementan otros dos algoritmos para analizar los 129 casos, **¿cuál es mejor?**

positivo	negativo
69	5
10	45

positivo	negativo
69	31
17	12

Resultados

Supón que implementan otros dos algoritmos para analizar los 129 casos, **¿cuál es mejor?**

positivo	negativo
69	5
10	45

positivo	negativo
69	31
17	12

Resultados

Supón que implementan otros dos algoritmos para analizar los 129 casos, **¿cuál es mejor?**

positivo	negativo
69	5
10	45

positivo	negativo
69	31
17	12

Machine Learning

Intuitivamente, queremos algoritmos que acumulen **más** casos en la **diagonal** (*Accuracy)*

sin embargo, esto **depende de la naturaleza del problema**

Matriz de confusión

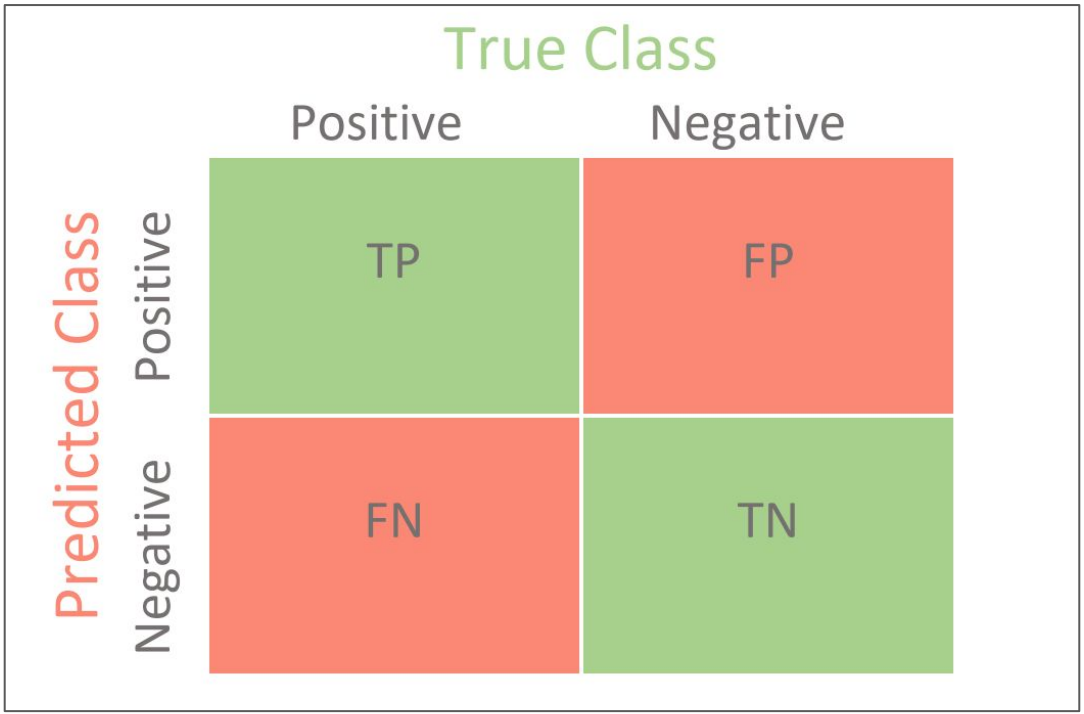

Machine Learning

Además de la matriz de confusión **existen otras métricas**

muy útiles para evaluar un algoritmo

Entradas Matriz de confusión

Construcción de métricas **a partir de estos indicadores**:

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Métricas

Otras **métricas** para algoritmos de **clasificación**:

- Tasa de falsos positivos: proporción de veces que nos equivocamos en la clasificación para casos negativos.

$$\frac{fp}{fp + nv} = \frac{fp}{neg}$$

- Tasa de falsos negativos: proporción de veces que nos equivocamos en la clasificación para casos positivos.

$$\frac{fn}{pv + fn} = \frac{fn}{pos}$$

Analicemos la **tasa de falsos positivos**

Tasa de falsos positivos

- Tasa de falsos positivos: proporción de veces que nos equivocamos en la clasificación para casos negativos.

$$\frac{fp}{fp + nv} = \frac{fp}{neg}$$

	positivo	**negativo**	**total**
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Tasa de falsos positivos

- Tasa de falsos positivos: proporción de veces que nos equivocamos en la clasificación para casos negativos.

$$\frac{fp}{fp + nv} = \frac{fp}{neg}$$

Negativos que clasifiqué erroneamente como positivos... 🤓

	positivo	negativo	total
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Tasa de falsos positivos

- Tasa de falsos positivos: proporción de veces que nos equivocamos en la clasificación para casos negativos.

$$\frac{fp}{fp + nv} = \frac{fp}{neg}$$

	positivo	negativo	total
positivo.pred	vp	fp	pred.pos
negativo.pred	fn	vn	pred.neg
total	pos	neg	

Métricas Complementarias (a tasas falsos)

Otras **métricas** para algoritmos de **clasificación**:

- Especificidad: tasa de correctos entre negativos, es el complemento de la tasa de falsos positivos.

$$\frac{vn}{fp + vn} = \frac{vn}{neg}$$

- Sensibilidad o Recall o Exhaustividad: tasa de correctos entre positivos, es el complemento de la tasa de falsos negativos.

$$\frac{vp}{vp + fn} = \frac{vp}{pos}$$

Métricas

Otras **métricas** para algoritmos de **clasificación**:

- Precisión o valor predictivo positivo: tasa de correctos entre todos los que *clasificamos* como positivos

$$\frac{vp}{vp + fp} = \frac{vp}{pred.\,pos}$$

- Valor predictivo negativo: tasa de correctos entre todos los que *clasificamos* como negativos

$$\frac{vn}{fn + vn} = \frac{vn}{pred.\,neg}$$

Métricas

Otras **métricas** para algoritmos de **clasificación**:

- **Tasa de clasificación incorrecta**

$$\frac{fn + fv}{neg + pos}$$

Y existen otras medidas que intentan resumir los dos tipos de errores de distinta manera, como

- **Medida F** (media armónica de precisión y recall)

$$2\frac{precision \cdot recall}{precision + recall}$$

Lista de Métricas

Si quieres conocer una lista más grande de posibles métricas, ingresa en el siguiente enlace
Seleccionar la o las métricas correctas para cada problema es clave

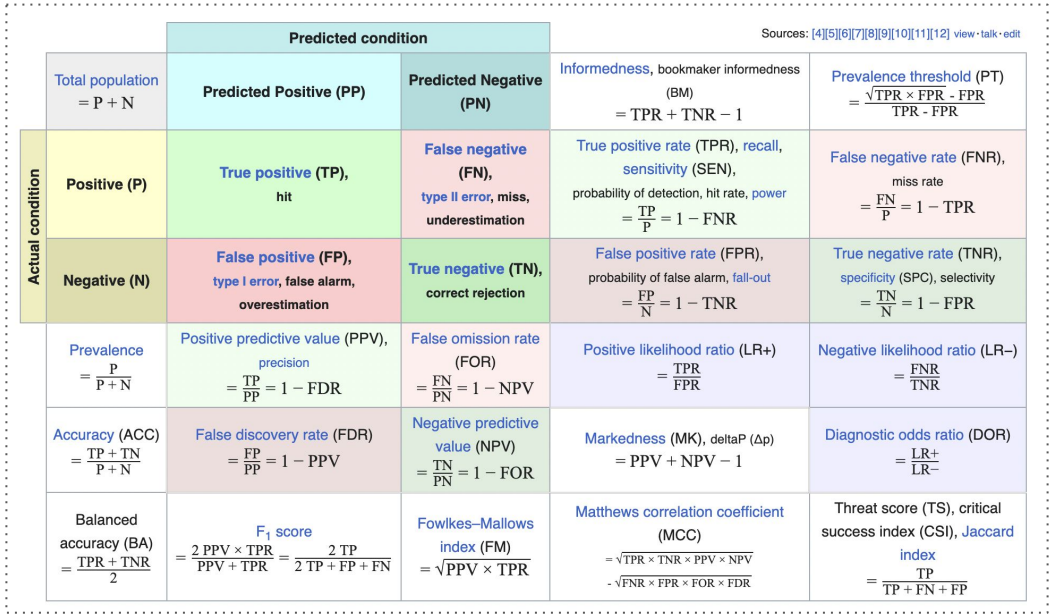

		Predicted condition		Sources: [4][5][6][7][8][9][10][11][12] view · talk · edit	
	Total population $= P + N$	**Predicted Positive (PP)**	**Predicted Negative (PN)**	Informedness, bookmaker informedness (BM) $= TPR + TNR - 1$	Prevalence threshold (PT) $= \frac{\sqrt{TPR \times FPR} - FPR}{TPR - FPR}$
Actual condition	**Positive (P)**	**True positive (TP),** hit	**False negative (FN),** type II error, miss, underestimation	True positive rate (TPR), recall, sensitivity (SEN), probability of detection, hit rate, power $= \frac{TP}{P} = 1 - FNR$	False negative rate (FNR), miss rate $= \frac{FN}{P} = 1 - TPR$
	Negative (N)	**False positive (FP),** type I error, false alarm, overestimation	**True negative (TN),** correct rejection	False positive rate (FPR), probability of false alarm, fall-out $= \frac{FP}{N} = 1 - TNR$	True negative rate (TNR), specificity (SPC), selectivity $= \frac{TN}{N} = 1 - FPR$
	Prevalence $= \frac{P}{P + N}$	Positive predictive value (PPV), precision $= \frac{TP}{PP} = 1 - FDR$	False omission rate (FOR) $= \frac{FN}{PN} = 1 - NPV$	Positive likelihood ratio (LR+) $= \frac{TPR}{FPR}$	Negative likelihood ratio (LR−) $= \frac{FNR}{TNR}$
	Accuracy (ACC) $= \frac{TP + TN}{P + N}$	False discovery rate (FDR) $= \frac{FP}{PP} = 1 - PPV$	Negative predictive value (NPV) $= \frac{TN}{PN} = 1 - FOR$	Markedness (MK), deltaP (Δp) $= PPV + NPV - 1$	Diagnostic odds ratio (DOR) $= \frac{LR+}{LR-}$
	Balanced accuracy (BA) $= \frac{TPR + TNR}{2}$	F_1 score $= \frac{2\,PPV \times TPR}{PPV + TPR} = \frac{2\,TP}{2\,TP + FP + FN}$	Fowlkes–Mallows index (FM) $= \sqrt{PPV \times TPR}$	Matthews correlation coefficient (MCC) $= \sqrt{TPR \times TNR \times PPV \times NPV} - \sqrt{FNR \times FPR \times FOR \times FDR}$	Threat score (TS), critical success index (CSI), Jaccard index $= \frac{TP}{TP + FN + FP}$

Observa que para seleccionar “el **mejor** algoritmo”,

antes debes **decidir el criterio o métrica**

Deptos NY - SFO

En el problema de los departamentos, podrías responder preguntas más específicas sobre las eficiencia de tus modelos, **por ejemplo:**

- ¿Qué porcentaje del **total** de registros clasifica correctamente?
- Respecto a los depto en **NY**, ¿cuántos clasifica correctamente?
- Respecto a los depto en **SFO**, ¿cuántos clasifica correctamente?
- ¿Qué porcentaje del **total** de registros clasifica erróneamente?

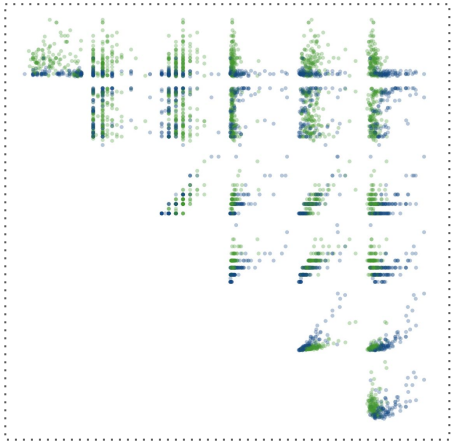

Deptos NY - SFO

En el problema de los departamentos, podrías responder preguntas más específicas sobre las eficiencia de tus modelos, **por ejemplo:**

- ¿Qué porcentaje del **total** de registros clasifica correctamente?
- Respecto a los depto en **NY**, ¿cuántos clasifica correctamente?
- Respecto a los depto en **SFO**, ¿cuántos clasifica correctamente?
- ¿Qué porcentaje del **total** de registros clasifica erróneamente?

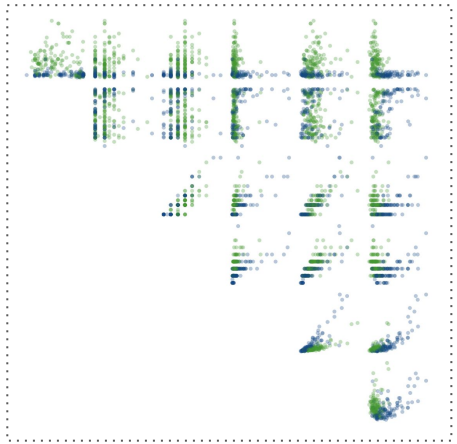

Deptos NY - SFO

En el problema de los departamentos, podrías responder preguntas más específicas sobre las eficiencia de tus modelos, **por ejemplo:**

- ¿Qué porcentaje del **total** de registros clasifica correctamente?
- Respecto a los depto en **NY**, ¿cuántos clasifica correctamente?
- Respecto a los depto en **SFO**, ¿cuántos clasifica correctamente?
- ¿Qué porcentaje del **total** de registros clasifica erróneamente?

🤓

Tasas de falsos
y sus complementos

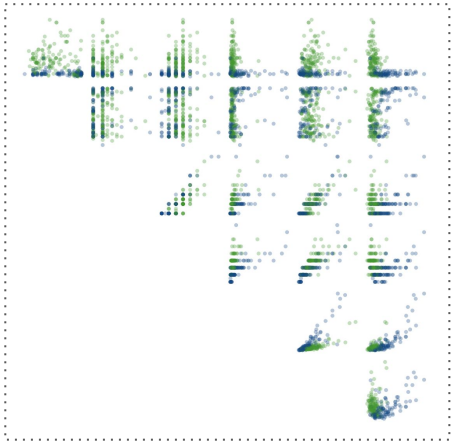

Machine Learning

¿Cómo cambiaría la matriz de confusión si tuvieras **3 clases**?

A, B y C

Predicción

Matriz de confusión (3 clases)

Realidad

A,A	A,B	A,C
B,A	B,B	B,C
C,A	C,B	C,C

Predicción

Matriz de confusión (3 clases)

Realidad

A,A	A,B	A,C
B,A	B,B	B,C
C,A	C,B	C,C

Matriz de confusión (3 clases)

Ejemplo: ¿Cómo armar matriz de confusión con una BD?

Ejemplo: Matriz de confusión (3 clases)

¿Cómo podemos armar una matriz de confusión dada una BD?

Descarga la siguiente BD en csv - Predicciones
Liga

Machine learning

Arma la matriz de confusión en Excel

Toma **5 minutos** para realizarlo

Definiciones frecuentes ML

Clase 3
ML y análisis de datos

ITAM

Para una **mejor comprensión**,

vamos a revisar algunos **conceptos frecuentes** en ML

Definiciones

Además de los conceptos presentados previamente (algoritmo, AI y ML), estudiamos algunas definiciones adicionales para tener una **referencia clara sobre los términos y desmitificar** una serie de conceptos que frecuentemente se usan sin claridad:

- Cómputo en la nube
- Paralelización
- *Web scraping*
- *Data science* y *data scientist*
- Paralelización
- *Query*

Cómputo en la nube

Servicios que ofrecen algunas compañías de software para **utilizar su infraestructura de cómputo y algoritmos que ofrecen como servicio**:

- En lugar de **desarrollar** todo por tu cuenta, las compañías lo rentan a cambio de tarifa
- Permite pagar por volumen de uso
- **En lugar de comprar muchas computadoras, las puedes rentar por el tiempo que necesites**

Cómputo en la nube

Existe un gran número de servicios disponibles actualmente (y es posible que siga aumentado). Por ejemplo, la suite de cómputo en la nube de Amazon se llama AWS (***Amazon Web Services***) y tiene los siguientes servicios:

- S3
- *Textract*
- Transcribe
- EC2

S3

Es un servicio que permite **almacenar, extraer y actualizar datos de forma segura en la nube de AWS**. Lo puedes pensar como **una especie de Dropbox o Google Drive**.

- S3 es particularmente útil para **acceder a archivos y bases de datos que alimentan algoritmos y aplicaciones**
- El espacio reservado para almacenar datos se llama **Bucket**

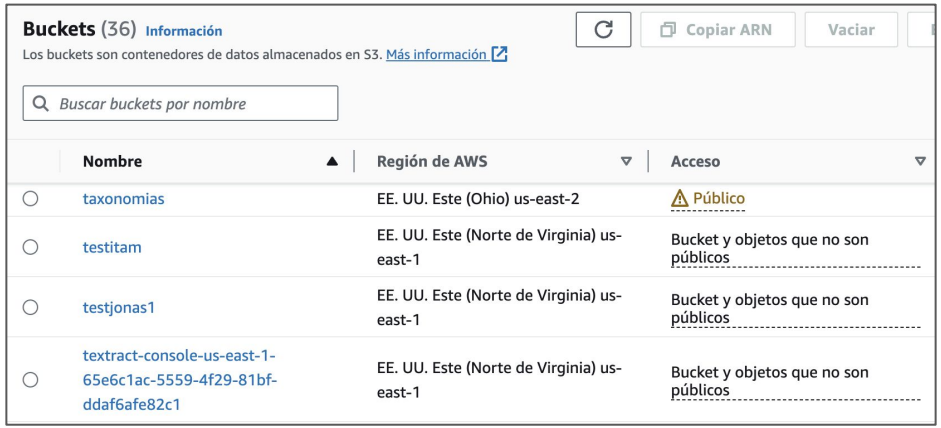

Textract

Esta herramienta de permite extraer el **texto** de un pdf (png o jpg) o imagen **a texto plano:**

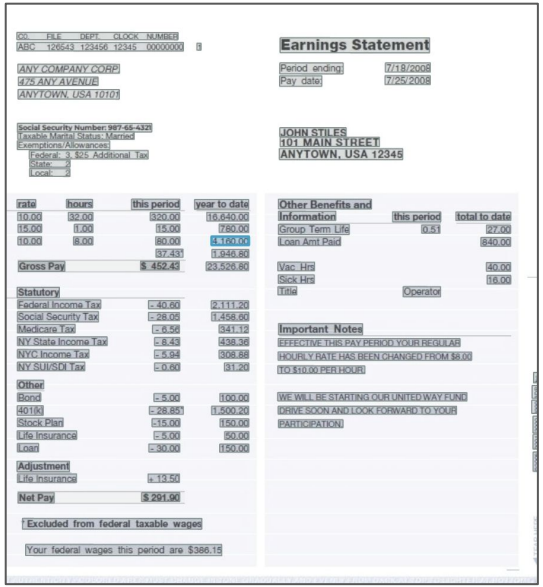

Earnings Statement

Period ending: 7/18/2008
Pay date: 7/25/2008

ANY COMPANY CORP
475 ANY AVENUE
ANYTOWN, USA 10101

Social Security Number: 987-65-4321
Taxable Marital Status: Married
Exemptions/Allowances:
Federal: 3, $25 Additional Tax
State: 2
Local: 2

JOHN STILES
101 MAIN STREET
ANYTOWN, USA 12345

rate	hours	this period	year to date
10.00	32.00	320.00	16,640.00
15.00	1.00	15.00	780.00
10.00	8.00	80.00	4,160.00
		37.43	1,946.80
Gross Pay		$ 452.43	23,526.80

Other Benefits and Information	this period	total to date
Group Term Life	0.51	27.00
Loan Amt Paid		840.00
Vac. Hrs		40.00
Sick Hrs		16.00
Title	Operator	

Statutory		
Federal Income Tax	- 40.60	2,111.20
Social Security Tax	- 28.05	1,456.60
Medicare Tax	- 6.56	341.12
NY State Income Tax	- 8.43	438.36
NYC Income Tax	- 5.94	308.88
NY SUI/SDI Tax	- 0.60	31.20
Other		
Bond	- 5.00	100.00
401K	- 28.851	1,500.20
Stock Plan	-15.00	150.00
Life Insurance	- 5.00	50.00
Loan	- 30.00	150.00
Adjustment		
Life Insurance	- 13.50	
Net Pay	$ 291.90	

Important Notes

EFFECTIVE THIS PAY PERIOD YOUR REGULAR HOURLY RATE HAS BEEN CHANGED FROM $8.00 TO $10.00 PER HOUR.

WE WILL BE STARTING OUR UNITED WAY FUND DRIVE SOON AND LOOK FORWARD TO YOUR PARTICIPATION.

* Excluded from federal taxable wages

Your federal wages this period are $386.15

CO. FILE DEPT. CLOCK NUMBER
ABC 126543 123456 12345 00000000 1 Earnings Statement
ANY COMPANY CORP. Period ending: 7/18/2008
475 ANY AVENUE Pay date: 7/25/2008
ANYTOWN USA 10101 Social Security Number: 987-65-4321
Taxable Marital Status: Married JOHN STILES
Exemptions/Allowances: 101 MAIN STREET
Federal: 3. $25 Additional Tax ANYTOWN, USA 12345 State: 2
Local: 2 Earnings rate hours this period year to date
Other Benefits and Regular 10.00 32.00 320.00
16,640.00 Information this period total to date Overtime
15.00 1.00 15.00 780.00 Group Term Life 0.51
27.00 Holiday 10.00 8.00 80.00 4,160.00

¿Textract es un “*algoritmo de ML supervisado de* ***clasificación***?

Transcribe

Esta herramienta de permite transcribir archivos de audio en texto plano:

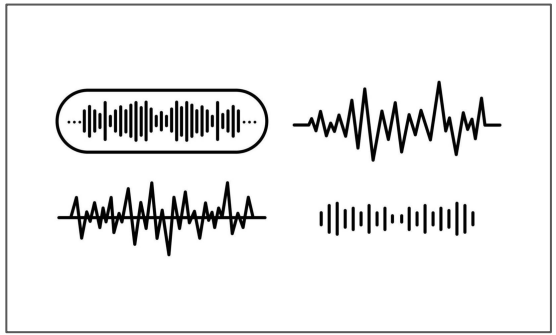

Google Translate

Google Translate tiene integrada una funcionalidad similar (además de traducir):

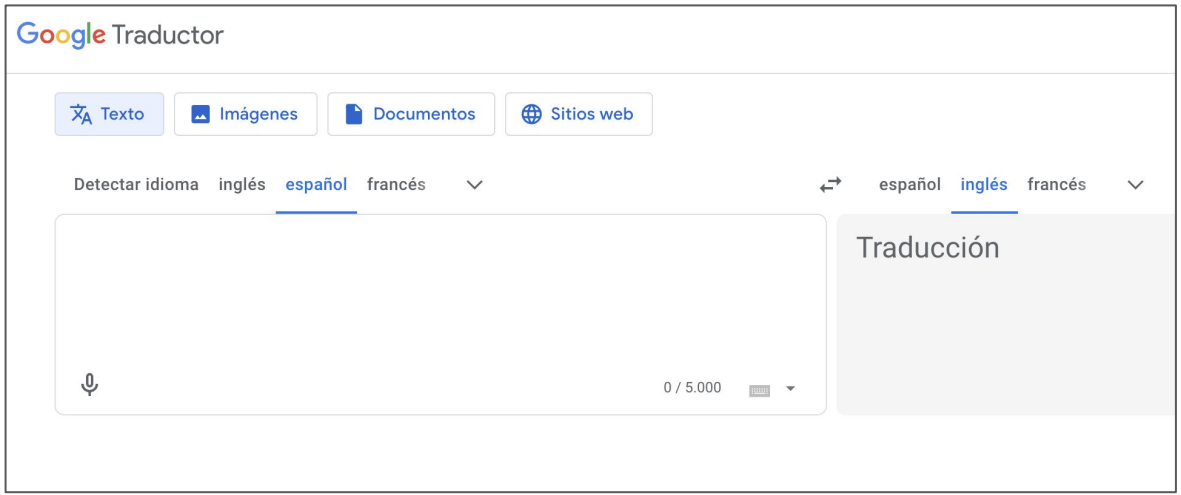

Textract* y *Transcribe en realidad son algoritmos de ML

Propiedad de Amazon

Otros productos

Entre los productos de AWS están herramientas de: ML, BD, Servidores, Contenedores, etc.

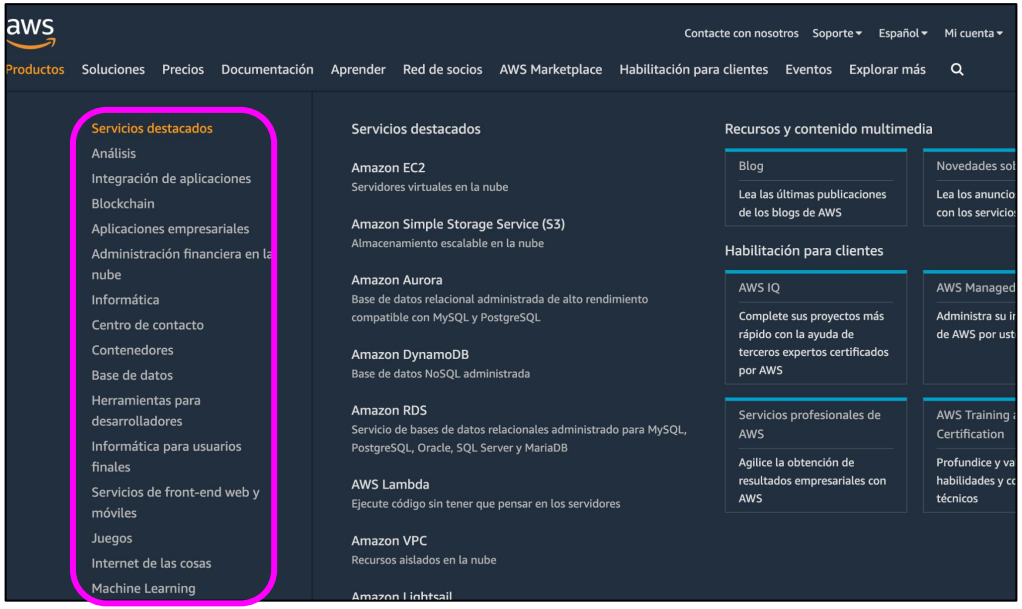

Opciones en el mercado

No solo Amazon desarrolla y ofrece este tipo de servicios, sin embargo, su uso está extendido en la comunidad de Ciencia de Datos:

Digital Ocean

Microsoft Azure

AWS

Servicios de cómputo en la nube

Mito: Se dice que el origen de este servicio ocurrió después de un *Black Friday*

Ejemplo:

Máquina virtual en Digital Ocean

- **Droplet**
- Cuenta
- Bash y terminal

Ejemplo:

Almacenamiento en nube en Digital Ocean

- **Space Object**
  - Cuenta
- Bash y terminal

Servicio de Mapas

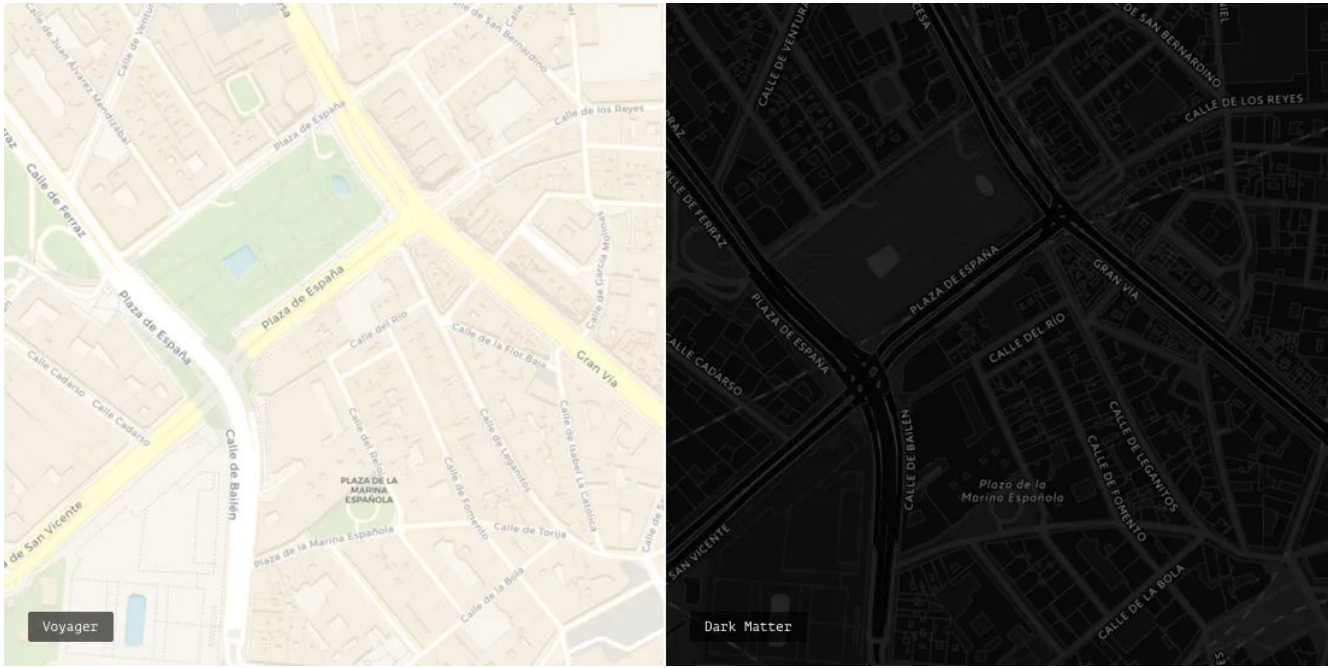

Sustitutos

Data Science

Consiste en una disciplina que engloba una serie de **métodos, técnicas, algoritmos y sistemas para analizar información**.

Su definición está **muy ligada** a otras disciplinas como:

- *Data mining*
- *Machine learning*
- *Data analytics*
- Estadística

Una buena referencia.

Data Science

Existe una **serie de habilidades** que un científico de datos debería tener, sin embargo, **no existe un acuerdo completo**.

Por otro lado, **es difícil conocer, *a priori*, la capacidad de un *data scientist***. Es un término popularmente utilizado del que **no hay impedimento para utilizarlo**.

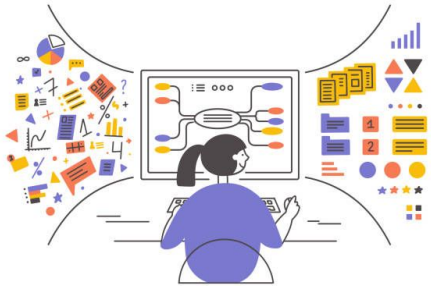

Data Science

No es como decir que alguien es Arquitecto, Médico o Ingeniero. **Por mucho tiempo no hubo una certificación respecto al término**:

- Regresión
- Tablas dinámicas
- Redes neuronales en Keras

Data Scientist

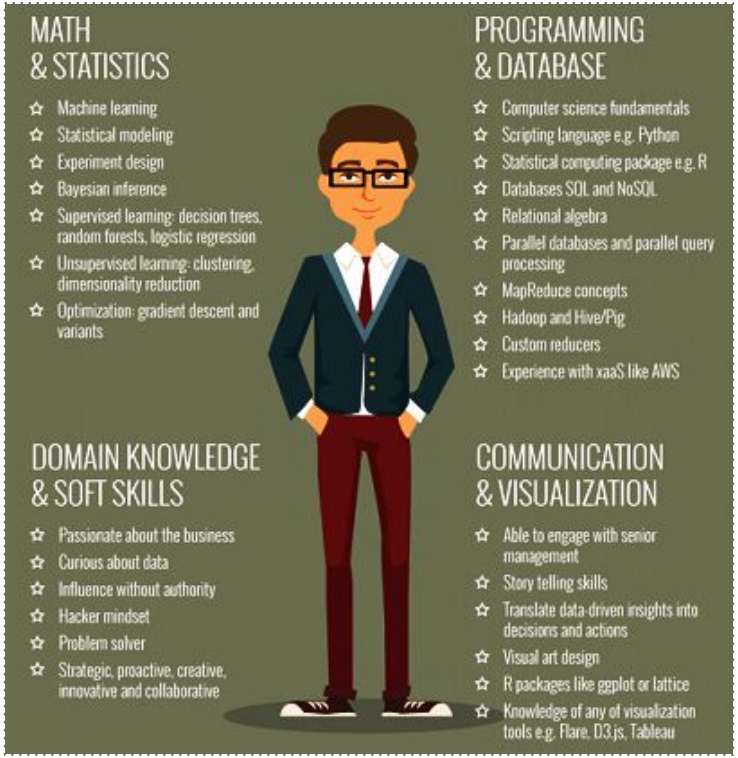

Prácticamente imposible
(de conseguir o **contratar**)

Paralelización

Grosso modo, paralelizar implica **dividir un problema en varias partes que se resuelven simultáneamente**, **reduciendo** significativamente el **tiempo total de procesamiento**.

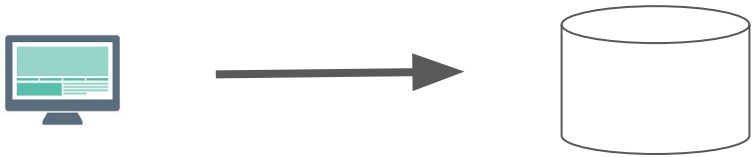

Una computadora para resolver un problema

Paralelización

Por ejemplo, **dividimos el problema original en 5 partes** y cada una es procesada por una computadora, esto **reduce el tiempo total de operaciones**.

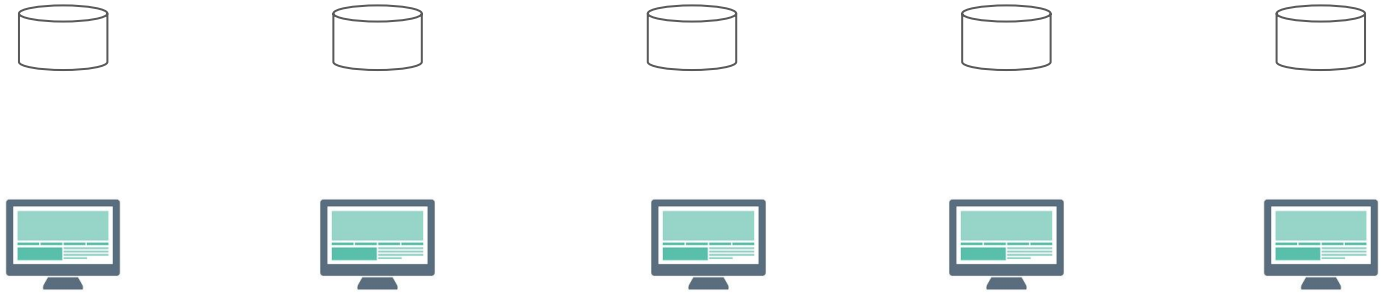

Paralelización

Juntamos los segmentos de la solución y resolvimos el problema original.

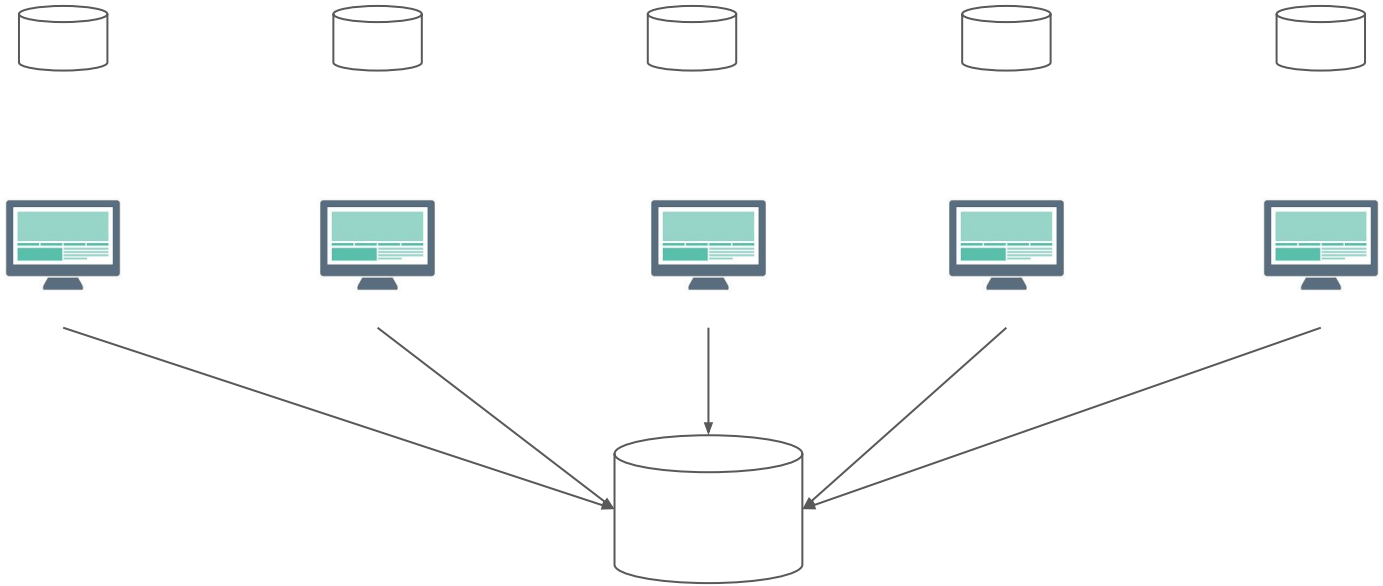

Ejemplos Paralelización

Los siguientes problemas **se pueden “paralelizar”** para encontrar una solución más rápida:

Ejemplos Paralelización

Los siguientes problemas **se pueden “paralelizar”** para encontrar una solución más rápida:

- Sumar todos los dígitos del 1 al 10.

Ejemplos Paralelización

Los siguientes problemas **se pueden “paralelizar”** para encontrar una solución más rápida:

- Sumar todos los dígitos del 1 al 10.

1, 2, 3, 4, 5, 6, 7, 8, 9, 10

¿Cómo resolverías este problema de **forma tradicional**?

1, 2, 3, 4, 5, 6, 7, 8, 9, 10

¿Cómo lo resolverías con 5 computadoras?

Ejemplos Paralelización

Los siguientes problemas **se pueden “paralelizar”** para encontrar una solución más rápida:

- Sumar todos los dígitos del 1 al 10.
  - Supongamos que tienes **5 computadoras**

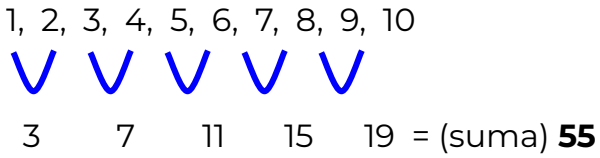

Ejemplos Paralelización

Los siguientes problemas **se pueden “paralelizar”** para encontrar una solución más rápida:

- Sumar todos los dígitos del 1 al 10
- Obtener la raíz cuadrada de 50 números distintos
- Preparar 30 tazas de café americano, **¿cómo los preparas más rápido?**
- Multiplicar los primeros 100 dígitos empezando por el número 1

Ejemplos Paralelización

En general, “Paralelizar” te permite resolver

un problema en partes más pequeñas y más rápido

Este concepto es importante en las aplicaciones de AI porque

muchos algoritmos de ML se pueden paralelizar

Recordando...

XGBoost

Algoritmo sustentado en los árboles de decisión. Este método **puede funcionar mejor** que un árbol de decisión o incluso mejor que **bosques aleatorios**:

- Es muy popular en la actualidad
- Es de fácil implementación
- Es un algoritmo que se puede **paralelizar**

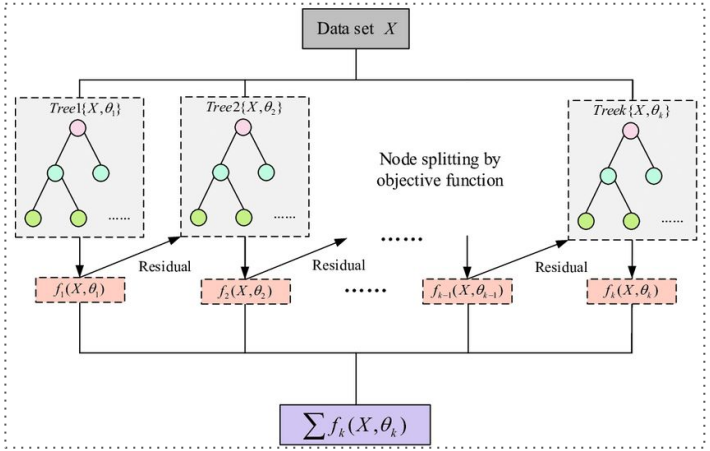

XGBoost

Por esta razón, XGBoost puede correr **más rápido que los bosques aleatorios**

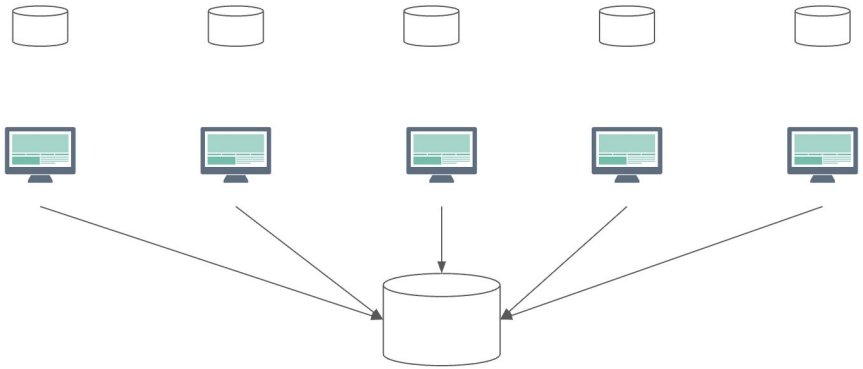

No todo se paraleliza

Por otro lado, también hay muchas aplicaciones que **no se pueden paralelizar**:

- Por ejemplo, obtener cierto **dígito** de la **serie de Fibonacci**

$$1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, 610, 987, 1597 \ldots.$$

¿Cómo se obtiene la **serie de Fibonacci**?

No todo se paraleliza

Por otro lado, también hay muchas aplicaciones que no se pueden paralelizar:

- Por ejemplo, obtener cierto número de la **serie de Fibonacci**

$$1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, 610, 987, 1597 \ldots.$$

No todo se paraleliza

Por otro lado, también hay muchas aplicaciones que no se pueden paralelizar:

- Por ejemplo, obtener cierto número de la **serie de Fibonacci**

$$1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, 610, 987, 1597 \ldots.$$

No todo se paraleliza

Por otro lado, también hay muchas aplicaciones que no se pueden paralelizar:

- Por ejemplo, obtener cierto número de la **serie de Fibonacci**

$$1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, 610, 987, 1597 \ldots.$$

No todo se paraleliza

Por otro lado, también hay muchas aplicaciones que no se pueden paralelizar:

- Por ejemplo, obtener cierto número de la **serie de Fibonacci**

$$1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, 610, 987, 1597 \ldots.$$

No todo se paraleliza

Por otro lado, también hay muchas aplicaciones que no se pueden paralelizar:

- Por ejemplo, obtener cierto número de la **serie de Fibonacci**

$$1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, 610, 987, 1597 \ldots.$$

¿Podemos obtener el **término 1,000** de la serie sin conocer los términos previos?

$$1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, 610, 987, 1597 \ldots .$$

No sería posible, necesitamos ir calculando término a término

No podríamos paralelizar el problema (1:200, 201:400: 401:600,...)

$1, 1, 2, 3, 5, 8, 13, 21, 34, 55, 89, 144, 233, 377, 610, 987, 1597 \ldots .$

¿Por qué es tan importante paralelizar?

En ML se utiliza la **paralelización** por las siguiente razones:

- Grandes cantidades de datos y problemas en **tiempo real**
- **Sistemas de recomendación** al dar click (por ejemplo, Netflix, Amazon, etc)
- Se puede paralelizar **localmente** utilizando los *cores* de tu computadora o en infraestructura en la nube como **AWS o Digital Ocean**

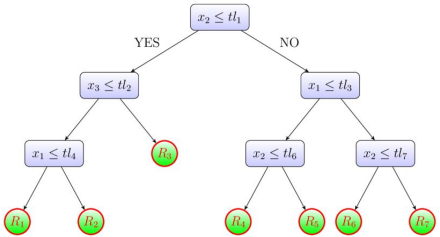

Machine Learning

Algoritmos de regresión

Clase 4

ML y análisis de datos

ITAM

Machine learning

Un problema de aprendizaje de máquina puede estudiarse como:

- Problema de clasificación.
- **Problema de regresión**

Machine learning

Un problema de aprendizaje de máquina puede estudiarse como:

- Problema de clasificación.
- **Problema de regresión**: **sirve para una predecir una variable numérica y continua**.

  Por ejemplo:

  - **Salario** de una persona
  - **Nivel** de precipitaciones
  - **Edad** de un aspirante

Diferencia esencial

A diferencia de los problemas de clasificación, ya no se busca predecir, por ejemplo:

si el salario es alto, medio o bajo (**categórico**)

sino un monto aproximado $85,232 (**numérico $**)

Algoritmos para regresión

Existen diversas opciones para estudiar un problema de regresión, (algunas también sirven para problemas de clasificación) a continuación se presentan algunas de las más comunes:

- Árboles de decisión
- Redes neuronales
- Regresión lineal
- Modelos Lineales Generalizados
- Para otras referencias consulta el siguiente enlace

Observa que algunos algoritmos **también sirven para problemas de clasificación**

Algoritmos para regresión

Existen diversas opciones para estudiar un problema de regresión, (algunas también sirven para problemas de clasificación) a continuación se presentan algunas de las más comunes:

- Árboles de decisión
- Redes neuronales
- Regresión lineal
- Modelos Lineales Generalizados
- Para mayores referencias consulta el siguiente enlace

Pregunta: Si un problema es de **ML regresión**,

¿implica que **sólo debemos** utilizar una regresión lineal?

Cotizador KAVAK

Ejemplo

Para facilitar el proceso de venta, Kavak presentó una **herramienta** que permite que los propietarios interesados en vender su automóvil puedan conocer, de forma rápida y precisa, el **precio** que la compañía pagaría por su vehículo en **1 minuto**. Liga

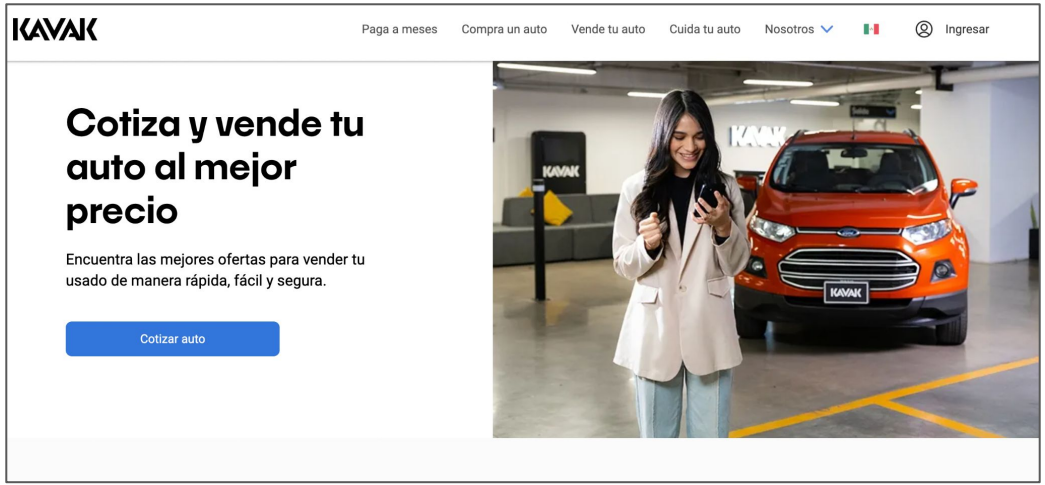

Cotizador KAVAK

Algoritmo ML para estimar el precio de cada auto con base en un conjunto de **variables que cada usuario indica (características de su auto)**

Cotizador KAVAK

En este problema, la estimación del precio final debe ser **muy precisa** por dos razones de mercado:

1. **Si el precio es muy bajo**, el usuario puede decidir ya **no vender** su auto o venderlo a otra empresa

2. **Si el precio es muy alto**, el propietario puede optar por **vender** su auto a Kavak, sin embargo, el **margen** de la compañía se puede **reducir mucho**

Por esta razón, **la estimación del precio debe ser precisa y efectiva**.

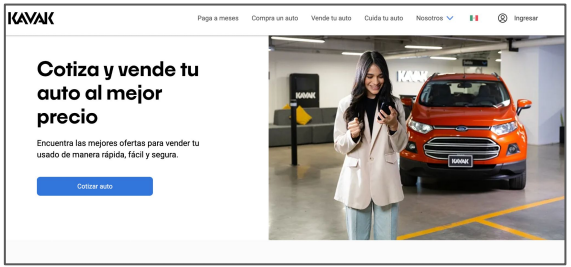

Kavak ¿Cómo puede medir qué tan preciso es su **algoritmo**?

ECM

El **error cuadrático medio** se calcula con la siguiente fórmula:

$$\text{ECM} = \frac{1}{n}\sum_{i=1}^{n}(\hat{Y}_i - Y_i)^2$$

- Donde $\hat{Y}_i$ son las predicciones y Y_i es el valor real.

ECM

Gráficamente la fórmula mide la **discrepancia** entre las predicciones y el valor real:

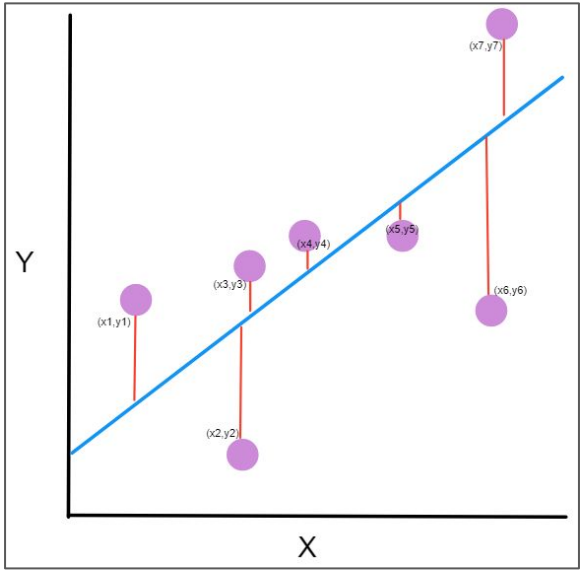

ECM

Gráficamente la fórmula mide la **discrepancia** entre las predicciones y el valor real:

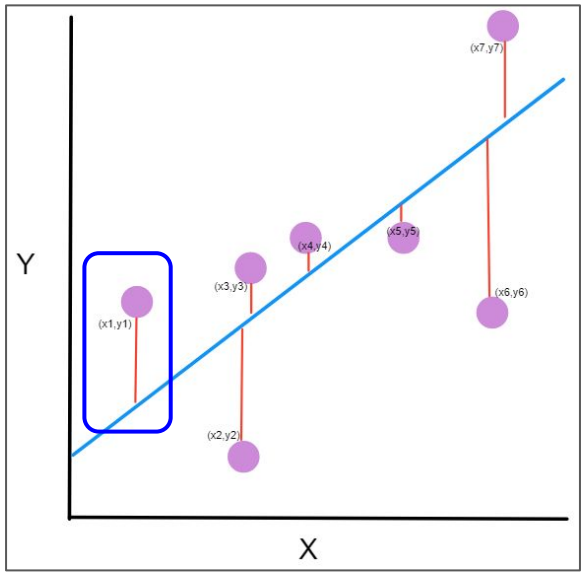

ECM

Gráficamente la fórmula mide la **discrepancia** entre las predicciones y el valor real:

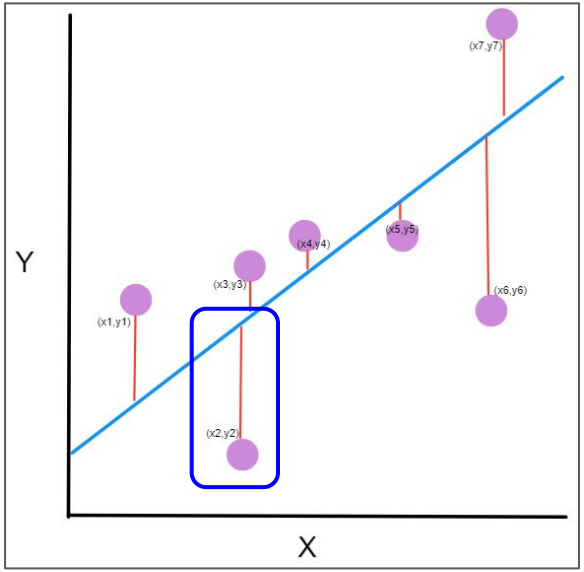

ECM

Gráficamente la fórmula mide la **discrepancia** entre las predicciones y el valor real:

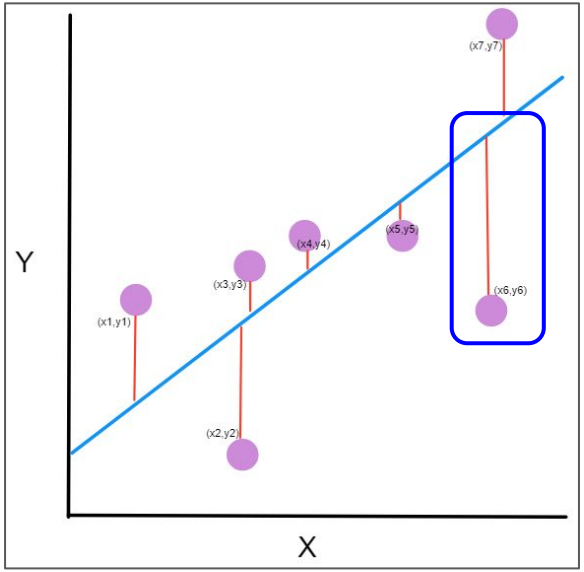

ECM

Supón que tienes un modelo de regresión que entrega predicciones para la glucosa. En el primer caso **80,** en el segundo **190,** y sucesivamente **34, 160, 100, 86, 23, 23, 234 y 120** respectivamente. ¿Cuál es el **ECM**?

	npreg	glu	bp	skin	bmi	ped
	<int>	<int>	<int>	<int>	<dbl>	<dbl>
1	5	86	68	28	30.2	0.364
2	7	195	70	33	25.1	0.163
3	5	77	82	41	35.8	0.156
4	0	165	76	43	47.9	0.259
5	0	107	60	25	26.4	0.133
6	5	97	76	27	35.6	0.378
7	3	83	58	31	34.3	0.336
8	1	193	50	16	25.9	0.655
9	3	142	80	15	32.4	0.2
10	2	128	78	37	43.3	1.22

¿Cuál es el ECM en este caso? **Estimación en Excel** o **R**

¿El ECM puede ser **negativo**? ¿Puede valer **cero**?

$$\text{ECM} = \frac{1}{n}\sum_{i=1}^{n}(\hat{Y}_i - Y_i)^2$$

Para **seleccionar entre varios modelos** para un problema de regresión, puedes apoyarte siempre del ECM

Algunos algoritmos importantes utilizaron ECM...

Error - como ECM

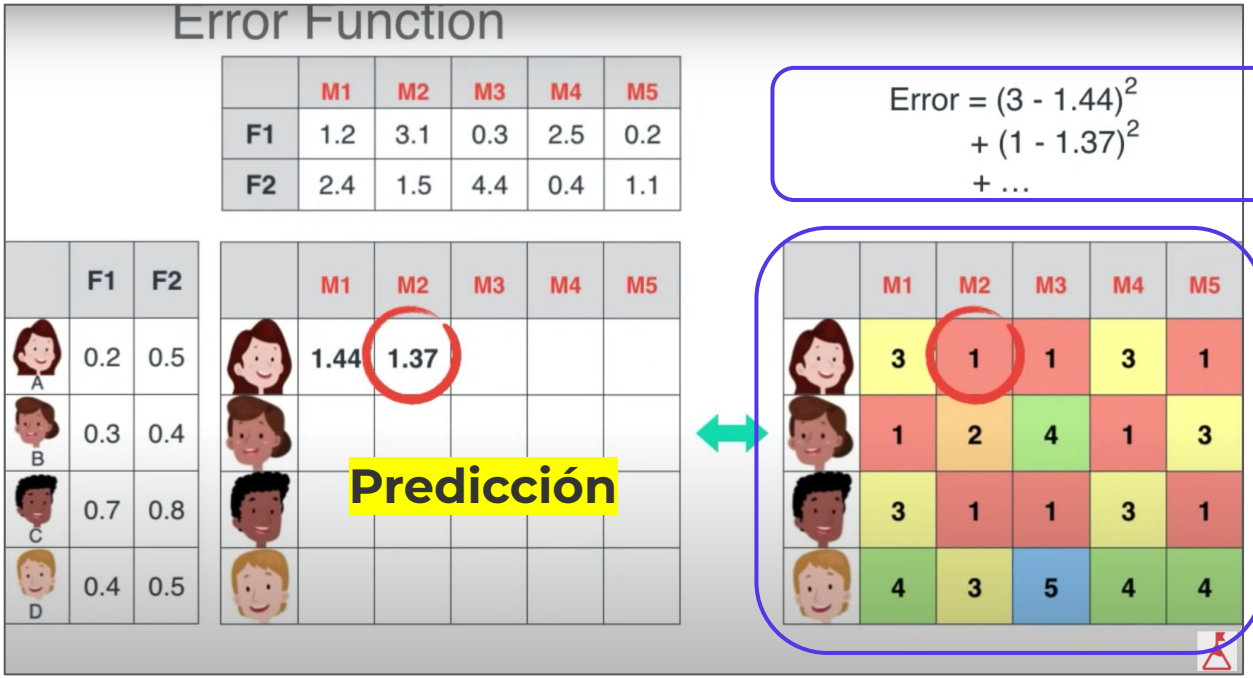

Si bien hay distintas formas de **evaluar** de algoritmos para problemas de regresión,

en esta clase **solo vamos a considerar ECM**

Recuerda que si un problema de ML es de regresión,

no implica necesariamente que debas utilizar una regresión lineal para estudiarlo

Algoritmos de regresión

Abre el código **Clase4. R**

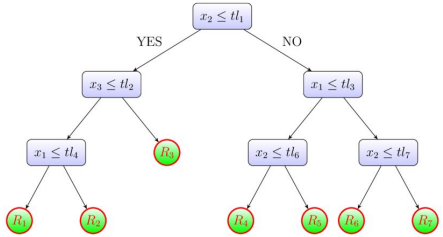

Bosques aleatorios Regresión

“Promediamos” el conocimiento (que aporta cada uno de los árboles)**.**

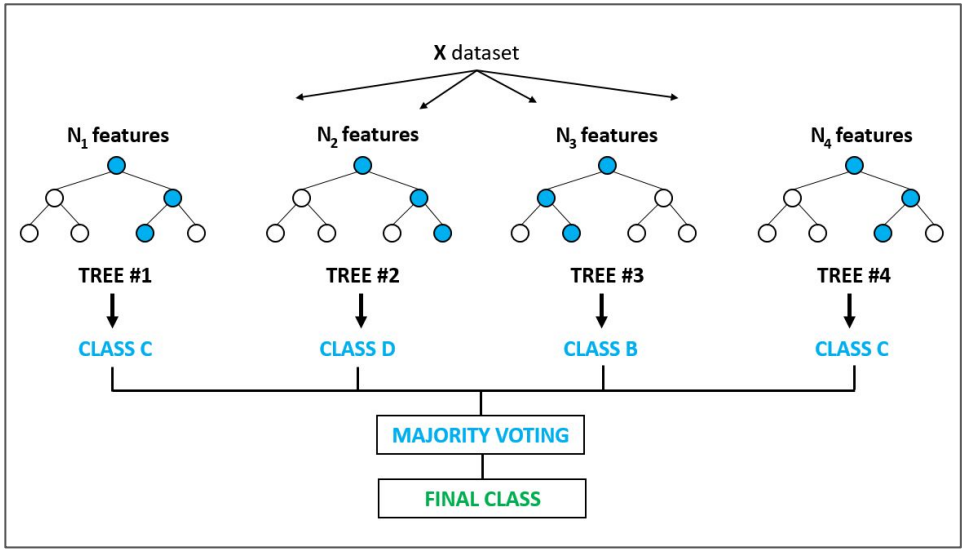

Bosques aleatorios Regresión

“Promediamos” el conocimiento (que aporta cada uno de los árboles)**.**

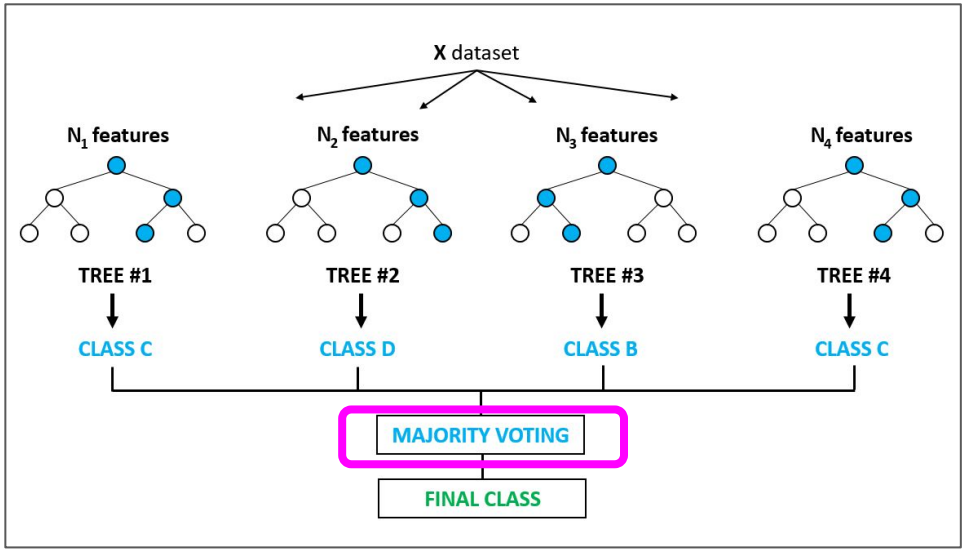

Bosques aleatorios Regresión

Predicción final **(promedio)**

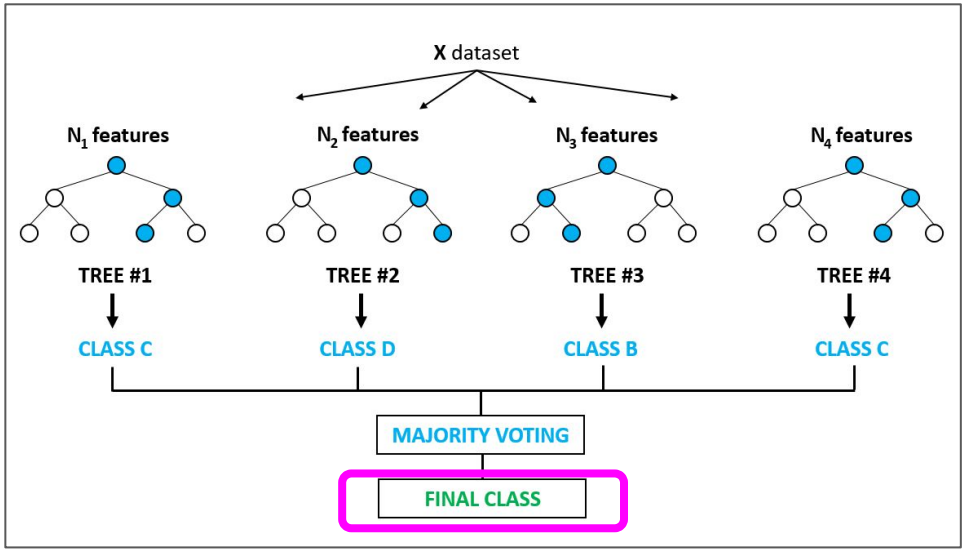

Shazam

Algoritmo

Clase 4

ML y análisis de datos

ITAM

¿Cómo **funciona** Shazam?

¿Todos saben **qué es Shazam**?

Estás en una **fiesta**.

Suena una canción que te encanta...

y **no sabes cómo se llama**

Sacas el celular,

lo acercas **10 segundos**...

y aparece el **nombre** de la canción

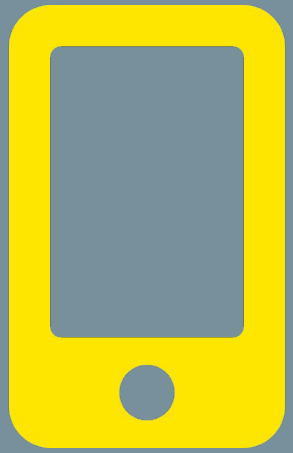

2003 Dimensión del problema

~2 millones

de canciones en su base de datos (en **2003**)

< 1 segundo

para encontrar la canción correcta

10 segundos

de grabación con ruido, desde un celular

Fuente: Wang, A. (2003). *An Industrial-Strength Audio Search Algorithm.*

Y lo hace con **ruido**: gente platicando, platos, bocina del bar...

Comparar tu grabación **sonido contra sonido**

con millones de canciones sería **lentísimo**

¿Cómo **enfrentar** este problema de **gran escala**?

Paper original

Wang, A. (2003). An Industrial-Strength Audio Search Algorithm.

An Industrial-Strength Audio Search Algorithm

Avery Li-Chun Wang
avery@shazamteam.com
Shazam Entertainment, Ltd.

USA:
2925 Ross Road
Palo Alto, CA 94303

United Kingdom:
375 Kensington High Street
4th Floor Block F
London W14 8Q

We have developed and commercially deployed a flexible audio search engine. The algorithm is noise and distortion resistant, computationally efficient, and massively scalable, capable of quickly identifying a short segment of music captured through a cellphone microphone in the presence of foreground voices and other dominant noise, and through voice codec compression, out of a database of over a million tracks. The algorithm uses a combinatorially hashed time-frequency constellation analysis of the audio, yielding unusual properties such as transparency, in which multiple tracks mixed together may each be identified. Furthermore, for applications such as radio monitoring, search times on the order of a few milliseconds per query are attained, even on a massive music database.

1 Introduction

Shazam Entertainment, Ltd. was started in 2000 with the 30-second clip of the song to a friend. Other services, such as purchasing an MP3 download may become available soon.

Idea:

Convertir cada canción en una **huella digital** que sea **fácil de buscar**

Primer paso

Visualizar el sonido

Ejemplo:

¿Cómo **cambia** la **temperatura** en un día?

Medición

¿Cómo se grafica algo que cambia?

Medimos **temperatura**... y ponemos **un punto**, cada hora

Vemos cómo **sube y baja** durante el día.

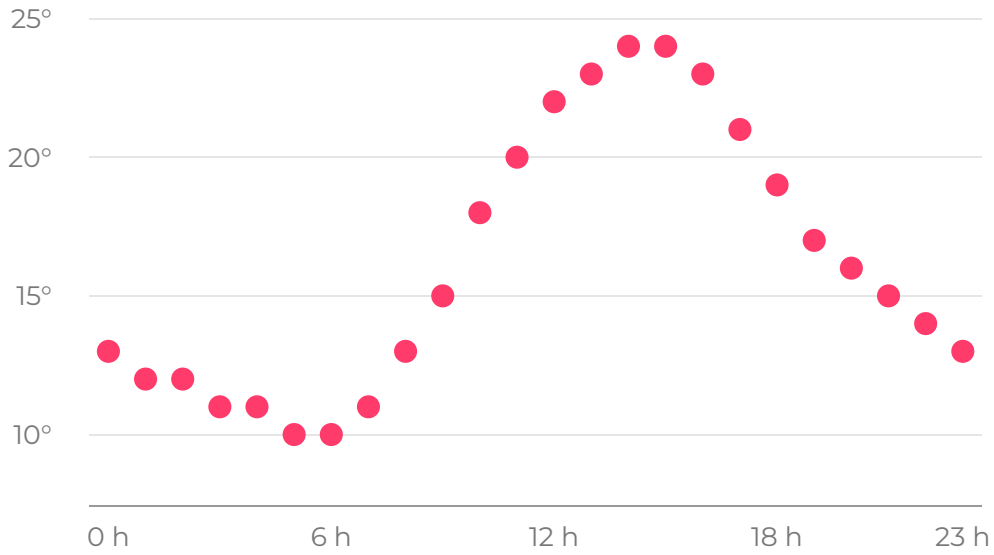

Ejemplo: temperatura de un día de otoño

Con el sonido hacemos **lo mismo**:

el micrófono mide **qué tanto empuja el aire**... **miles de veces por segundo**

Funcionamiento

Suena la canción

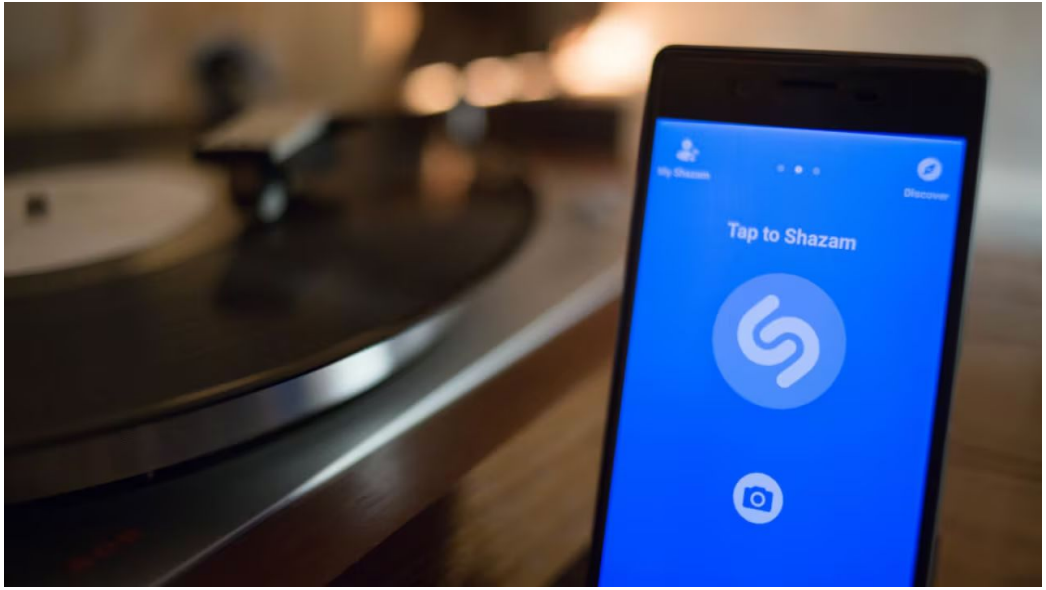

Funcionamiento

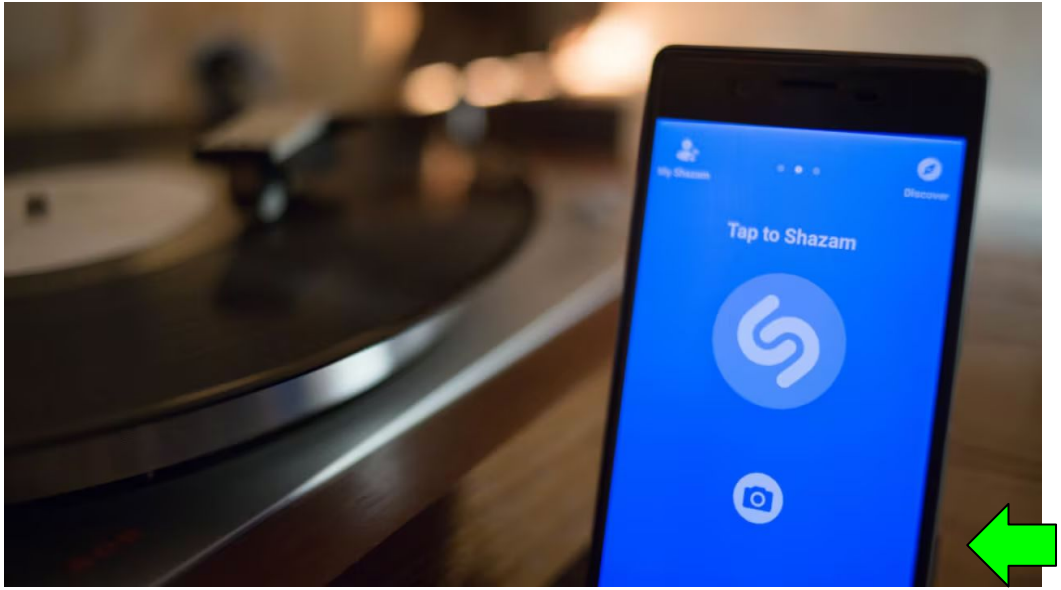

La bocina vibra y empuja el aire del micrófono

Funcionamiento

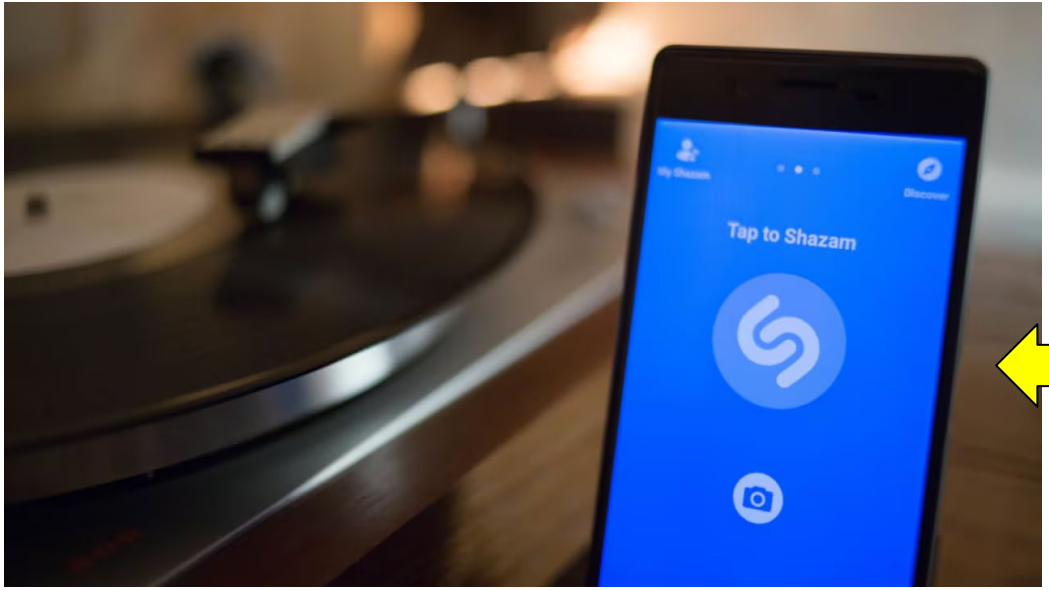

La **vibración** del aire es el **sonido**

Procesamiento de Shazam

1. Convierte el **sonido** en números **entre -1 y 1**
2. El resultado es una **“señal de audio”**
3. Señal se observa con **osciloscopio**

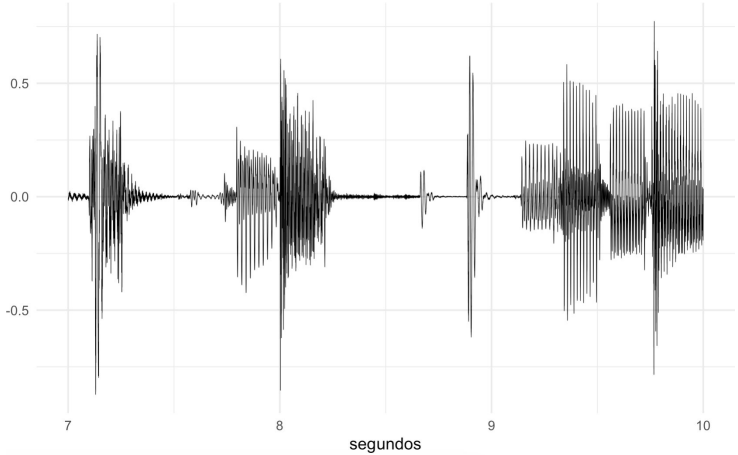

Señal de audio

Liga

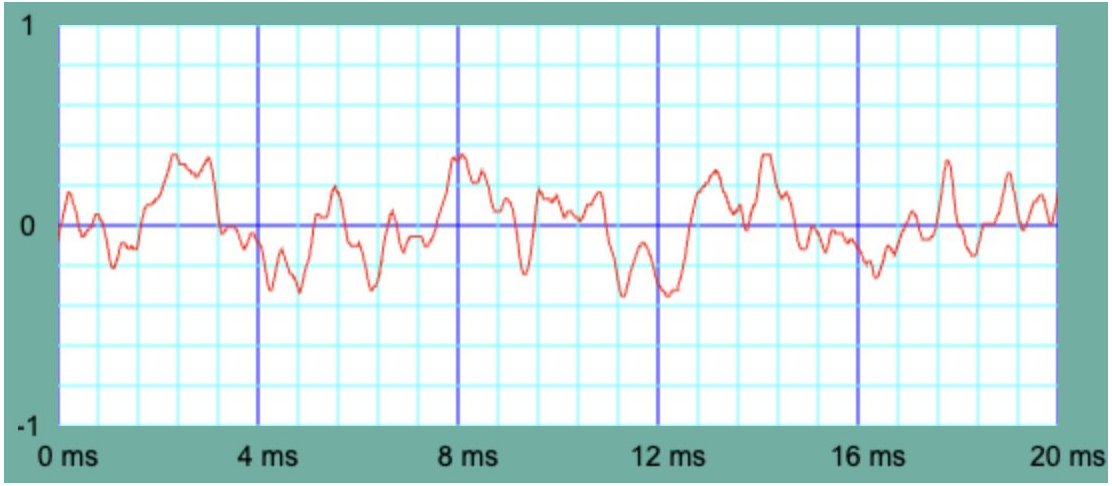

Señal de audio

Abre el código **Clase4. R**

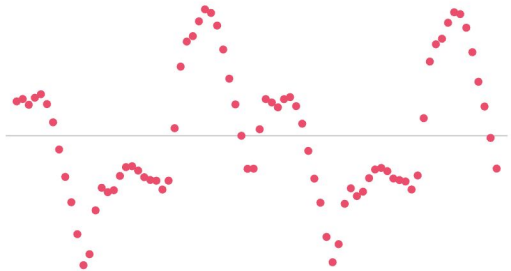

Hagamos zoom: una centésima de segundo

Cada punto es **una medición** del aire.

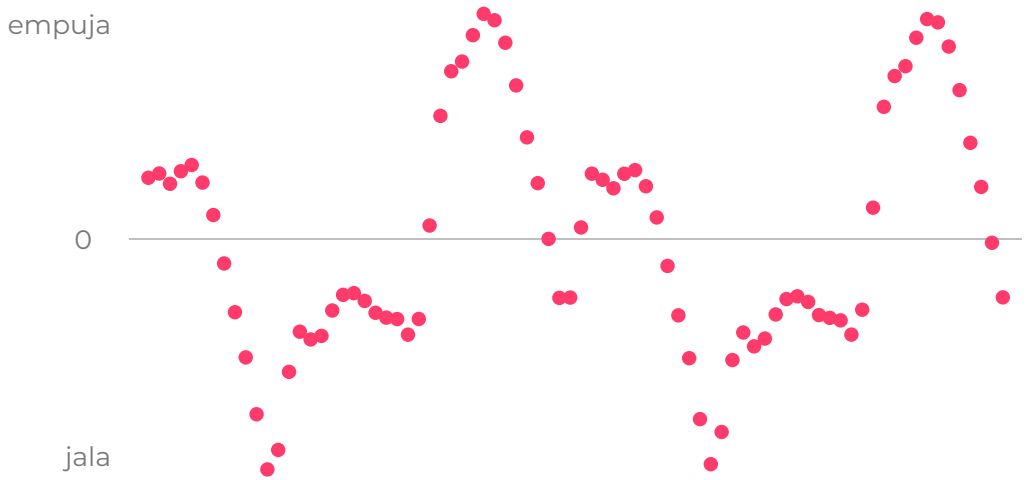

0.01 segundos de la misma canción = 80 mediciones

Tu muestra de 10 segundos son **miles de puntos** como éstos...

Pero la onda **no** **nos dice qué notas** están sonando

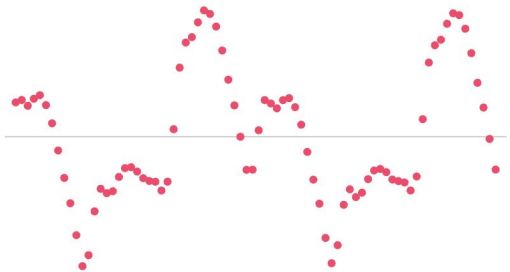

Idea

Separar el sonido en notas, como lo hace un **prisma**

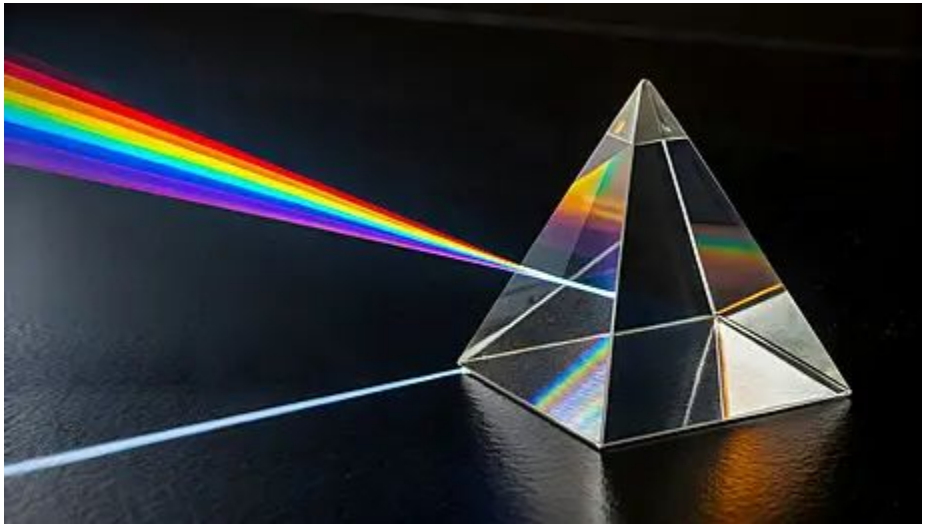

Transformada de Fourier

Transformación matemática para convertir señales entre el dominio del **tiempo y la frecuencia**

- Describe función como combinación de senos y cosenos (exponenciales complejas)

$$F(\omega) = \int_{-\infty}^{+\infty} f(t) e^{-i\omega t}\, dt$$

Separar el sonido en notas

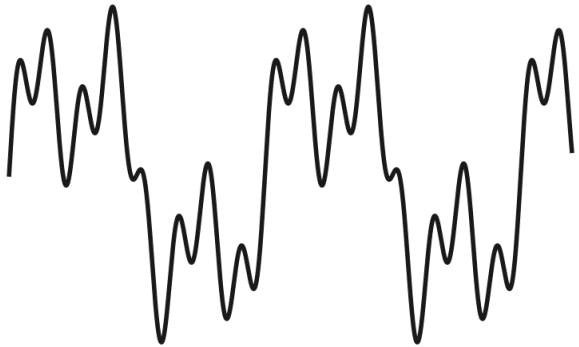

un sonido mezclado

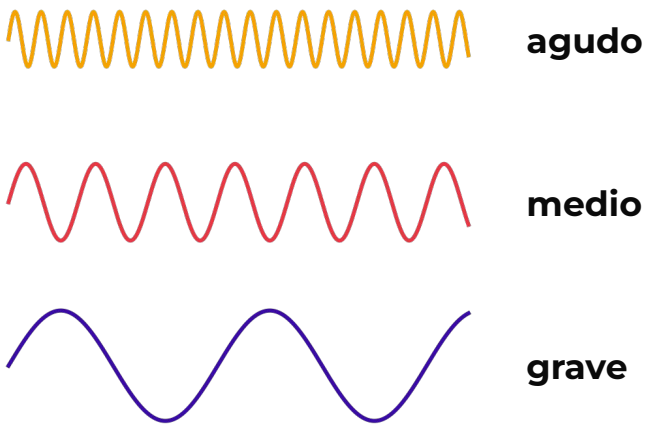

Si hacemos esto **cada fracción de segundo**,

obtenemos una imagen: el **espectrograma**

El espectrograma: la partitura de la canción

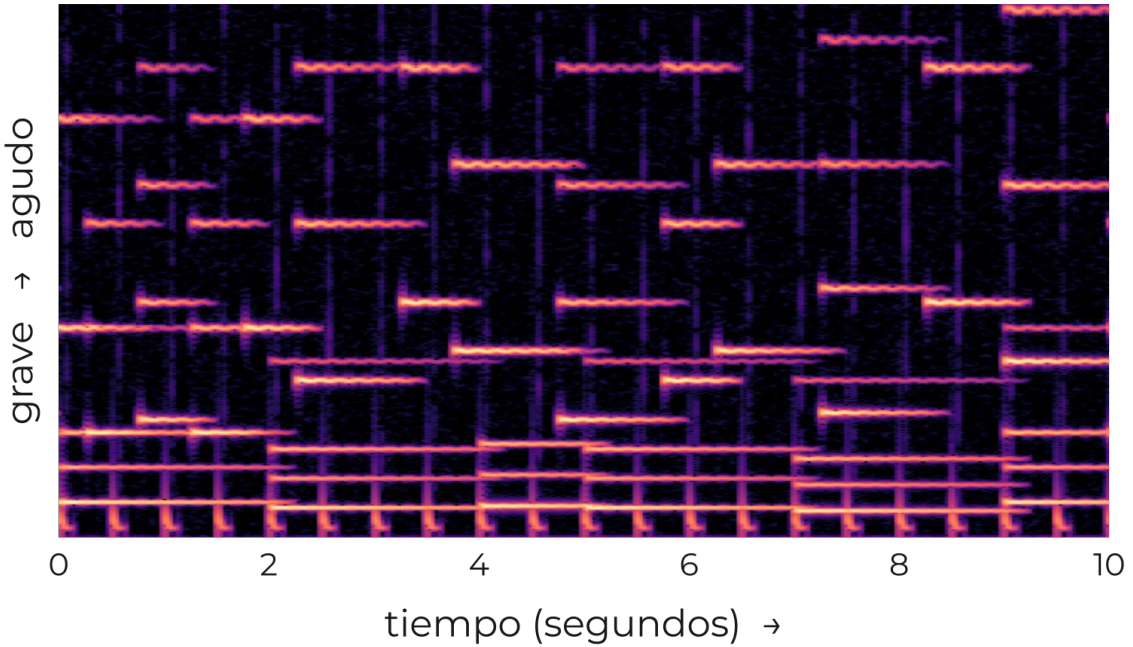

El **tiempo** avanza hacia la derecha

Arriba sonidos agudos, **abajo** graves

Más **brillante** = más fuerte

Espectograma

Liga

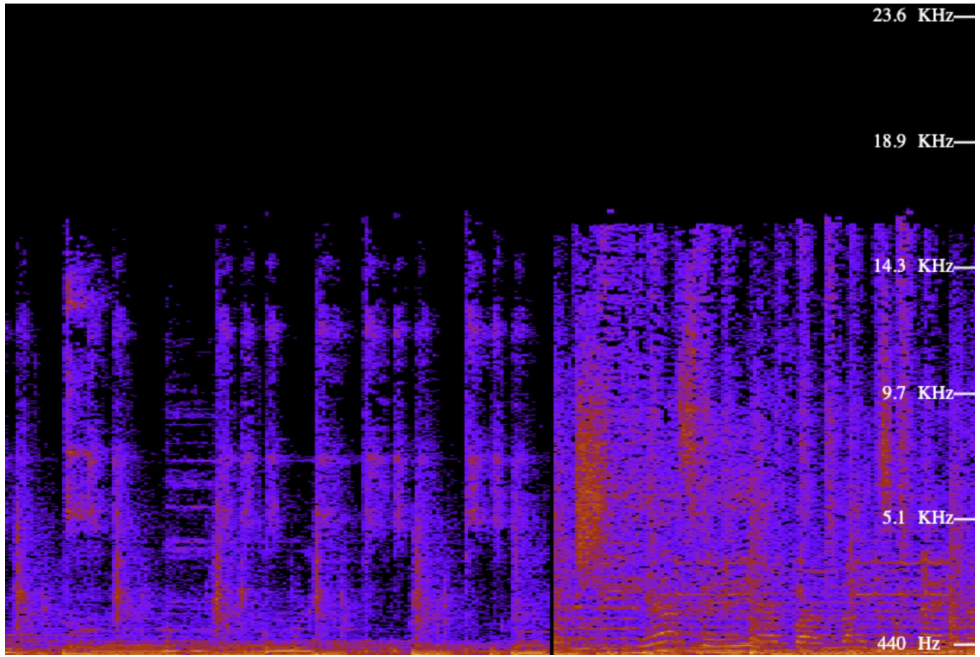

Ya no escuchamos la canción: “**la observamos”**

Espectrograma

Abre el código **Clase4. R**

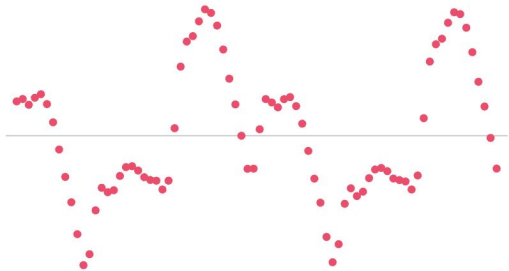

Ahora, nos **quedamos con lo más importante**

Imagina ver una ciudad **de noche** desde el avión: no ves calles, sólo las **luces más brillantes**...

y aun así **sabes qué es una ciudad**

Aplicamos la **misma idea** al **espectrograma**

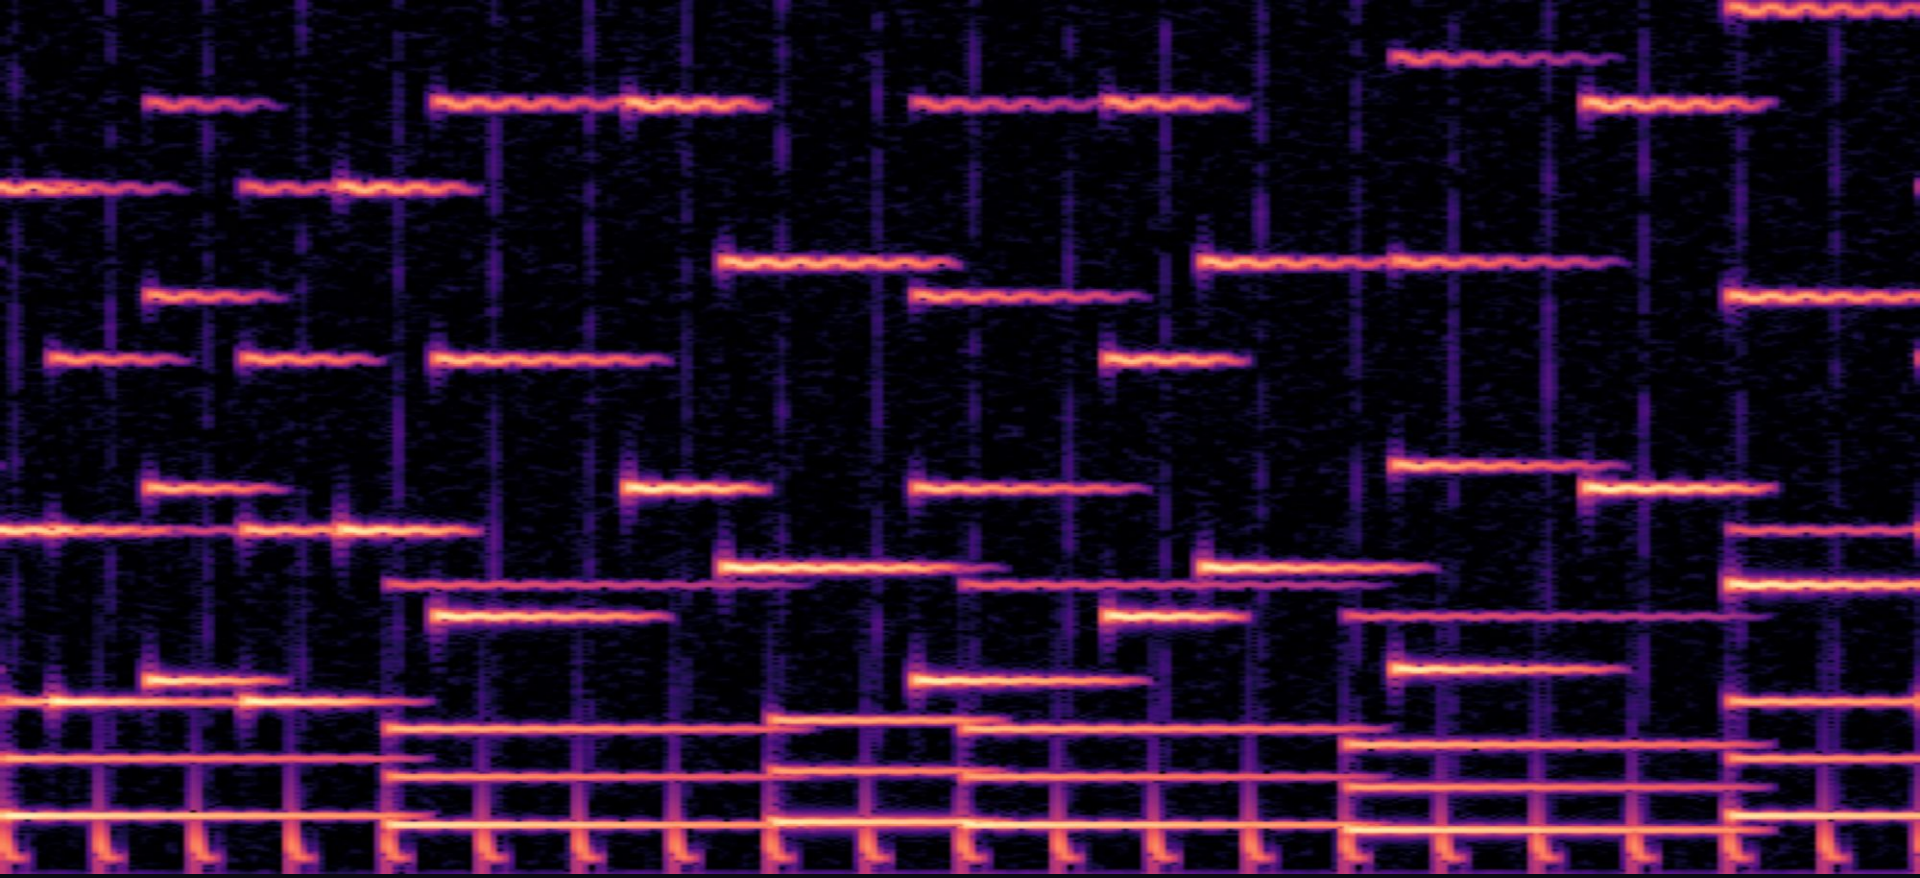

Un espectrograma tiene **muchísima** información...

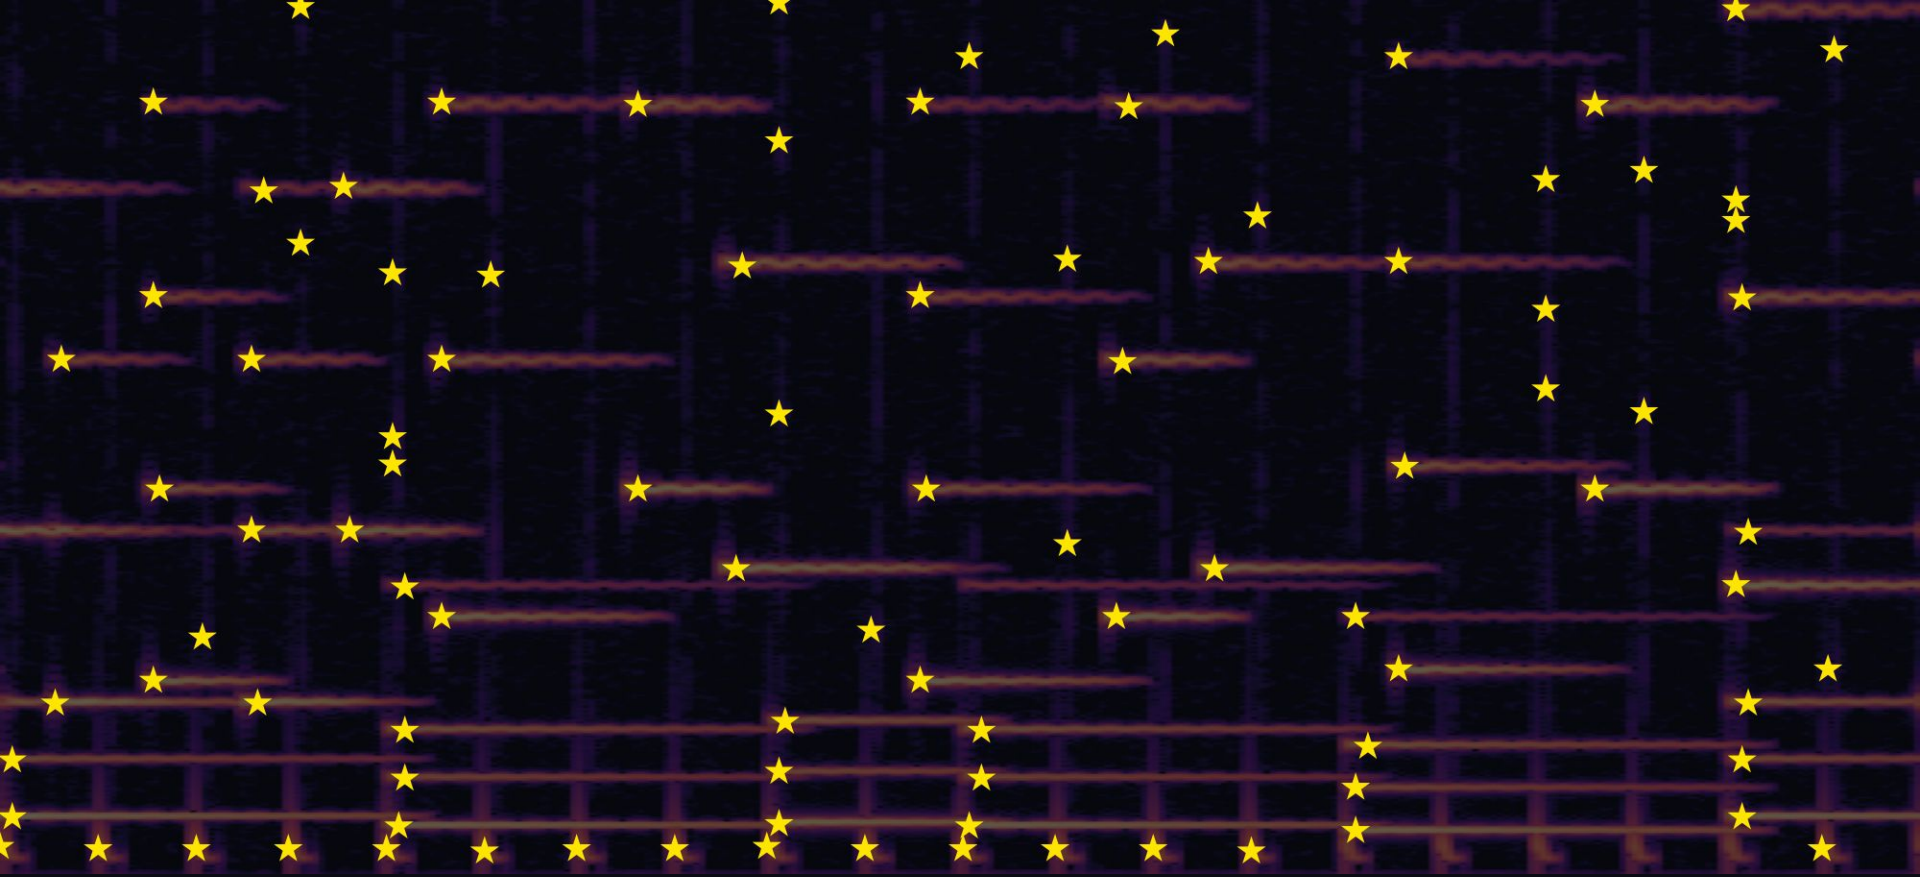

...nos quedamos sólo con los **picos**: el punto más fuerte de su vecindario

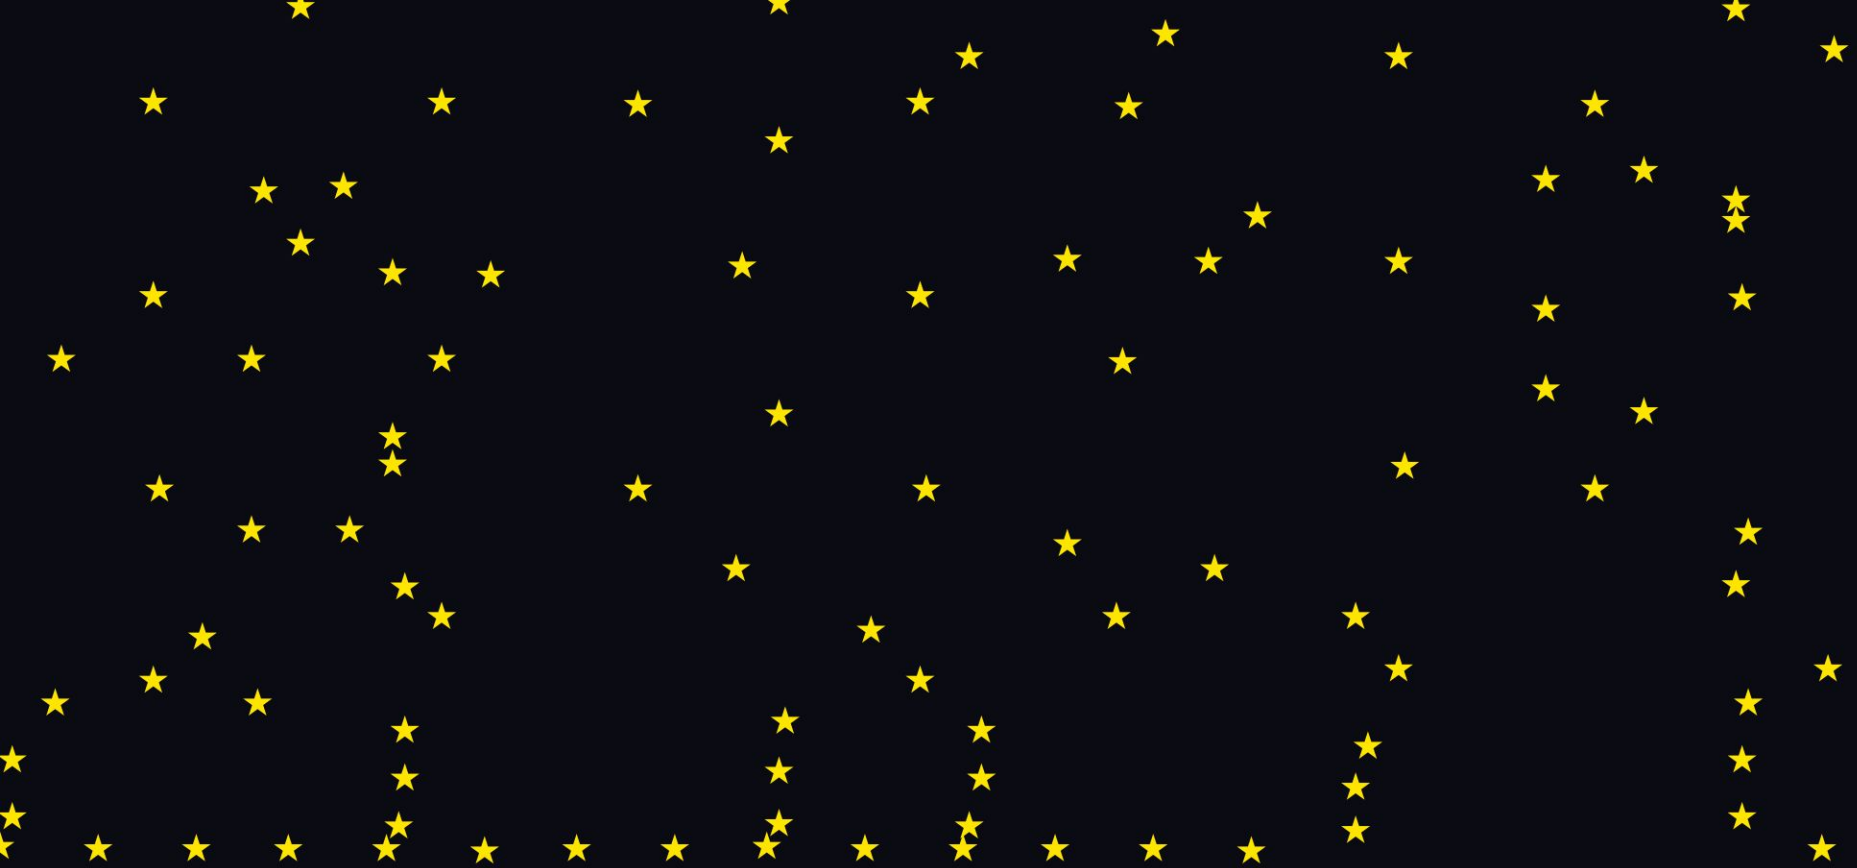

El resultado parece un cielo estrellado: la **constelación** de la canción

De **nueva cuenta**...

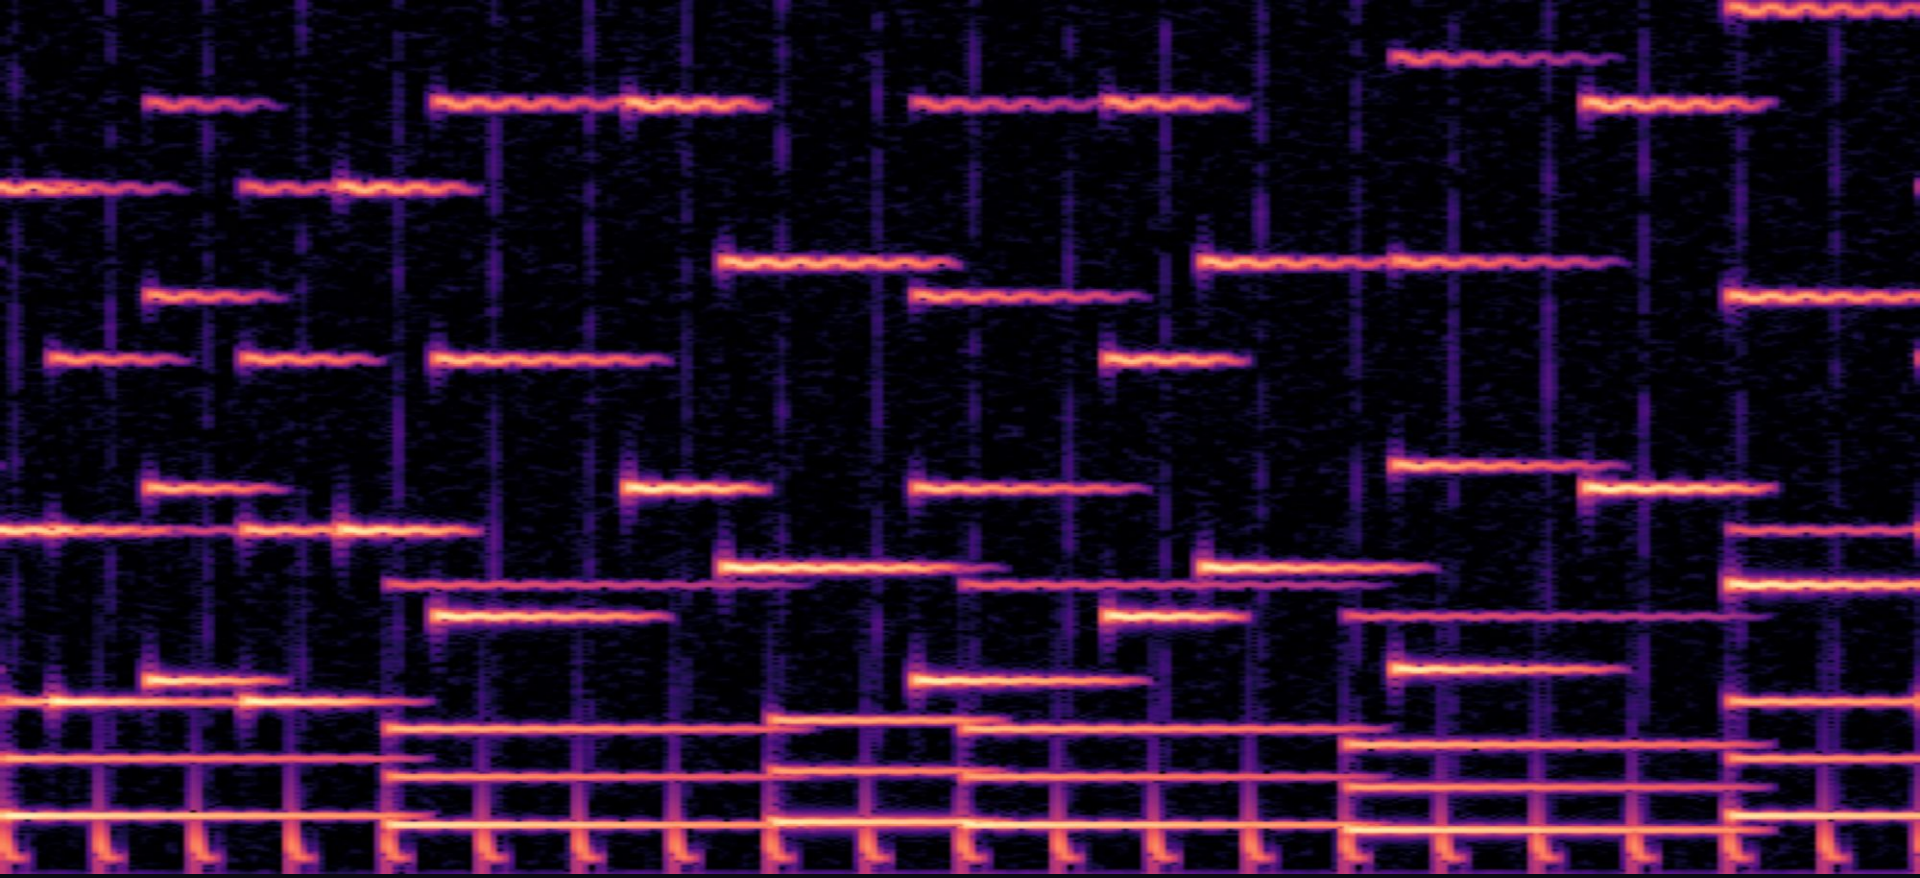

Un espectrograma tiene **muchísima** información...

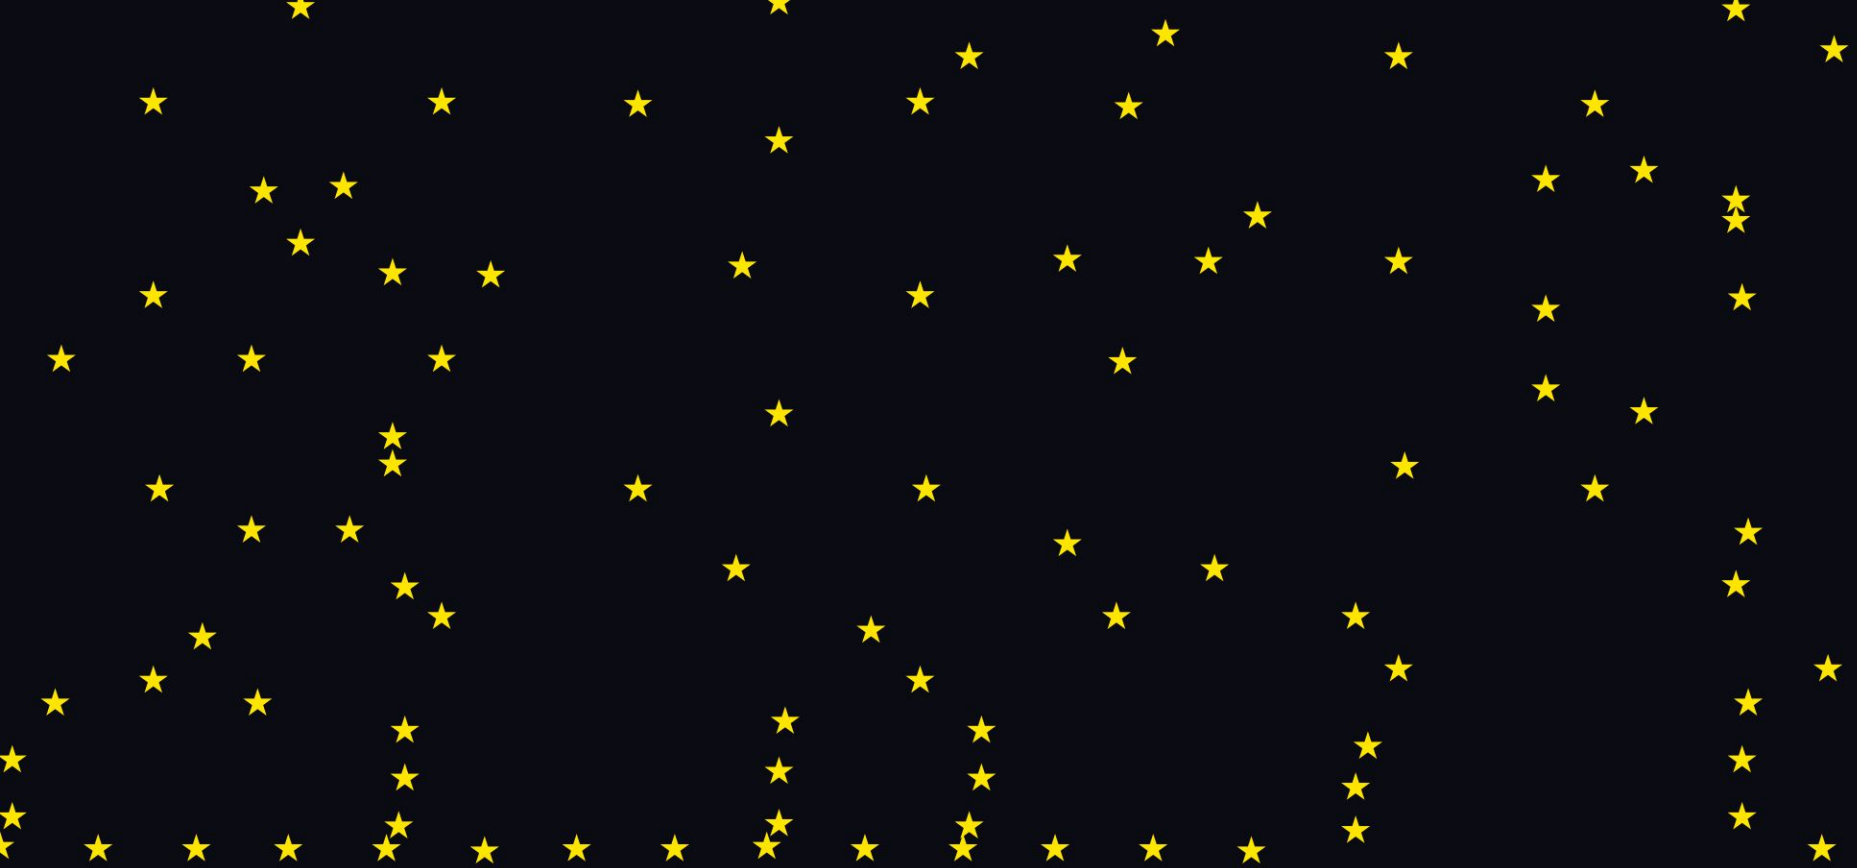

El resultado parece un cielo estrellado: la **constelación** de la canción

¿Cómo **determinamos las estrellas**?

Criterios estrella

De manera **muy general:**

1. Ser la más fuerte de su **vecindario**
2. Estar entre el **15%** más fuente de la canción

¿Por qué tirar **todo lo demás**?

El ruido **ensucia lo débil**,

pero las **estrellas** de la canción **siguen en su lugar**

Las estrellas sobreviven al ruido

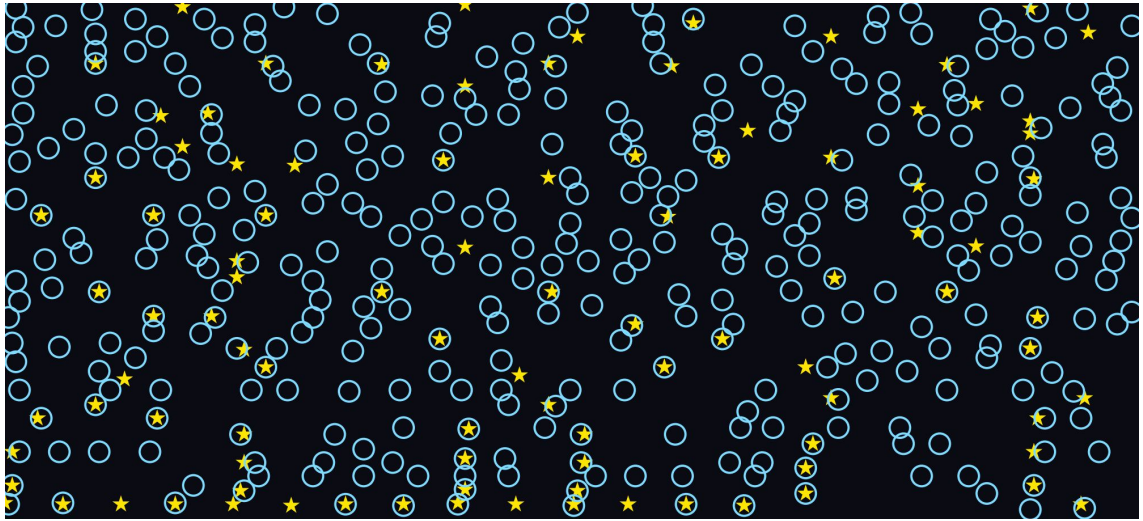

canción original

tu grabación con ruido

1 de cada 2

estrellas originales **sigue ahí**, aunque el ruido sea tan fuerte como la música

Constelación

Abre el código **Clase4. R**

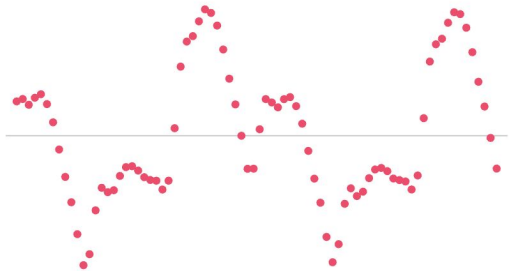

Ahora, necesitamos **crear “huellas”**

Una estrella sola dice **muy poco**:

«un tono agudo en el segundo 12» pasa en **miles de canciones**

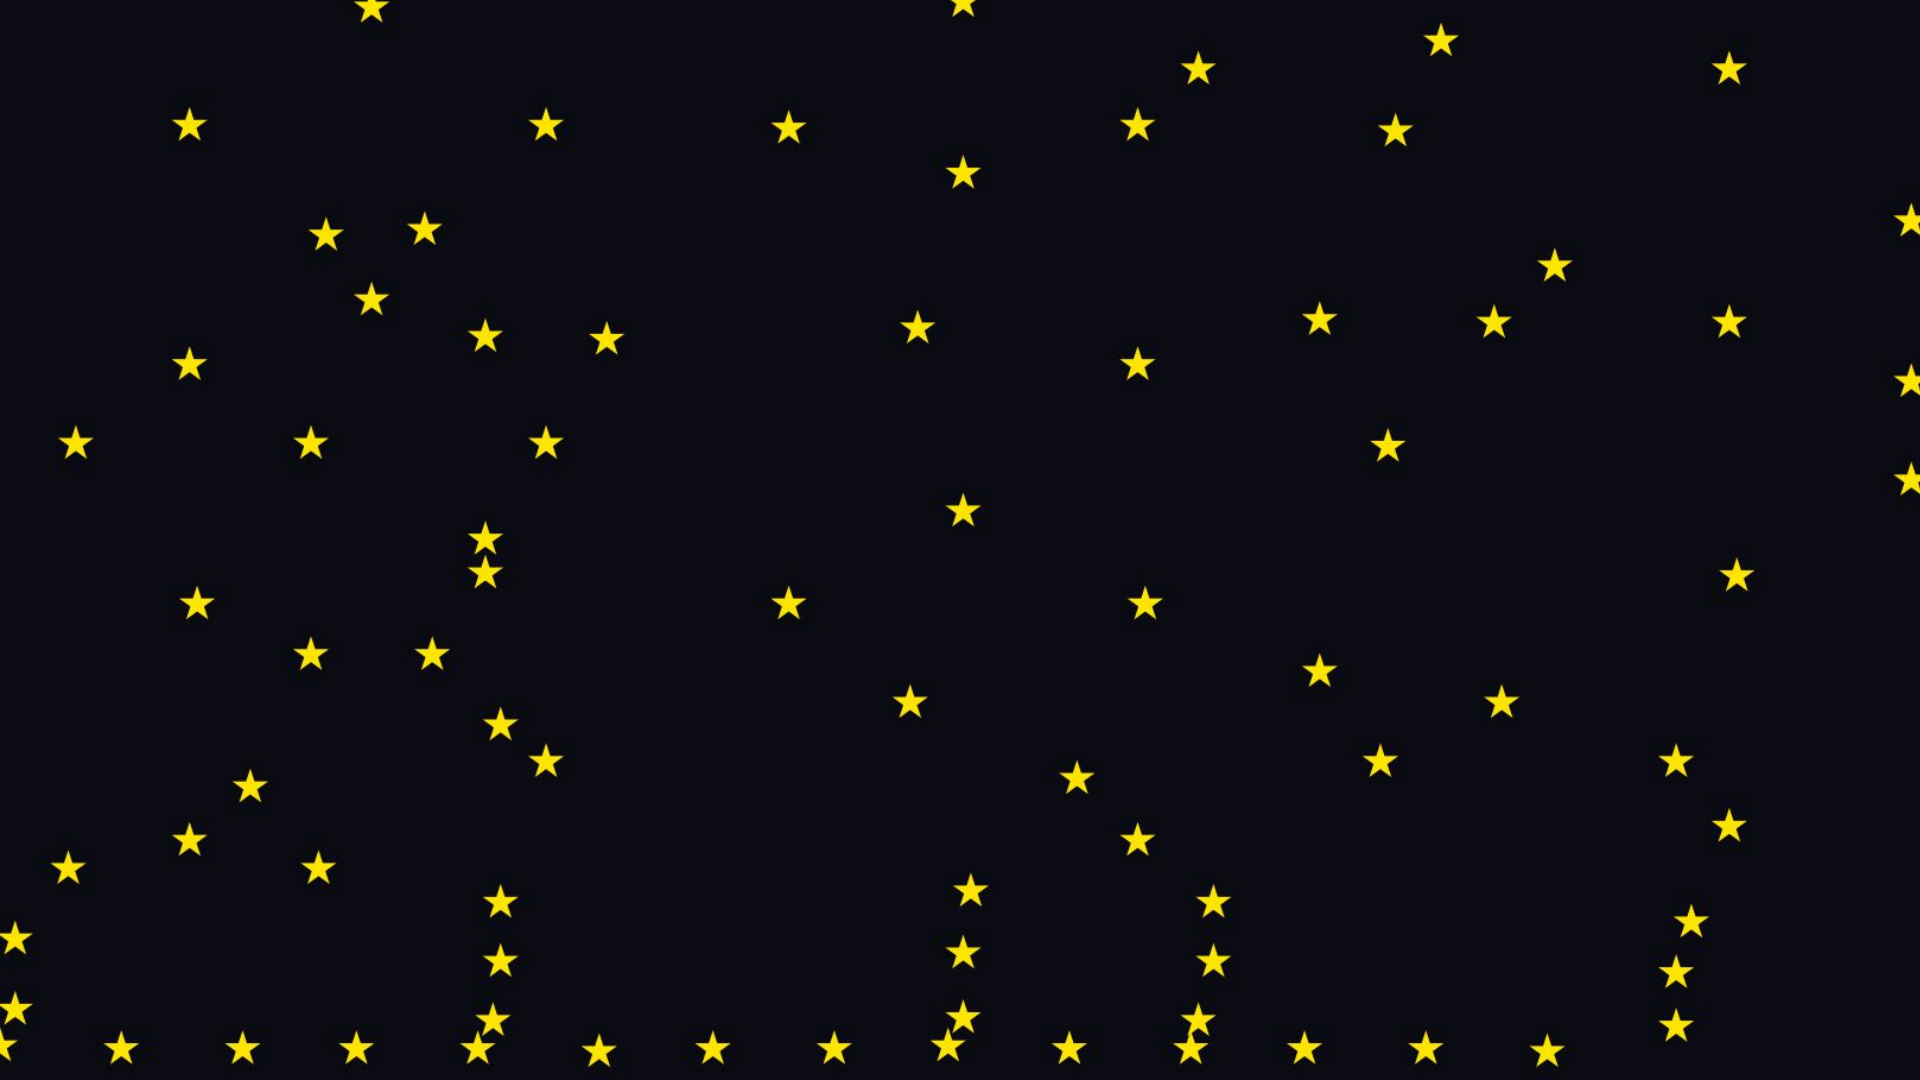

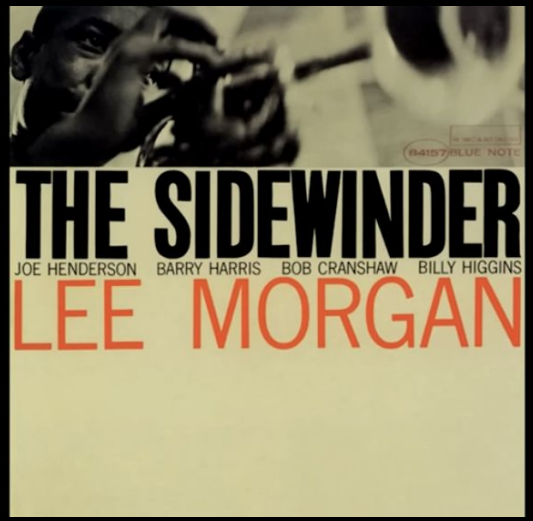
84157 BLUE NOTE
THE SIDEWINDER
JOE HENDERSON BARRY HARRIS BOB CRANSHAW BILLY HIGGINS
LEE MORGAN

★

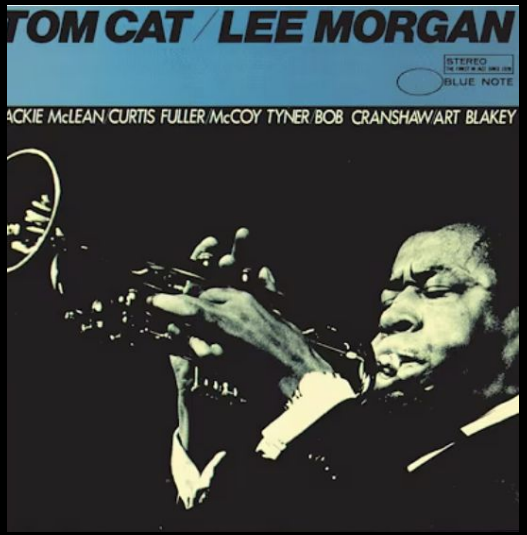
TOM CAT / LEE MORGAN
STEREO
BLUE NOTE
ACKIE McLEAN CURTIS FULLER McCOY TYNER BOB CRANSHAW ART BLAKEY

LEE MORGAN / JACKIE McLEAN / HANK MOBLEY
HERBIE HANCOCK / LARRY RIDLEY / BILLY HIGGINS
CORNBREAD
CORNBREAD
CORNBREAD
CORNBREAD
STEREO
BLUE NOTE

Una **misma estrella solita** puede **aparecer en muchas canciones**

Es como un **número de teléfono**:

un dígito no identifica a nadie,

pero **10 dígitos juntos** sí

Necesitamos **un criterio más sólido**

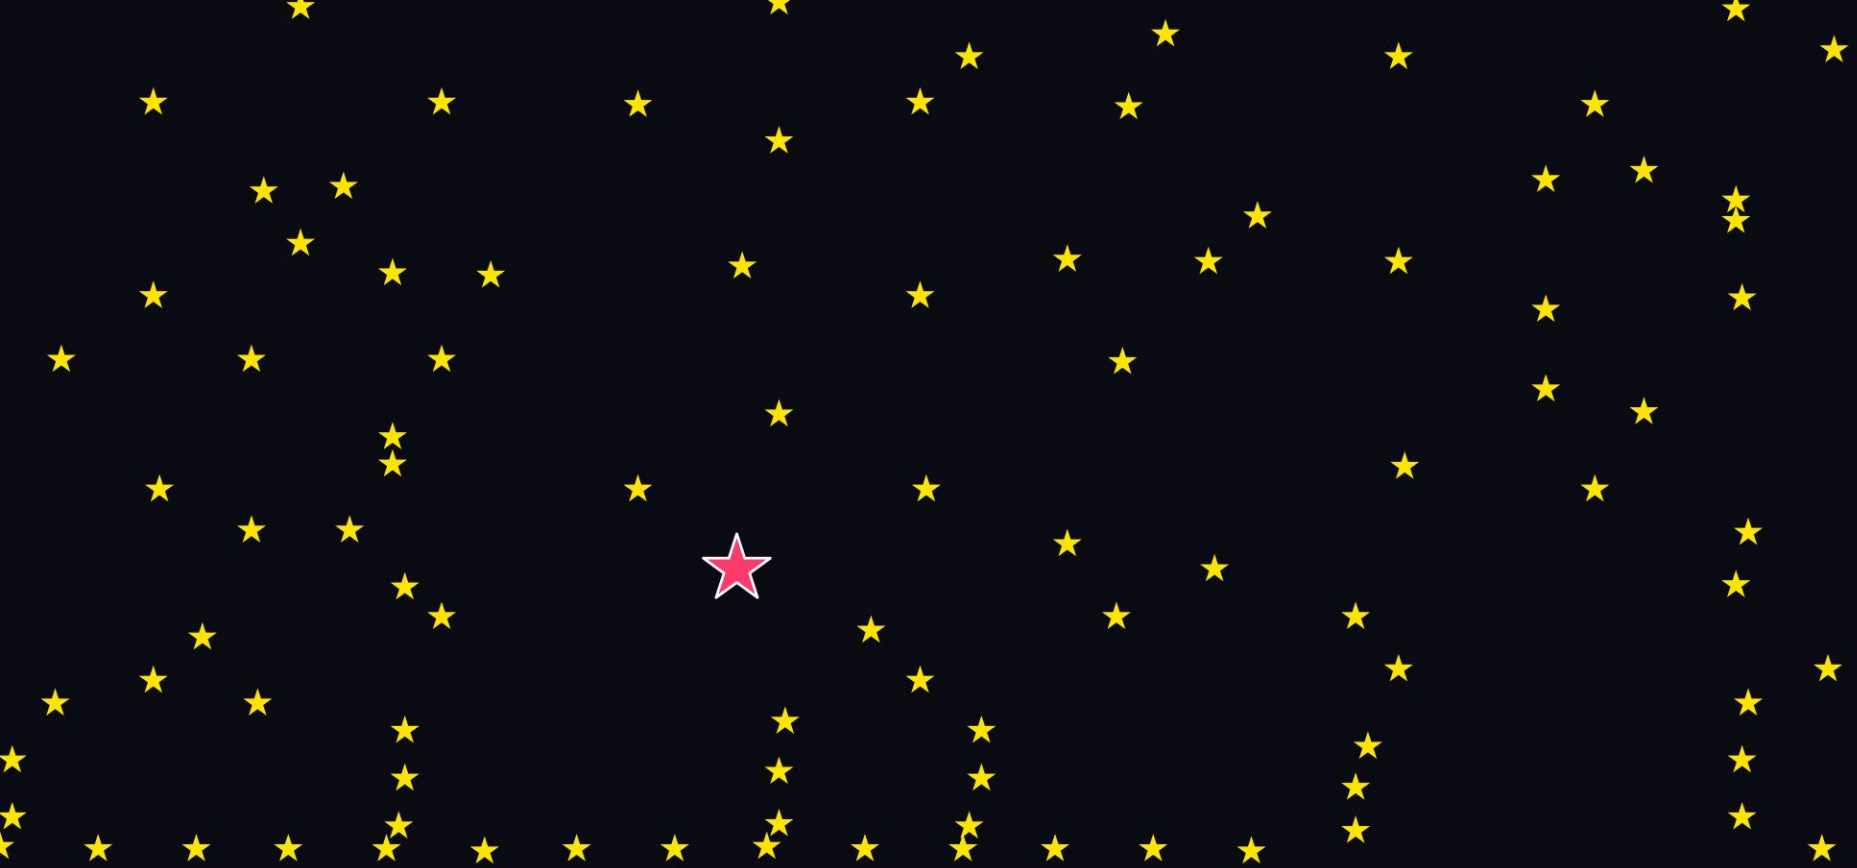

Elegimos una estrella: el **ancla**

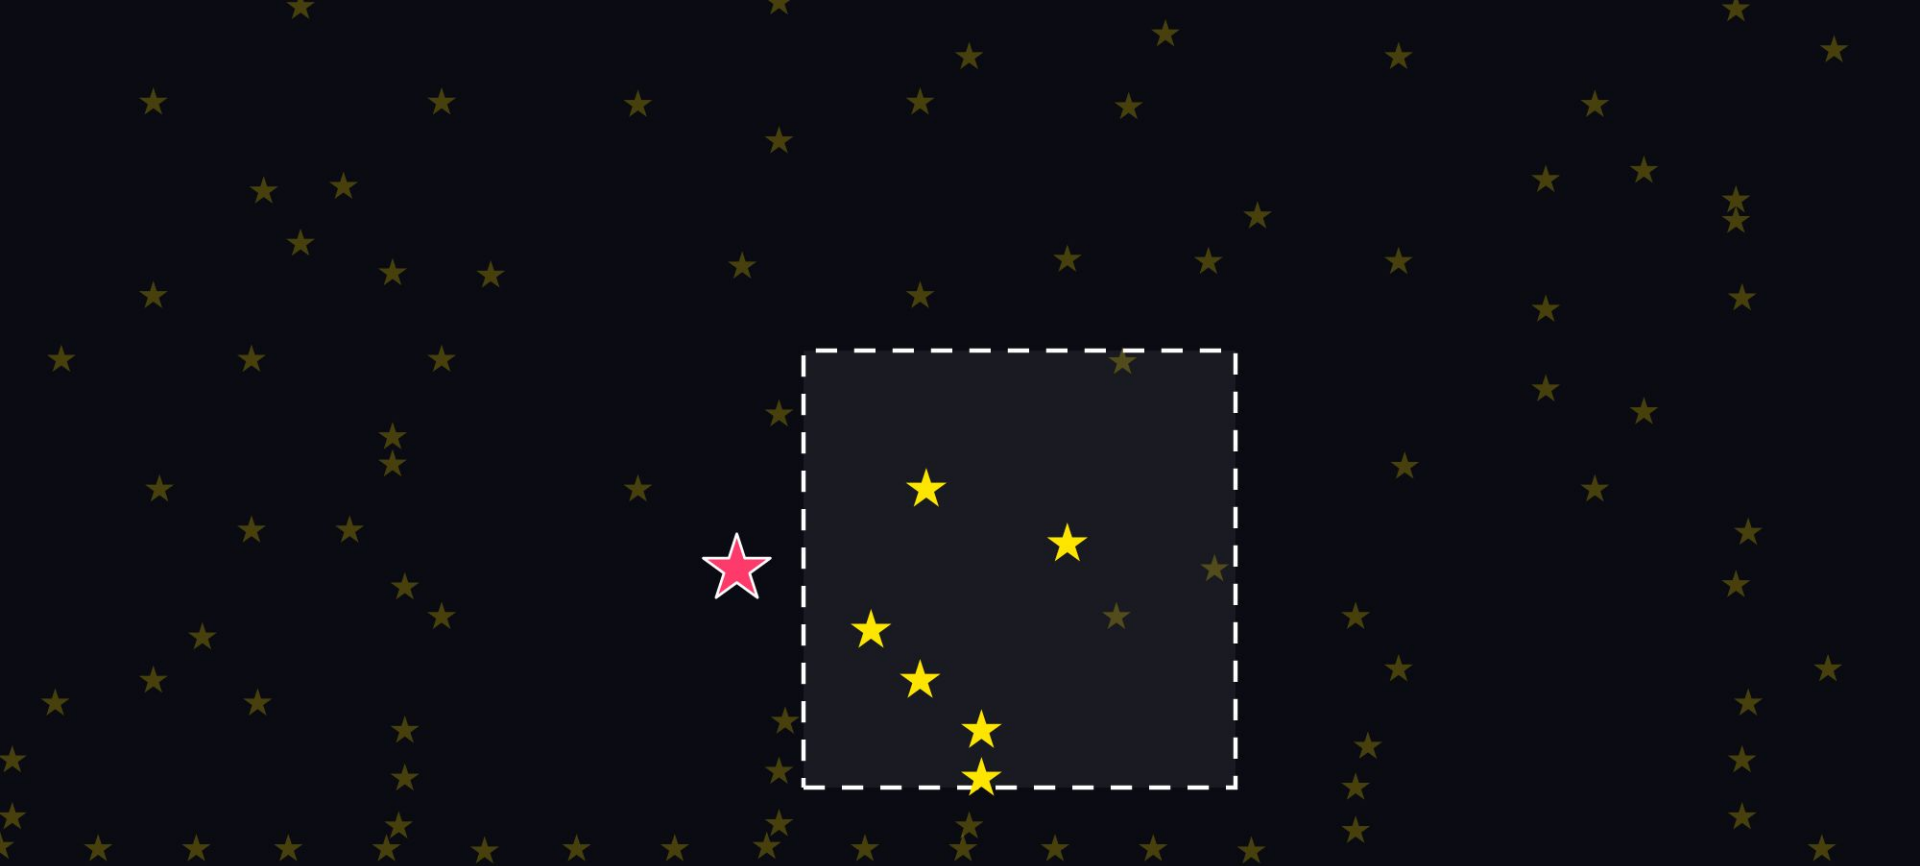

Miramos una **zona** un poco más adelante

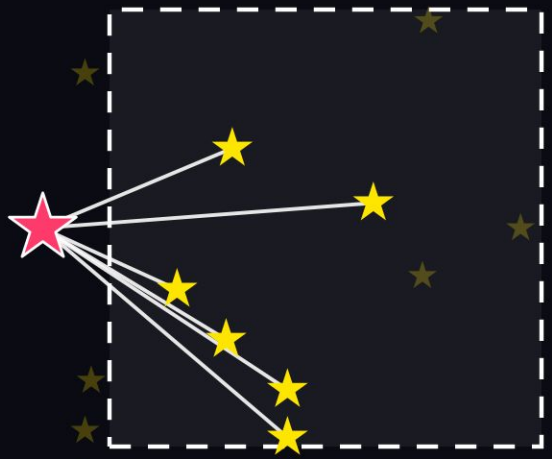

Y la unimos con las estrellas de esa zona (Shazam usa unas **10**)

Cada pareja es una huella

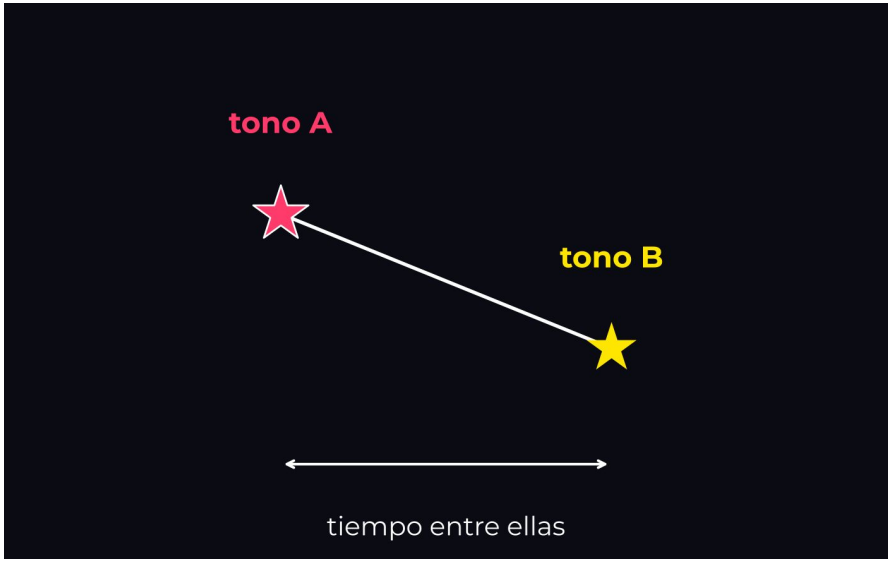

La huella son **3 números**:

tono A	tono B	tiempo
1,047 Hz	**664 Hz**	**0.96 s**

Y anotamos **dónde apareció**: segundo **43.8** de la canción

Cada pareja es una huella

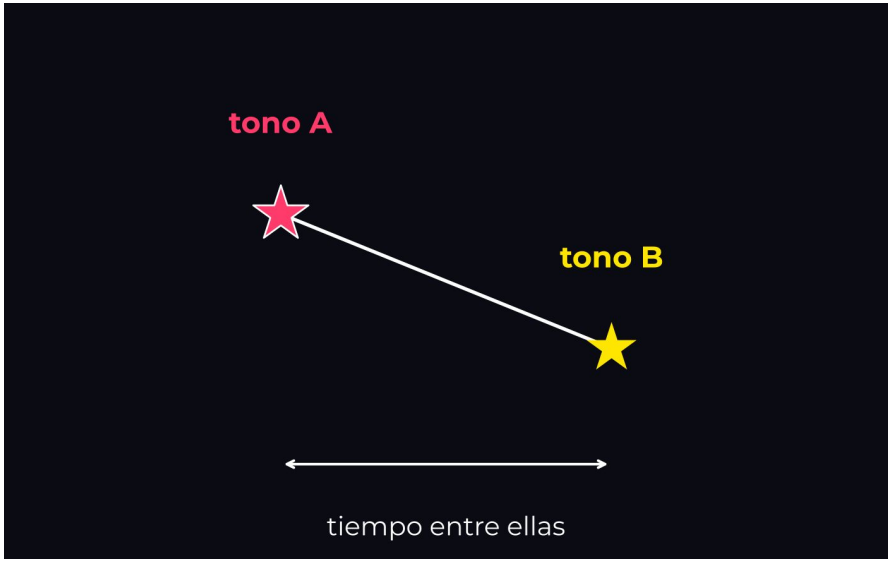

La huella son **3 números**:

tono A	tono B	tiempo
1,047 Hz	**664 Hz**	**0.96 s**

Y anotamos **dónde apareció**: segundo **43.8** de la canción

Esos **3 números** son la huella...

pero Shazam los convierte en **un solo número**

A ese número se le llama **hash**:

convierte datos en **un número que sirve como llave**

Así se arma el hash

la pareja

1,047 Hz
664 Hz
0.96 s

Empezamos con la pareja: **3 números**

Así se arma el hash

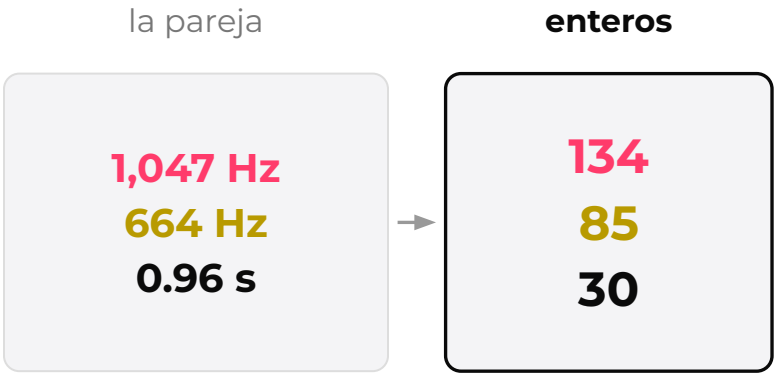

Paso 1: los redondeamos a **números enteros**

Así se arma el hash

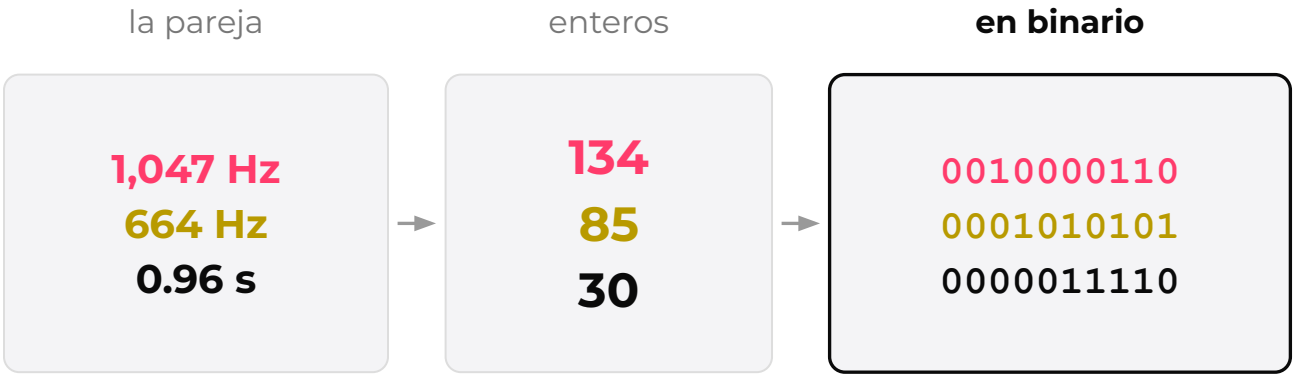

Paso 2: escribimos cada uno en **binario** (10 dígitos)

Así se arma el hash

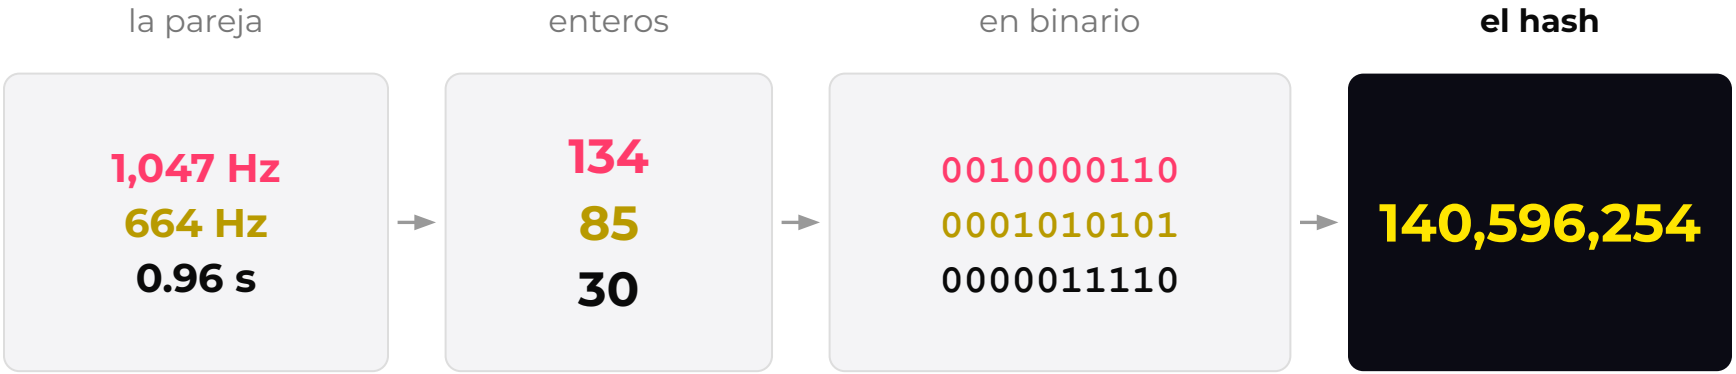

Paso 3: los pegamos uno tras otro: **es el hash**

Misma pareja de estrellas → **siempre el mismo hash**

Así tu grabación y la canción producen **la misma llave**

i.e. **trata** de producir un ***hash* único**

Como tu **CURP**:

se arma con tus datos...

y es **una sola llave**

que te **identifica de forma única**

¿Por qué parejas? Son mucho más específicas

1 estrella

~miles

canciones posibles

1 pareja

~decenas

combinaciones posibles

Una pareja es **mucho más más difícil** de encontrar por casualidad

Como cada estrella forma **varias parejas**, si el ruido **borra** algunas, **quedan otras**

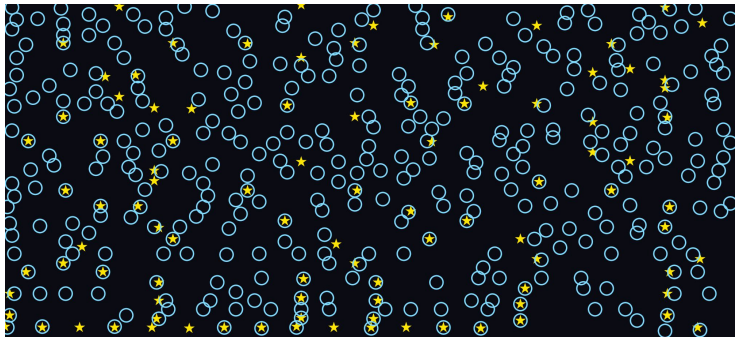

En resumen:

Shazam crea una **biblioteca** de **hashes de millones de canciones**

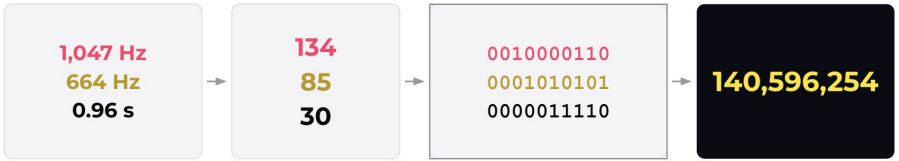

Piensa en el **índice al final de un libro**:

buscas **capítulo** y te dice en qué **página** está

Nuestro índice de huellas

Huella (tono A · tono B · tiempo)	Canción	Segundo
1047 · 664 · 0.96	Canción A	43.8
523 · 784 · 0.35	Canción C	12.1
1047 · 664 · 0.96	Canción E	7.3
392 · 1,175 · 1.20	Canción B	31.6
…	…	…

Una misma huella puede aparecer en **varias canciones**

El índice se arma **una sola vez** con todas las canciones

Nuestro índice de huellas

Huella (tono A · tono B · tiempo)	Canción	Segundo
1047 · 664 · 0.96	Canción A	43.8
523 · 784 · 0.35	Canción C	12.1
1047 · 664 · 0.96	Canción E	7.3
392 · 1,175 · 1.20	Canción B	31.6
…	…	…

Una misma huella puede aparecer en **varias canciones**

El índice se arma **una sola vez** con todas las canciones

Buscar una huella en el índice es **instantáneo**:

no hay que escuchar ninguna canción

hashes y huellas

Abre el código **Clase4. R**

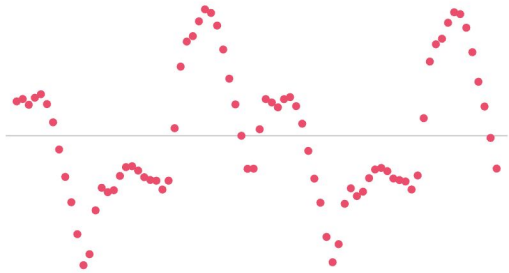

La votación

Esto es **lo más importante**

Llega tu grabación de **10 segundos**:

sacamos sus huellas y las **buscamos en el índice**

Problema:

Muchas huellas coinciden **por casualidad** con **muchas canciones**

Contar coincidencias no basta

Huellas de tu grabación que encontramos en...

135

la canción correcta

122

una canción equivocada

¡Casi empatan! Necesitamos **otra pista**

En el código vimos ***hashes*** que **aparecen muchas veces**

¿Cómo resolverlo? ¿Alguna sugerencia?

Ver la siguiente tabla...

Nuestro índice de huellas

Huella (tono A · tono B · tiempo)	Canción	Segundo
1047 · 664 · 0.96	Canción A	43.8
523 · 784 · 0.35	Canción C	12.1
1047 · 664 · 0.96	Canción E	7.3
392 · 1,175 · 1.20	Canción B	31.6
…	…	…

Nuestro índice de huellas

Huella (tono A · tono B · tiempo)	Canción	Segundo
1047 · 664 · 0.96	Canción A	43.8
523 · 784 · 0.35	Canción C	12.1
1047 · 664 · 0.96	Canción E	7.3
392 · 1,175 · 1.20	Canción B	31.6
…	…	…

Nuestro índice de huellas

Huella (tono A · tono B · tiempo)	Canción	Segundo
1047 · 664 · 0.96	Canción A	43.8
523 · 784 · 0.35	Canción C	12.1
1047 · 664 · 0.96	Canción E	7.3
392 · 1,175 · 1.20	Canción B	31.6
…	…	…

No importa **cuántas** huellas coinciden, sino **cuándo** coinciden

¿Cómo determinamos que una **muestra** **sí pertenece a una canción**?

Desfase y huella

Desfase y huella

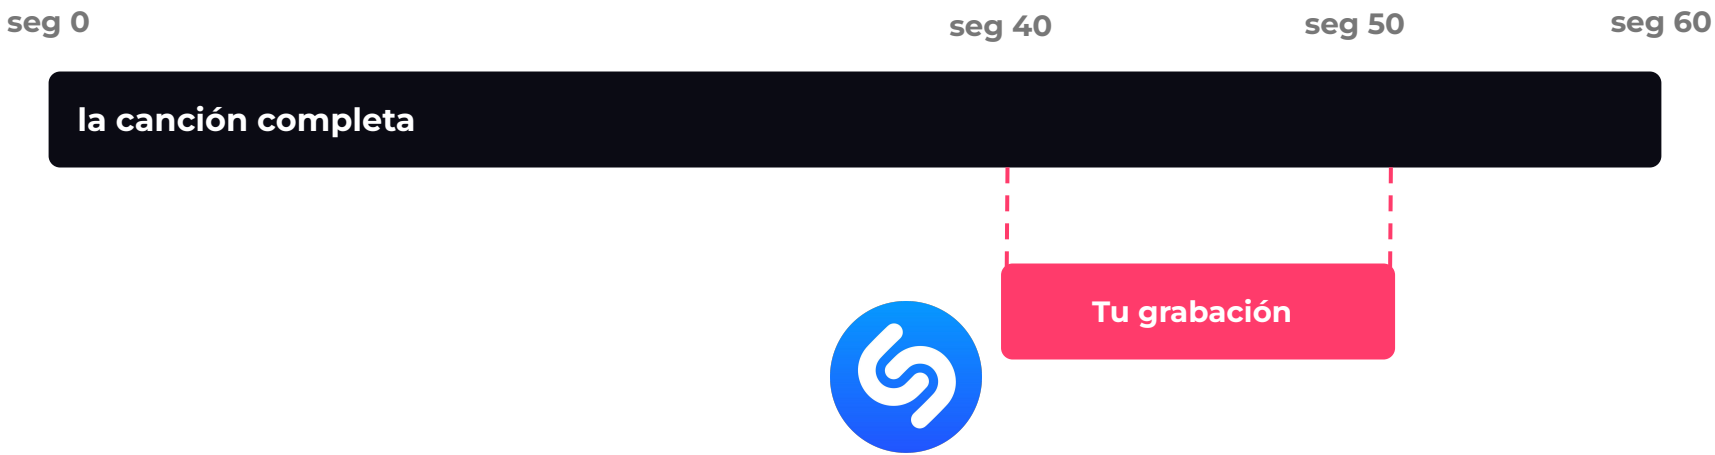

A priori, **Shazam no sabe** en qué segundo de la canción comenzaste a grabar

Desfase y huella

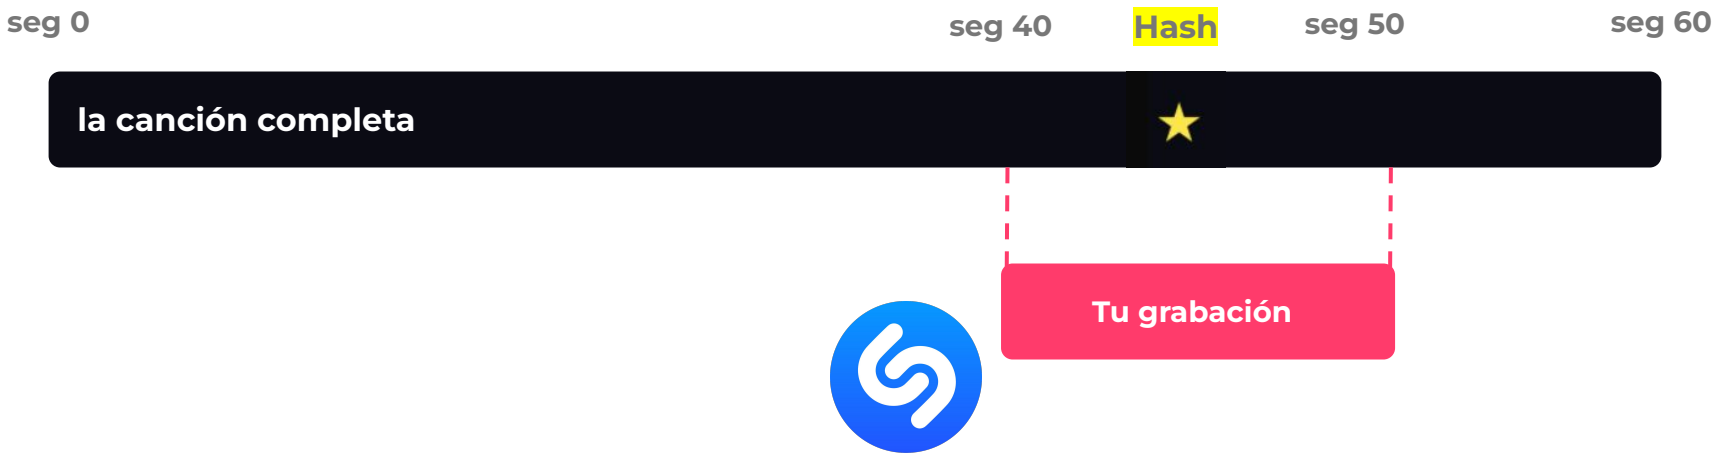

Desfase y huella

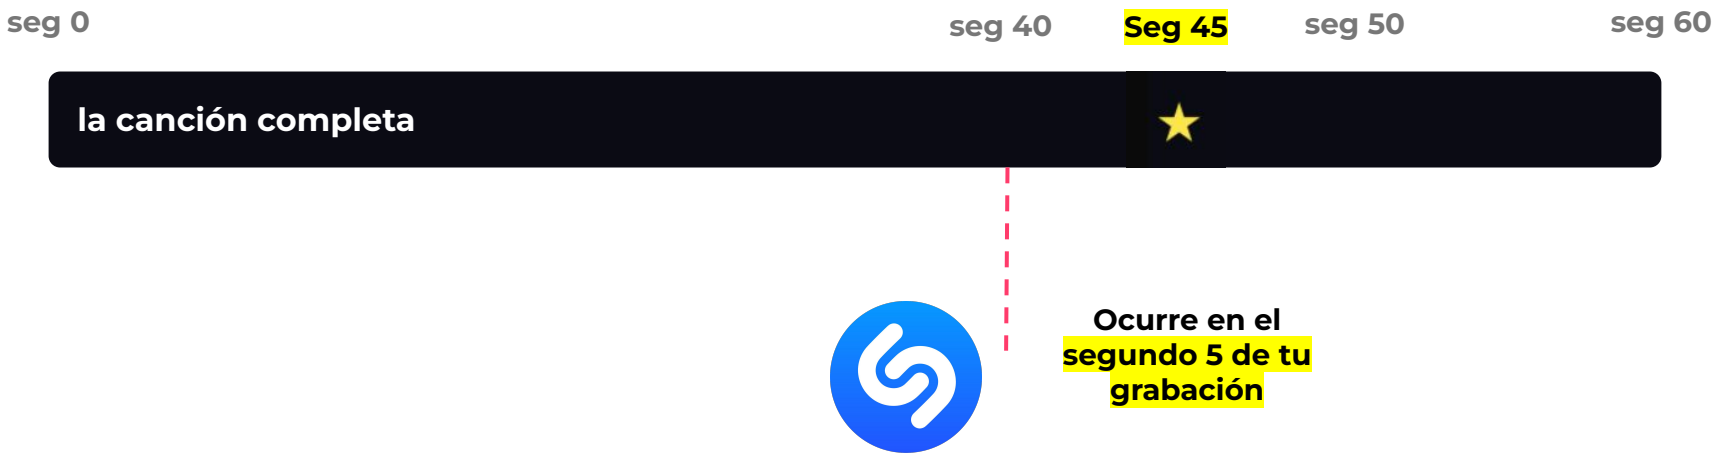

Intenta **adivinar:**

¿En qué momento de la canción empezaste a grabar?

Diferencia en segundos

Calcula la **diferencia** con un **Testigo**

Testigo

«Aparecí en el **segundo 5** de tu grabación
y en el **segundo 45** de la canción... ★

...entonces **empezaste a grabar en el segundo 40 de *X* canción**»

45 − 5 = **40**

Desfase y huella

Cada **Testigo** nos dice: “yo creo que **empezaste a grabar en el segun X**”

Importante:

Cada huella que coincide es un **testigo más...**

¿Quién dice la verdad?

Canción correcta

tu grabación	la canción	dice que empezaste en...
seg 2	seg 42	**seg 40**
seg 5	seg 45	**seg 40**
seg 7	seg 47	**seg 40**
seg 9	seg 49	**seg 40**

Muchos testigos dicen **lo mismo**

Canción equivocada

tu grabación	la canción	dice que empezaste en...
seg 2	seg 13	seg 11
seg 5	seg 51	seg 46
seg 7	seg 30	seg 23
seg 9	seg 58	seg 49

Cada dice **algo distinto**

¿Quién dice la verdad?

Canción correcta

tu grabación	la canción	dice que empezaste en...
seg 2	seg 42	**seg 40**
seg 5	seg 45	**seg 40**
seg 7	seg 47	**seg 40**
seg 9	seg 49	**seg 40**

Muchos testigos dicen **lo mismo**

Canción equivocada

tu grabación	la canción	dice que empezaste en...
seg 2	seg 13	seg 11
seg 5	seg 51	seg 46
seg 7	seg 30	seg 23
seg 9	seg 58	seg 49

Cada dice **algo distinto**

Los testigos de la canción correcta **“se ponen de acuerdo”**

Los de la equivocada **difieren**...

Dibujemos a los testigos

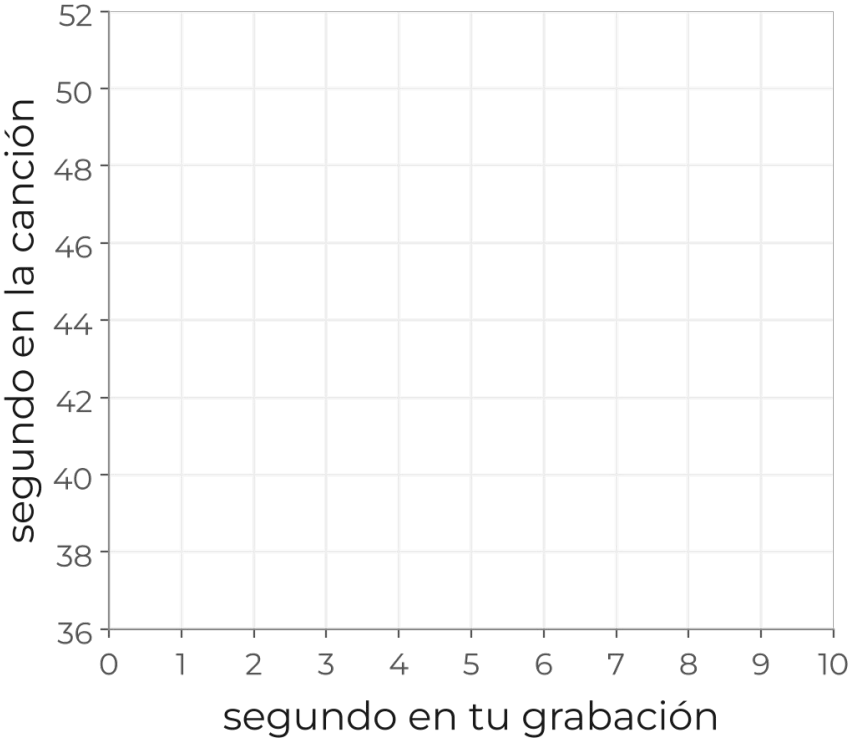

Dibujemos a los testigos

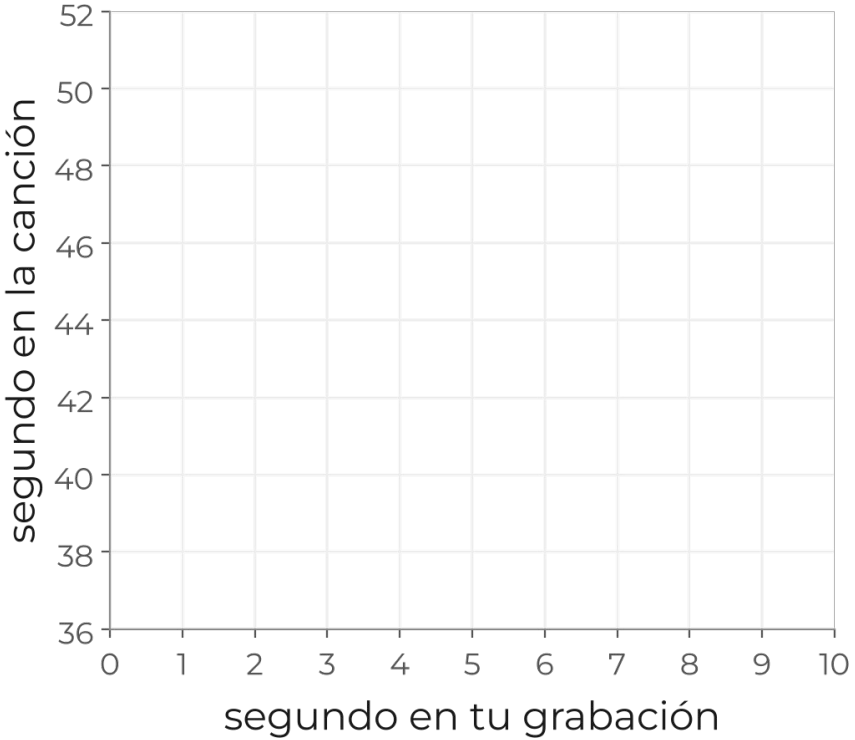

Cada testigo será un **punto**:

→ horizontal: cuándo apareció en **tu grabación**

↑ vertical: cuándo apareció en **la canción**

Dibujemos a los testigos

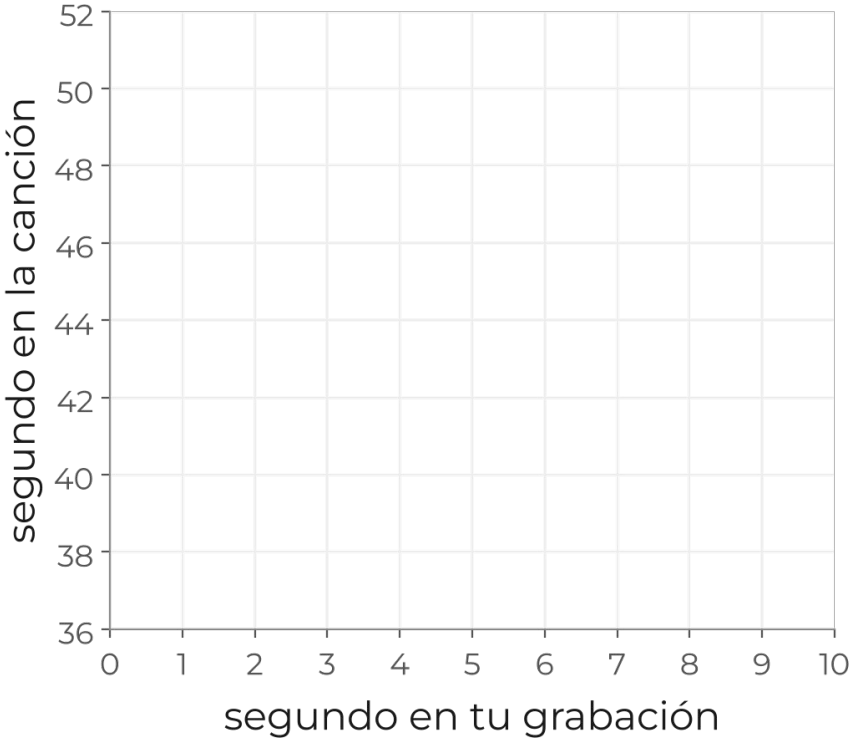

Cada testigo será un **punto**:

→ horizontal: cuándo apareció en **tu grabación**

↑ vertical: cuándo apareció en **la canción**

El primer testigo

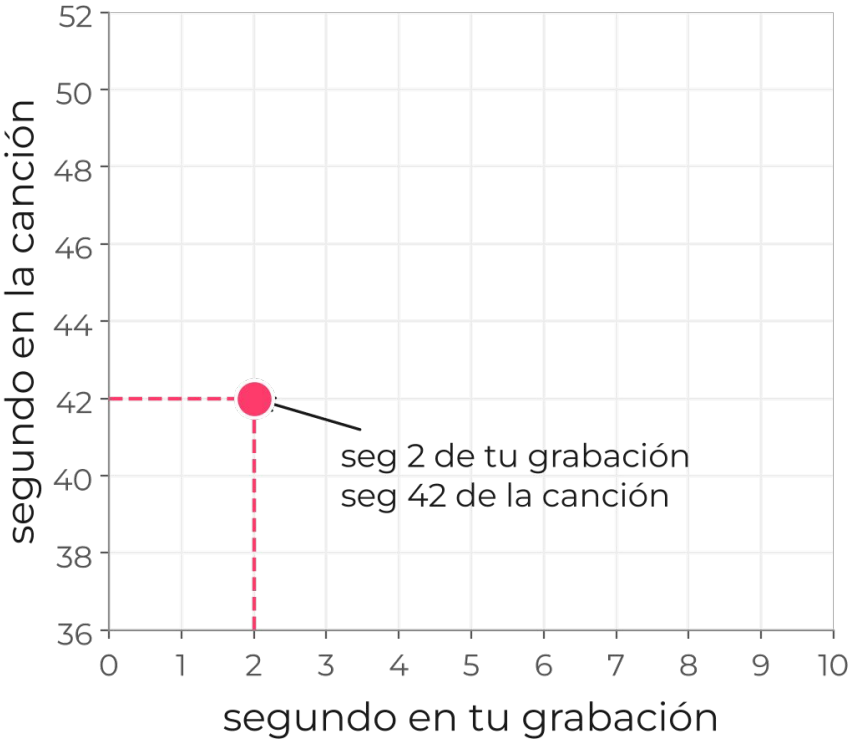

Apareció en tu **segundo 2**

y en el **segundo 42** de la canción.

Ahí va su punto.

Agreguemos más testigos

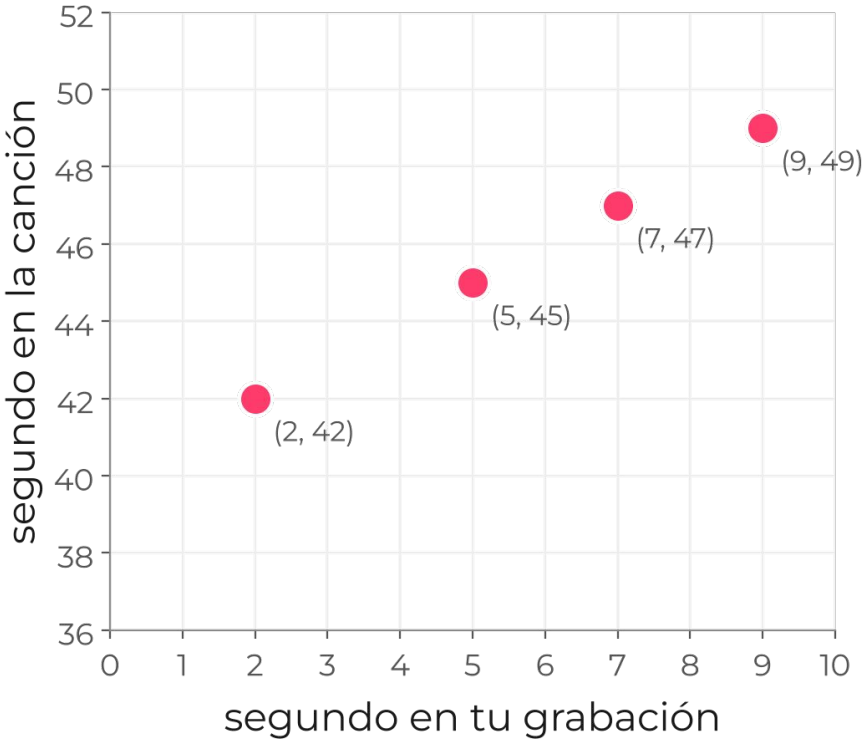

Si seguimos poniendo testigos de la **canción correcta**...

¿qué figura van a formar?

¿Por qué?

¡Una línea recta!

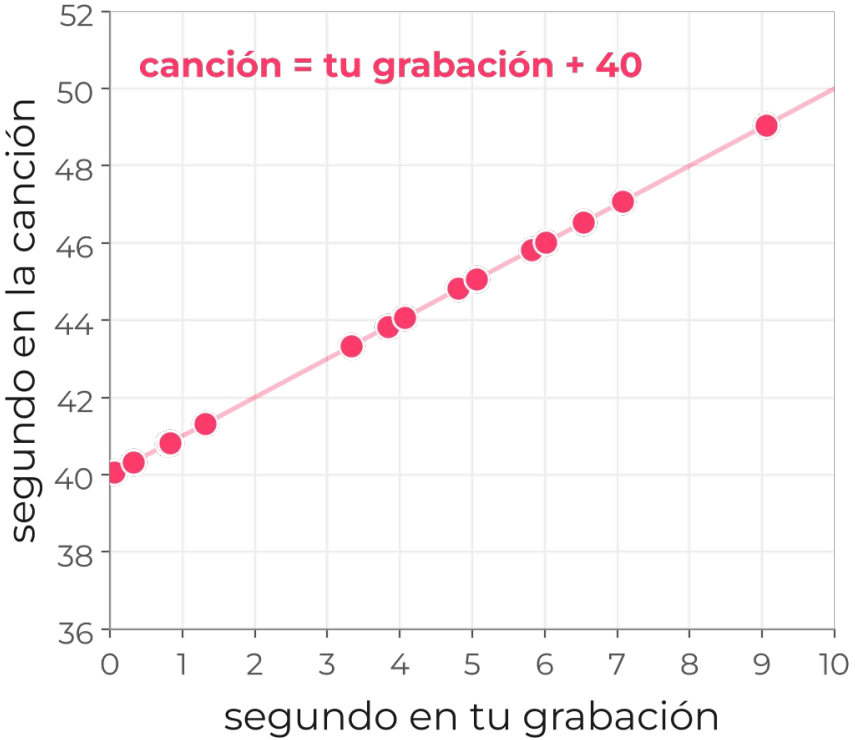

¡Una línea recta!

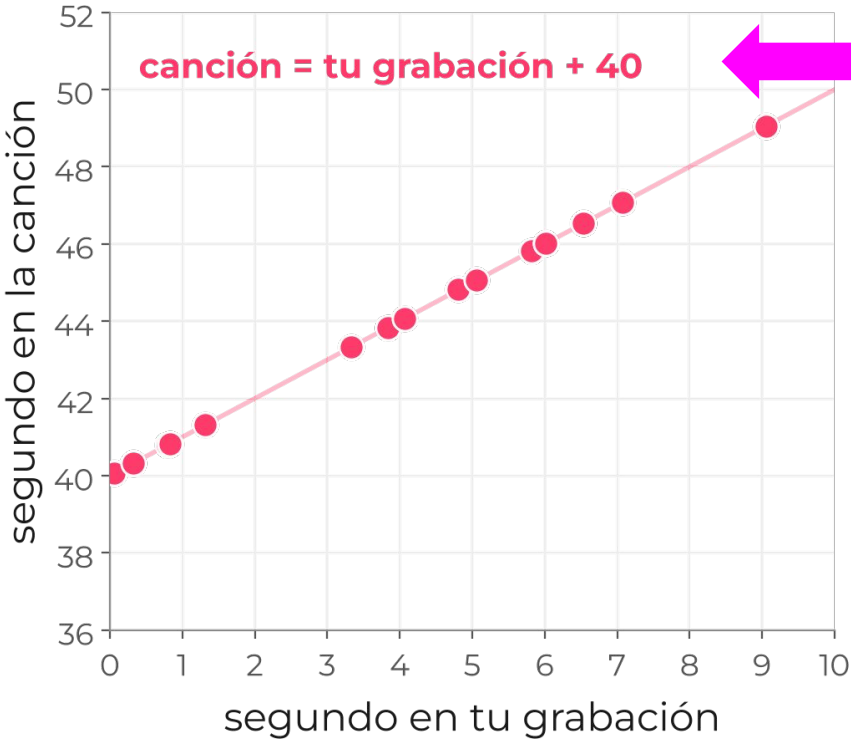

40: segundo de la canción en que **empezaste a grabar**

¡Una línea recta!

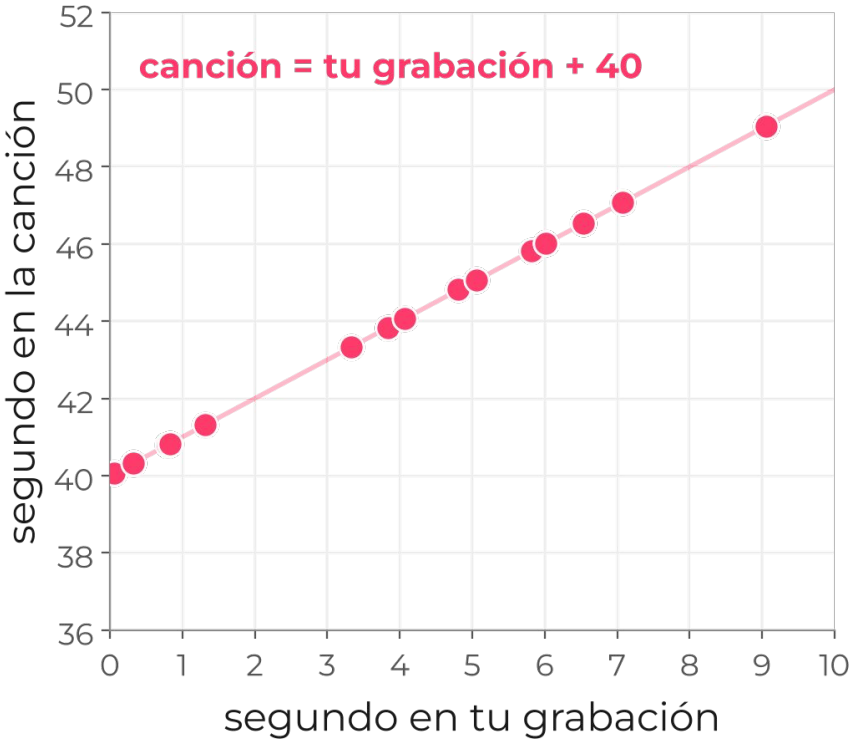

Porque todos cumplen la misma regla:
canción = tu grabación + 40

Cada segundo que avanza tu grabación, avanza **un segundo** la canción.

¿Y qué figura forman los testigos de la **canción equivocada**?

Canción equivocada: puntos regados

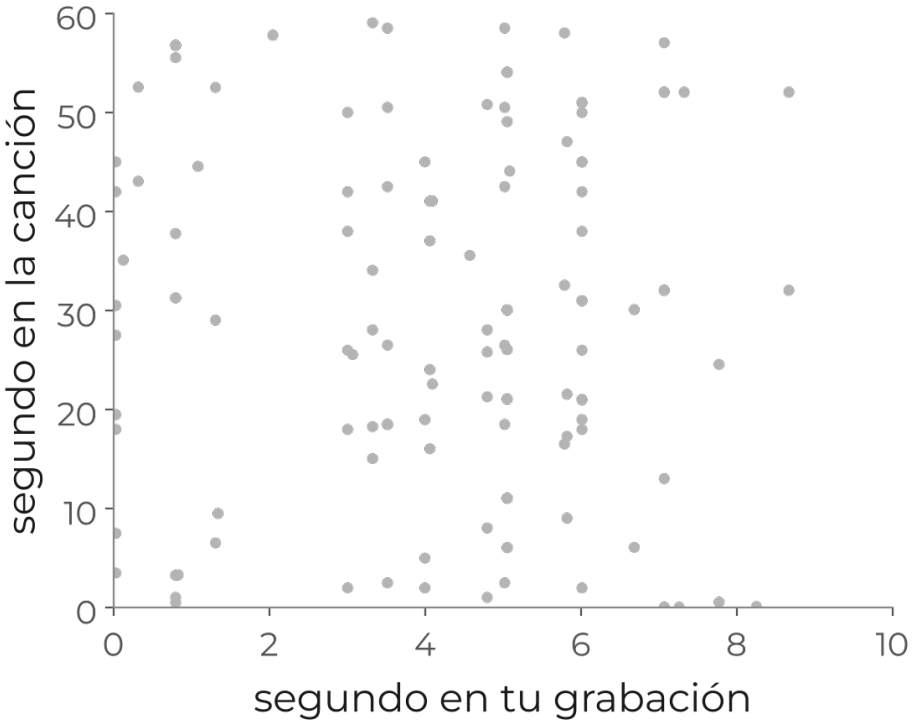

No hay línea: cada testigo determinar un segundo distinto.

(Alejamos la cámara: ahora vemos la canción completa, del segundo 0 al 60.)

Canción correcta, con todo y ruido

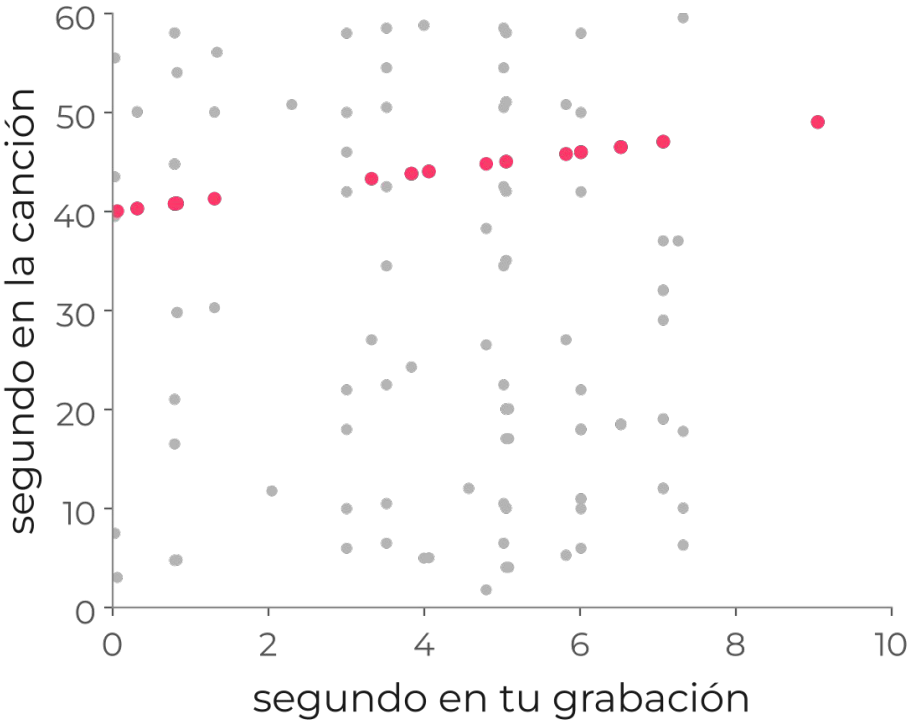

También tiene testigos que mienten (**gris**)...

pero la **línea** de los que dicen la verdad sobresale (**rosa**).

¿Cuántos testigos dicen cada número?

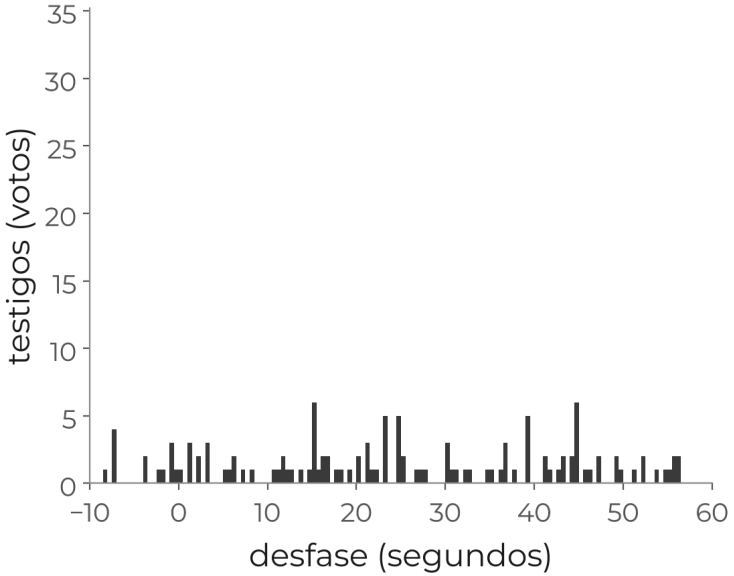

Equivocada: **ninguna sobresale**

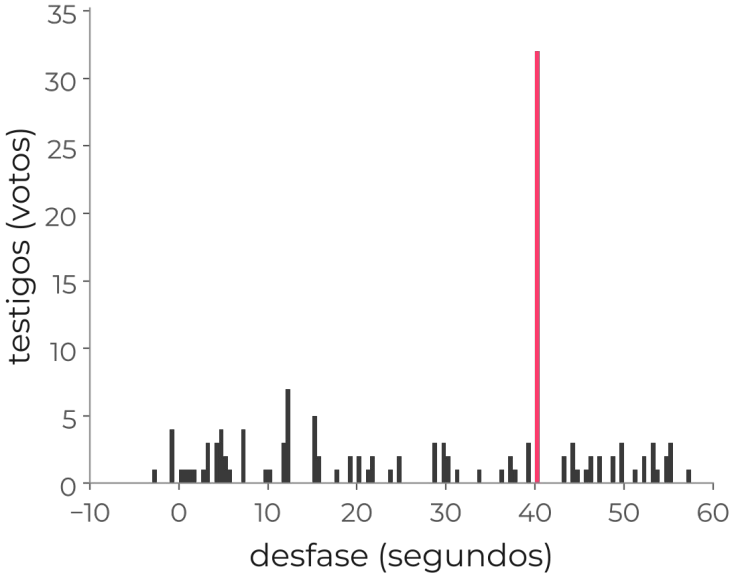

Correcta: **una torre** en el 40

¿Cuántos testigos dicen cada número?

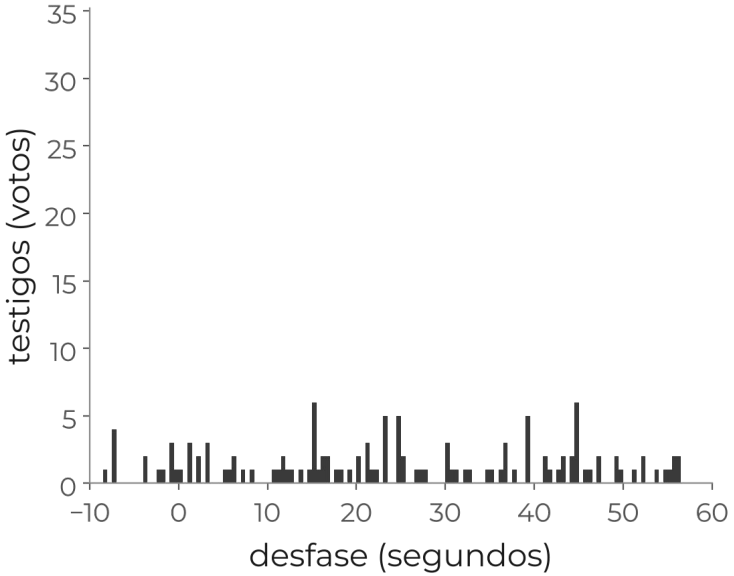

Equivocada: **ninguna sobresale**

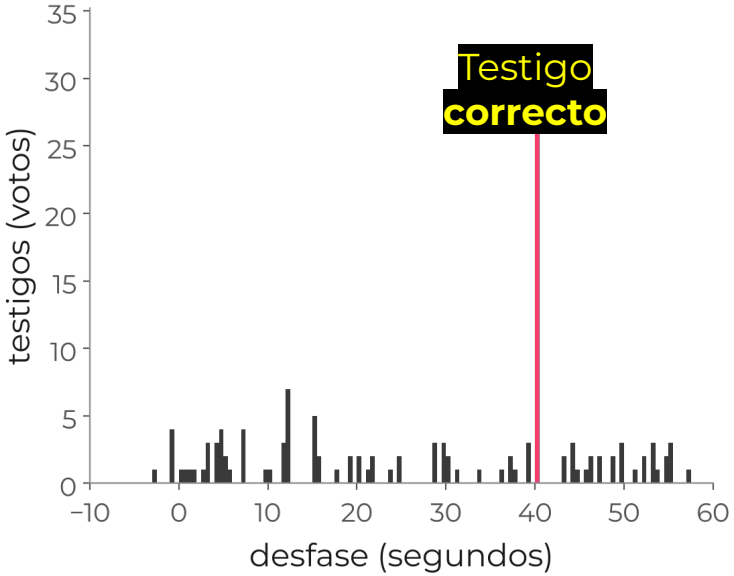

Correcta: **una torre** en el 40

¿Cuántos testigos dicen cada número?

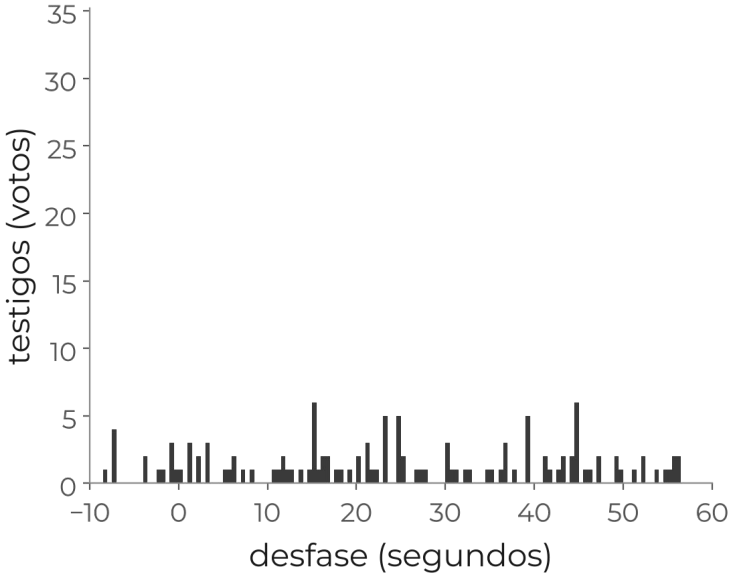

Equivocada: **ninguna sobresale**

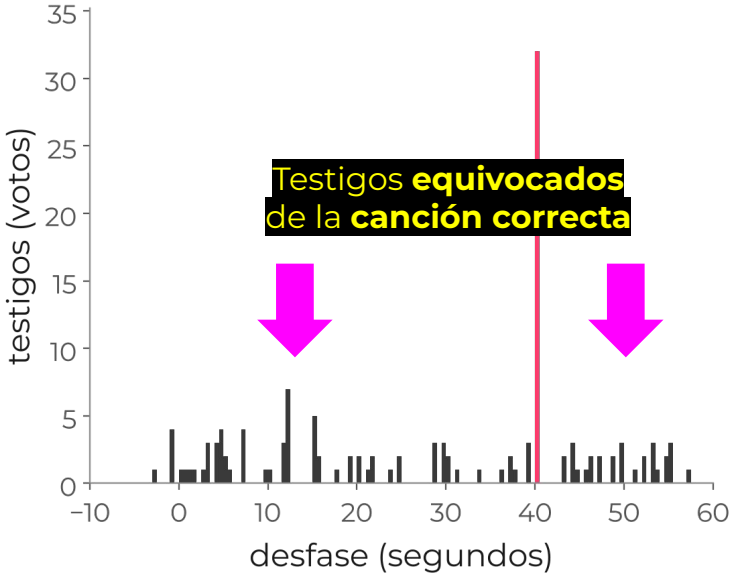

Correcta: **una torre** en el 40

Shazam no compara sonidos:

compara **estrellas**, forma **parejas** y cuenta **votos**

Votación

Abre el código **Clase4. R**

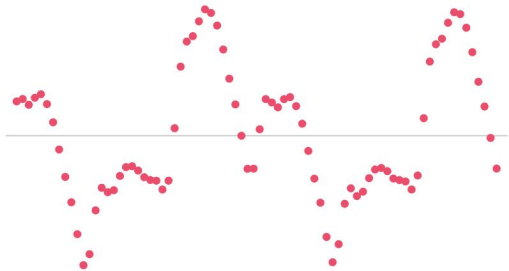

Funciona incluso con **mucho ruido**

Con la mitad de las grabaciones reconocidas, el **ruido** puede ser...

grabación de 5 s

2 veces

más fuerte que
la música

grabación de 10 s

4 veces

más fuerte que
la música

grabación de 15 s

8 veces

más fuerte que
la música

Fuente: Wang (2003)

Funciona incluso con **mucho ruido**

Con la mitad de las grabaciones reconocidas, el **ruido** puede ser...

grabación de 5 s

2 veces

más fuerte que
la música

grabación de 10 s

4 veces

más fuerte que
la música

grabación de 15 s

8 veces

más fuerte que
la música

Fuente: Wang (2003)

¿Por qué?

Basta con muy poco

1–2%

de las huellas tiene que sobrevivir
para reconocer la canción

Curiosidades del paper

Distingue versiones

de la misma canción que a nuestro oído suenan idénticas

Escucha detrás del locutor

reconoce música aunque alguien hable encima, como en la radio

Varias a la vez

puede identificar varias canciones mezcladas en la misma grabación

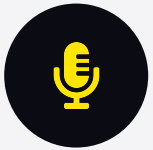

Detectó playback

en conciertos encontró artistas sospechosamente idénticos al disco

Este algoritmo del *paper*,

¿puede reconocer una versión en vivo de la biblioteca?

Fuente: Wang (2003)

¿Puede reconocer si ***tarareas*** una canción?

Fuente: Wang (2003)

Lo que no puede hacer

Si tú cantas o *tarareas*

tu voz crea otras estrellas

Una versión en vivo distinta

otra grabación, otra constelación

Shazam busca la **misma grabación**, no la misma canción

¿Podemos considerar **Shazam** como un algoritmo de **ML**?

¿Todos saben **qué** es y **cómo** funciona un **algoritmo de ML**?

Algoritmo

Serie de pasos que sirven para

resolver un problema o tarea de **forma estructurada**

Machine learning (ML)

Algoritmos que permiten **aprender** **patrones directamente de los datos** para tomar una decisión

Algoritmos *Machine learning*

Algunas de las opciones **más populares**:

- Bosques aleatorios
- Árboles de decisión
- **Redes neuronales**
- Análisis de regresión
- Regresión logística

¿Cómo **funciona** un algoritmo de **ML**?

Por ejemplo,

¿cómo podría un agricultor **separar** una fruta por su calidad, utilizando **ML**?

¿Qué **criterios** revisa una persona para

evaluar la calidad de la fruta?

¿Qué **criterios** debería revisar una máquina o algoritmo?

Características de cada clase:

Class	Images
Unripe (Green/Green-red)	
Ripe (red)	
Defective (Overripe/rotten)	

Un **algoritmo** de ML puede **“aprender” las características** de cada clase

Posteriormente, clasifica **NUEVOS tomates automáticamente**

Entonces:

¿Podemos considerar **Shazam** como un algoritmo de **ML**?

¿Por qué podría **fallar** Shazam?

i.e. **no entregarte** una canción o darte la **incorrecta**

Resumen Algoritmo Shazam

1. Ver el sonido
2. Espectrograma
3. Constelación
4. Huellas
5. Votación

Referencia

Wang, A. (2003). *An Industrial-Strength Audio Search Algorithm*. Proceedings of the 4th International Conference on Music Information Retrieval (ISMIR).

ee.columbia.edu/~dpwe/papers/Wang03-shazam.pdf

Algoritmo Netflix

Sistemas de recomendación

Clase 4

ML y análisis de datos

ITAM

Para **reforzar** los **problemas supervisados de regresión** ,

analicemos un **caso real**

NETFLIX

Sistemas de recomendación

Algunas de las empresas más importantes del mundo utilizan frecuentemente sistemas de recomendación
En la mayoría de los casos, te ofrecen productos, servicios o perfiles de personas, **con base en las calificaciones otorgadas por otros usuarios “similares” a ti**

Sistemas de recomendación

Recomendaciones:

- **Netflix**: recomienda series y películas
- **Amazon**: recomienda productos
- **Tinder**: recomienda personas con probabilidad de *match*
- **Youtube**: recomienda nuevos videos
- **Facebook**: recomiendas páginas para dar *like*
- **Twitter**: recomienda cuentas similares con base en las cuentas que sigues
- **Linkedin**: recomienda personas

NETFLIX

¿Por qué Netflix me recomienda cierto tipo de películas?

¿Por qué Amazon me recomienda comprar una serie de productos?

¿Cómo es el algoritmo que utilizaba **Netflix**?

¿Cómo es el algoritmo que utilizaba **Netflix**?

NETFLIX

Netflix Prize

En el año 2009 **Netflix** lanzó una convocatoria y ofreció un premio de **1,000,000 USD** **al mejor algoritmo** que pudiera **predecir las calificaciones que los usuarios darán a las películas**.

Hasta ese momento, utilizaban **Cinematch** un modelo estadístico **lineal** con múltiples restricciones sobre los datos (como un **problema de optimización**).

BD Netflix Prize

Para el concurso Netflix proporcionó diversos conjuntos de datos y métricas que los participantes debían considerar en el diseño del algoritmo:

- **Entrenamiento**: **100 millones de calificaciones,** otorgadas por más de 480,000 usuarios a cerca de 18,000 películas.
- **Prueba**: **cerca de 1.4 millones** de calificaciones.
- **Validación**: **cerca de 1.4 millones** de calificaciones.
    - Este conjunto **sólo era conocido por el jurado**.

NETFLIX

¿Qué es **entrenamiento, prueba y validación**?

Información completa

Considera que tienes todos los registros **disponibles de una BD** para aplicar un algoritmo:

Conjuntos de entrenamiento y prueba

Los **divides en dos conjuntos**:

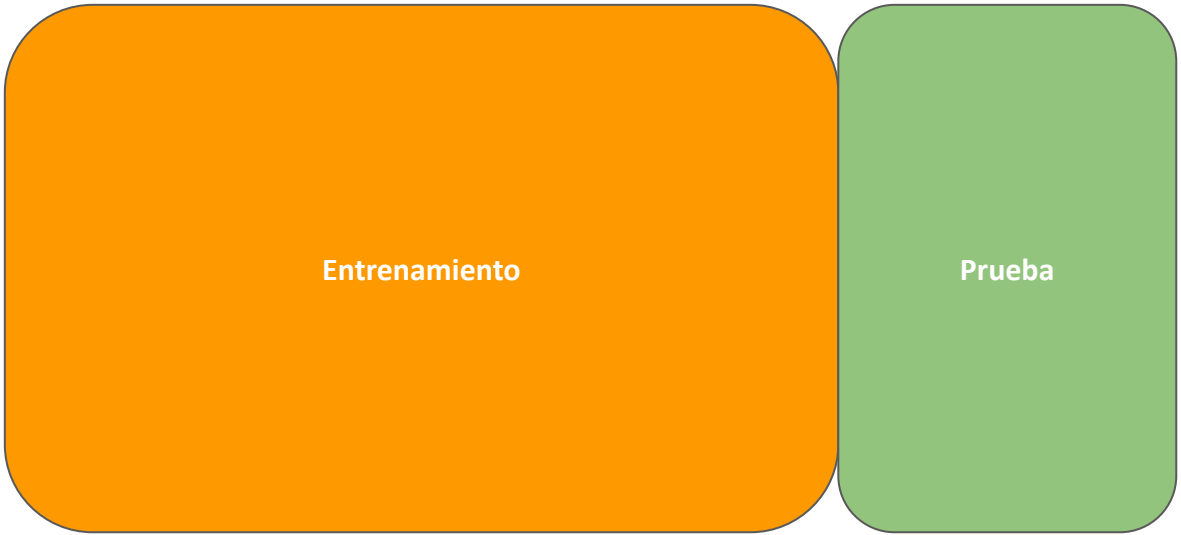

Conjuntos de entrenamiento y prueba

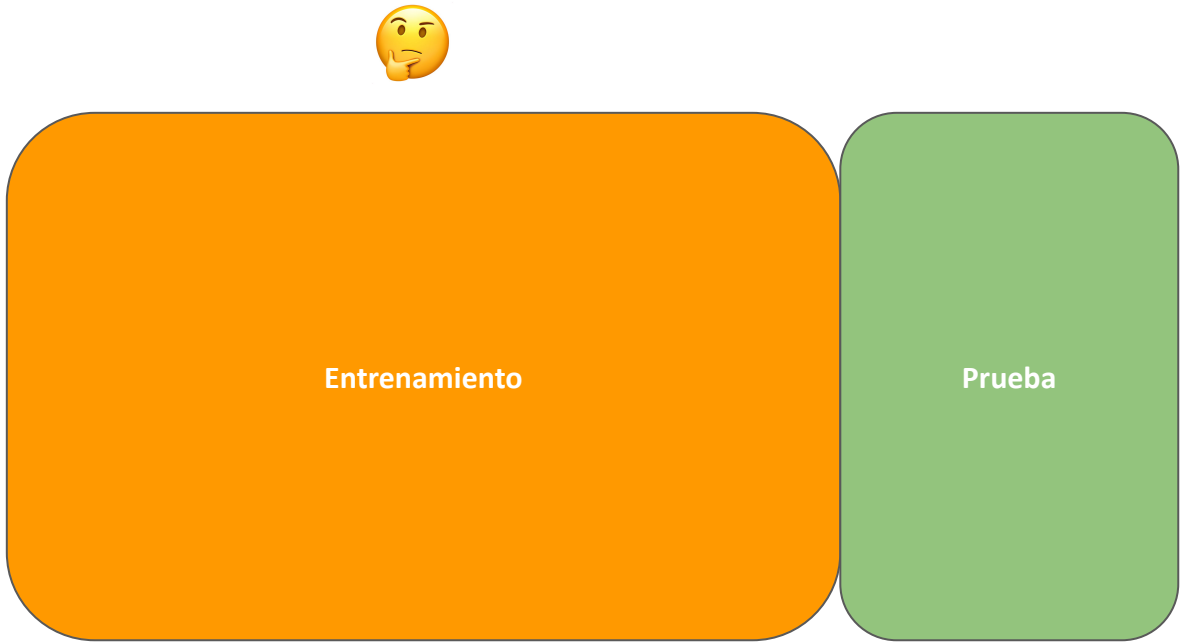

Conjuntos de entrenamiento y prueba

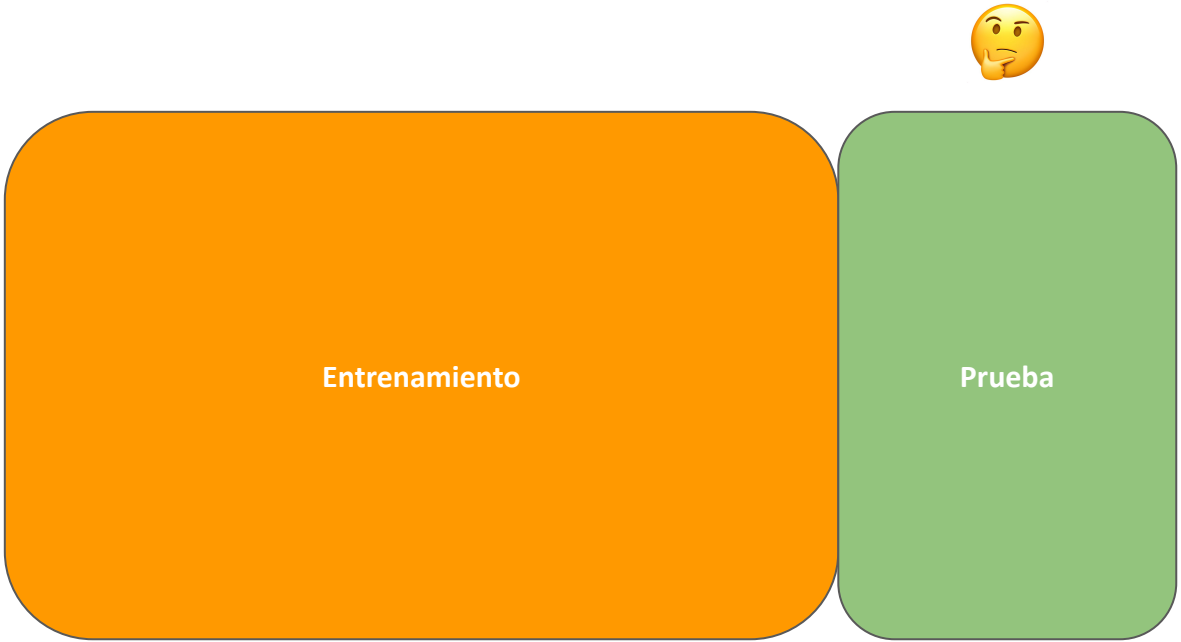

Entrenamiento, validación y prueba

Existe un **enfoque adicional:**

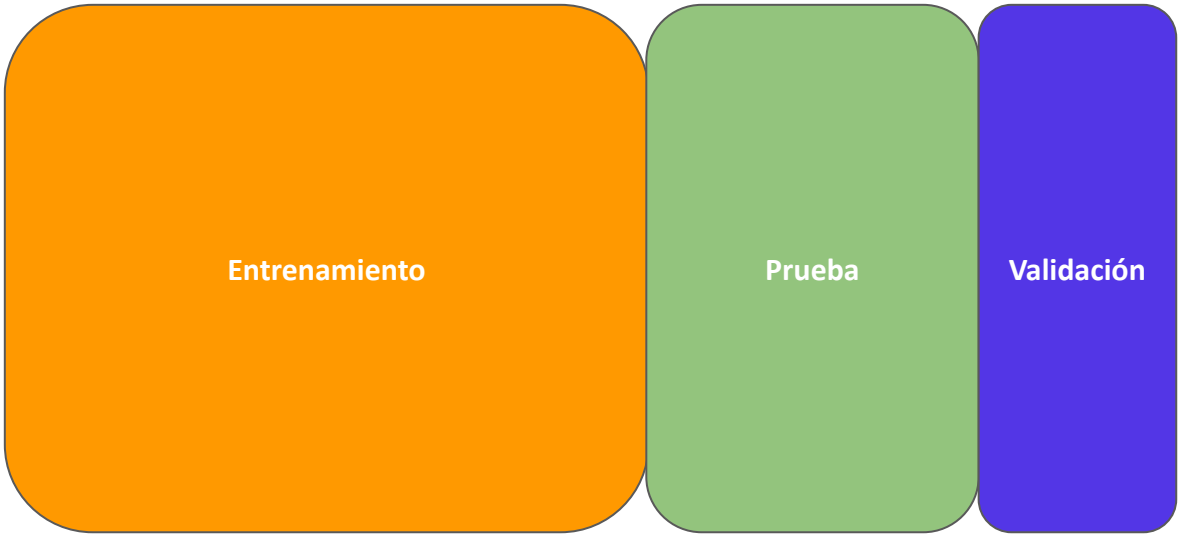

Entrenamiento, validación y prueba

Existe un **enfoque adicional:**

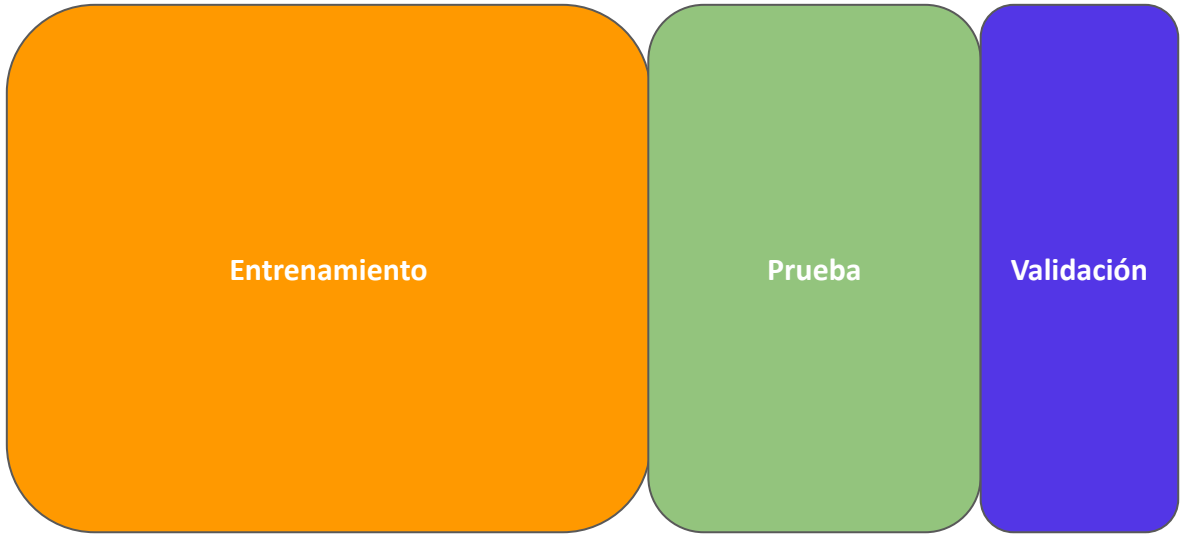

BD Netflix Prize

Para el concurso Netflix proporcionó diversos conjuntos de datos y métricas que los participantes debían considerar en el diseño del algoritmo:

- **Entrenamiento**: **100 millones de calificaciones,** otorgadas por más de 480,000 usuarios a cerca de 18,000 películas.
- **Prueba**: **cerca de 1.4 millones** de calificaciones.
- **Validación**: **cerca de 1.4 millones** de calificaciones.
  - Este conjunto **sólo era conocido por el jurado**.

NETFLIX

Más detalles, **siguiente clase**

BD Netflix Prize

Los datos de **entrenamiento** fueron presentados en una **BD** con las siguientes columnas:

<ID usuario, Película, Fecha de calificación, Calificación>

El diccionario de datos:

- **ID usuario**: identificador asignado por Netflix a cada usuario.
- **Película**: nombre o ID de la película en el catálogo.
- **Fecha de publicación**: fecha en que el usuario evaluó la película.
- **Calificación**: *rating* asignado por el usuario a la película, va del **1 al 5**.

NETFLIX

Métricas y evaluación

- El objetivo del concurso consistió en mejorar la predicción, reduciendo una especie de ECM.
- Antes del concurso, Netflix utilizaba un algoritmo propio - desarrollado internamente - llamado **Cinematch** que sostenía las predicciones de la plataforma.
- Desde el punto de vista técnico, la idea consistía en **mejorar(reducir)**, en **al menos 10%**, el **ECM obtenido por Cinematch.**

A continuación, veremos detalles sobre **ECM** y los **problema de regresión**

ITAM

Algoritmo Netflix Prize

A partir de los **datos de entrenamiento**, en este problema se implementa el método de **descomposición matricial** conocido como **Descomposición en valor singulares**.

Consideremos una matriz **A**, con ***n* renglones y *p* columnas:**

$$A_{nxp}$$

Algoritmo Netflix Prize

La **descomposición en valores singulares**, toma la matriz original **A** y la separa en el **producto de 3 matrices**:

$$\mathbf{A}_{nxp} = \mathbf{U}_{nxn}\,\mathbf{S}_{nxp}\,\mathbf{V}^{\mathbf{T}}_{pxp}$$

Tales que U y V son matrices ortogonales:

$$\mathbf{U}^{\mathbf{T}}\mathbf{U} = \mathbf{I}_{nxn}$$

$$\mathbf{V}^{\mathbf{T}}\mathbf{V} = \mathbf{I}_{pxp}$$

Referencia Álgebra Lineal

Si te interesa profundizar en los detalles e implicaciones matemáticas de esta descomposición puedes revisar el libro: Friedberg, Álgebra lineal

Te recomiendo profundizar **si tienes buenas nociones** de:

- Valores propios (eigenvalores).
- Vectores propios (eigenvectores).
- Independencia.
- Propiedades de matrices ortogonales.

¿Cómo utilizar la descomposición en **valores singulares** para el algoritmo de Netflix?

SVD

NETFLIX

BD Netflix Prize

Recordemos que los datos proporcionados tenían la siguiente forma:

<ID usuario, Película, Fecha de calificación, Calificación>

ID usuario	Película	Fecha de calificación	Calificación
1	1	04/05/22	1
1	2	04/05/22	4
1	3	29/04/22	5
2	2	04/05/22	3
3	3	24/04/22	4
4	3	04/05/22	1

BD Netflix Prize

Sin embargo, **dada una fecha o periodo fijo**, podemos transformar esta estructura:

	1	2	3
1	1	4	5
2	-	3	-
3	-	-	4
4	-	-	1

Reestructura

ID usuario	Película	Fecha de calificación	Calificación
1	1	04/05/22	1
1	2	04/05/22	4
1	3	29/04/22	5
2	2	04/05/22	3
3	3	24/04/22	4
4	3	04/05/22	1

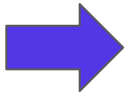

Película

Usuario	**1**	**2**	**3**
1	1	4	5
2	-	3	-
3	-	-	4
4	-	-	1

NETFLIX

Reestructura

A_{nxp}

ID usuario	Película	Fecha de calificación	Calificación
1	1	04/05/22	1
1	2	04/05/22	4
1	3	29/04/22	5
2	2	04/05/22	3
3	3	24/04/22	4
4	3	04/05/22	1

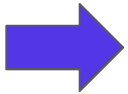

Película

Usuario	**1**	**2**	**3**
1	1	4	5
2	-	3	-
3	-	-	4
4	-	-	1

NETFLIX

Reestructura

A_{nxp}

ID usuario	Película	Fecha de calificación	Calificación
1	1	04/05/22	1
1	2	04/05/22	4
1	3	29/04/22	5
2	2	04/05/22	3
3	3	24/04/22	4
4	3	04/05/22	1

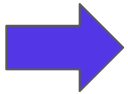

Película

Usuario	**1**	**2**	**3**
1	1	4	5
2	-	3	-
3	-	-	4
4	-	-	1

NETFLIX

¿Cómo estimar estos valores faltantes?

O sea, calificación de **películas aún no vistas** ...

¿Cómo podemos dimensionar, intuitivamente, la complejidad y tamaño de este problema?

NETFLIX

Si tienes Netflix, ¿cuántas **películas** estimas haber visto?

¿Cuántos **usuarios** crees que hay en México?

¿Cuántas películas tiene en su catálogo?

NETFLIX

Dimensionamiento

Supón que en promedio los usuarios han visto (y evaluado) alrededor de 300 películas de Netflix en México y además:

- Al **2018**, Netflix tenía cerca de 6.6 millones de suscriptores. Referencia.
- Y cuenta con 4,162 tíulos disponibles. Referencia.

¿De qué tamaño es la matriz A?

- 6,600,000 * 4,162 = **27,469,200,000** es el número de entradas de la matriz.
- Si cada usuario ve y evalúa en promedio 300 películas:
    - 6,600,000 * 300 = **1,980,000,000**, es el número de calificaciones.

Sólo **el 7.2% de la matriz** tiene valores (calificaciones)

distintos a cero o nulo (información útil)

NETFLIX

Pero... ¿cómo **funciona** el algoritmo de **Netflix**?

Intuición Algoritmo Netflix Prize

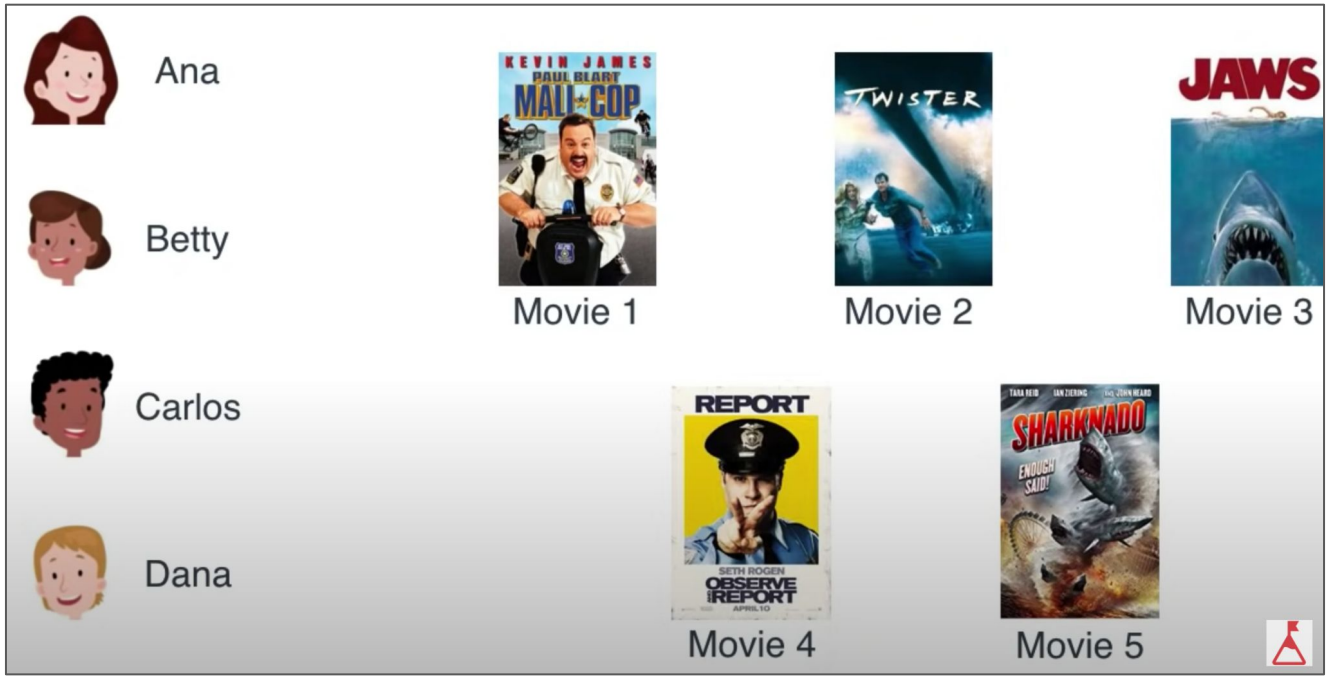

Registramos preferencias

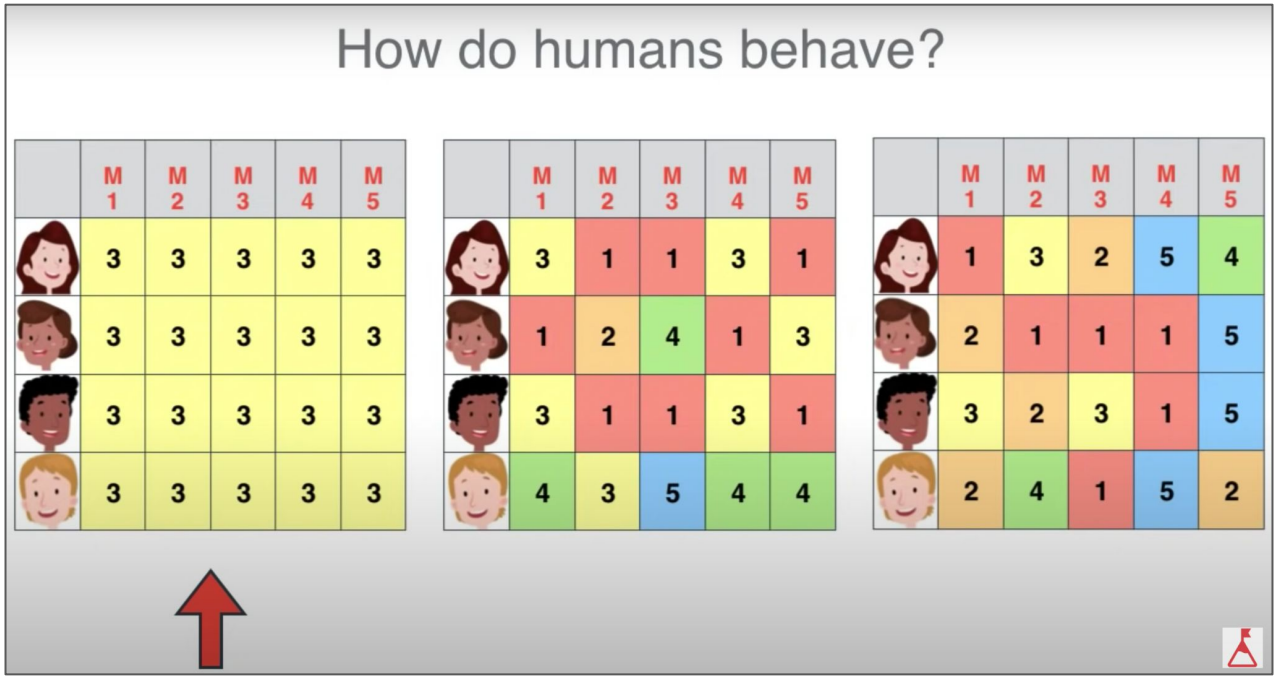

¿Qué podemos **intuir** de estas matrices?

Intuición Algoritmo Netflix Prize

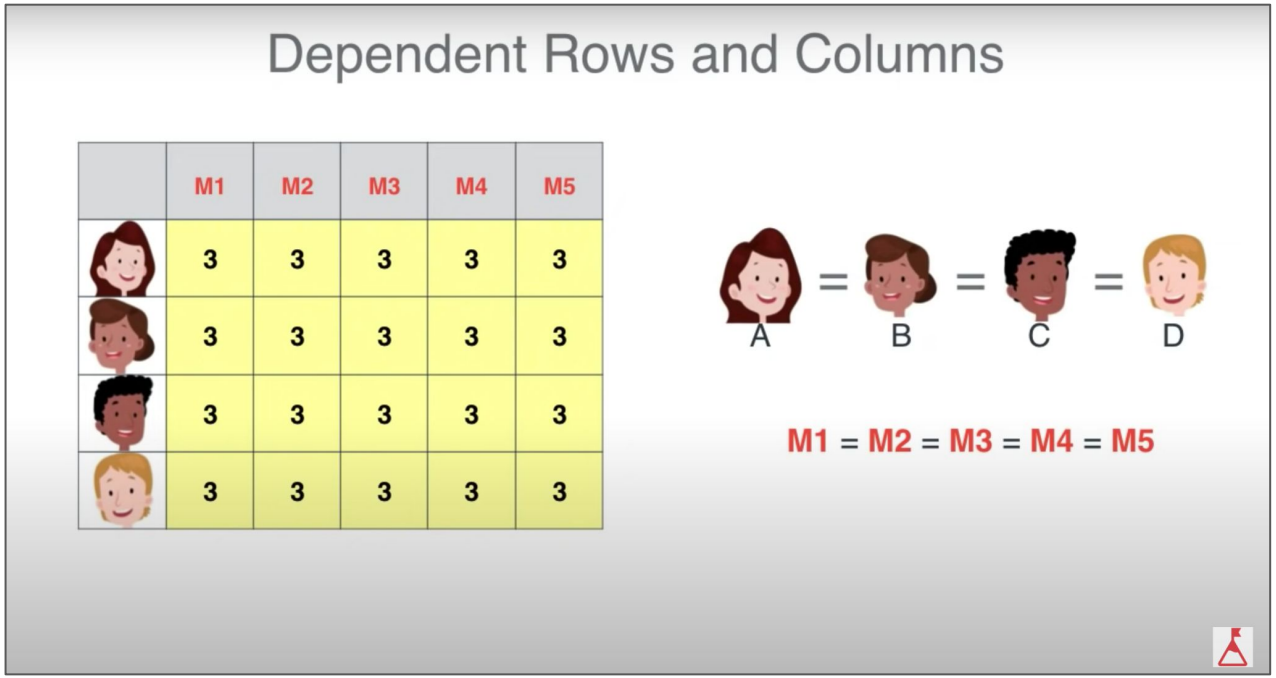

Punto de vista personas (renglones)

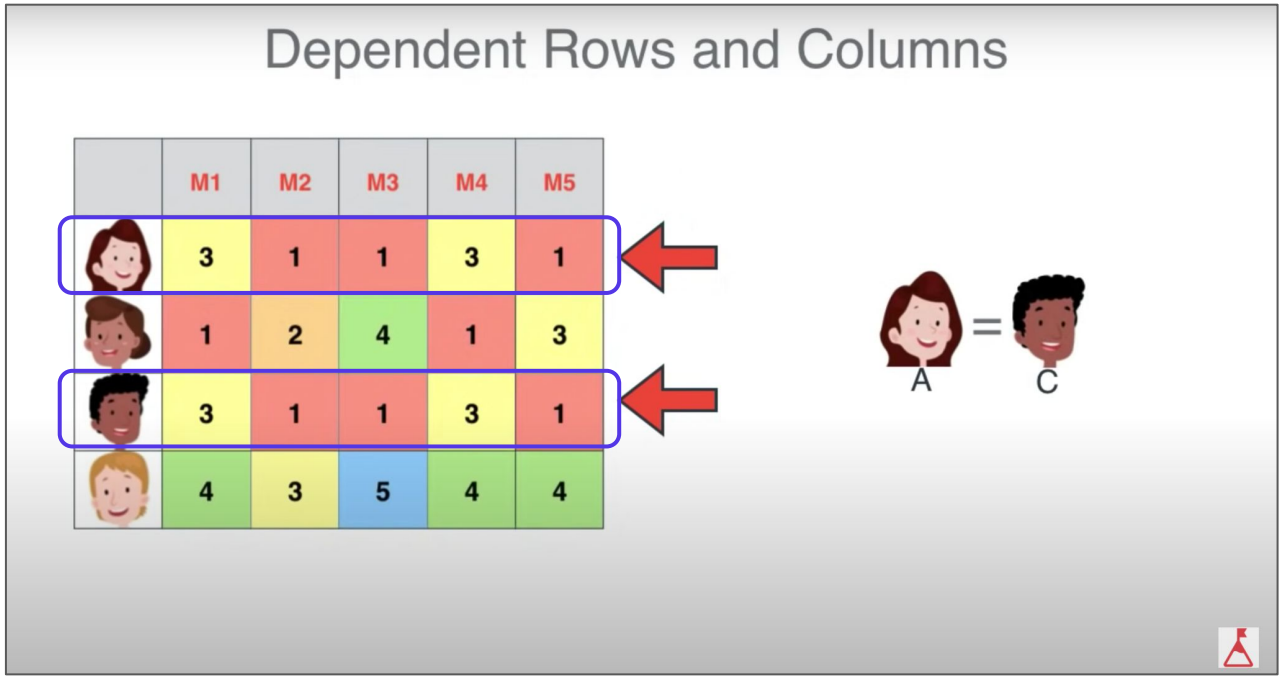

Punto de vista películas (columnas)

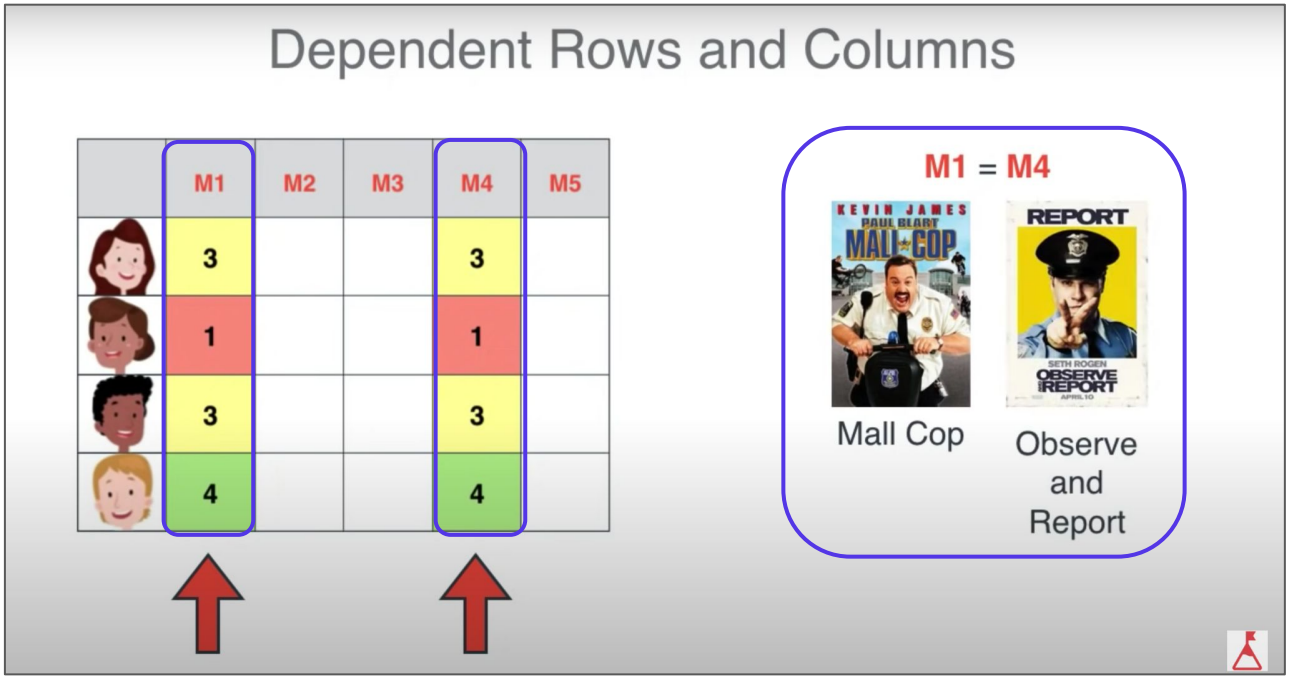

Intuición Algoritmo Netflix Prize

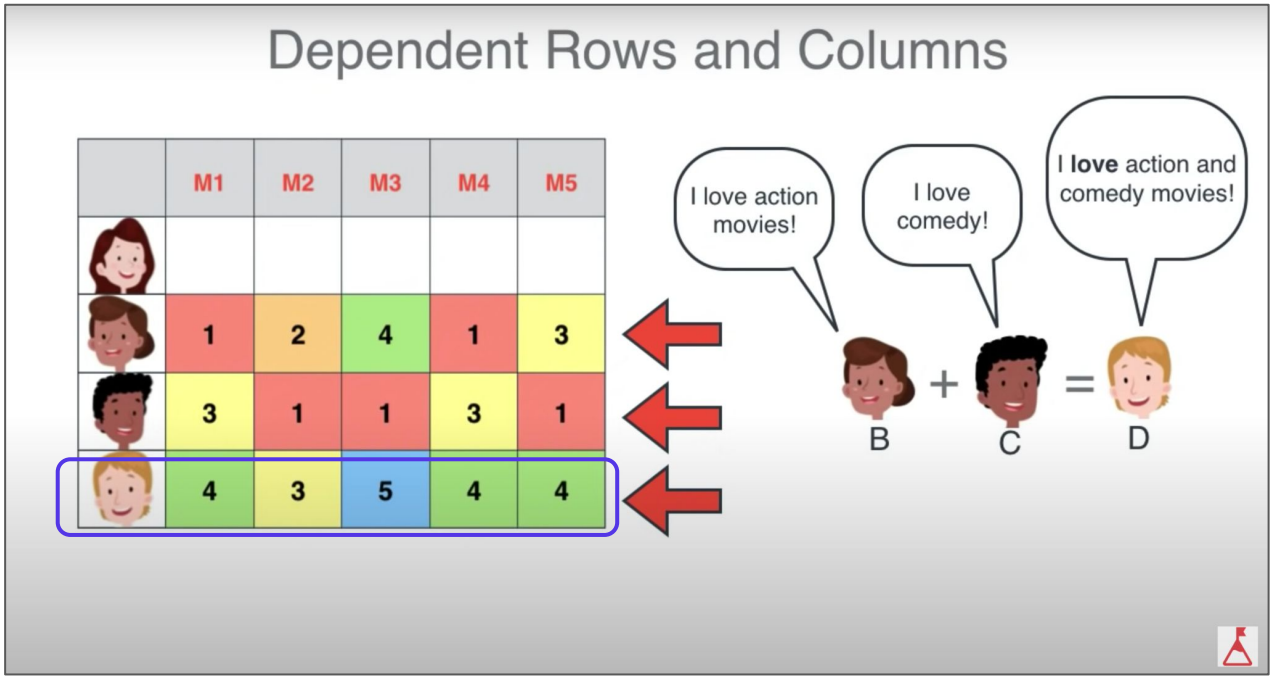

Intuición Algoritmo Netflix Prize

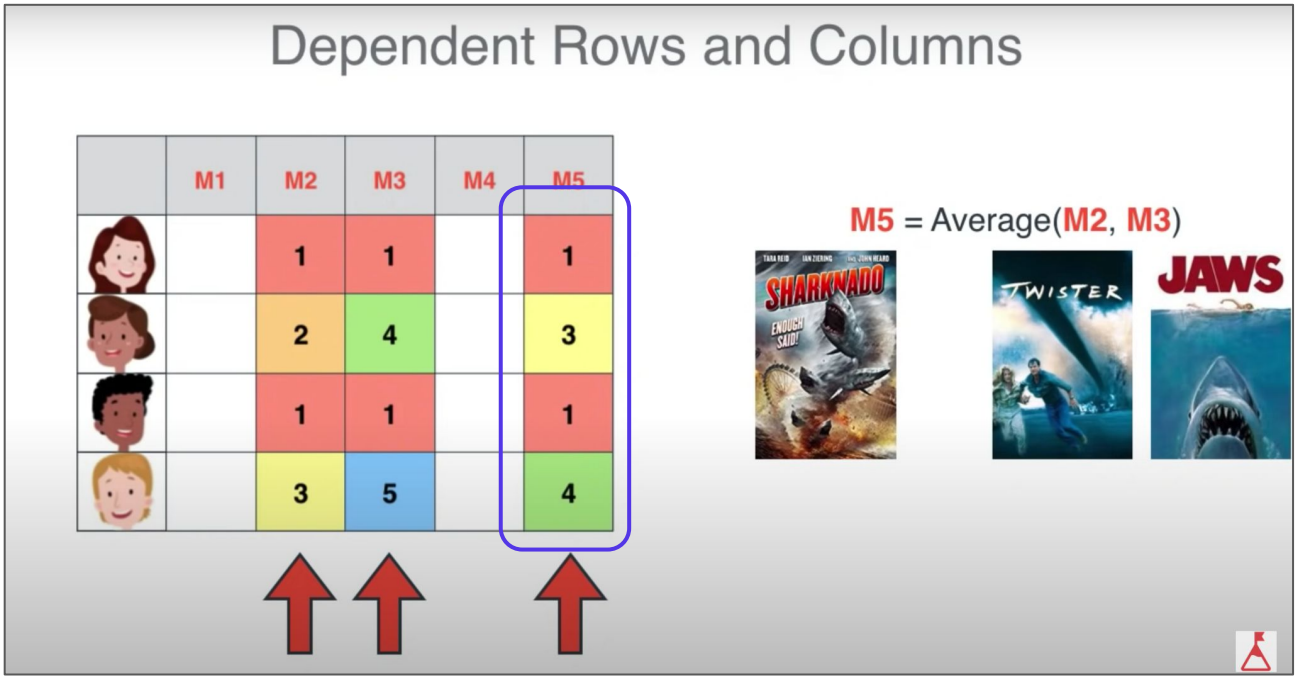

¿Cómo podemos utilizar esta información para **recomendar** películas que

no ha visto cierto usuario y que le puedan gustar ?

NETFLIX

Intuición Algoritmo Netflix Prize

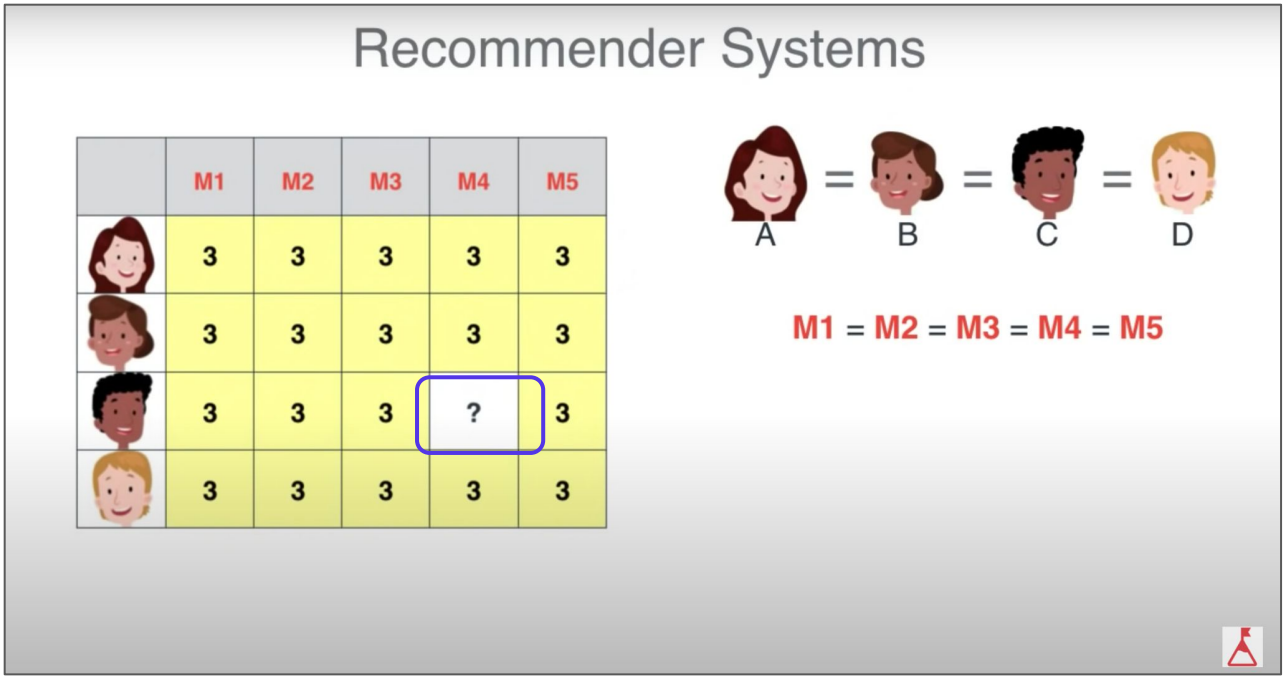

Intuición Algoritmo Netflix Prize

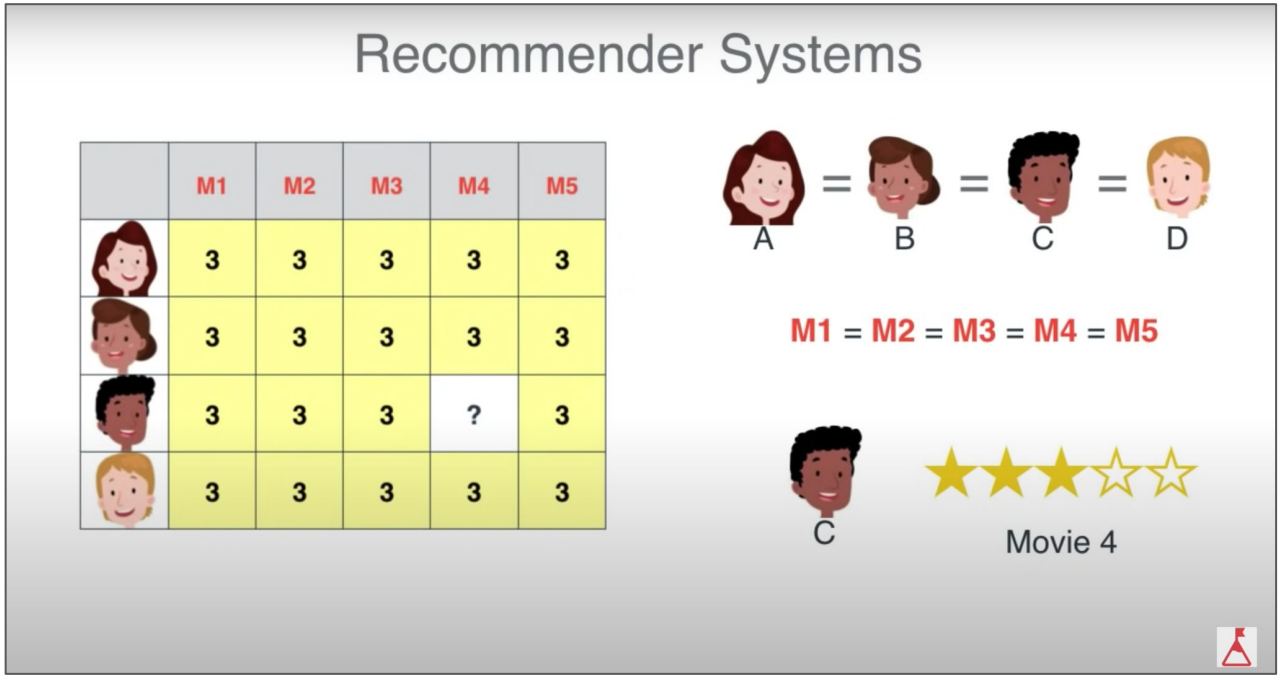

Intuición Algoritmo Netflix Prize

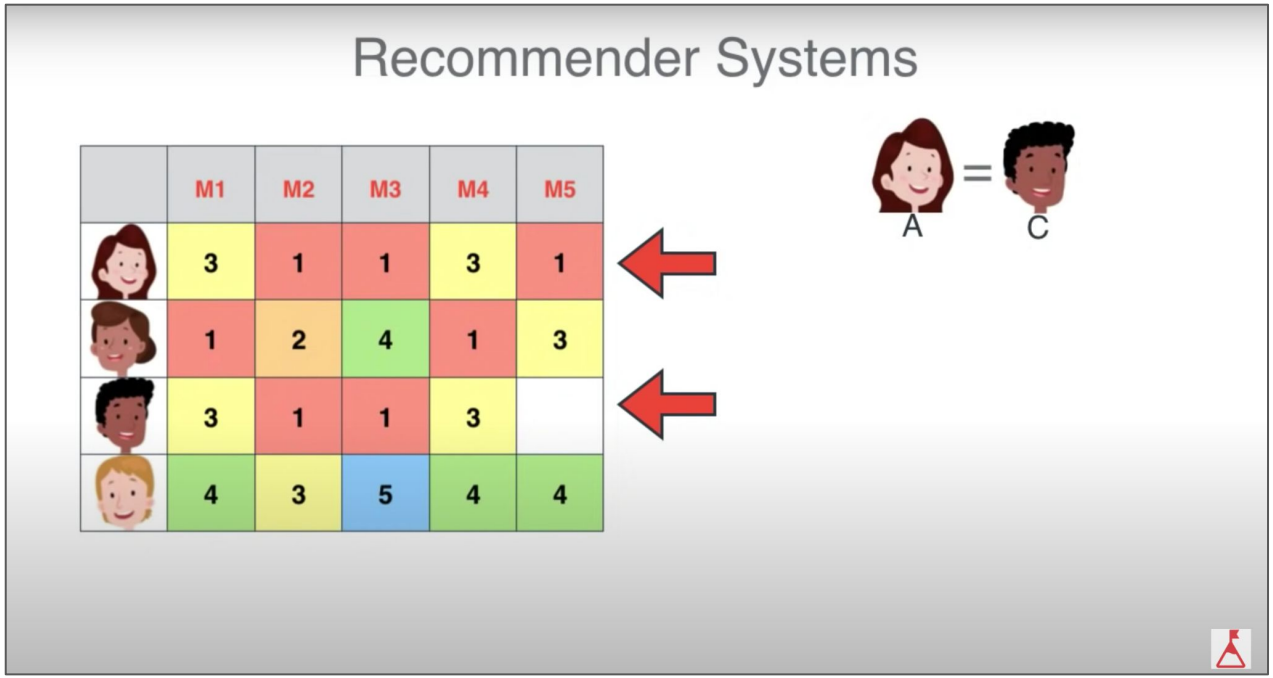

Intuición Algoritmo Netflix Prize

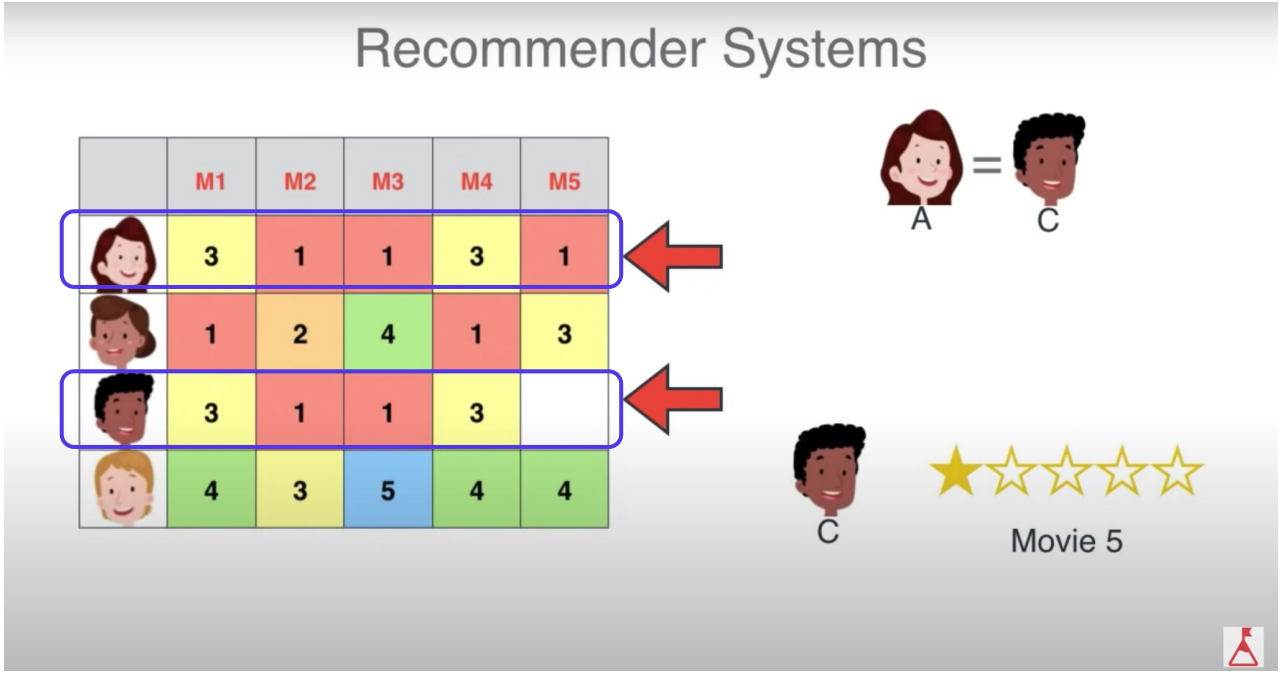

Intuición Algoritmo Netflix Prize

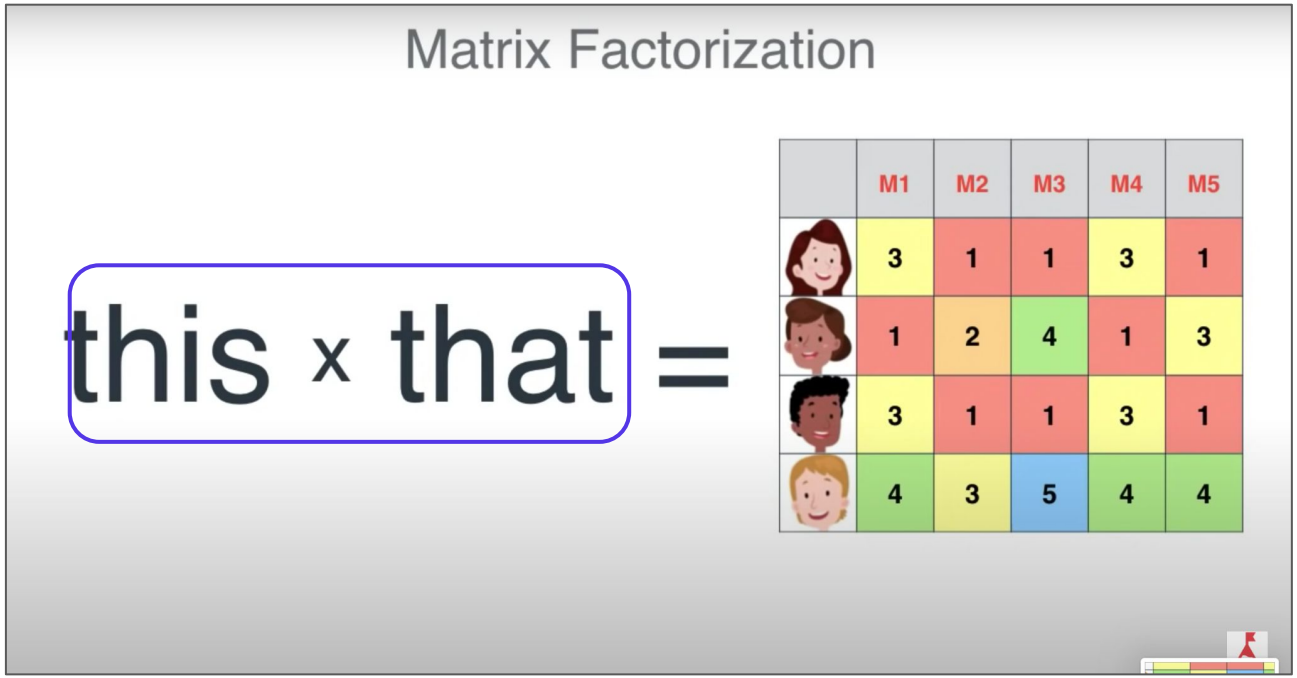

Además, cada película tiene una serie de **características...**

Intuición Algoritmo Netflix Prize

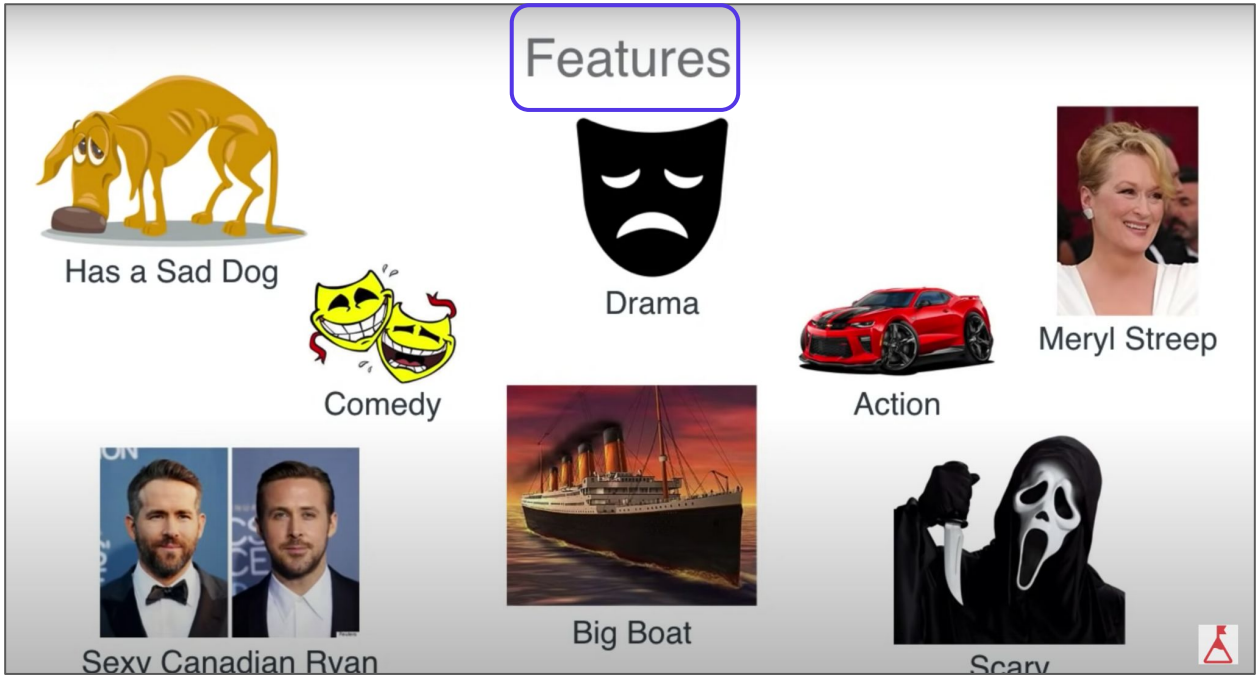

Intuición Algoritmo Netflix Prize

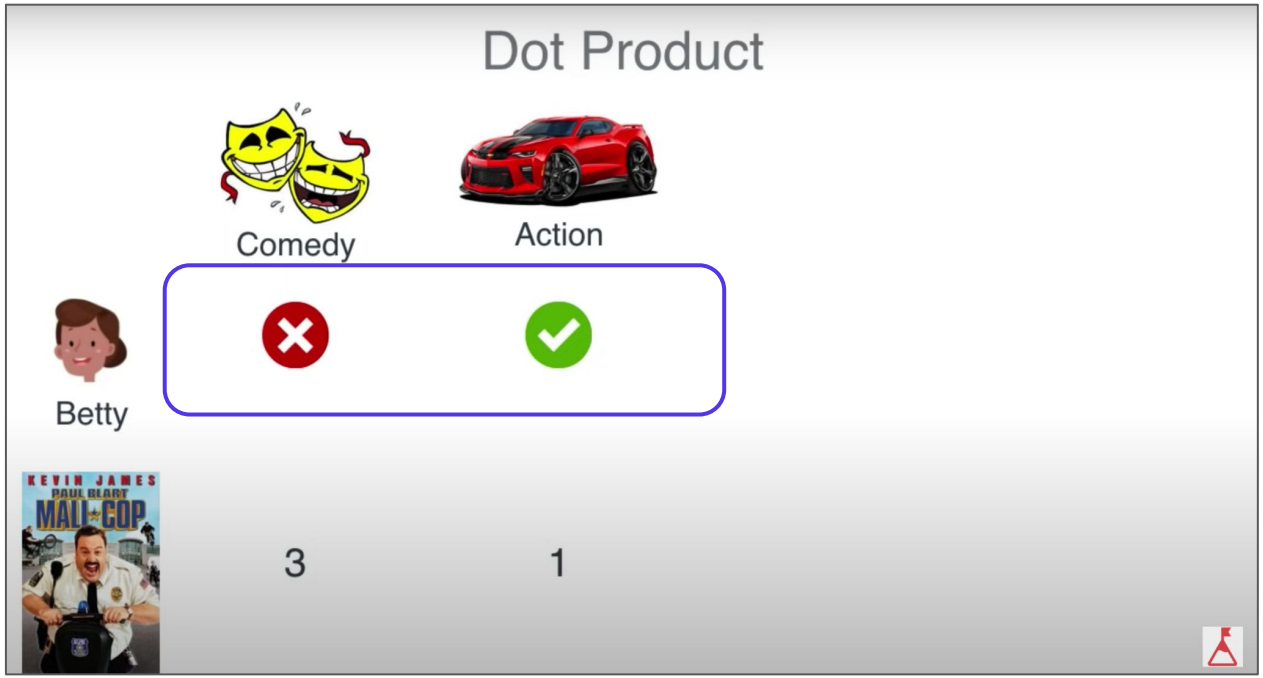

Intuición Algoritmo Netflix Prize

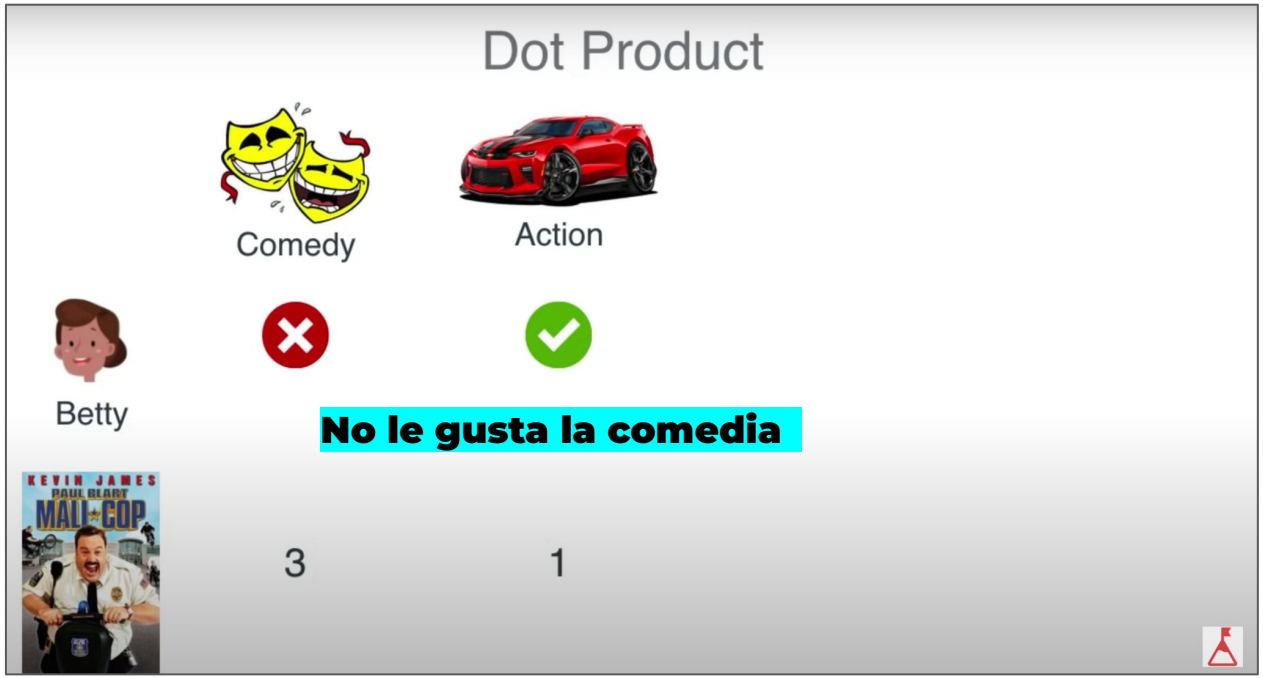

Intuición Algoritmo Netflix Prize

Intuición Algoritmo Netflix Prize

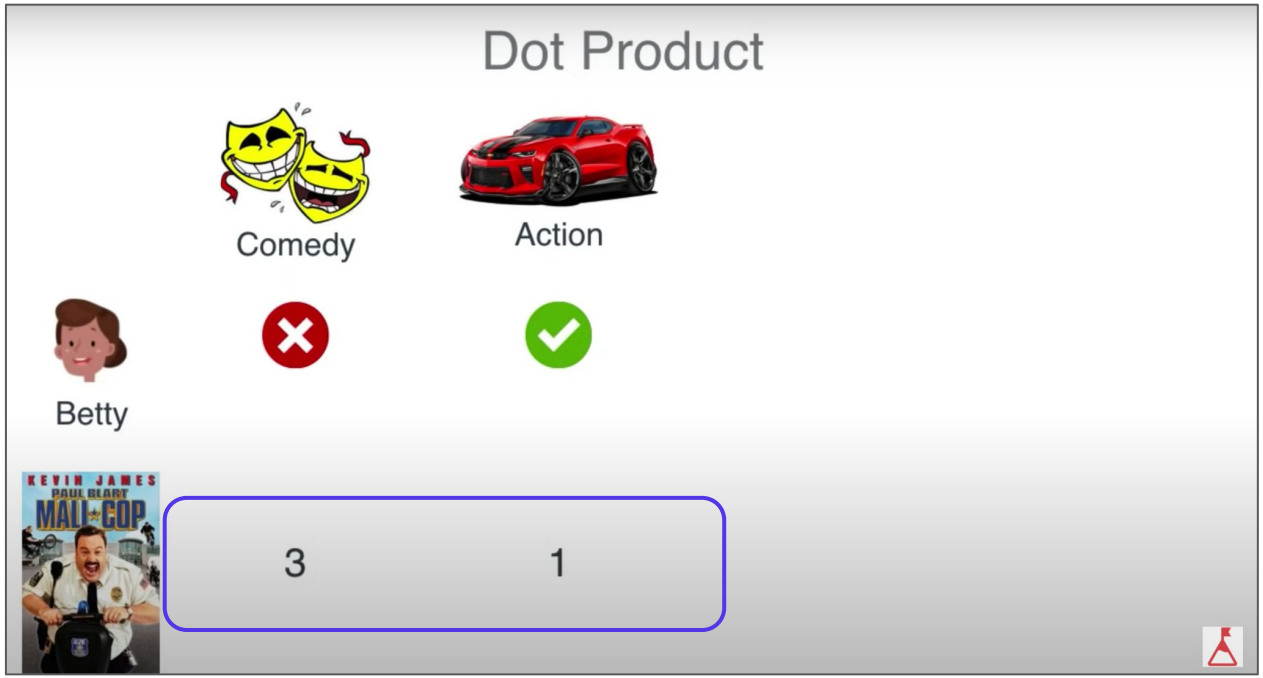

Intuición Algoritmo Netflix Prize

Intuición Algoritmo Netflix Prize

Intuición Algoritmo Netflix Prize

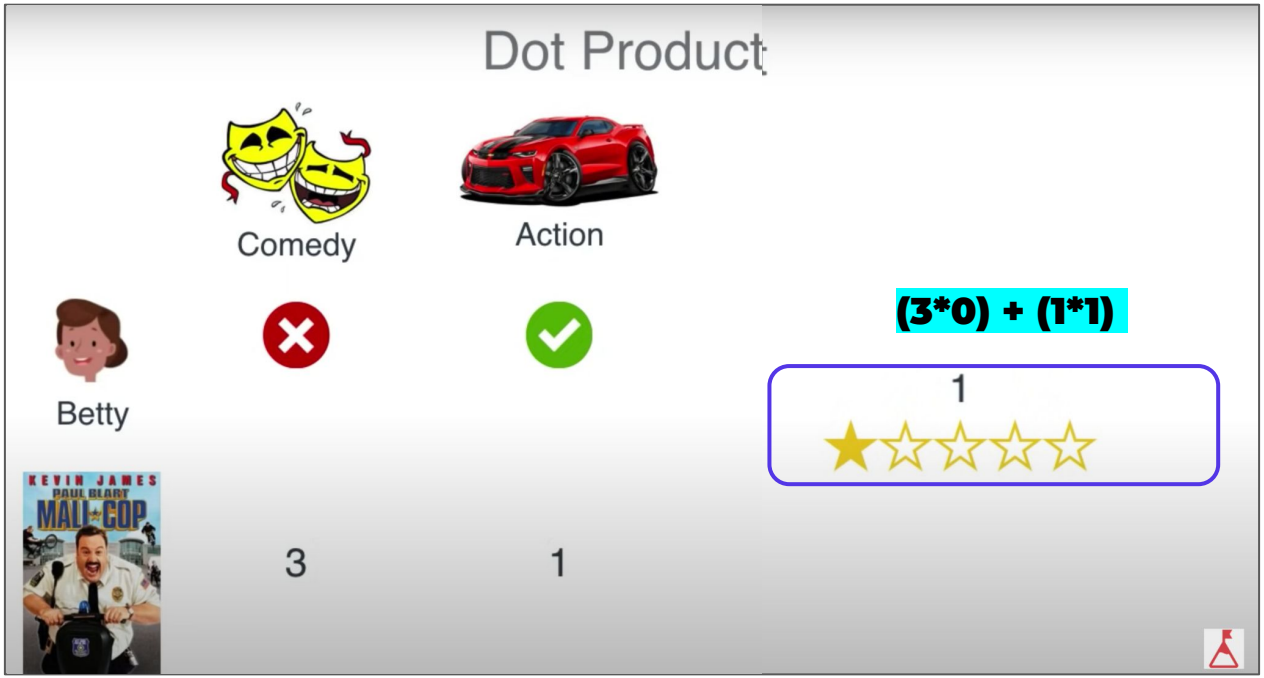

Intuición Algoritmo Netflix Prize

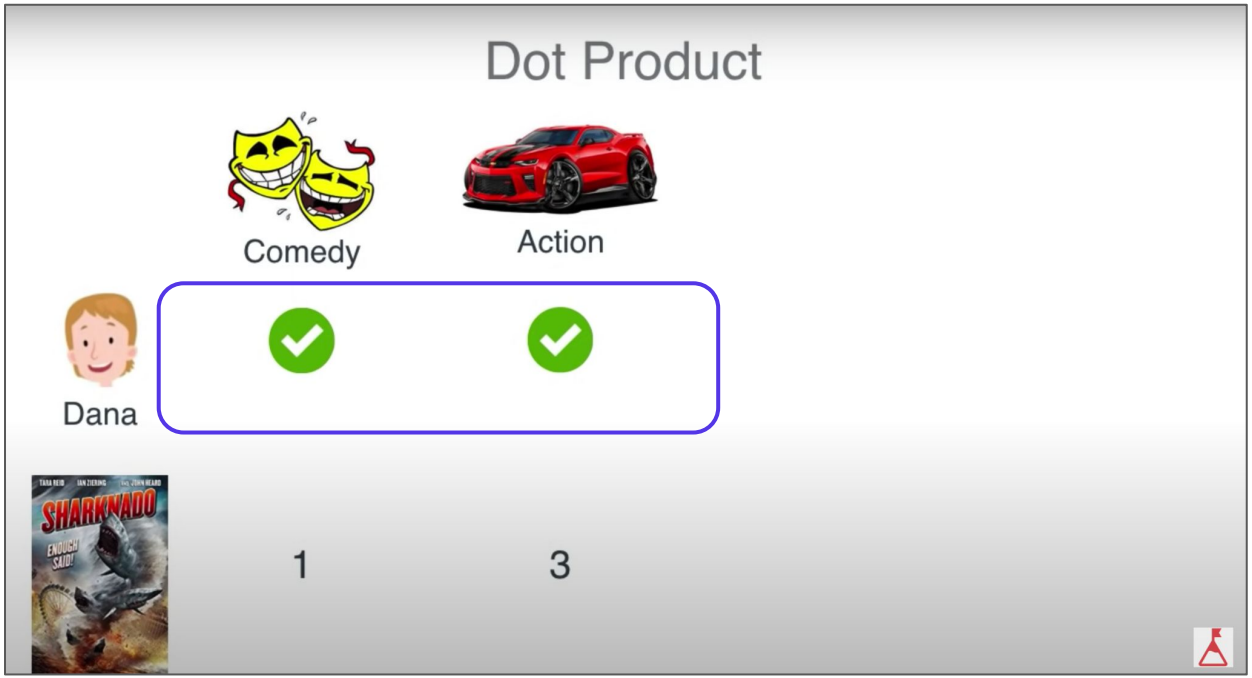

Intuición Algoritmo Netflix Prize

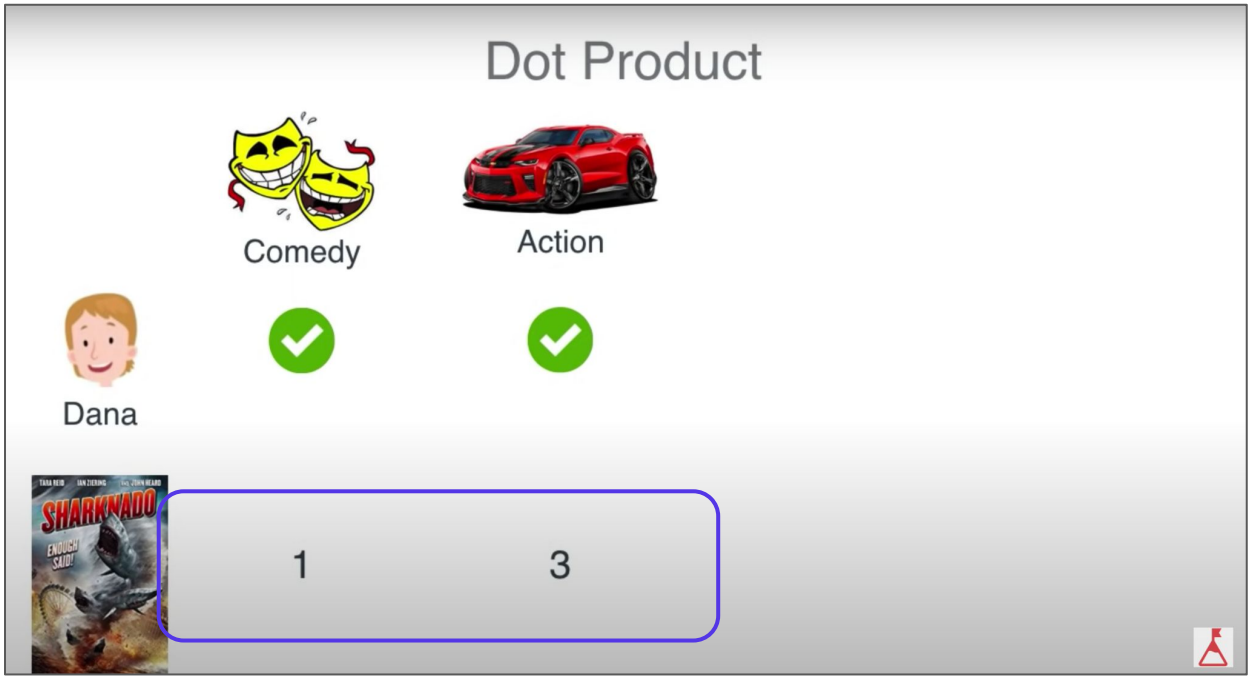

Intuición Algoritmo Netflix Prize

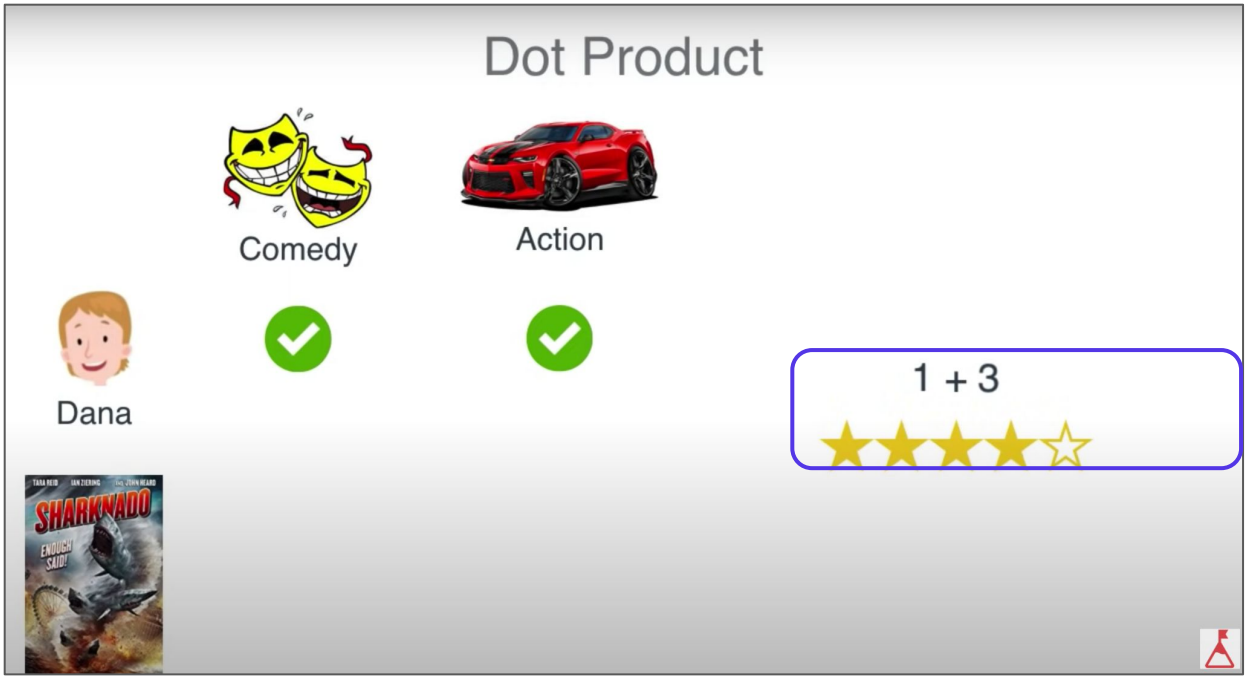

Intuición Algoritmo Netflix Prize

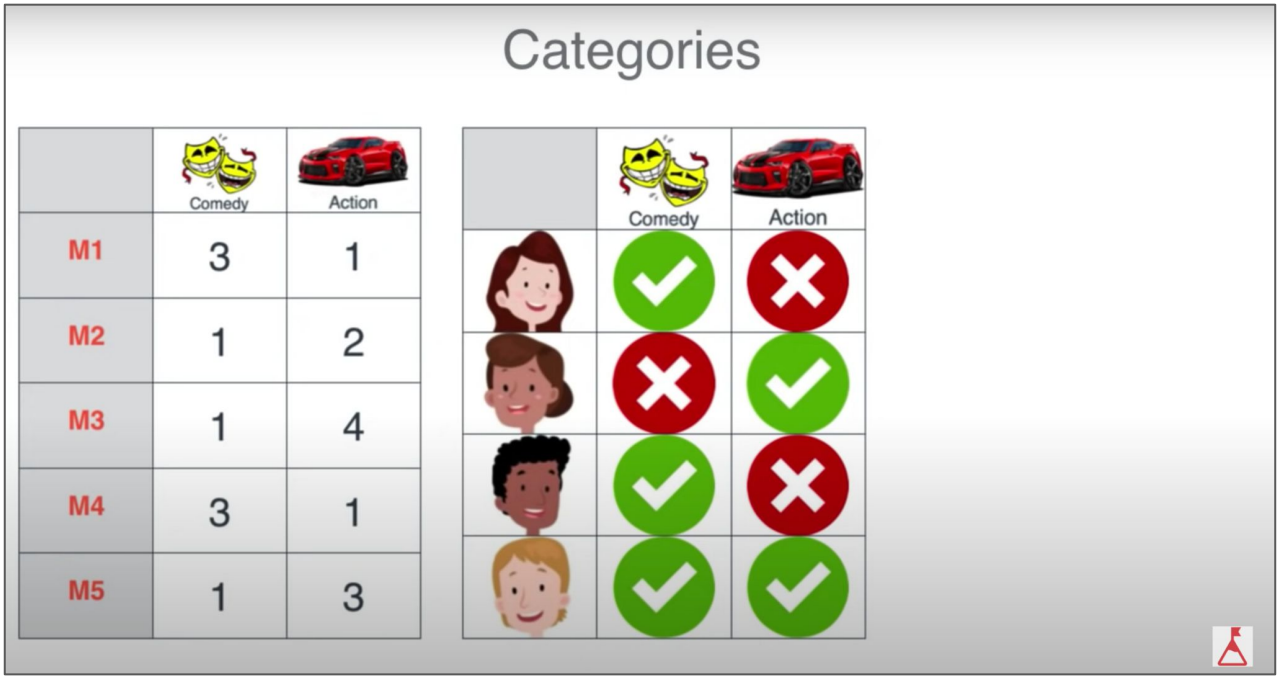

Intuición Algoritmo Netflix Prize

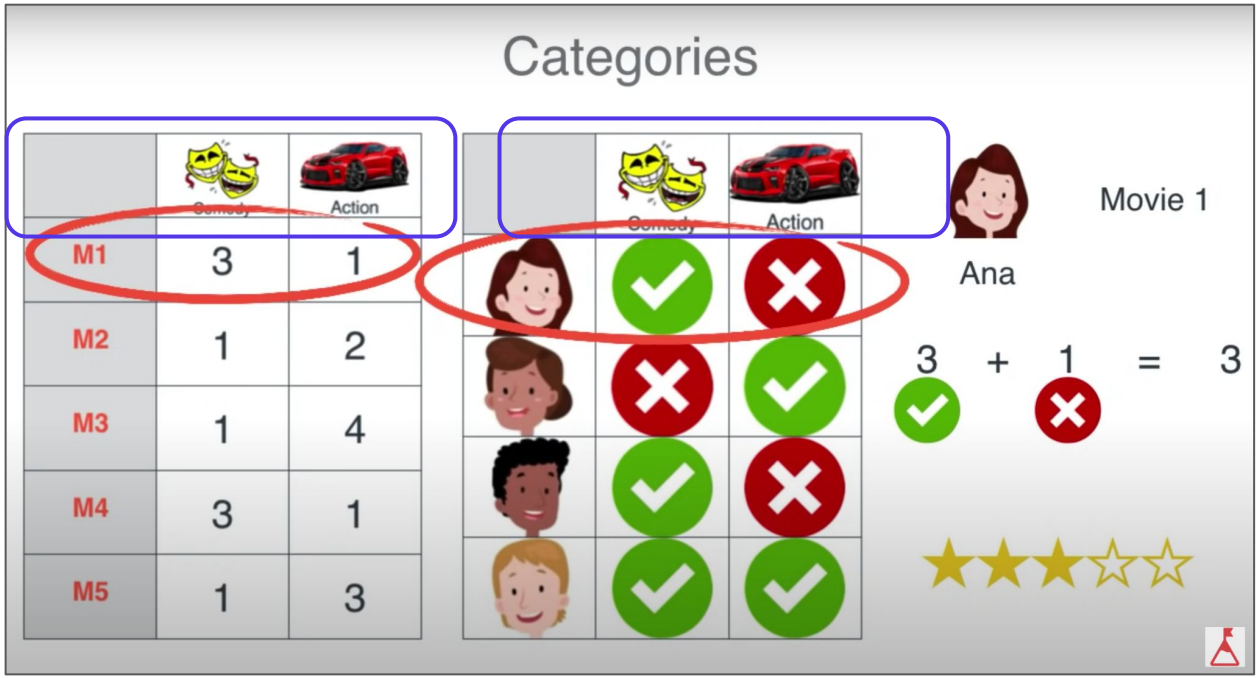

Intuición Algoritmo Netflix Prize

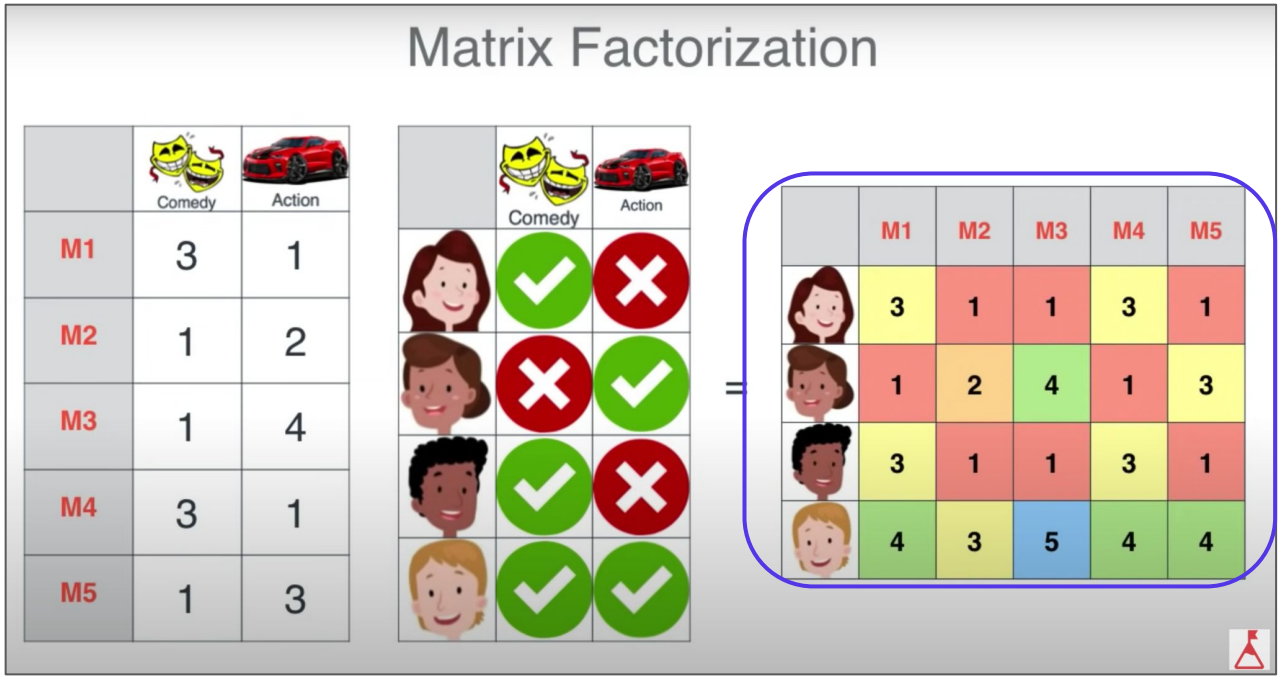

Las **calificaciones faltantes** se pueden estimar a partir de las **características** de cada película y las **preferencias** de los usuarios

Multiplicación usuarios y películas

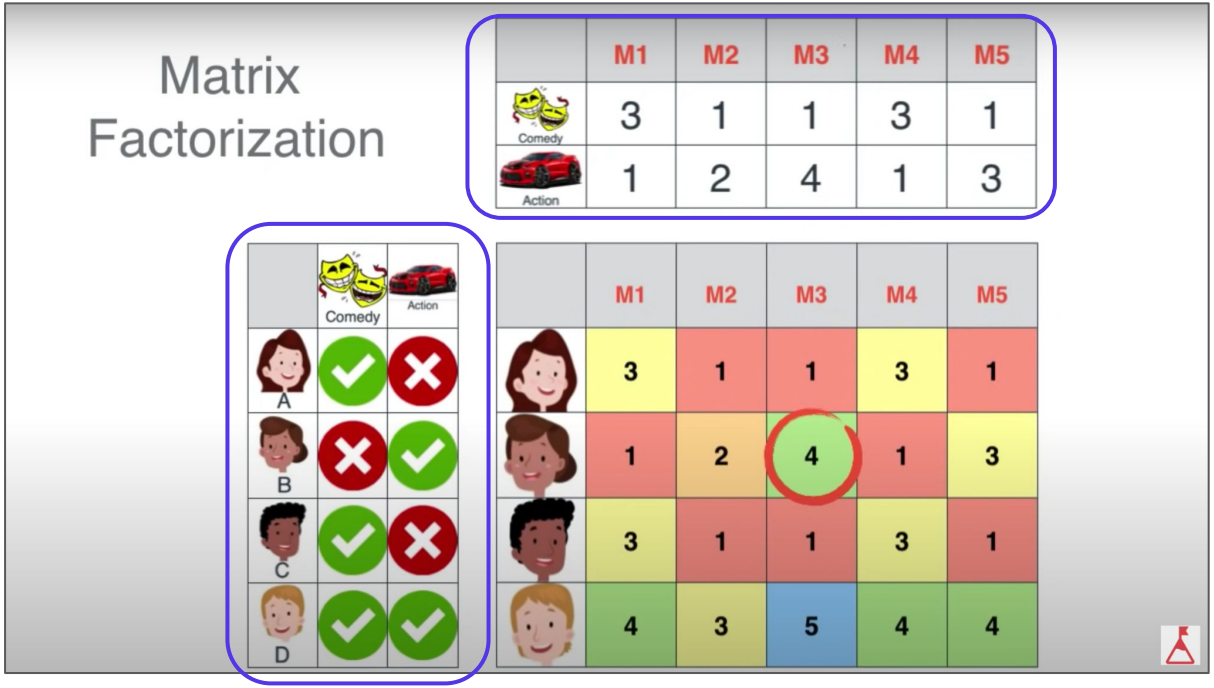

Intuición Algoritmo Netflix Prize

Descomposición de matrices

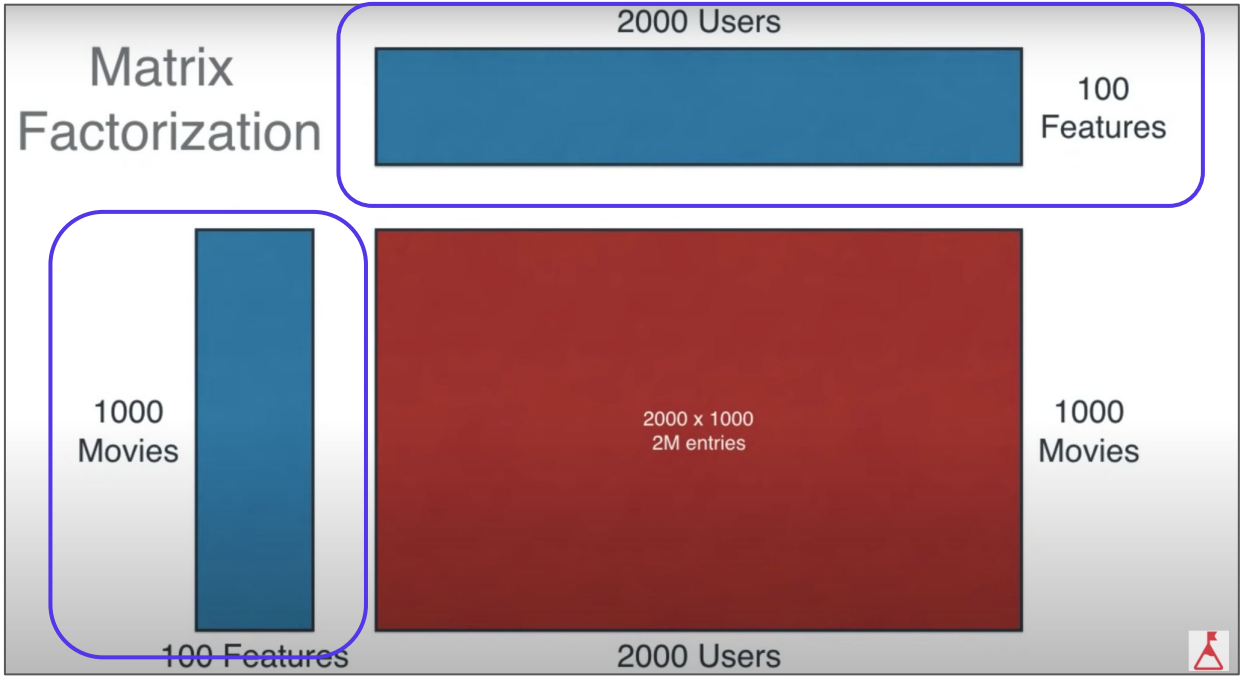

Nota: No es necesario entender los siguientes cálculos, sin embargo,

solo es una serie de multiplicaciones y sumas (multiplicación entre vectores)

Intuición Algoritmo Netflix Prize

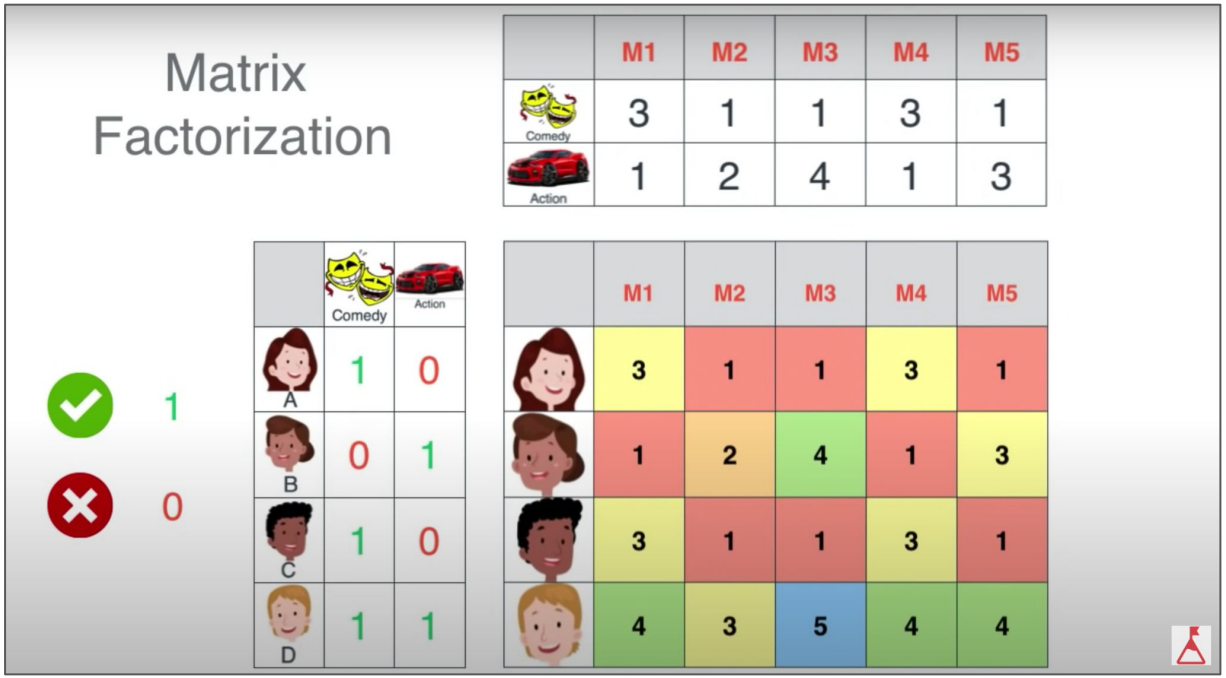

¿Cómo **calcular** para estimar los **datos faltantes** ?

Intuición Algoritmo Netflix Prize

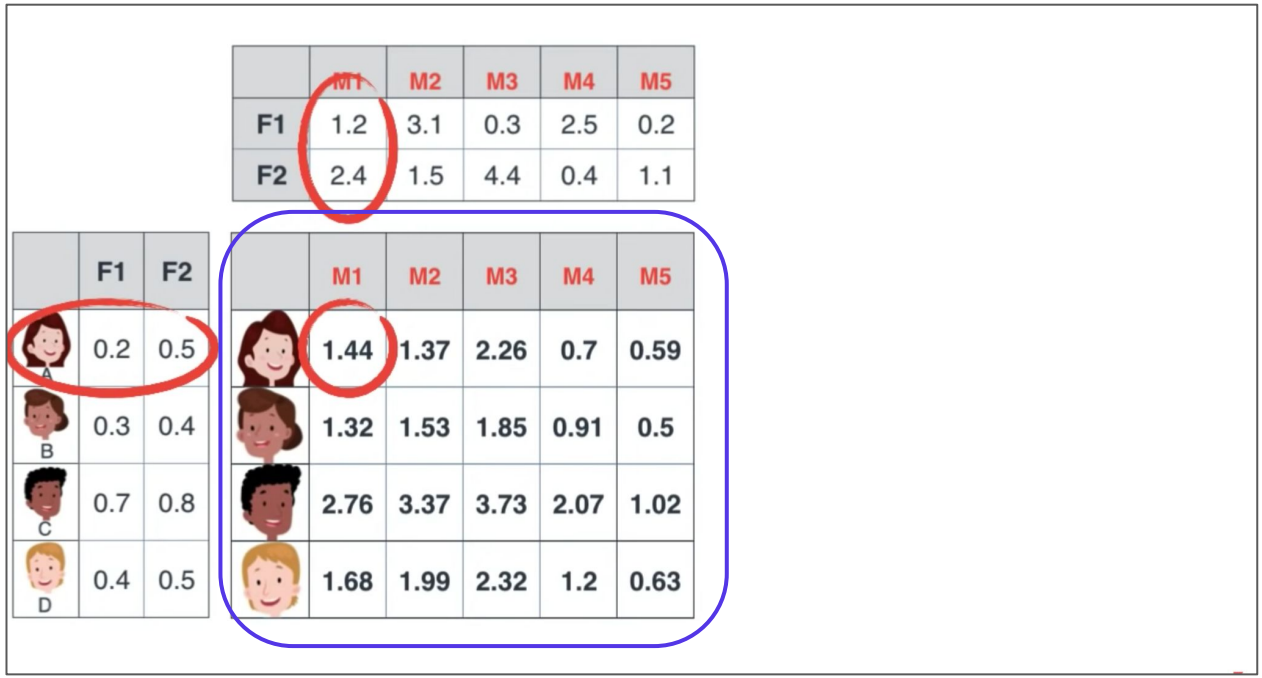

	M1	M2	M3	M4	M5
F1	1.2	3.1	0.3	2.5	0.2
F2	2.4	1.5	4.4	0.4	1.1

	F1	F2
A	0.2	0.5
B	0.3	0.4
C	0.7	0.8
D	0.4	0.5

	M1	M2	M3	M4	M5
	1.44	1.37	2.26	0.7	0.59
	1.32	1.53	1.85	0.91	0.5
	2.76	3.37	3.73	2.07	1.02
	1.68	1.99	2.32	1.2	0.63

Intuición Algoritmo Netflix Prize

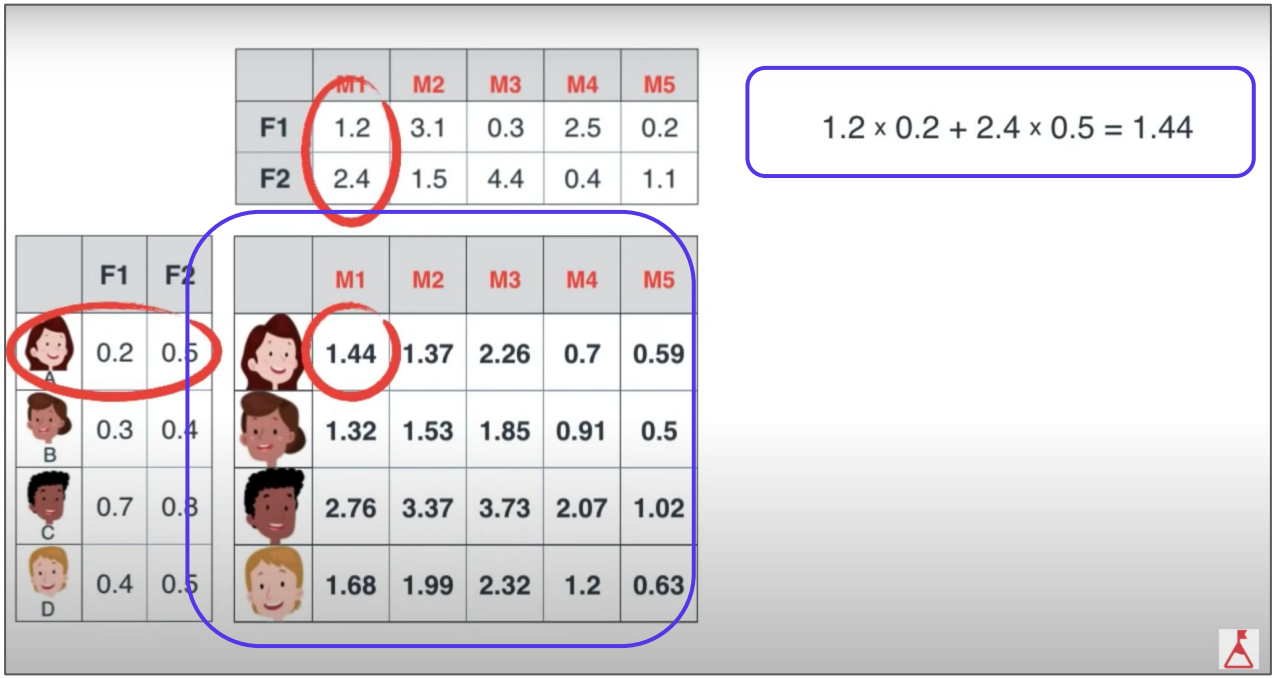

Intuición Algoritmo Netflix Prize

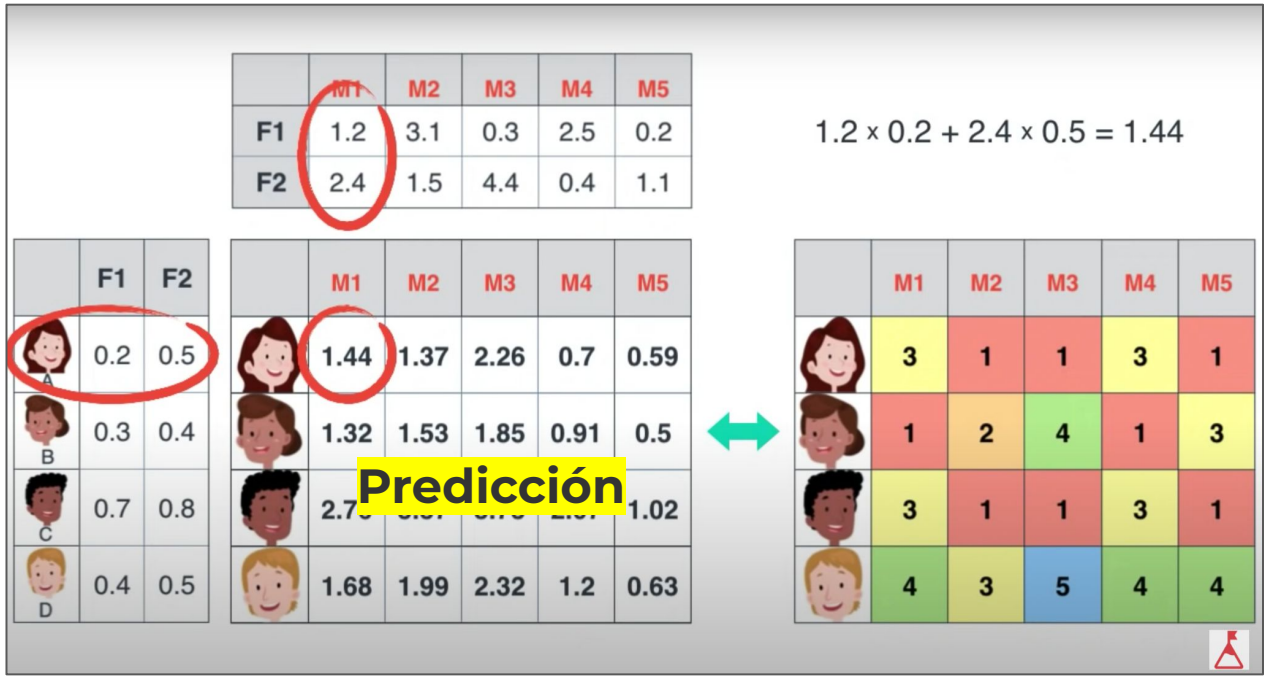

Valor real después de verla

NETFLIX

Error - como ECM

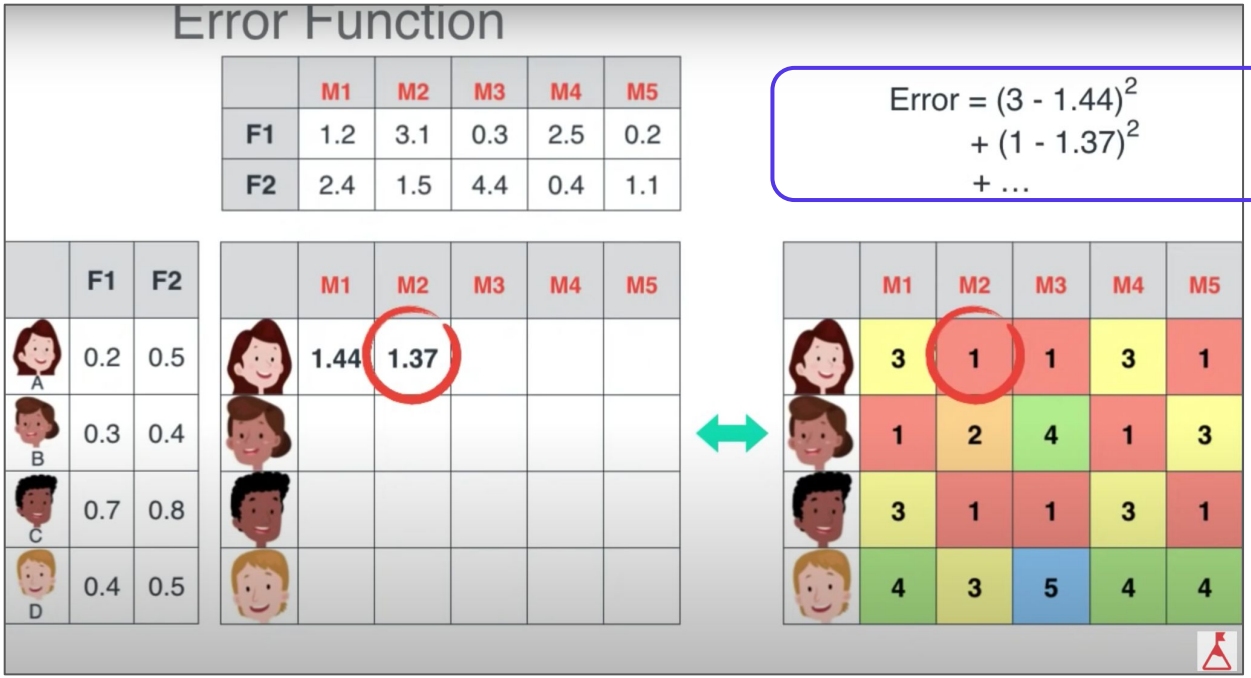

El **ECM** es la **métrica principal** para problema de **regresión**

Moraleja:

¿Encontrar el **mejor algoritmo** nos garantiza resolver un **problema real de datos**?

Lecciones algoritmo Netflix

Referencia:

> engine by 10 percent. But it doesn't use the million-dollar code, and has no plans to implement it in the future, Netflix announced on its blog Friday. The post goes on to explain why: a combination of too much engineering effort for the results, and a shift from movie recommendations to the "next level" of personalization caused by the transition of the business from mailed DVDs to video streaming.

Lecciones algoritmo Netflix

La implementación exitosa de ML **no depende únicamente de la precisión de un algoritmo,** en una decisión de negocios hay otros factores importantes Referencia:

engine by 10 percent. But it doesn't use the million-dollar code, and has no plans to implement it in the future, Netflix announced on its blog Friday. The post goes on to explain why: a combination of too much engineering effort for the results, and a shift from movie recommendations to the "next level" of personalization caused by the transition of the business from mailed DVDs to video streaming.

Lecciones algoritmo Netflix

La implementación exitosa de ML **no depende únicamente de la precisión de un algoritmo,** en una decisión de negocios hay otros factores importantes Referencia:

engine by 10 percent. But it doesn't use the million-dollar code, and has no plans to implement it in the future, Netflix announced on its blog Friday. The post goes on to explain why: a combination of too much engineering effort for the results, and a shift from movie recommendations to the "next level" of personalization caused by the transition of the business from mailed DVDs to video streaming.

Lecciones Netflix

En la **vida real**, además de optimizar la métrica correcta también se consideran **otros aspectos**:

- Tiempo de procesamiento (cómputo en la nube)
- Costo de servidores
- Equipo
- Sueldos, entre otros

.

NETFLIX

Otros usos de estos algoritmos

Existen distintos problemas que se pueden resolver a través de este tipo de algoritmos (aunque **no necesariamente utilizan las mismas técnicas ni enfoques**):

- Sugerir nuevos productos en **Amazon**
- Encontrar pareja ideal en **Tinder o Bumble**
- Sugerir alimentos complementarios en **Uber Eats**
- Sugerir una nueva película en **Amazon Prime**
- Encontrar el documental ideal para ti en **Youtube**
- Sugerir un nuevo contacto en **LinkedIn**

Referencias Netflix Prize

Existe un **buen número de referencias interesantes** sobre este problema:

- https://link.springer.com/chapter/10.1007/978-3-540-68880-8_32
- https://www.youtube.com/watch?v=ImpV70uLxyw&ab_channel=AT%26TTechChannel
- https://netflixtechblog.com/netflix-recommendations-beyond-the-5-stars-part-1-55838468f429
- https://www.wired.com/2012/04/netflix-prize-costs/

Otros premios por Matemáticas

Instituto Clay de Matemáticas - Problemas del Milenio

7 problemas - **Se ofrece 1 millón de dólares por cada problema resuelto**

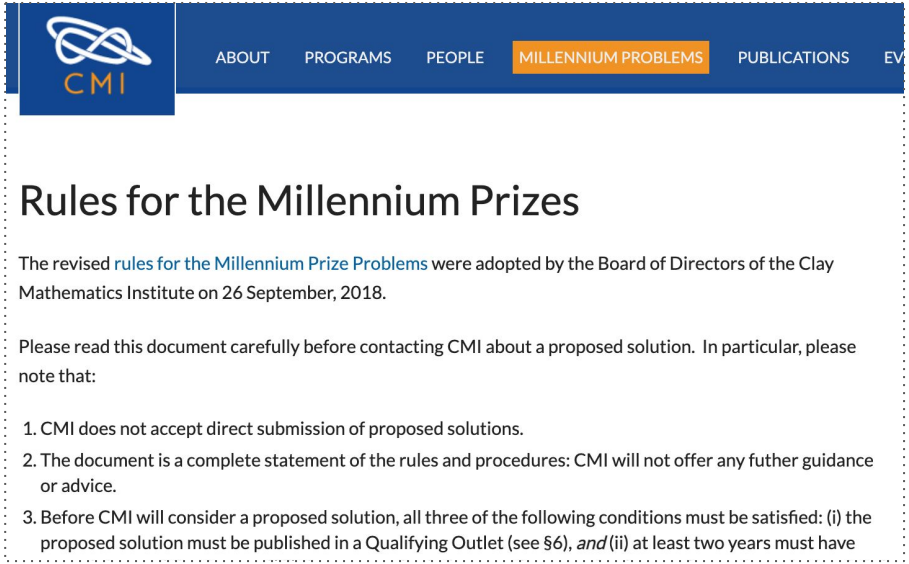

Otros premios por Matemáticas

Problemas

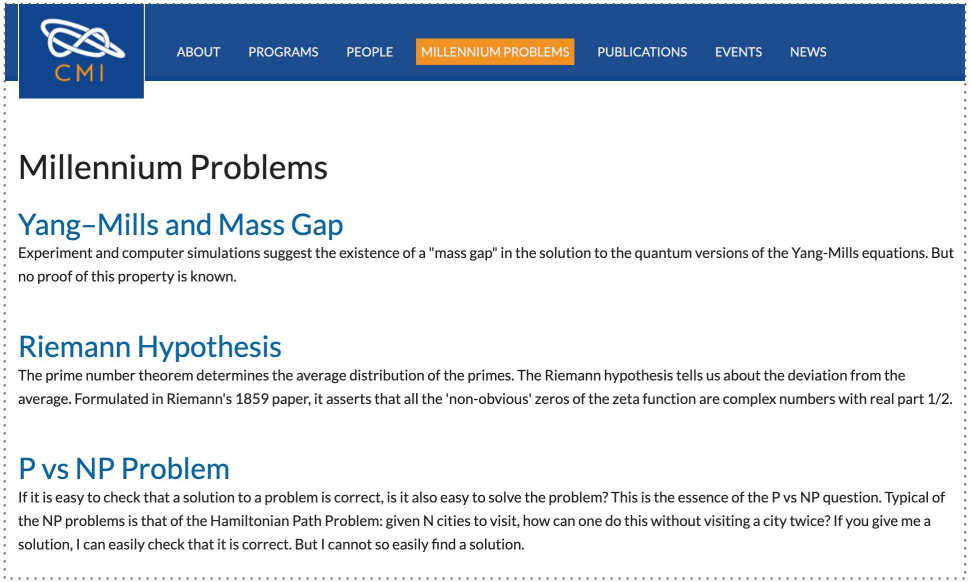

Otros premios por Matemáticas

Sólo un problema ha sido resuelto: en el 2003 Grigori Perelmán resolvió la connjetura de Poincaré **pero rechazó el premio :(**

También ganó la Medalla Fields en 2006 (como el Nobel de Matemáticas) pero **rechazó asistir a la premiación** y el premio

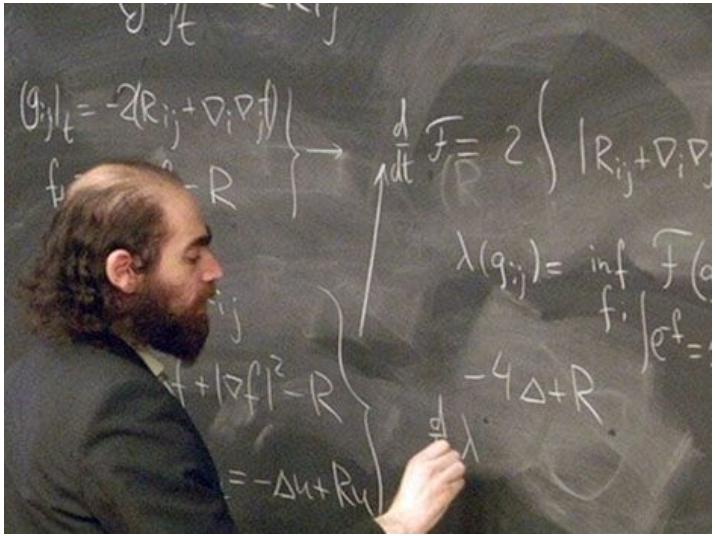

Descomposición valores singulares

Abre el código **Clase4. R**

Referencia2

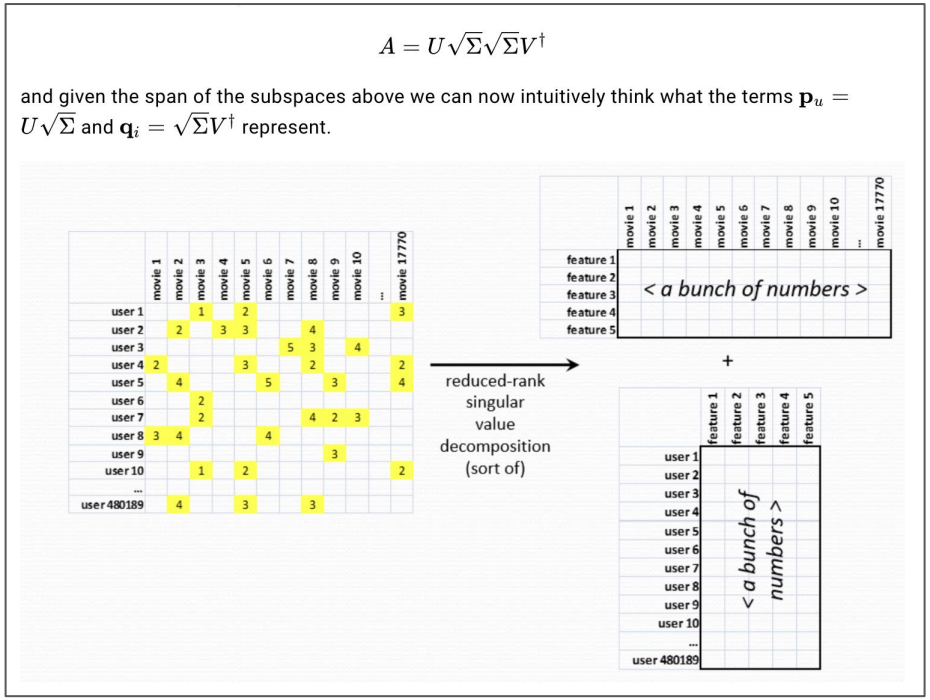

Libros de referencia

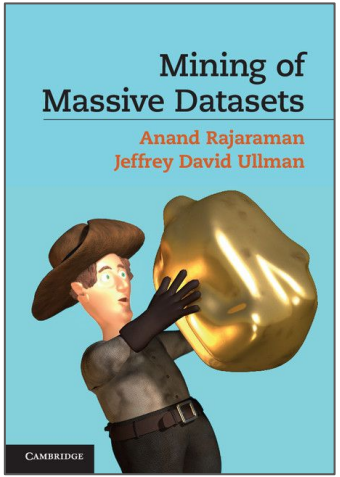

Liga

Linear Algebra, *Friedberg*

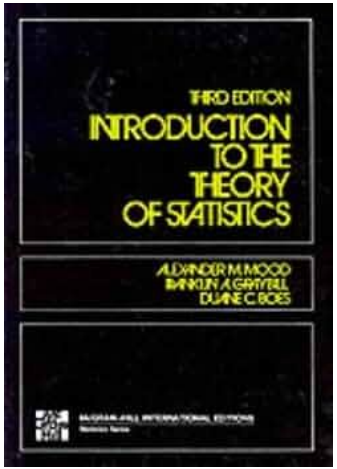

Statistics, *Mood*

Tabasco Global Pulse

Ejemplo Políticas Públicas

Clase 4

ML y análisis de datos

ITAM

Patrones de Movilidad

Datos anonimizados de Foursquare y redes sociales, **liga**

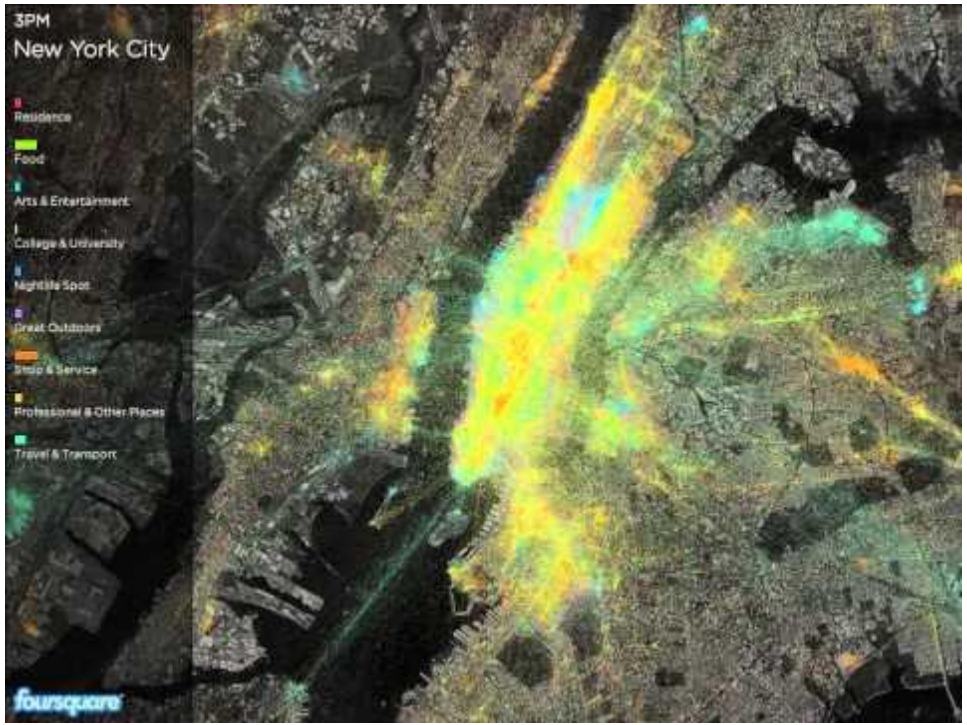

Este tipo de datos y su análisis también pueden servir para salvar vidas en desastres naturales

En nuestro curso, estudiaremos un caso de uso con la ONU

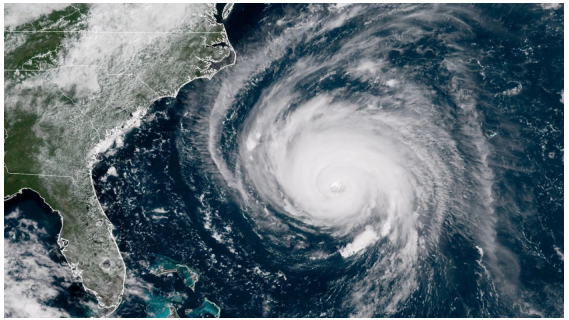

¿Cómo podemos mejorar la atención de **desastres naturales**?

Situación inundaciones Tabasco 2009

Tabasco es uno de los estados que sufren, con mayor frecuencia, inundaciones en la temporada de huracanes y tormentas en el golfo de México.

- El 28 de octubre del 2009, el frente frío no. 9 entró por el noroeste de México, llegó a Tabasco el 31 de octubre y permaneció por cuatro días.

- Según datos del Servicio Meteorológico Nacional, se registraron 800mm de lluvia acumulada que implica **cuatro veces más** el nivel usual en el mes de noviembre.

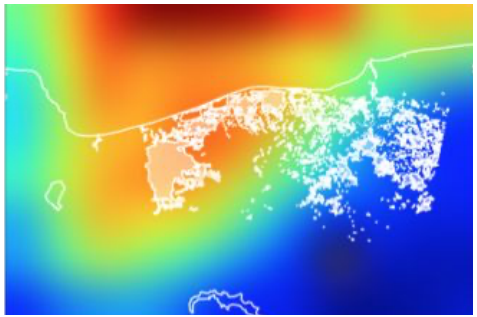

Imagen satelital de la precipitación acumulada en Tabasco durante las dos primeras semanas de noviembre.

Pregunta 1:

¿Cómo podemos aprovechar la información demográfica y los patrones de movilidad de la población para evaluar la situación después de un **desastre natural**?

Pregunta 2:

¿Es posible diseñar una mejor estrategia de protección civil?

UN Global Pulse

Esta investigación fue realizada en colaboración con *Global Pulse*, iniciativa de análisis de datos de la ONU.

Información y referencias proporcionadas para este análisis:

- Dirección General de Protección Civil
- INEGI
- CONAGUA
- SRE
- CENAPRED

DSSG: Esquema de Colaboración

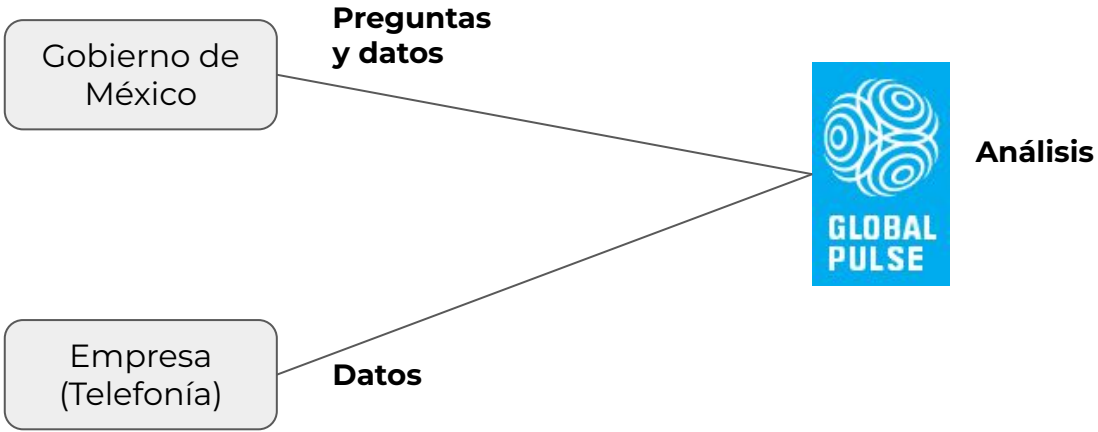

CDR Telefonía

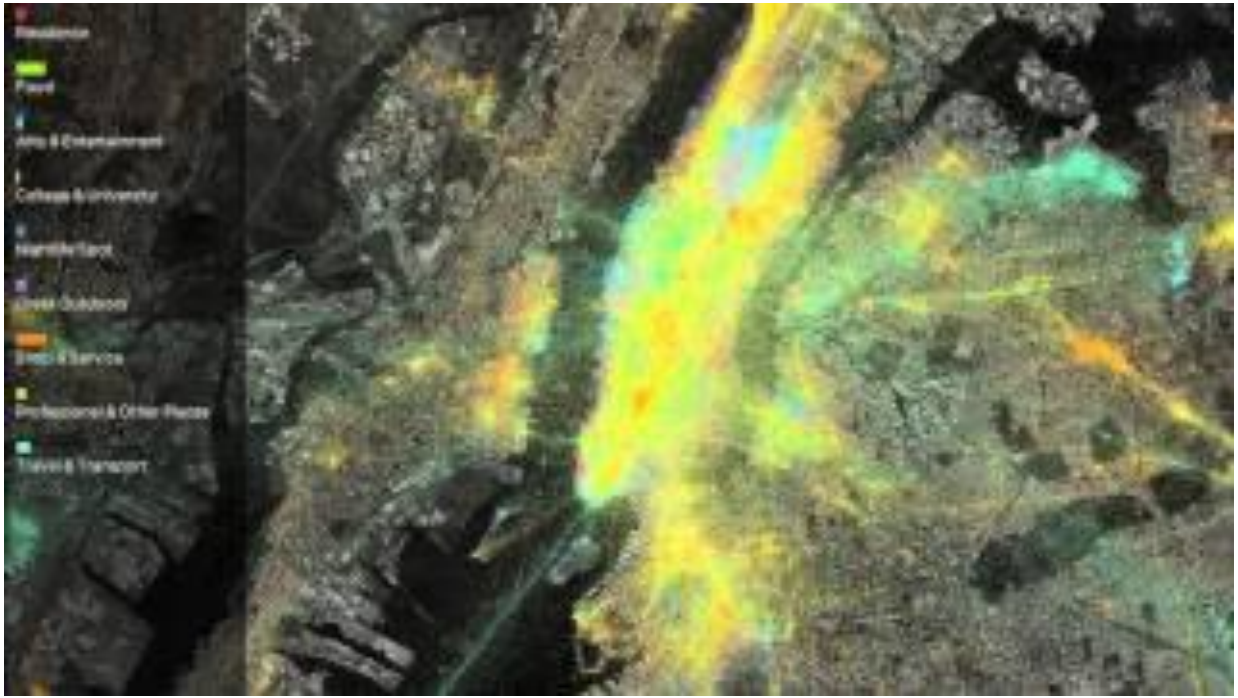

Fuentes de datos

Antenas telefónicas

- Están localizadas geográficamente con **latitud y longitud.**
- El área de cobertura por cada antena se conoce como célula.
- La antena que brinda cobertura a un celular es asignada en función del tráfico en la red y la posición geográfica.

Registros de llamadas

- Cada que un teléfono celular recibe o realiza una llamada, mensaje u otro servicio, se registra información como la duración y antena a la que fue enlazado.
- Aunque no existe información sobre la posición exacta del teléfono, se puede estimar considerando la ubicación de la antena.
- La información utilizada para este estudio incluye datos encriptados de la fecha, hora, duración y antena a la que fue enlazada cada llamada. El equipo de la CEDN no participó en la extracción y resguardo de esta información que estuvo a cargo del equipo de Global Pulse de la ONU.

¿Cómo podemos deducir **patrones de movilidad** a partir de estos datos?

Antenas

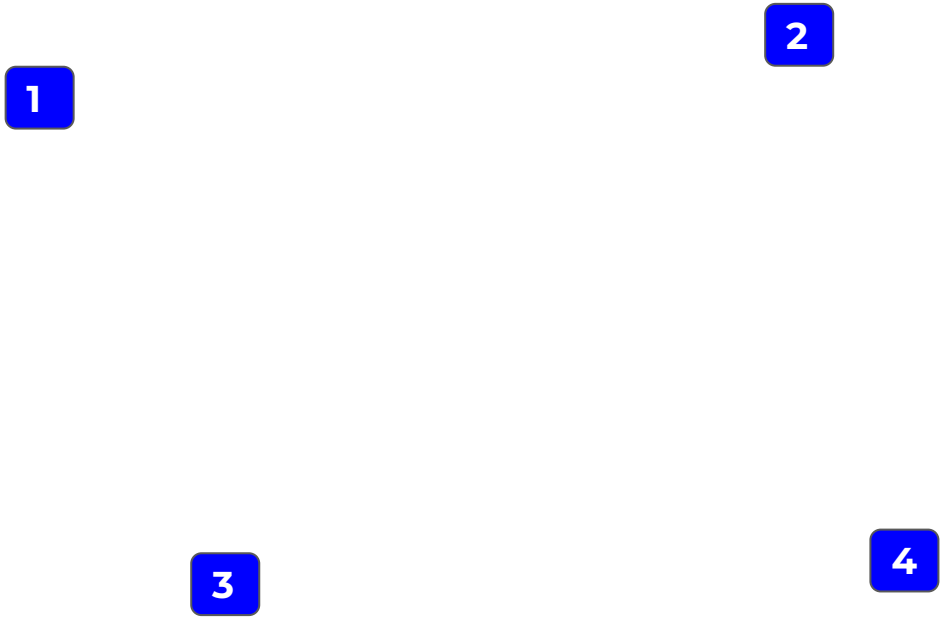

Usuarios

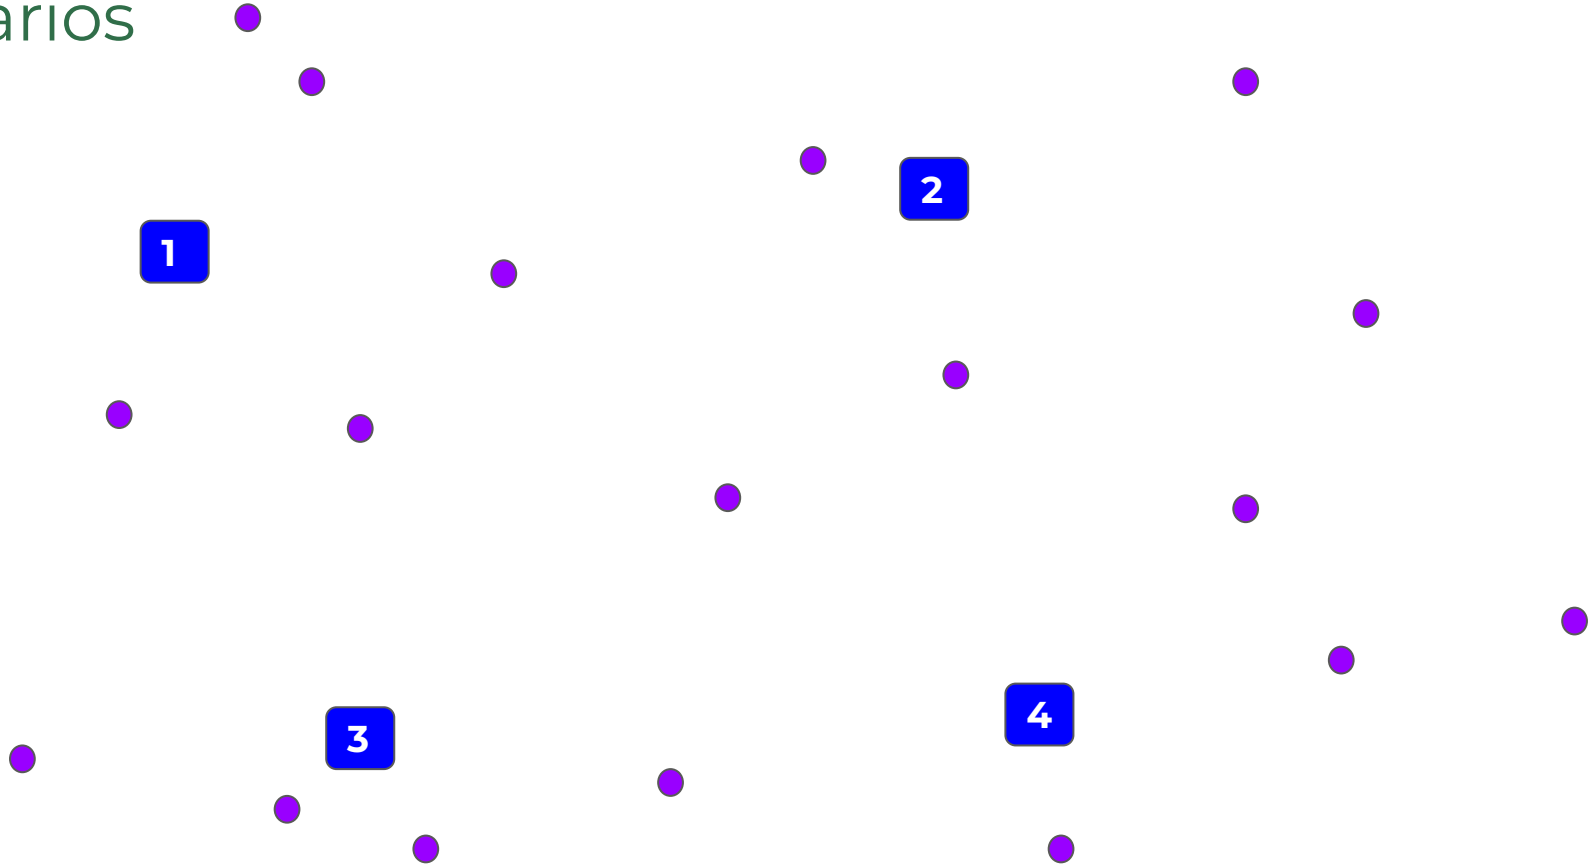

La **ubicación exacta** de los usuarios es **desconocida**

¿Qué antena procesa tu llamada?

Llamadas

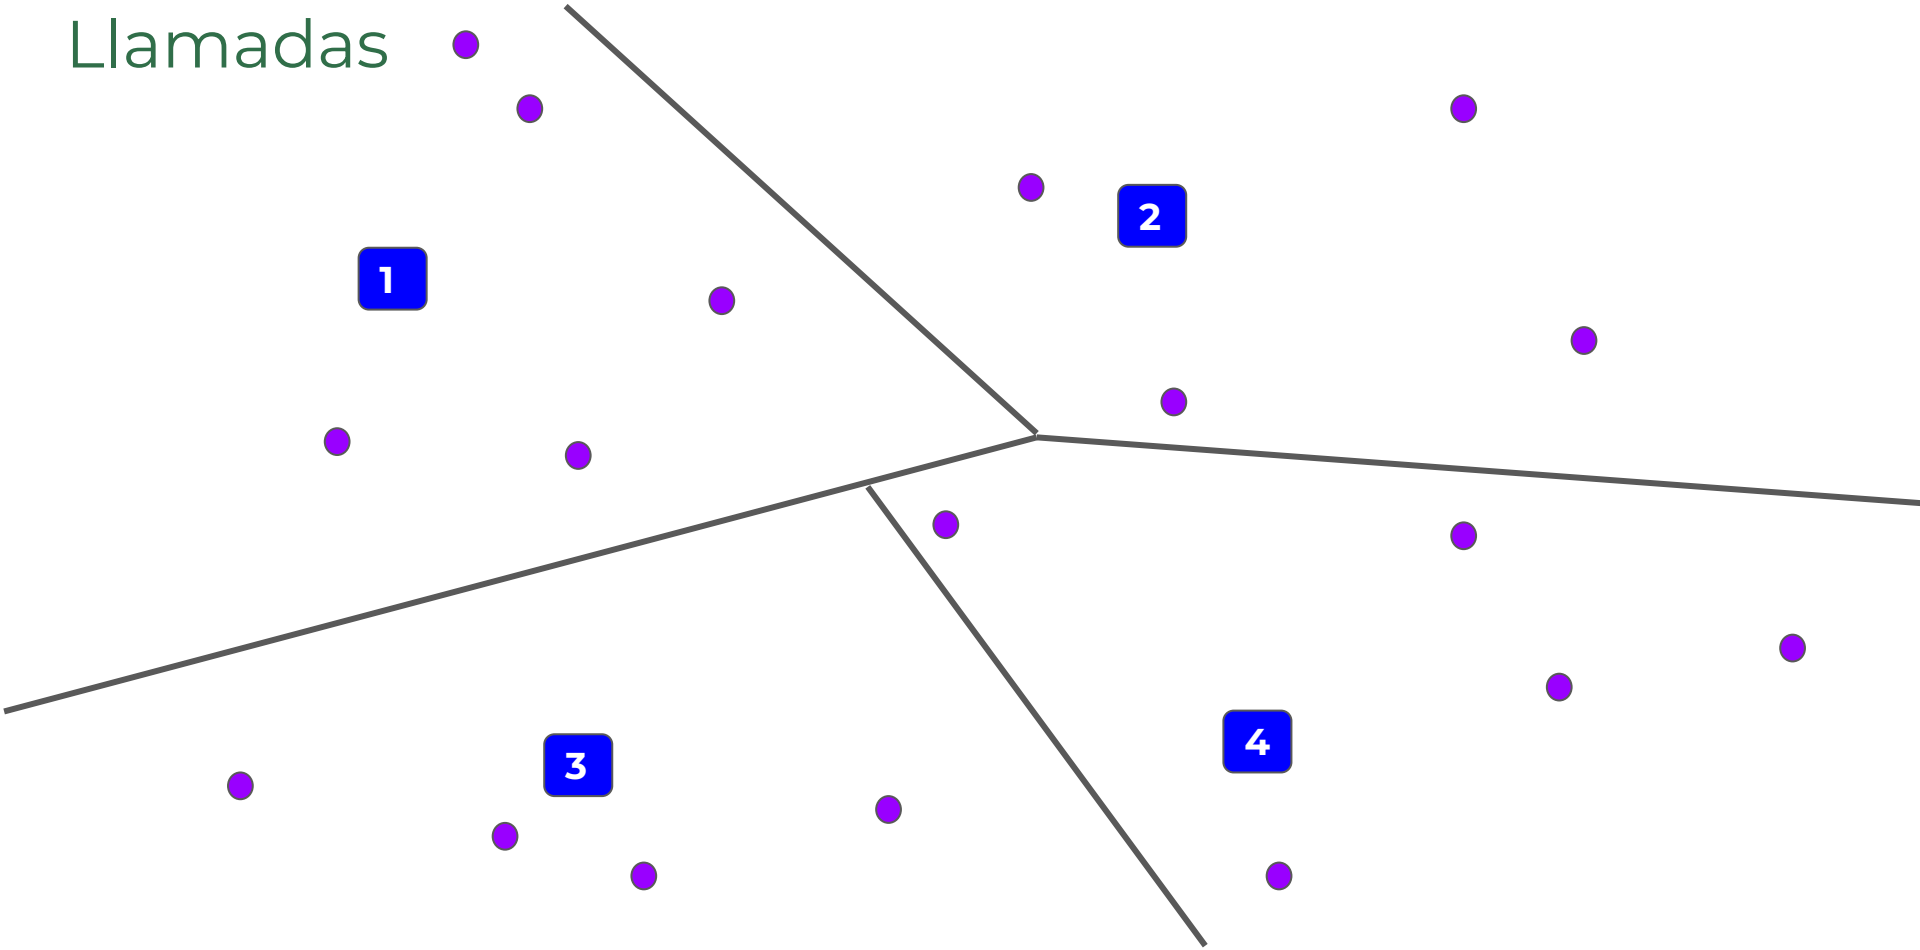

La fecha y hora en que cada usuario se enlaza a las antenas
se registran en una BD conocida como ***Call details records*** (CDR).

Cada usuario **tiene un ID_único** y es posible
determinar la **fecha y hora en la que se enlazo a cada antena**

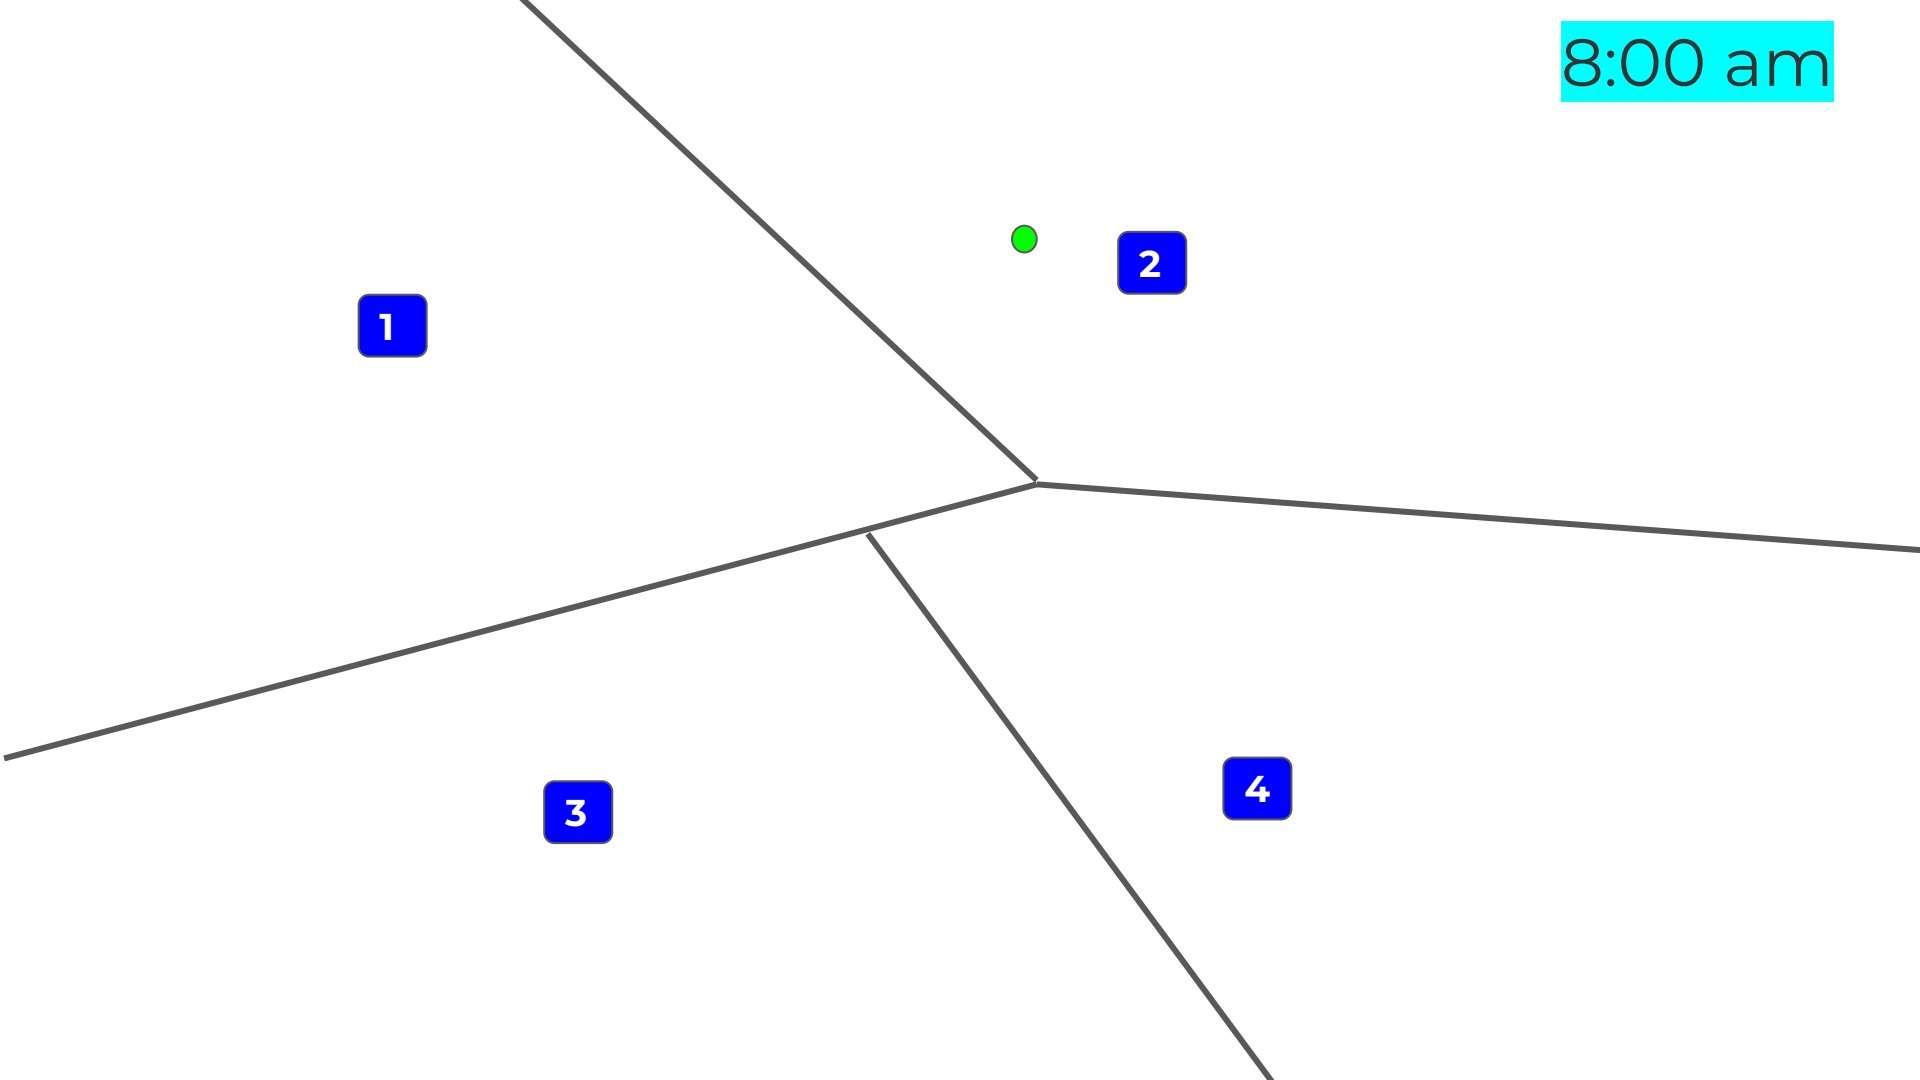
8:00 am
1
2
3
4

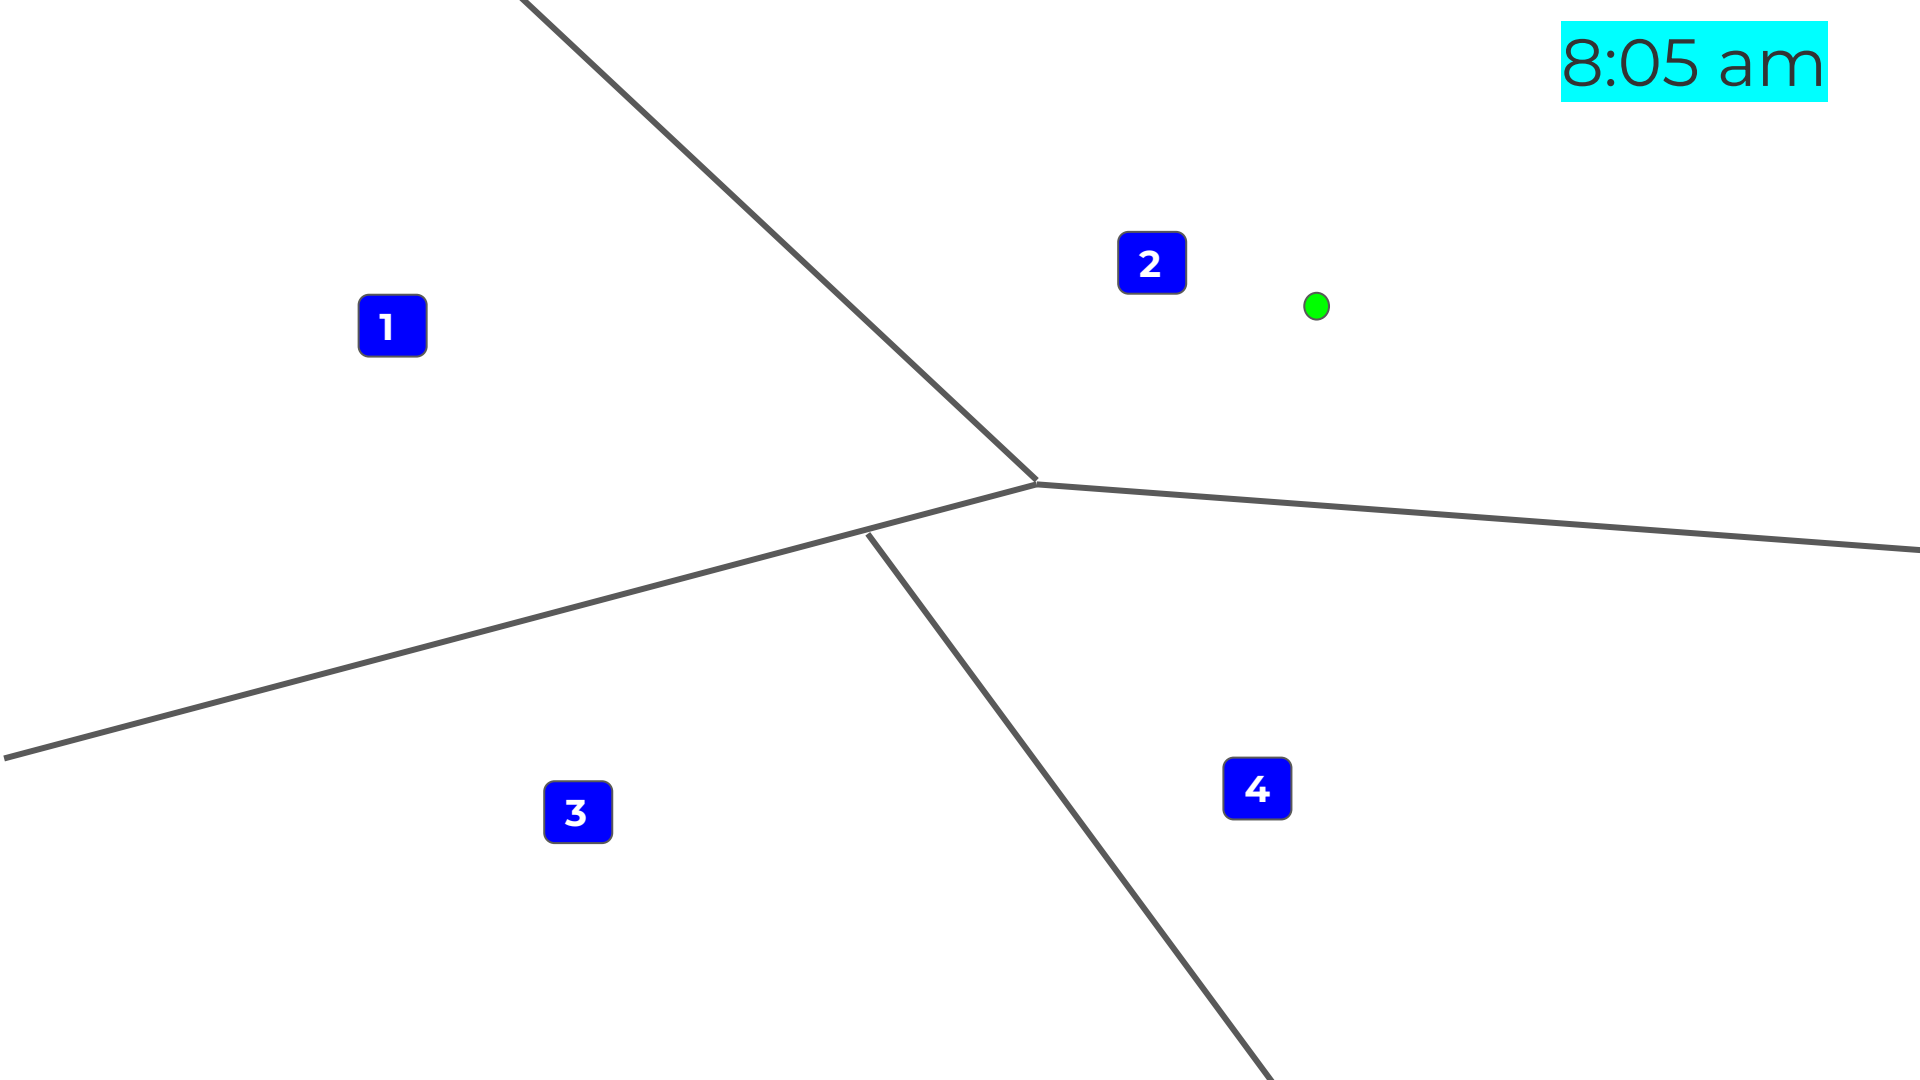
8:05 am
1
2
3
4

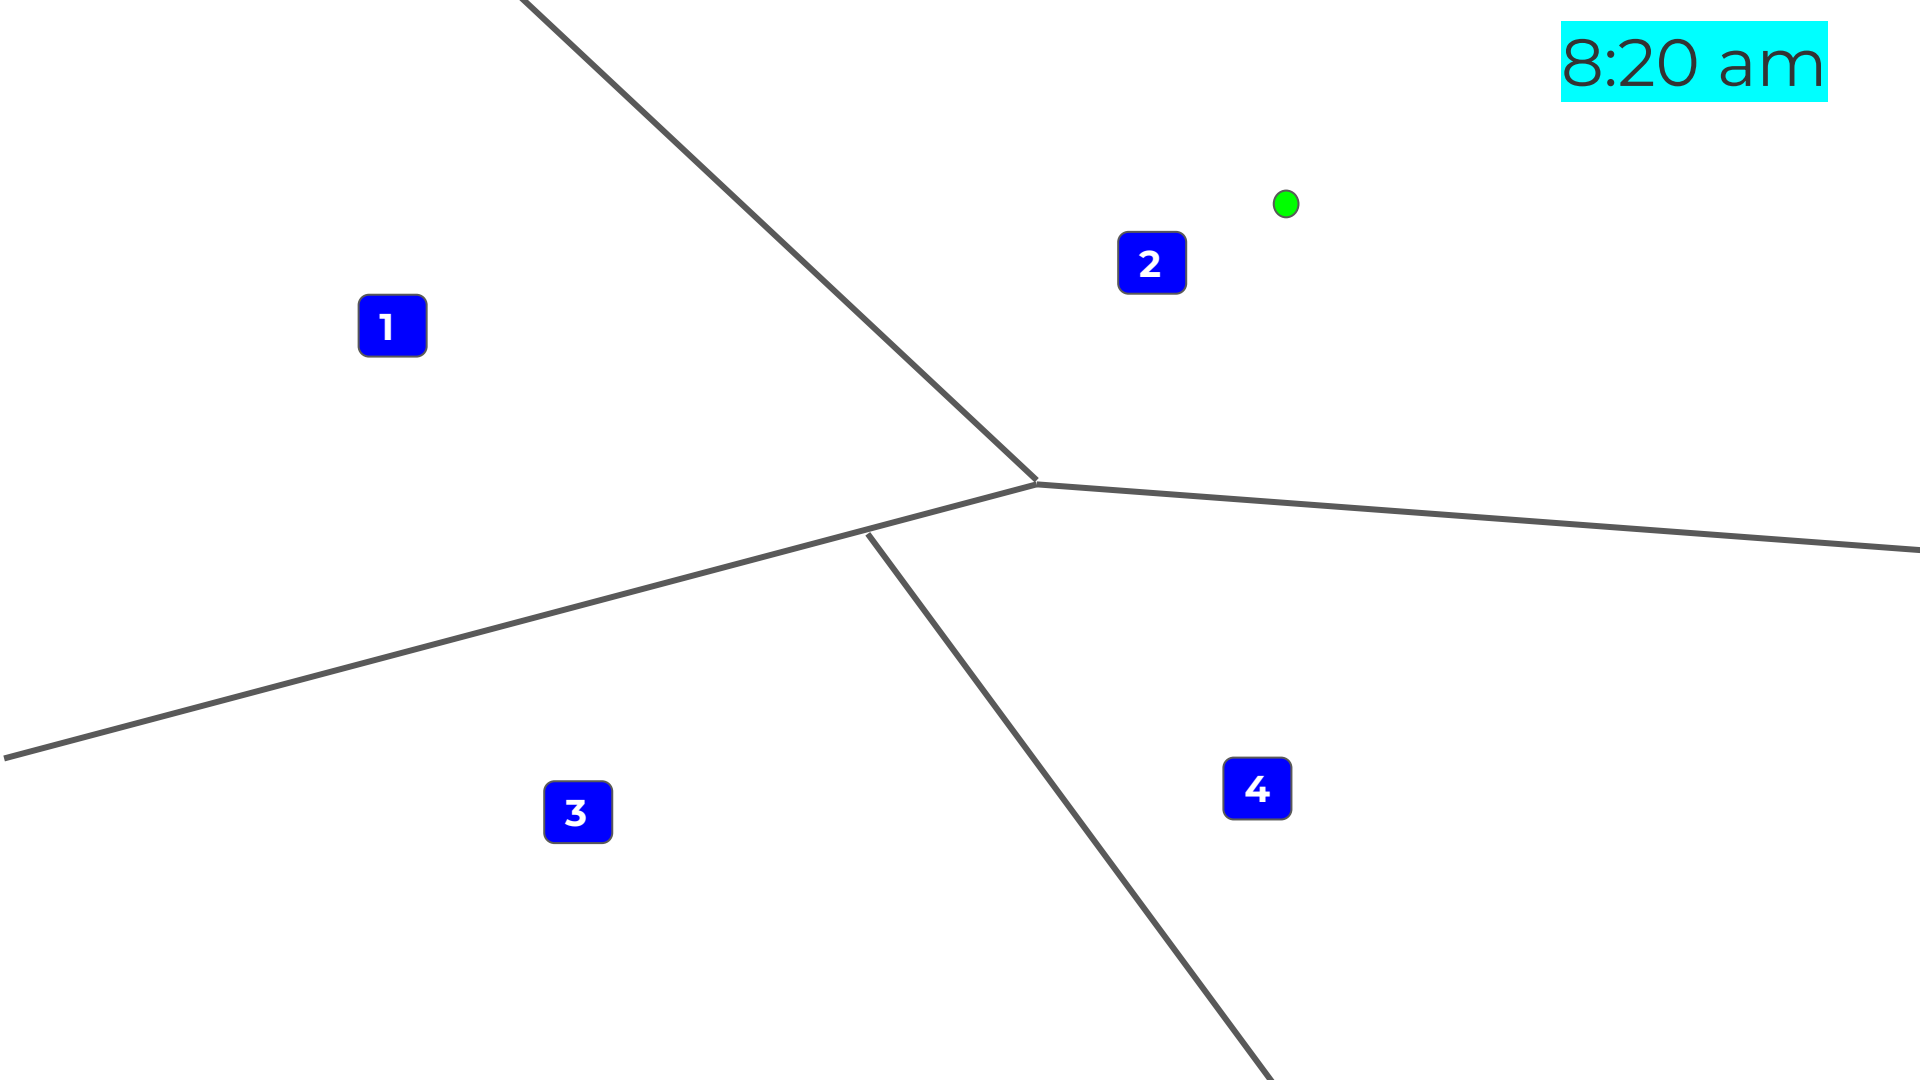
8:20 am
1
2
3
4

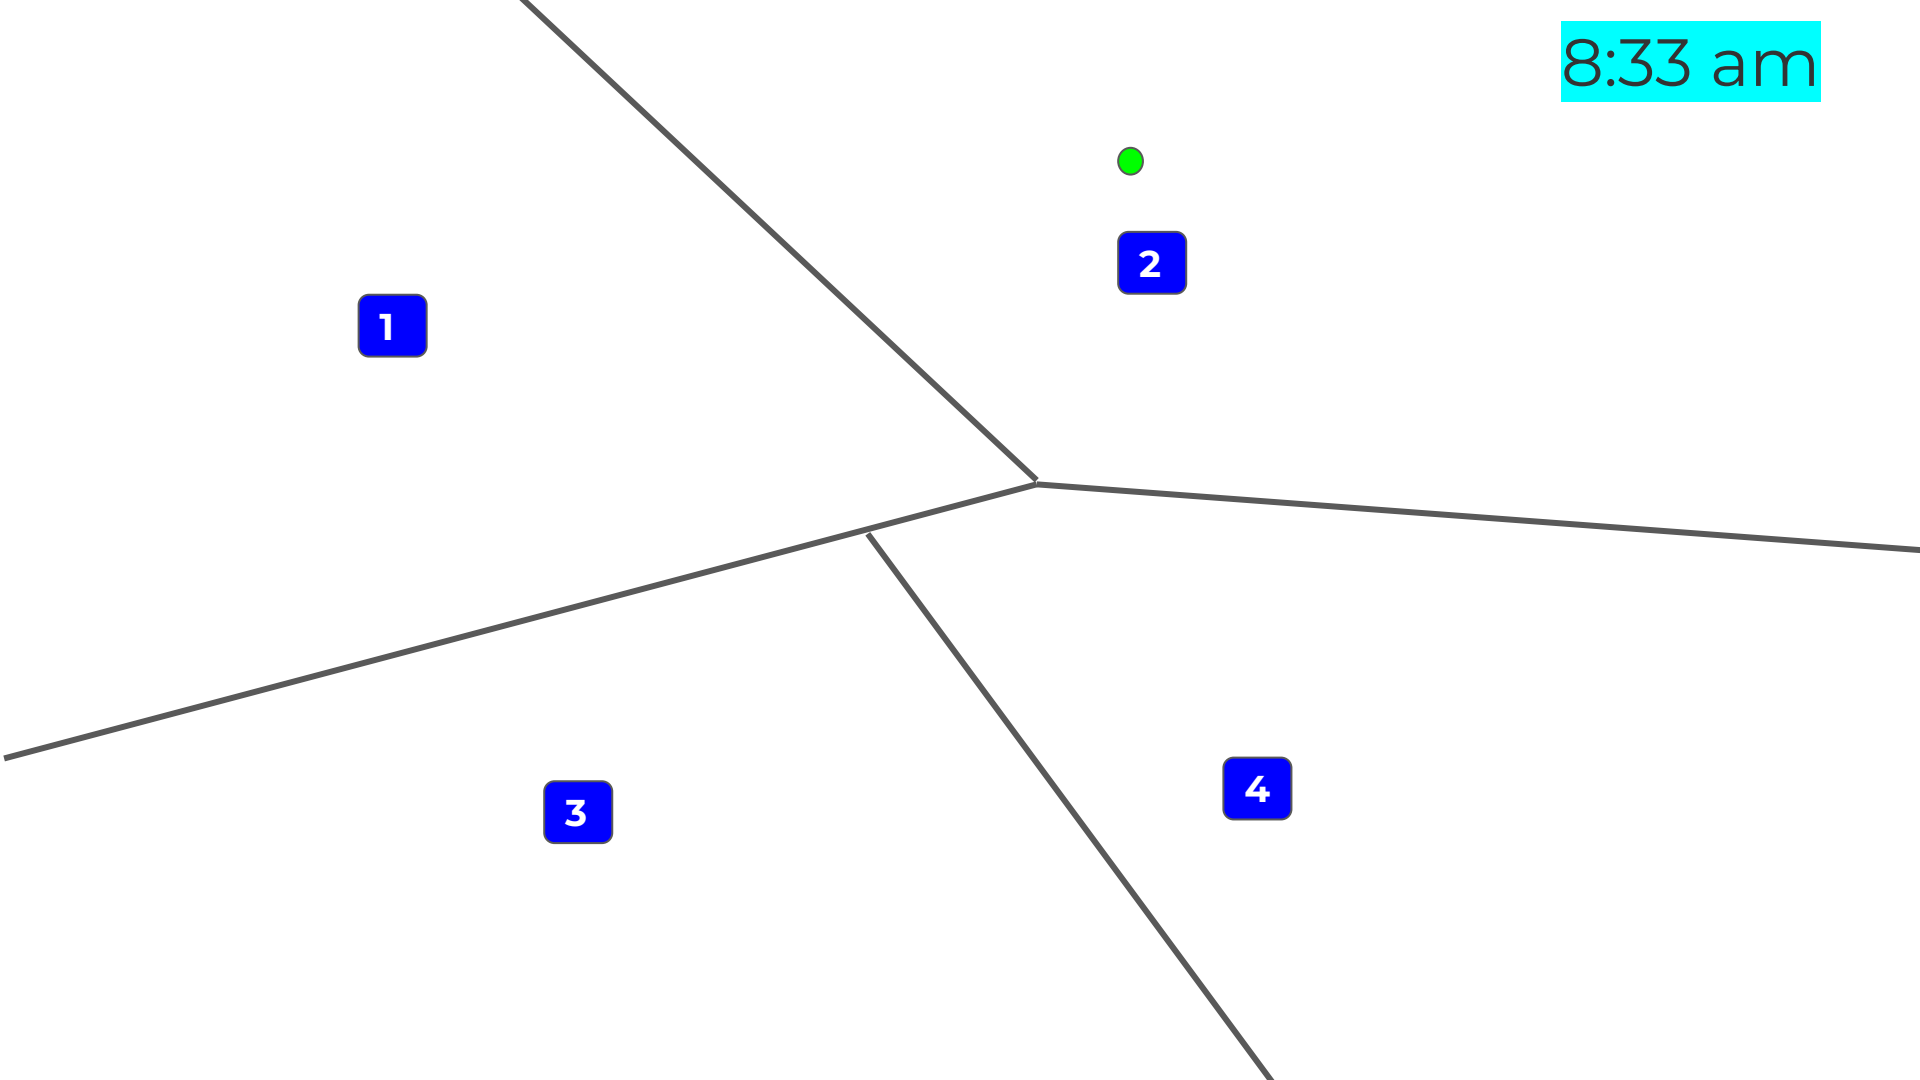
8:33 am
1
2
3
4

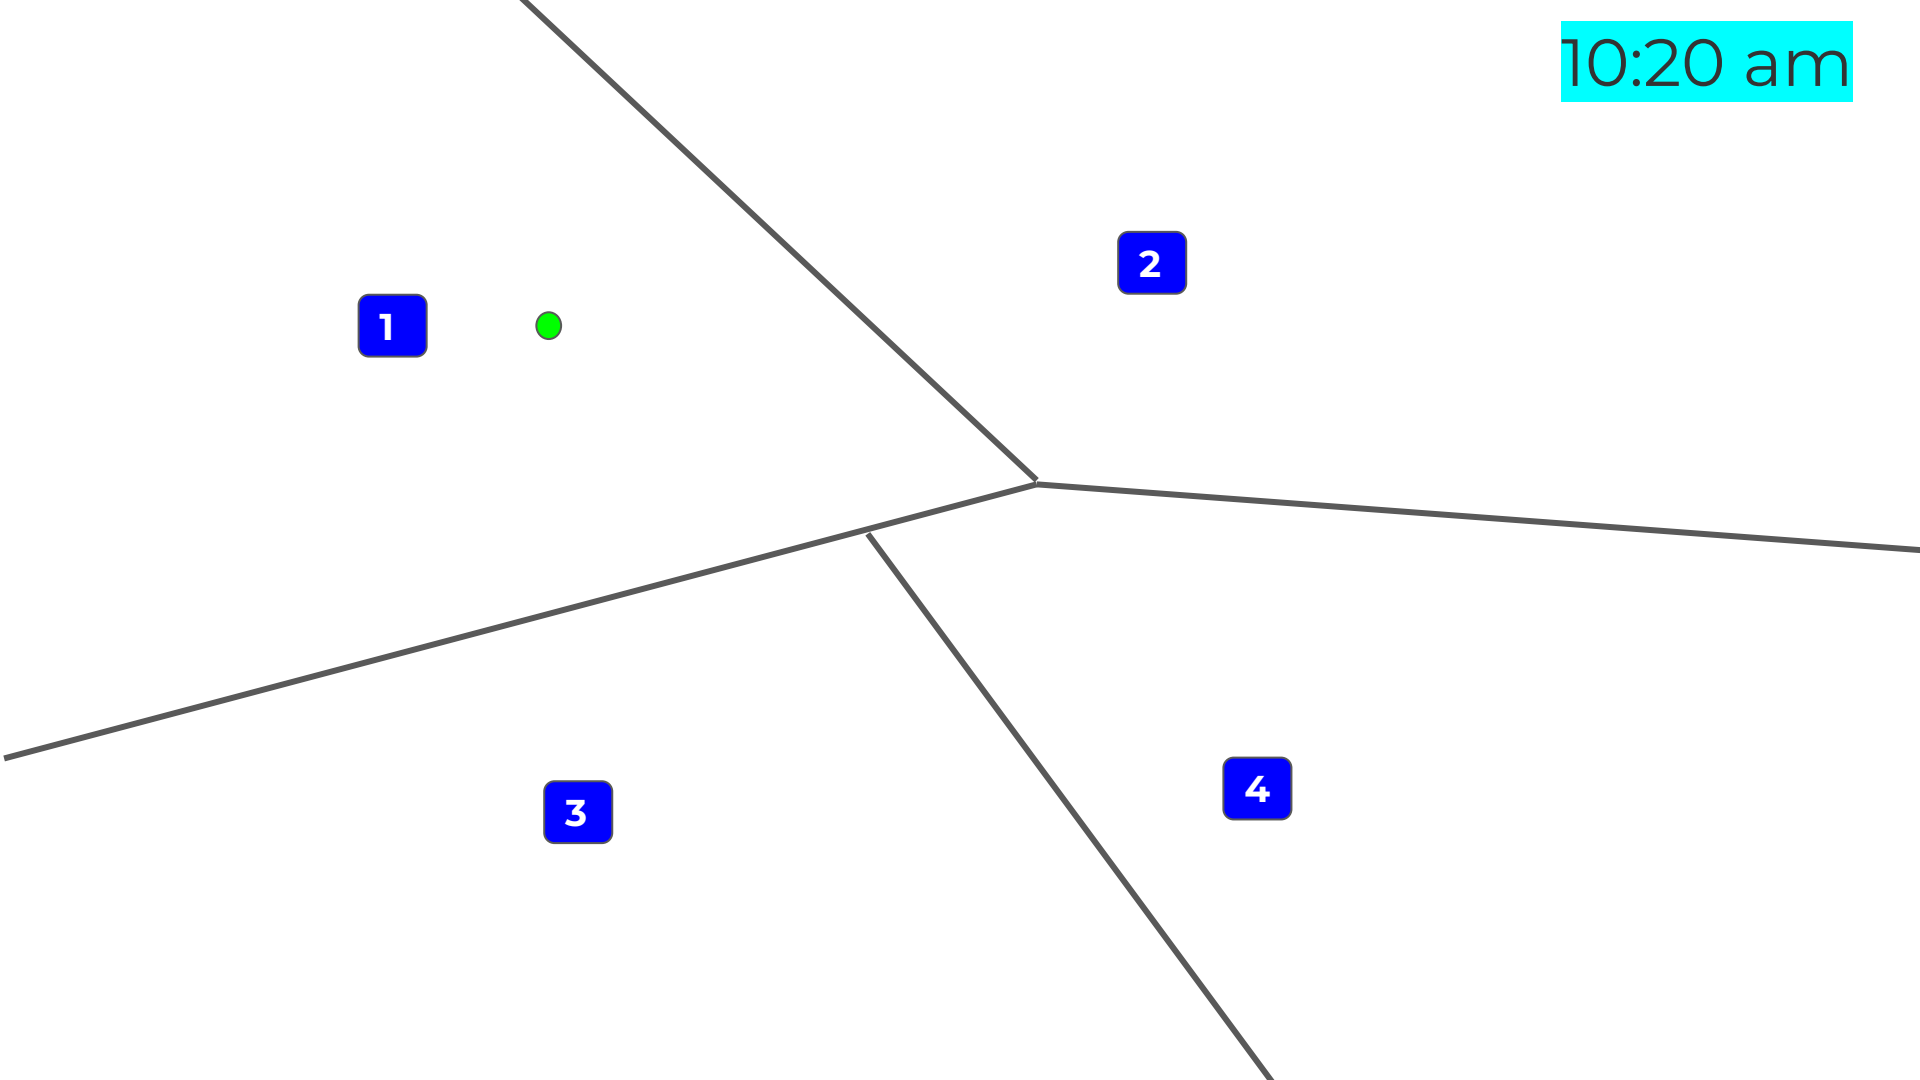
10:20 am
1
2
3
4

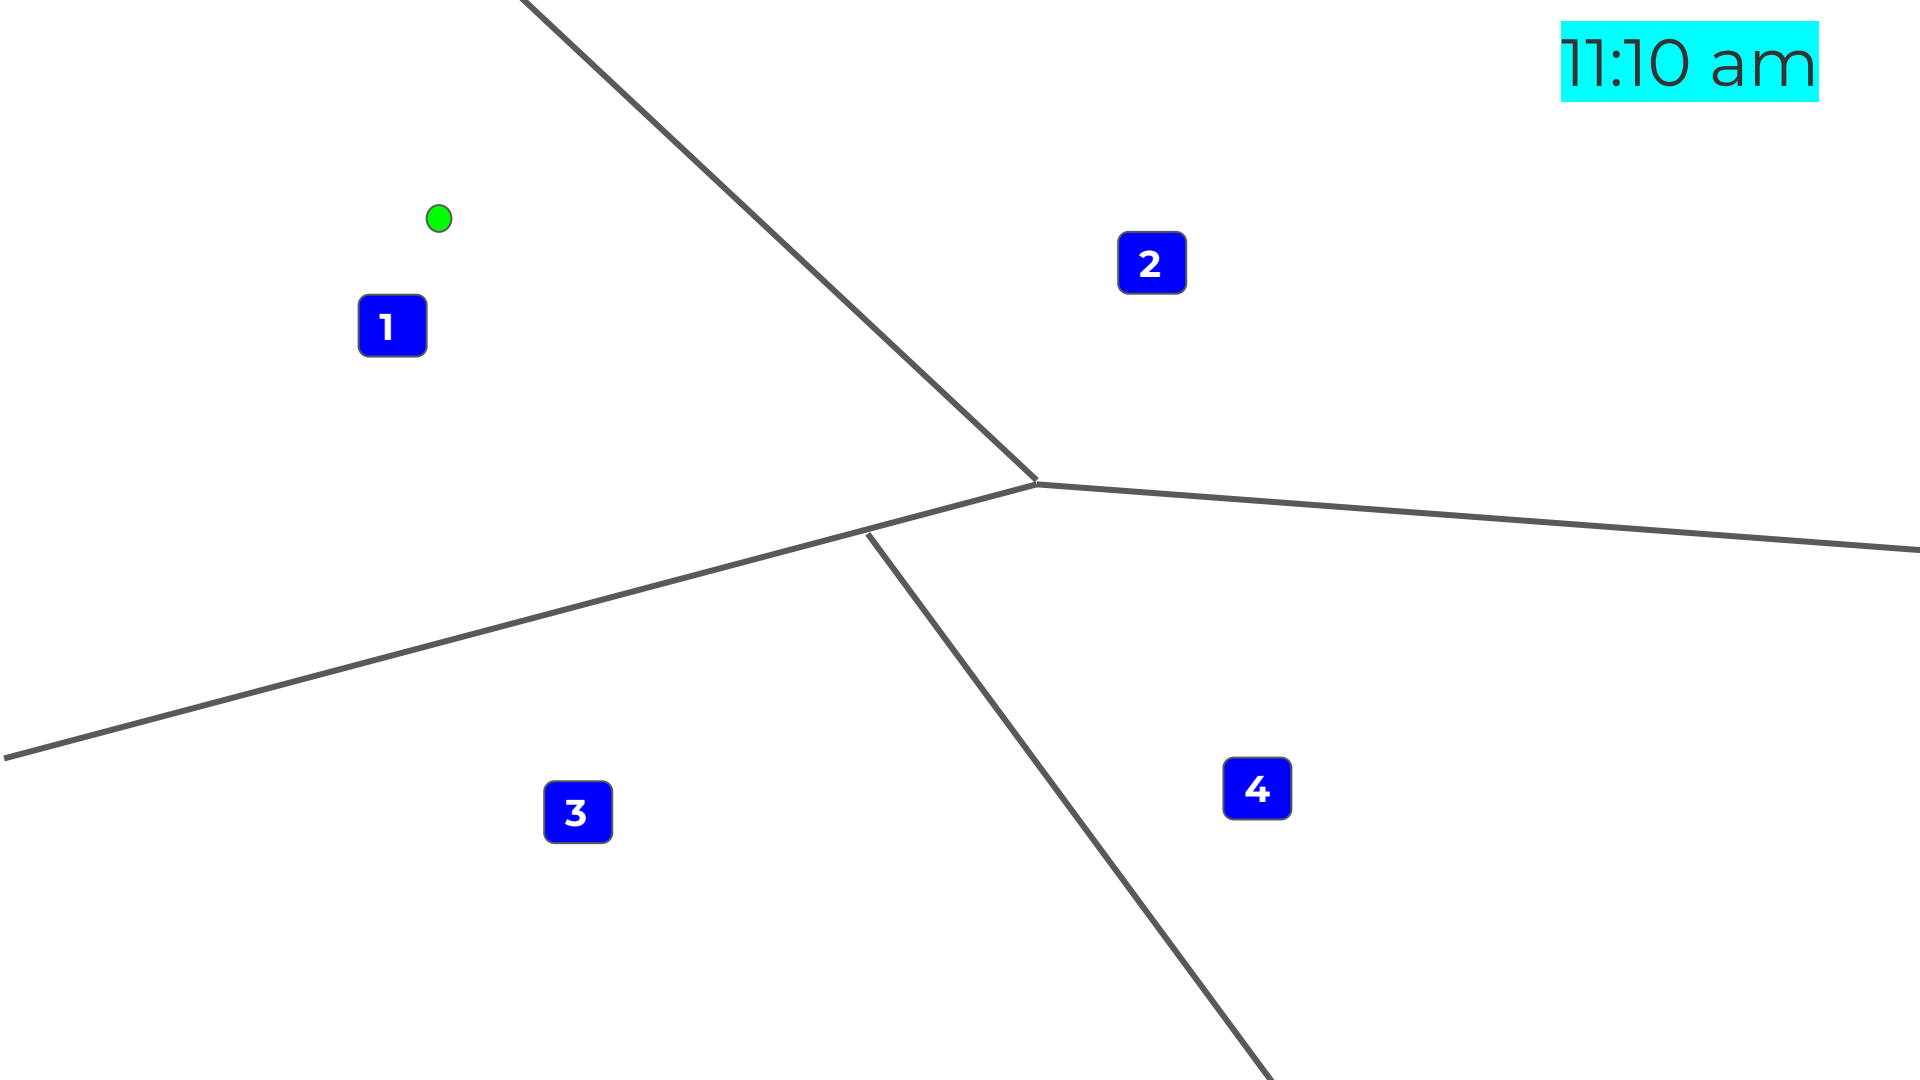
11:10 am
1
2
3
4

Fin de semana

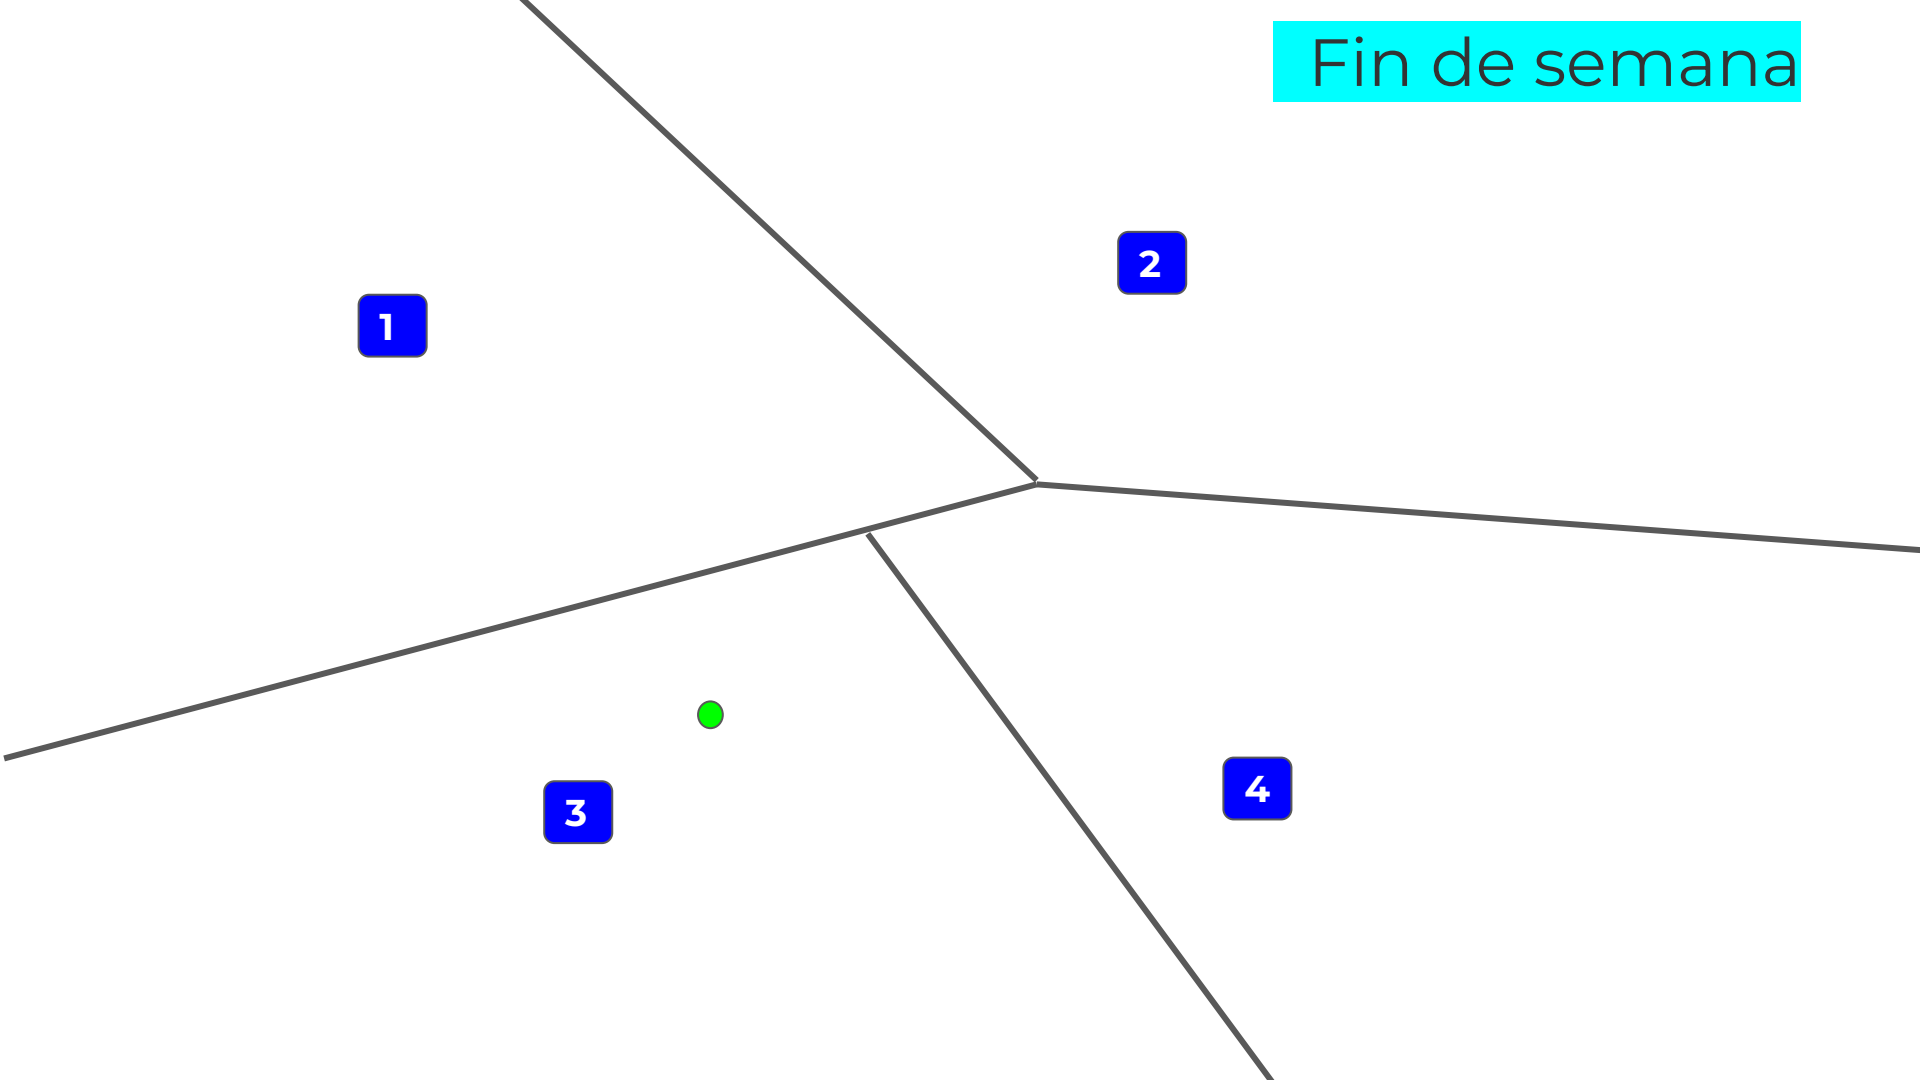

Fin de semana

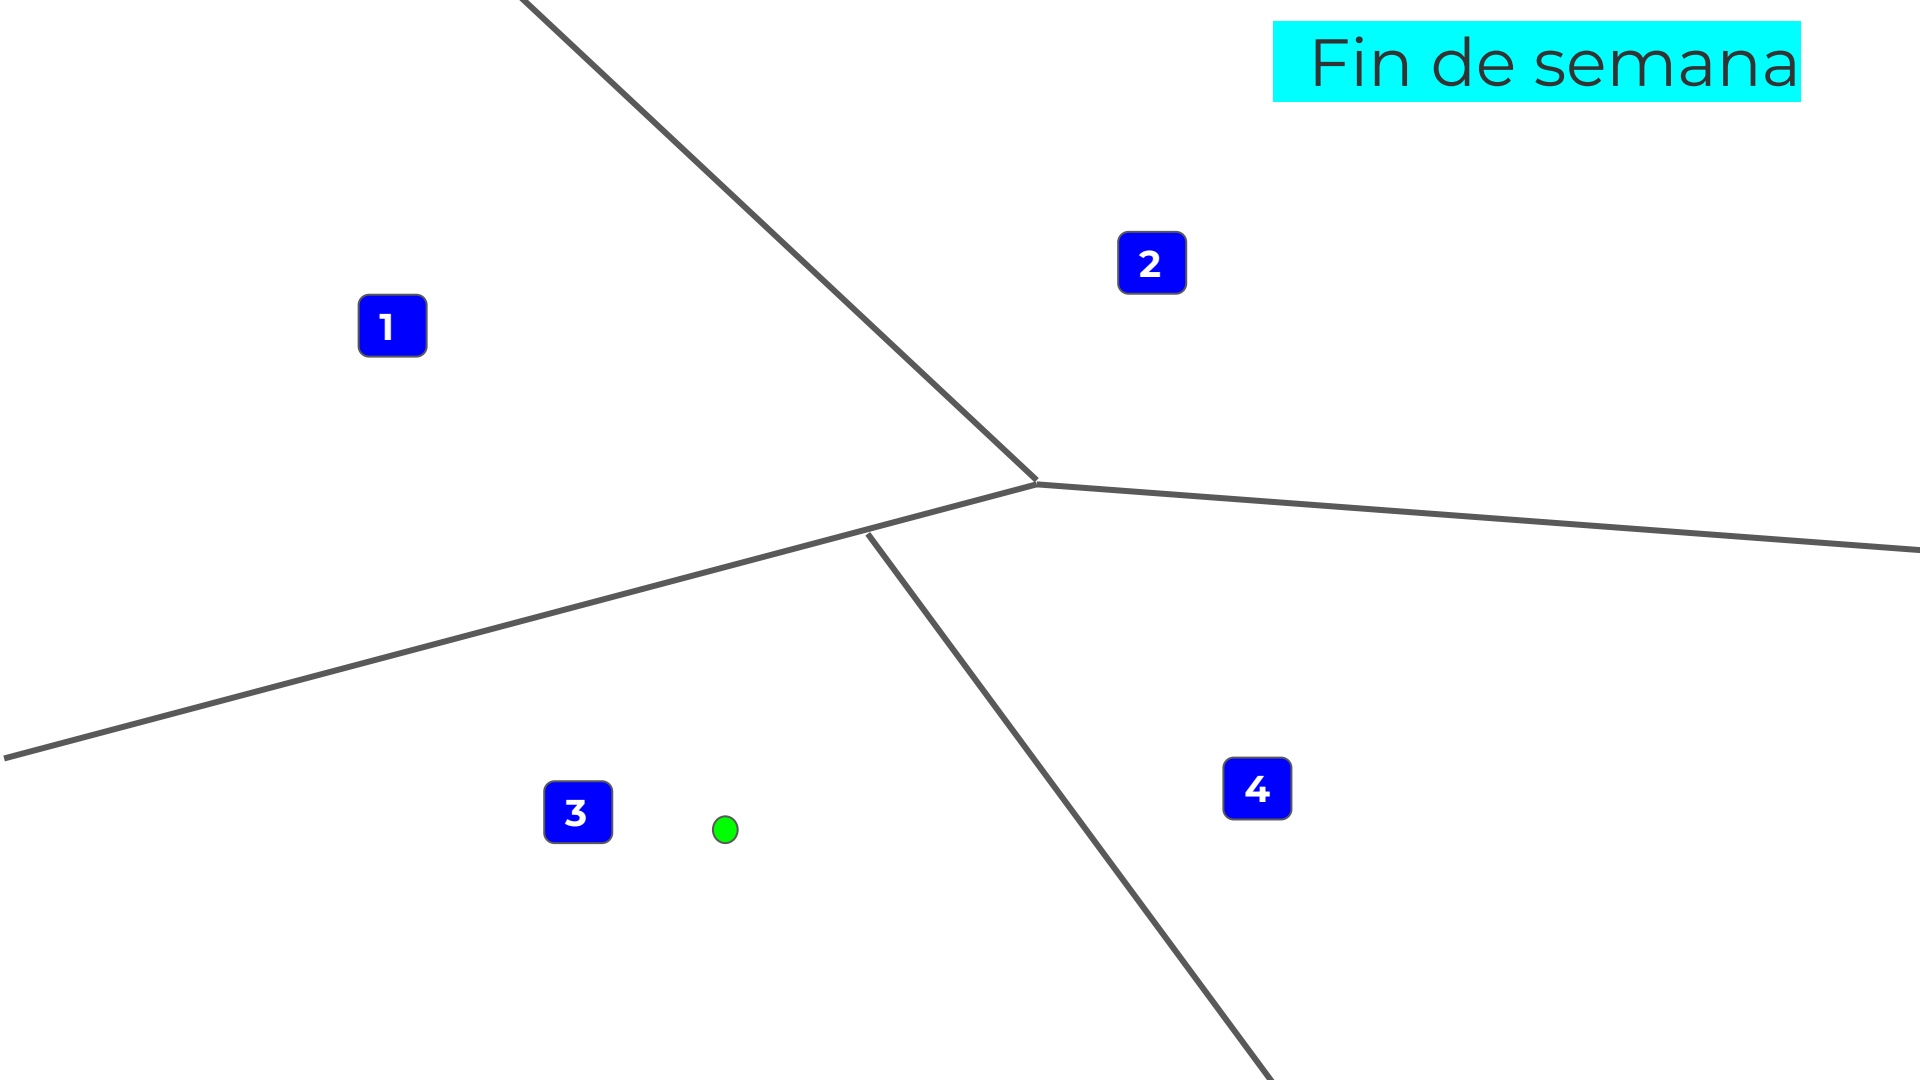

Fin de semana

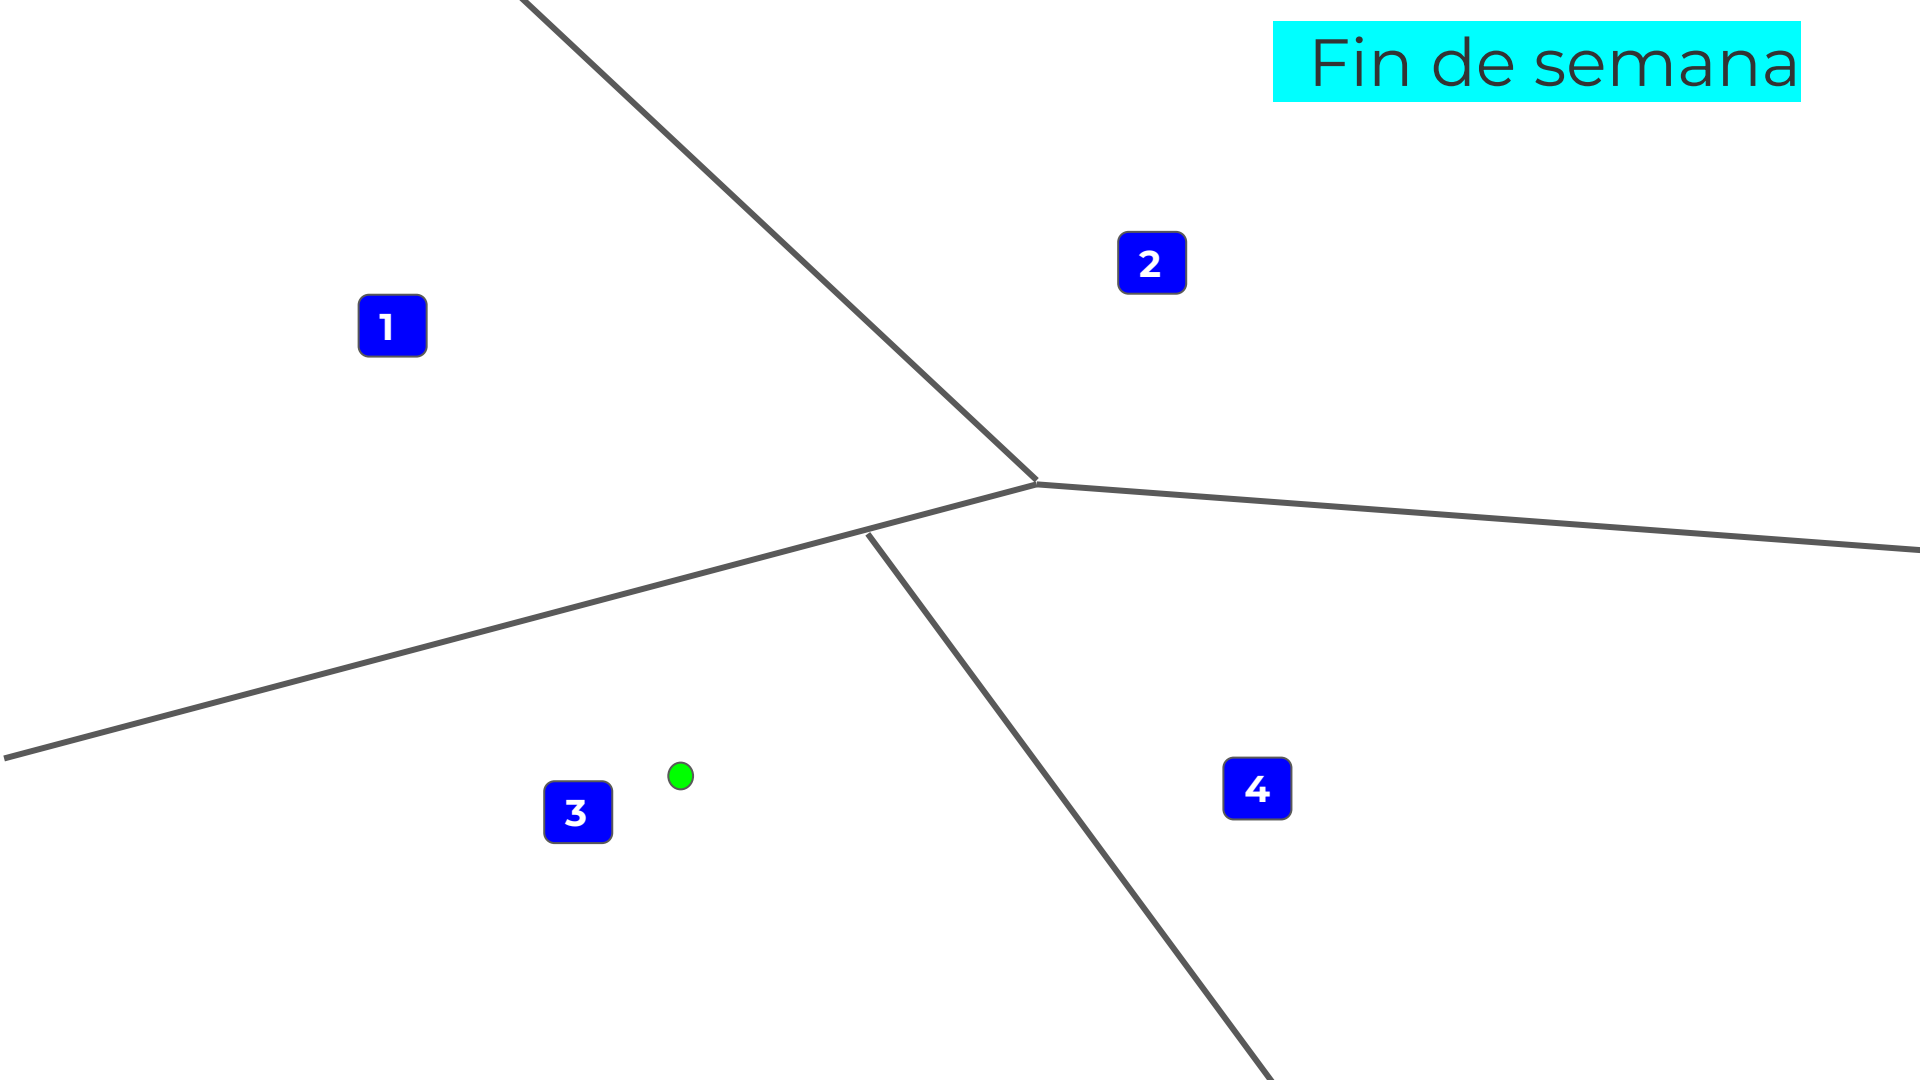

Fin de semana

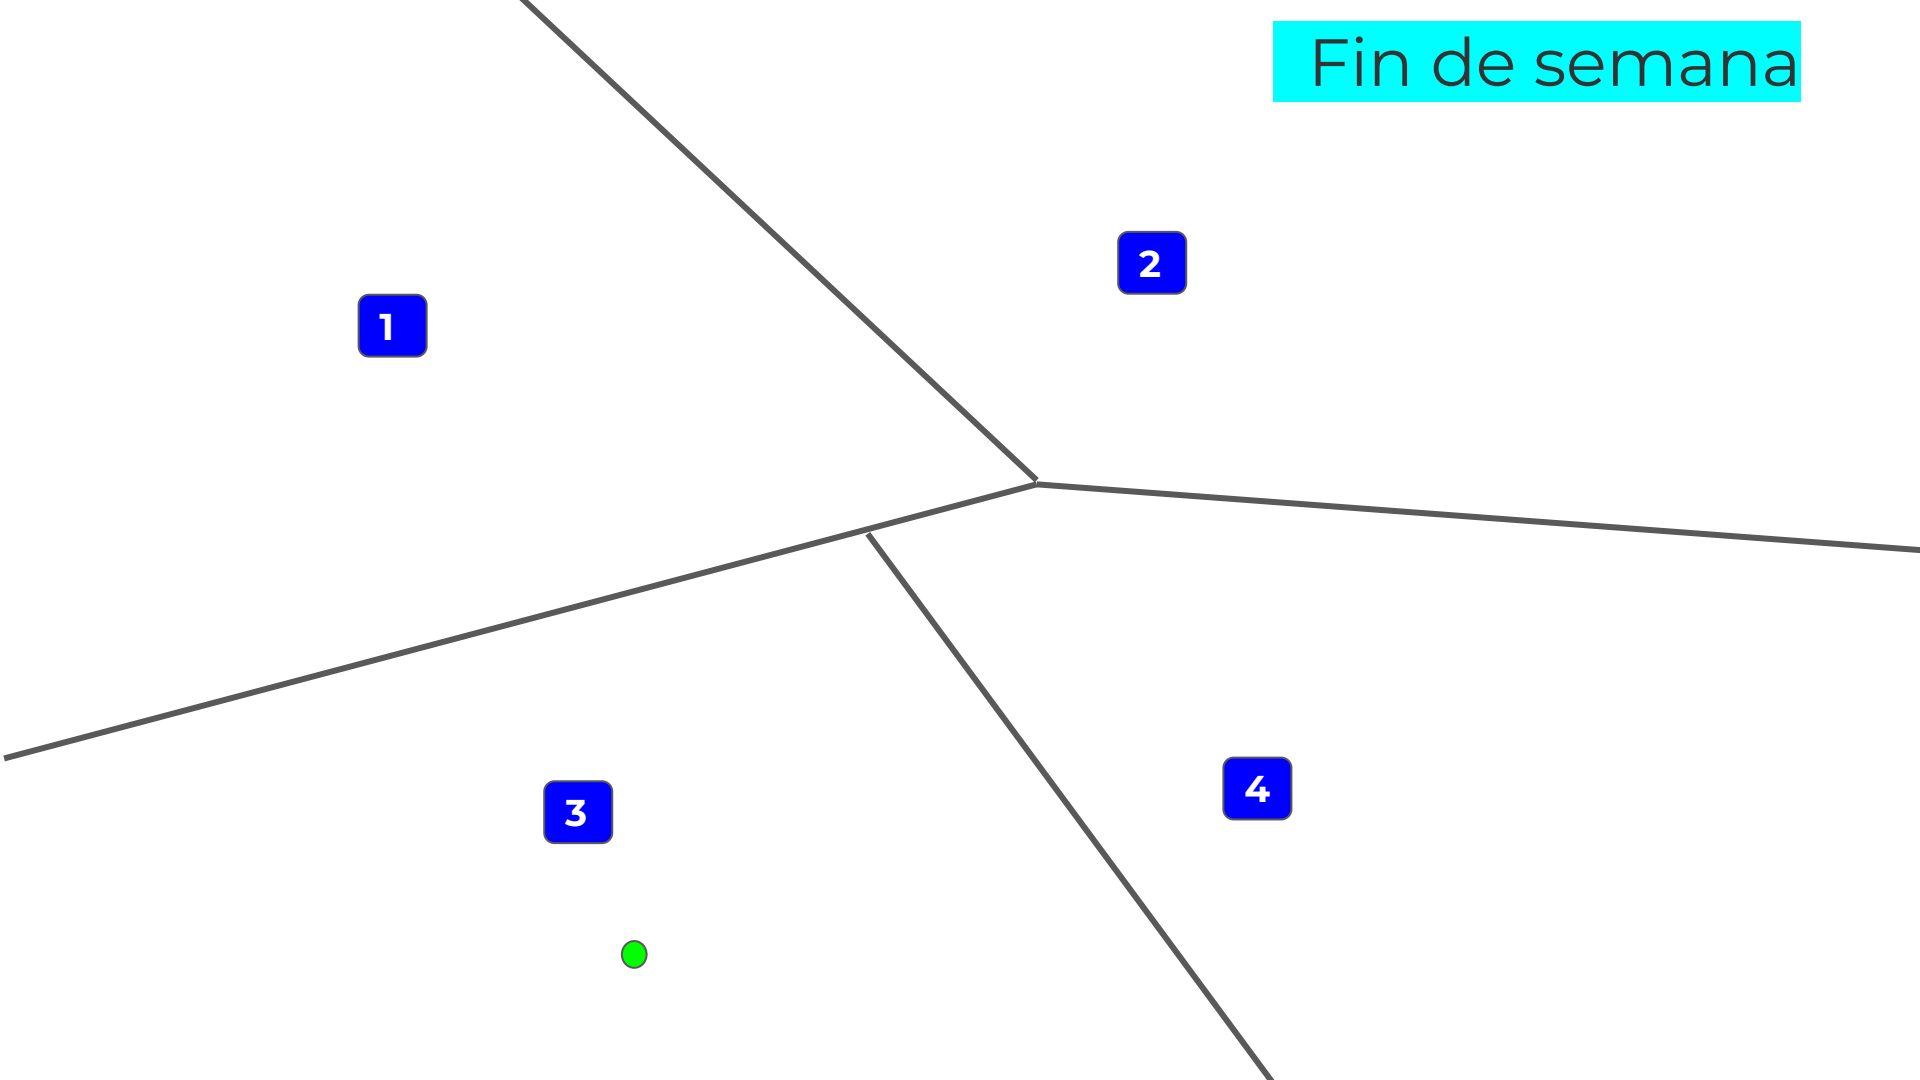

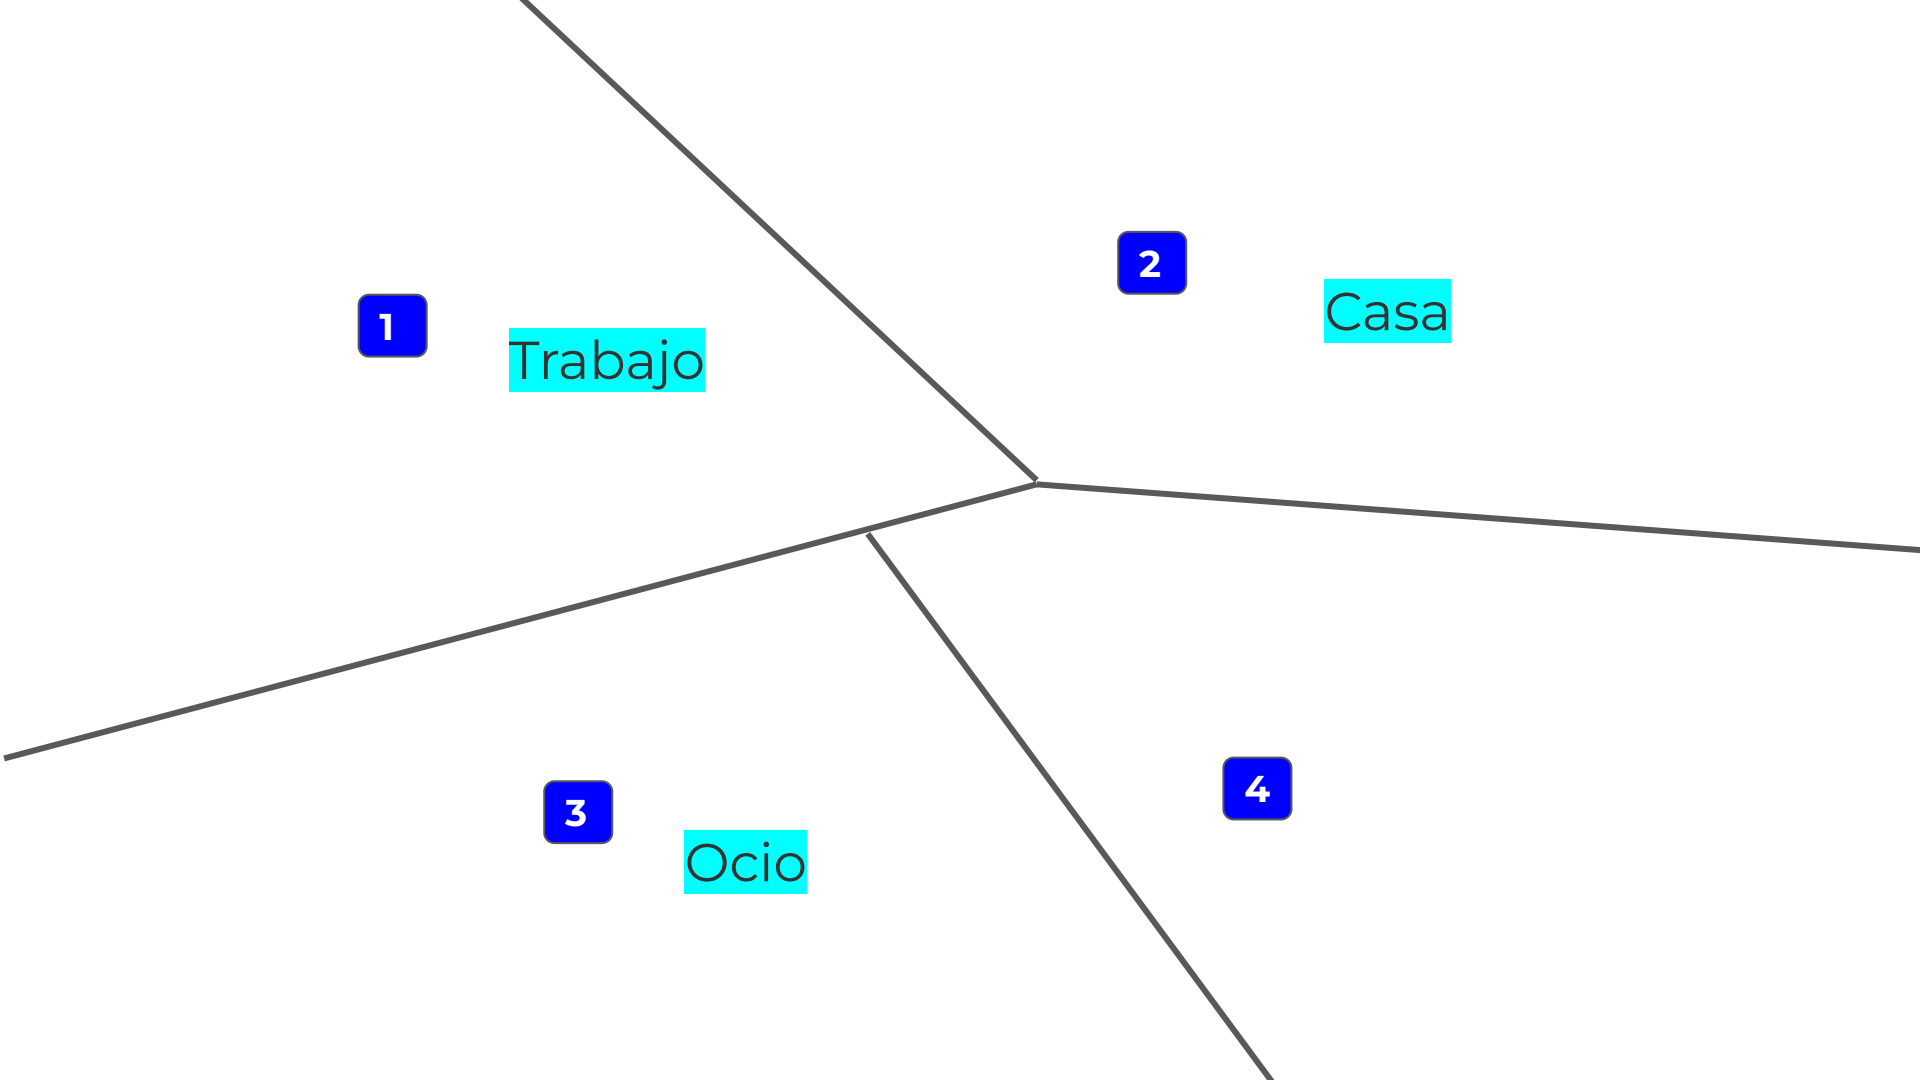
1
Trabajo
2
Casa
3
Ocio
4

Aún **sin conocer la ubicación exacta** de cada usuario,
es posible **aproximar** su ubicación mediante la antena utilizada

Nota: sólo la propia empresa de telefonía tiene acceso a los *CDR*

(Es un dato interno para ellos)

Otras fuentes de datos externos

Imágenes satelitales

- Ayudan a determinar el área afectada con mayor precisión que sólo utilizando noticias y documentos históricos.

Precipitación pluvial

- Permite conocer el nivel de precipitación durante el desastre. Estos datos permiten comparar el nivel de lluvia con la actividad en las antenas celulares.

Protección civil

- Información sobre población afectada, albergues y refugios temporales. Estos datos permiten validar los resultados obtenidos con otras fuentes de información.
- Sistema de alertamiento de ciclones tropicales.

Otras fuentes de datos externos

Censo INEGI

- Utilizado para evaluar la representatividad y distribución de la población inferido por los registro telefónicos.

Sistemas de Información geográfica

- Información contextual de la inundación: carreteras, calles y red hidrográfica.

Otra información contextual

- Atlas Nacional de Riesgos.
- Noticias y fotografías de diversos periódicos.

Otras preguntas de investigación

- ¿Existe alguna **relación entre la dinámica social** durante un desastre natural y los registros de llamadas de las antenas telefónicas?
- ¿La información de las antenas telefónicas podría ser utilizada, en el futuro, para mejorar la respuesta ante un desastre natural como las inundaciones de Tabasco en el año 2009?
- ¿Los hallazgos obtenidos por los registros de las antenas **contrastan** con la información que proveen dependencias oficiales?
- ¿Cómo **afectan las inundaciones a los patrones usuales** de comunicación y movilidad en la región?

Metodología

- El periodo base de estudio empezó con los datos de **01/11/2009**, aproximadamente un mes antes de las inundaciones. La información de las llamadas y usuarios que tuvieron actividad en Tabasco durante este periodo fueron considerados en el análisis.

- Para cada usuario, se determina la antena principal aquella que fue más utilizada en la noche en este periodo. **El objetivo es definir la antena que está más cerca del lugar en donde vive y por tanto, los usuarios que viven en cada municipio.**

Usuarios por municipio

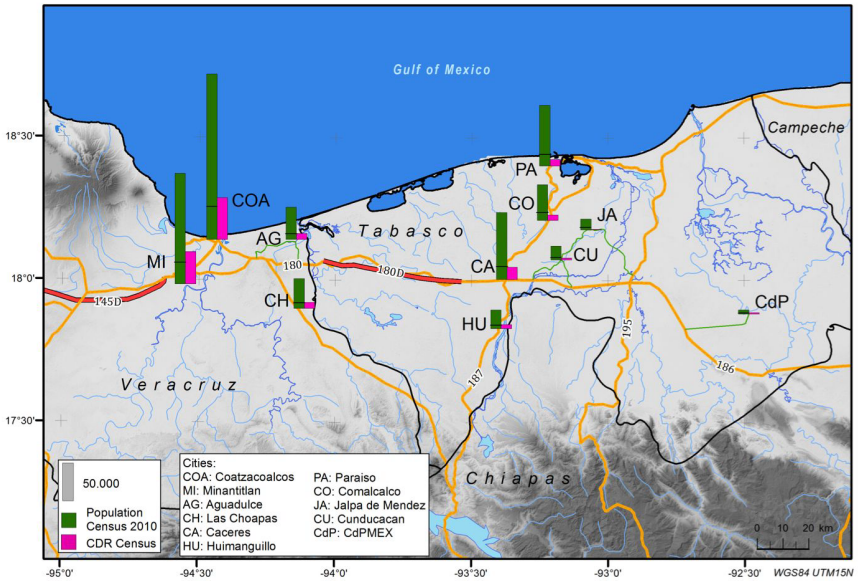

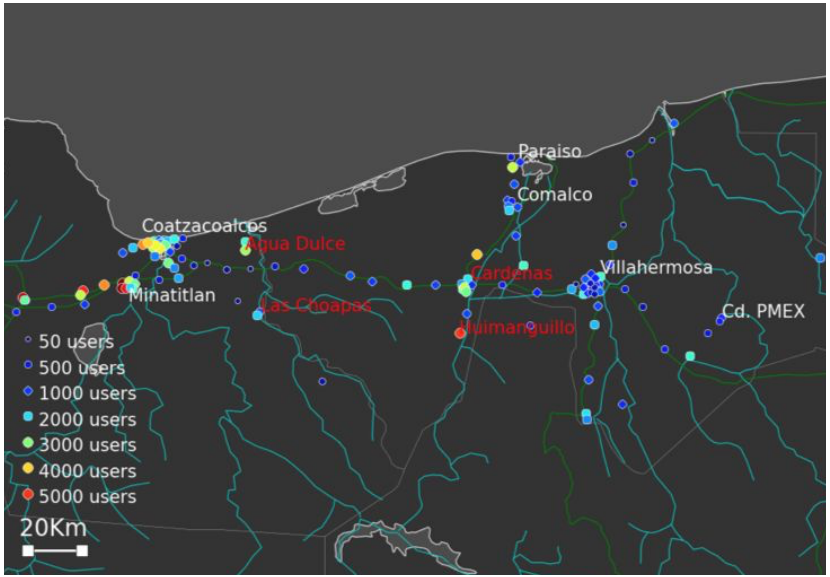

Métrica de variación

- Los datos de **cada antenas** fueron **agregados por día y hora** en la región afectada.
- Se define x(t) actividad de comunicación de la antena como el número de usuarios únicos que realizaron o recibieron alguna llamada en cada día. Para analizar el cambio en esta actividad, se propone una métrica de variación xnorm(t) tal que:
- **Variación en el patrón de llamadas**

$$x_{norm}(t) = \frac{x(t) - \mu_{BL}}{\sigma_{BL}}$$

Desplazamientos

Desplazamientos poblacionales, considerando la métrica de variación. **En color rojo son salidas y en amarillo el desplazamiento a nuevos lugares.**

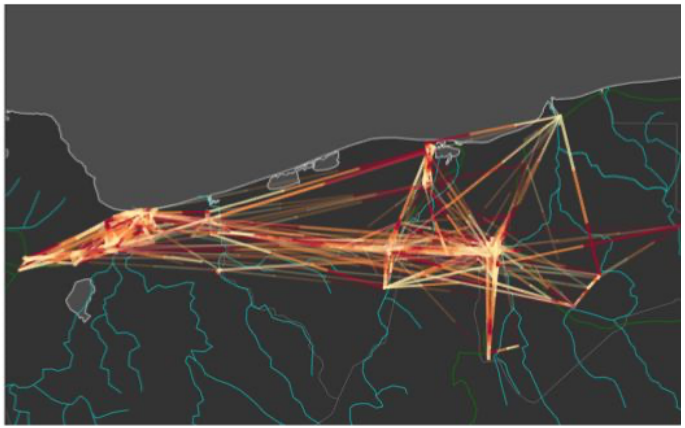

- Durante la inundación

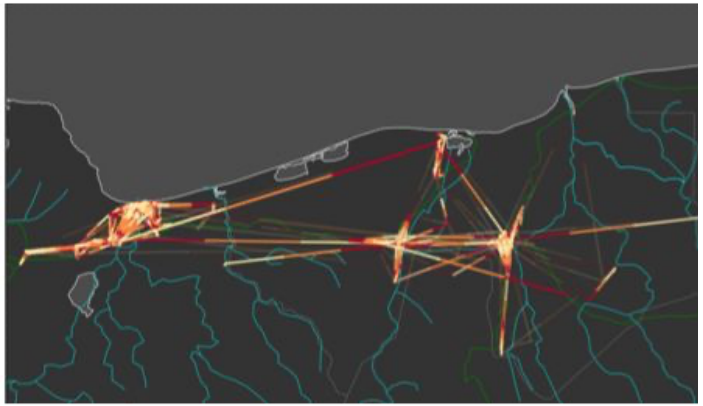

- Periodo aleatorio

Desplazamientos

Los lugares con **mayor cambio en la métrica de variación, coinciden con las zonas más afectadas por las inundaciones**: los municipios de Cárdenas y Huimanguillo.

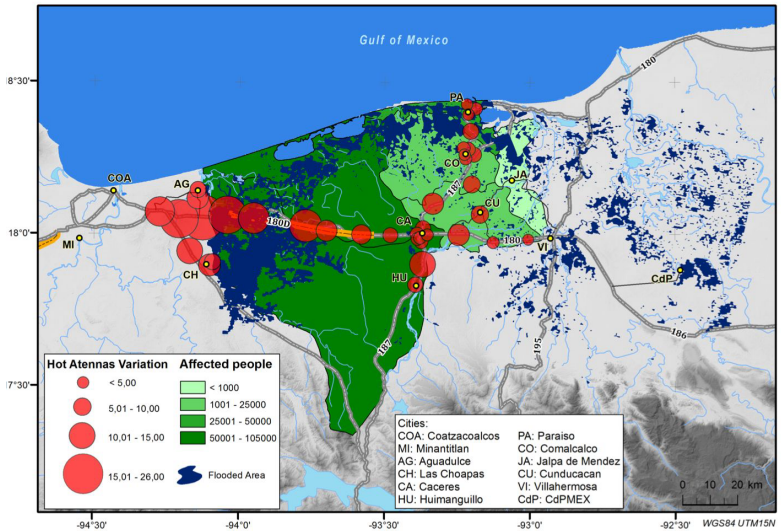

Animación

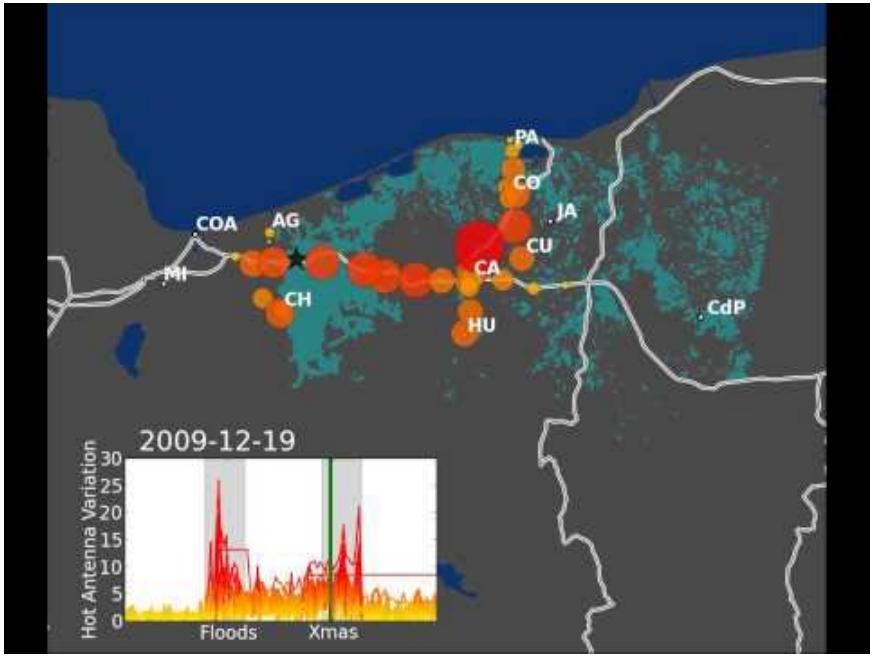
PA
CO
JA
COA
AG
CU
CA
MI
CH
HU
CdP
2009-12-19
Hot Antenna Variation
30
25
20
15
10
5
0
Floods
Xmas

Distancia

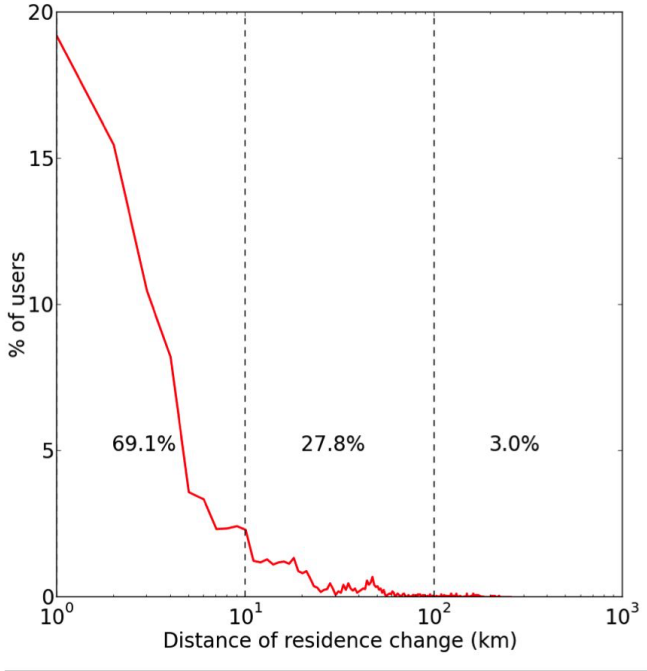

- La gráfica muestra la **distancia** recorrida entre el lugar donde se localiza la **antena principal de los usuarios y una nueva zona** debido al desplazamiento por las inundaciones.
    - El 70% de los usuarios se desplaza más de 10 kilómetros.
    - El 3% tuvo que desplazarse más de 100 kilómetros.

Tiempo

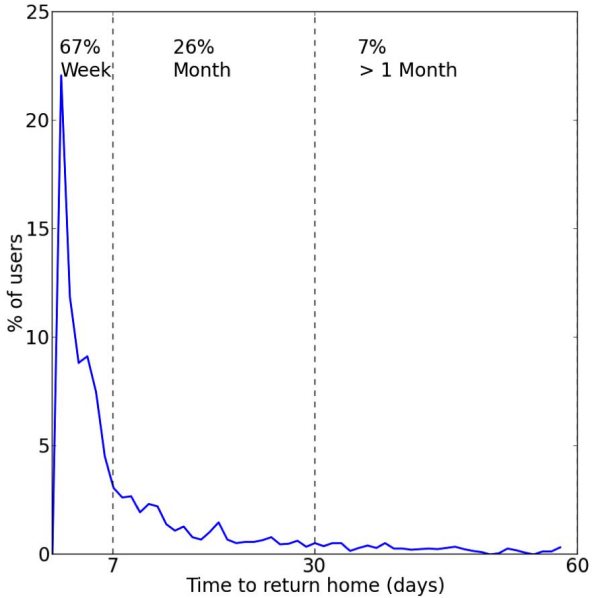

- Ahora se muestra el **tiempo promedio** que los usuarios tardan en **regresar a su lugar habitual**, a partir del primer desplazamiento.
    - El 70% de los usuarios tardó menos de una semana en regresar a casa.
    - El 7% de los usuarios duró más de un mes fuera.

Actividad y niveles de precipitación

- Las antenas con mayor cambio en la métrica de variación fueron las localizadas cerca de caminos, carreteras y autopistas.

- Las antenas cercanas a la **carretera federal 180D tuvieron una gran variación, este camino terminó totalmente inundado**.

Actividad y niveles de precipitación

Para estudiar el uso en tiempo real de los teléfonos celulares, se **compara el nivel de precipitación por hora contra la métrica de variación en diferentes antenas**.

- Existe una diferencia de **cuatro días** entre el tiempo de la mayor variación en la actividad celular y la precipitación pluvial máxima.
- Esto sugiere que la **población no responde**, inmediatamente, a condiciones climatológicas extremas durante el periodo de alerta.

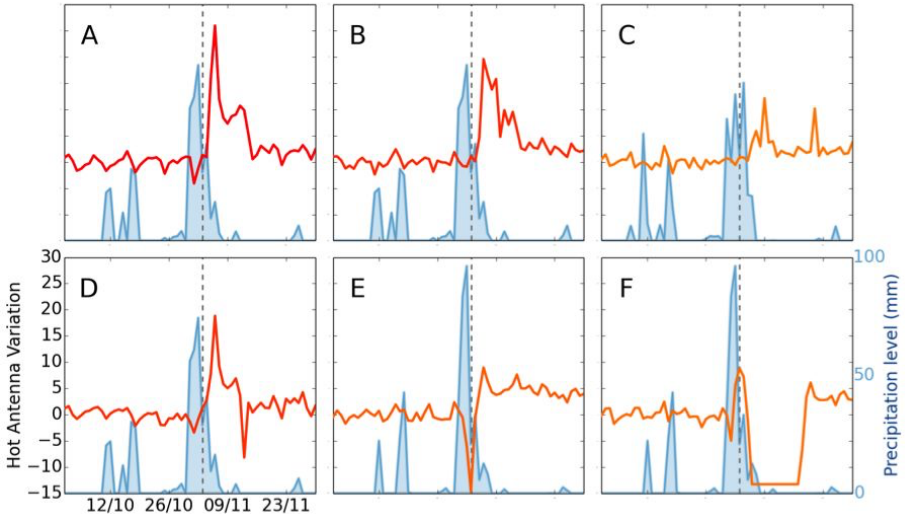

Referencias

- Una **alerta de Protección Civil** fue difundida el día **03/11/2009** en el estado, sin embargo, un **cambio en la métrica de variación sólo puede ser observado en dos antenas cercanas a la carretera federal 180D.**

- Durante el día **05/11/2009 y 06/11/2009 se registró un desbordamiento** en algunos ríos y presas debido a la precipitación pluvial de días anteriores. **La población empezó a reaccionar, al menos en términos de comunicación, hasta la inundación y no durante la alerta**.

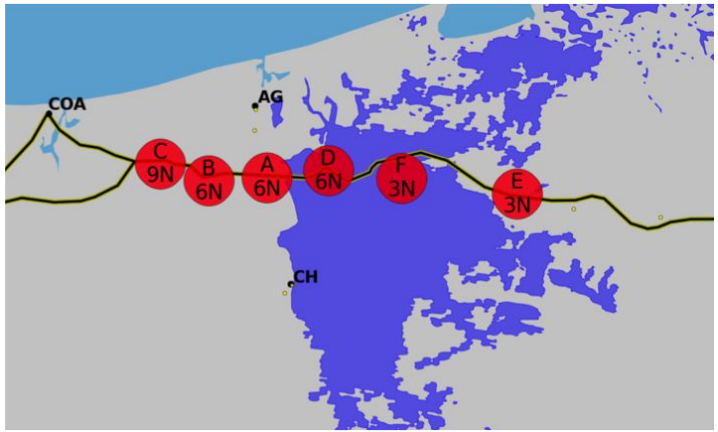

Referencias

- Liga 1
- Liga 2
- Liga 3

Referencias

- Liga 1
- Liga 2
- Liga 3

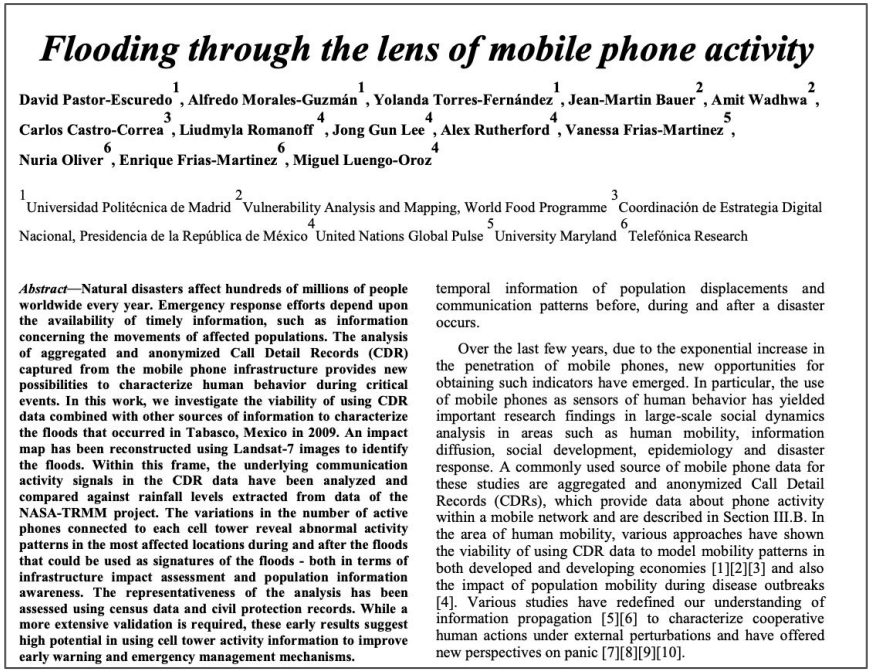

Flooding through the lens of mobile phone activity

David Pastor-Escuredo[1], Alfredo Morales-Guzmán[1], Yolanda Torres-Fernández[1], Jean-Martin Bauer[2], Amit Wadhwa[2], Carlos Castro-Correa[3], Liudmyla Romanoff[4], Jong Gun Lee[4], Alex Rutherford[4], Vanessa Frias-Martinez[5], Nuria Oliver[6], Enrique Frias-Martinez[6], Miguel Luengo-Oroz[4]

[1]Universidad Politécnica de Madrid [2]Vulnerability Analysis and Mapping, World Food Programme [3]Coordinación de Estrategia Digital Nacional, Presidencia de la República de México [4]United Nations Global Pulse [5]University Maryland [6]Telefónica Research

***Abstract*—Natural disasters affect hundreds of millions of people worldwide every year. Emergency response efforts depend upon the availability of timely information, such as information concerning the movements of affected populations. The analysis of aggregated and anonymized Call Detail Records (CDR) captured from the mobile phone infrastructure provides new possibilities to characterize human behavior during critical events. In this work, we investigate the viability of using CDR data combined with other sources of information to characterize the floods that occurred in Tabasco, Mexico in 2009. An impact map has been reconstructed using Landsat-7 images to identify the floods. Within this frame, the underlying communication activity signals in the CDR data have been analyzed and compared against rainfall levels extracted from data of the NASA-TRMM project. The variations in the number of active phones connected to each cell tower reveal abnormal activity patterns in the most affected locations during and after the floods that could be used as signatures of the floods - both in terms of infrastructure impact assessment and population information awareness. The representativeness of the analysis has been assessed using census data and civil protection records. While a more extensive validation is required, these early results suggest high potential in using cell tower activity information to improve early warning and emergency management mechanisms.**

temporal information of population displacements and communication patterns before, during and after a disaster occurs.

Over the last few years, due to the exponential increase in the penetration of mobile phones, new opportunities for obtaining such indicators have emerged. In particular, the use of mobile phones as sensors of human behavior has yielded important research findings in large-scale social dynamics analysis in areas such as human mobility, information diffusion, social development, epidemiology and disaster response. A commonly used source of mobile phone data for these studies are aggregated and anonymized Call Detail Records (CDRs), which provide data about phone activity within a mobile network and are described in Section III.B. In the area of human mobility, various approaches have shown the viability of using CDR data to model mobility patterns in both developed and developing economies [1][2][3] and also the impact of population mobility during disease outbreaks [4]. Various studies have redefined our understanding of information propagation [5][6] to characterize cooperative human actions under external perturbations and have offered new perspectives on panic [7][8][9][10].

¿Puedes identificar los elementos?

Global Pulse Tabasco

- **Definición de preguntas** de negocio o investigación (fundamental).
- **Bases de datos** internas + externas.
- **Análisis**.
- **Presentación** o herramienta (con diseño).